

Résumer pour informer

Position, dispersion, concentration — cours resserré et système de révision

Ce document reconstruit le deuxième chapitre de Techniques statistiques et couvre les 70 diapositives du support, sans exception. Les quatorze questions posées en amphithéâtre y sont corrigées, chaque formule est démontrée et illustrée par un calcul complet, et tous les chiffres du support ont été recalculés — ce qui a révélé quatre anomalies, signalées à l'endroit exact. Le cours tient en une trentaine de pages ; le reste est un système de révision destiné à être consulté et pratiqué, non lu. Une version intégrale, deux fois plus développée, accompagne ce document pour les points qui résistent.

Date · 10 septembre 2026 **Travail estimé** · lecture du cours 2 h — maîtrise complète $\approx$ 12 h réparties sur 3 semaines

Version · 2.0

Document de travail autonome — il remplace le support de cours original, qu'il n'est pas nécessaire de relire. Toute notion évoquée dans le cours y est définie, démontrée et illustrée.

SOMMAIRE

1. Carte du chapitre

- 1.1 — Vue d'ensemble
- 1.2 — Les dix idées maîtresses
- 1.3 — Prérequis, enseignés ici
- 1.4 — Lien avec la finance de marché

2. Le cours

- 2.1 — Résumer la position (diapositives 3 à 26)
- 2.2 — Résumer la dispersion (diapositives 27 à 58)
- 2.3 — Résumer la concentration (diapositives 59 à 69)
- 2.4 — Récapitulons (diapositive 70)

3. Points de vigilance

- 3.1 — Les confusions classiques
- 3.2 — Les erreurs que commet la majorité des étudiants
- 3.3 — Ce qui sépare une copie moyenne d'une excellente copie
- 3.4 — Les quatre anomalies du support à connaître

4. Système d'ancrage mémoriel

- 4.1 — Fiche de synthèse
- 4.2 — Cartes de révision
- 4.3 — Moyens mnémotechniques
- 4.4 — Schéma récapitulatif

5. Entraînement progressif

- Niveau 1 — Restitution
- Niveau 2 — Application chiffrée
- Niveau 3 — Maîtrise
- Niveau 4 — Simulation d'examen

6. Auto-évaluation finale

- 6.1 — Liste de contrôle
- 6.2 — Grille de vérification chiffrée
- 6.3 — Protocole de révision daté

Annexe — Tableau de couverture du support d'origine

Chapitre 2 — Résumer pour informer

MÉTHODE — CE QUE CONTIENT CE DOCUMENT, ET COMMENT ON S'EN SERT

Les **70 diapositives** du support y sont couvertes sans exception — le **tableau de couverture** en annexe permet de le vérifier ligne par ligne. Les **quatorze questions** posées à l'amphithéâtre sont intégralement corrigées, et **tous les chiffres ont été recalculés**.

Partie	Pages	Ce que tu en fais
§ 1 — Carte	2	Tu la lis une fois , avant tout le reste
§ 2 — Le cours	18	Tu le lis deux fois : une fois pour comprendre, une fois stylo en main
§ 3 — Vigilance	4	Tu le relis avant l'examen
§ 4 — Ancrage	12	Tu ne le lis pas : fiche, 65 cartes et schéma se consultent , en boucle
§ 5 — Entraînement	28	Tu le fais , tu ne le lis pas — 10 exercices et une simulation de 2 h
§ 6 + annexe	6	Contrôle final et preuve de couverture

La charge de lecture réelle est de 27 pages — pour un chapitre de 70 diapositives. Les 46 pages restantes ne se lisent pas : elles se consultent et se pratiquent.

Un second fichier accompagne celui-ci : *Résumer pour informer — version intégrale*. Même contenu, deux fois plus développé : chaque démonstration détaillée, chaque tableau de calcul ligne par ligne, chaque vérification refaite sous tes yeux. **Tu ne le lis jamais d'un bout à l'autre — tu l'ouvres quand un point de ce cours-ci résiste**. Les renvois « → intégrale § X » t'y conduisent, aux mêmes numéros de paragraphes.

1. Carte du chapitre

1.1 — Vue d'ensemble

Le chapitre 1 apprenait à **présenter** une distribution **sans rien perdre**. Celui-ci apprend à la **résumer** — donc à **perdre volontairement** de l'information, en échange d'une capacité de comparaison et de décision. **La perte est le prix de la décision** : on ne décide pas devant 1 200 nombres.

Trois familles d'indicateurs, trois questions :

Famille	Question	Indicateurs
Position	Où se situe la distribution ?	Mode · Moyenne · Médiane
Dispersion	À quel point est-elle étalée ?	Étendue · écarts inter-quantiles · EAM · variance · écart-type · coefficient de variation
Concentration	Comment le total se partage-t-il ?	Part de l'agrégat · courbe de Lorenz · indice de Gini

1.2 — Les dix idées maîtresses

1. **Résumer, c'est perdre de l'information à dessein.** Tout le chapitre consiste à choisir *quoi* perdre.
2. **La position seule ne suffit jamais** : deux distributions de même moyenne peuvent être radicalement différentes. Une moyenne sans dispersion est une information incomplète — et en finance, dangereuse.
3. **Dès que les classes ont des amplitudes inégales, il faut raisonner en densité**, pas en effectif. C'est vrai pour le mode comme pour l'histogramme, où l'aire représente l'effectif.
4. **La somme des écarts à la moyenne est nulle.** C'est de ce fait que découle toute la section dispersion : il faut casser les signes, par la valeur absolue (EAM) ou par le carré (variance).
5. **La variance est une étape, l'écart-type est la réponse.** La variance est en unité au carré, donc ininterprétable.
6. **Koenig rend l'agrégation possible** : deux sommes suffisent à transmettre un groupe.
7. **Ce qui repose sur des sommes s'agrège ; ce qui repose sur des rangs ne s'agrège pas.** Moyenne et variance oui ; médiane, quantiles et Gini non.
8. **La concentration n'existe que si la somme de la variable a un sens.** Salaires oui, notes et âges non.
9. **La courbe de Lorenz se lit par sa distance à la diagonale**, et sa pente en chaque point vaut m_{x_k}/m_X .
10. **Le choix de l'indicateur dépend du type de données ET de l'objectif.** C'est la seconde moitié de la phrase qu'on oublie.

1.3 — Prérequis, enseignés ici

DÉFINITION — LES SIX NOTIONS DU CHAPITRE 1 À AVOIR EN TÊTE

Notion	Rappel
Effectif n_i / fréquence f_i	$f_i = n_i/n$; $\sum f_i = 1$
Fréquence cumulée F_k	$F_k = \sum_{i \leq k} f_i$; croissante , $F_p = 1$. Répond à « au plus cette modalité »
Fonction de répartition	L'application $x \mapsto F(x)$. Les quantiles en sont l'inverse
Série brute / distribution	Un individu par case / une modalité par ligne avec son effectif
Variable discrète / continue	Comptage / mesure. La continue impose des classes , donc des amplitudes
Classe, borne, amplitude	$[b_{\inf} ; b_{\sup}[$; amplitude $a_i = b_{\sup} - b_{\inf}$

1.4 — Lien avec la finance de marché

ANALOGIE — MARCHÉS FINANCIERS — LES CINQ TRADUCTIONS, À CONNAÎTRE PAR CŒUR

Statistique	Finance de marché
Moyenne	Rendement espéré
Écart-type	VOLATILITÉ — annualisée en multipliant par $\sqrt{252}$ sur des rendements quotidiens, $\sqrt{12}$ sur des mensuels
Quantile	Value at Risk — la VaR à 99 % est le centile d'ordre 1 de la distribution des pertes
Rapport m/σ	Structure du ratio de Sharpe — donc le coefficient de variation en est l'inverse
Décomposition intra / inter	Risque spécifique / risque systématique . La diversification agit sur l'intra, jamais sur l'inter
Lorenz et Gini	Concentration d'un portefeuille (parent de l'indice de Herfindahl $HHI = \sum w_i^2$) ou d'un P&L

Le point à retenir : une stratégie à 8 % de rendement moyen avec $\sigma = 3\%$ et une autre à 8 % avec $\sigma = 40\%$ ne se gèrent pas de la même façon. **La moyenne décrit l'espérance ; l'écart-type décrit ce qu'il faut survivre pour l'atteindre.**

2. Le cours

2.1 — Résumer la position (diapositives 3 à 26)

2.1.1 Les trois indicateurs de position (d. 3)

DÉFINITION — MODE, MOYENNE, MÉDIANE

Indicateur	Définition	Utilisable sur
Mode	La modalité de fréquence maximale	Toute variable, y compris qualitative — c'est le seul dans ce cas
Moyenne	Le centre de gravité : elle utilise toutes les valeurs	Quantitative cardinale
Médiane	Le centre de l'effectif : elle n'utilise que le rang	Quantitative, et ordinale

2.1.2 Le mode et la classe modale (d. 4 à 9)

DÉFINITION — MODE, CLASSE MODALE, AMPLITUDE, DENSITÉ

Mode = modalité de fréquence maximale. **Variable continue** → « **classe modale** » : l'indicateur désigne un **intervalle**, pas une valeur. Dire « le mode est [20 ; 30[» est un abus de langage sanctionné.

$$a_i = b_{\text{sup}} - b_{\text{inf}} \quad d_i = \frac{n_i}{a_i}$$

⚠ **Dès que les amplitudes sont inégales, la classe modale est celle de densité maximale, pas d'effectif maximal.** Une classe deux fois plus large contient mécaniquement plus d'individus sans être plus dense.

CORRIGÉ — LES DEUX ILLUSTRATIONS DU SUPPORT, CORRIGÉES

① **Logements en Outre-mer, recensement 2023 (d. 4-5) — trois questions posées, aucune réponse.**

Type de logement	Guadeloupe	Martinique	Guyane	Réunion
Habitation de fortune	1 098	790	3 698	1 867
Case traditionnelle	2 322	578	1 798	23 062
Maison ou immeuble en bois	8 363	6 086	11 841	12 913
Maison ou immeuble en dur	168 050	164 290	71 089	321 445
Ensemble	179 833	171 743	88 425	359 288

Q1 — Éléments statistiques. Population : les **logements** des quatre territoires en 2023. Unité : **un logement**. Taille : par territoire, et $N = 799\,289$ pour l'ensemble. **Deux caractères, tous deux qualitatifs nominaux** : le **type de logement** (4 modalités) et la **zone géographique** (4 modalités). **Q2 — Est-ce une distribution au sens classique ? Non.** Une distribution associe un effectif à chaque modalité d'une **seule** variable ; ici **quatre distributions sont juxtaposées**, une par territoire. La zone géographique est la variable de **découpage**, le type de logement la variable **étudiée**. **Q3 — Le mode** : « **maison ou immeuble en dur** », dans les quatre territoires — de **80 %** (Guyane) à près de **94 %** (Guadeloupe) des logements. ⚠ *Trois colonnes ne bouclent pas à une unité près (Martinique 171 744 recalculé contre 171 743 annoncés ; Guyane 88 426 contre 88 425 ; Réunion 359 287 contre 359 288).* **Ce n'est pas une erreur mais un effet d'arrondi** : la somme des arrondis n'est pas l'arrondi de la somme. **Ne corrige pas le total publié ; signale-le.**

② **Personnes incarcérées par tranche d'âge (d. 6-9) — le cas des amplitudes inégales.** Le support passe d'un diagramme en effectifs à un diagramme en **densités**, et la classe modale change. **C'est l'exemple qui justifie toute la notion.** → intégrale § 2.1.3 pour le tableau recalculé ligne par ligne.

2.1.3 L'histogramme (d. 10-11)

FORMULE CLÉ — L'AIRE REPRÉSENTE L'EFFECTIF

Dans un **histogramme**, la **hauteur** porte la **densité** et l'**aire** porte l'**effectif** :

$$\text{aire} = d_i \times a_i = \frac{n_i}{a_i} \times a_i = n_i$$

	Histogramme	Diagramme en barres
Hauteur	Densité	Effectif
Ce qui représente l'effectif	L'aire	La hauteur
Quand l'employer	Variable continue , classes	Variable discrète ou qualitative

⚠ **Porter les effectifs en hauteur avec des amplitudes inégales produit une figure fautive** : l'aire vaut alors $n_i \times a_i$, et les classes larges paraissent surreprésentées. **Contrôle** : la somme des aires doit redonner l'effectif total.

2.1.4 La moyenne : trois écritures (d. 12 à 15)

FORMULE CLÉ — LES TROIS FORMULES, ET LEUR ÉQUIVALENCE

$$m_X = \frac{1}{N} \sum_{i=1}^N x_i \quad m_X = \sum_{i=1}^p f_i x_i \quad m_X = \sum_{k=1}^K \frac{N_k}{N} m_{X_k}$$

(1) données brutes · (2) distribution · (3) agrégation. Ce sont trois regroupements de la même somme :

$$\frac{1}{N} \sum n_i x_i = \sum \frac{n_i}{N} x_i = \sum f_i x_i$$

⚠ **L'avertissement du support sur l'agrégation, à ne pas manquer** : « il s'agit de la fréquence du caractère qui **scinde la population en sous-groupes** et non de la fréquence du caractère X qui nous intéresse ». **On pondère toujours par des effectifs de population, jamais par des valeurs de la variable étudiée.**

L'erreur type — la moyenne simple des moyennes : deux groupes de 900 et 100 personnes gagnant 2 000 € et 4 000 €.

$$\text{Moyenne simple} = 3\,000 \text{ € } \times ; \text{ moyenne pondérée} = \frac{900}{1000} (2\,000) + \frac{100}{1000} (4\,000) = 1\,800 + 400 = 2\,200 \text{ € } \checkmark$$

2.1.5 Les trois propriétés de la moyenne (d. 16, 17, 19) et l'application (d. 18)

FORMULE CLÉ — LES TROIS PROPRIÉTÉS

① La somme des écarts à la moyenne est nulle.

$$\sum_{i=1}^N (x_i - m_X) = \sum x_i - N m_X = N m_X - N m_X = 0$$

⚠ **C'est la propriété qui commande toute la section dispersion** : un indicateur fondé sur la moyenne des écarts vaudrait **0 pour toute distribution**. D'où les valeurs absolues et les carrés.

② La moyenne est un opérateur linéaire : $m_{aX+b} = a m_X + b$. C'est elle qui autorise l'agrégation — ce que l'écart-type ne permettra pas.

③ La moyenne est sensible aux valeurs extrêmes. Elle utilise la **valeur** de chaque observation ; la médiane n'utilise que le **rang**. « Deux écarts de 5 comptent autant qu'un écart de 10. »

CORRIGÉ — APPLICATION : LES SALAIRES DES FONCTIONNAIRES (D. 18) — DEUX QUESTIONS, AUCUNE RÉPONSE

	Fréq. 2022 (%)	Fréq. 2023 (%)	Salaire moyen 2022 (€)	Salaire moyen 2023 (€)
Catégorie A	68,4	68,7	3 193	3 373
Catégorie B	18,7	18,9	2 632	2 720
Catégorie C	12,9	12,4	2 161	2 283
Titulaires A+B+C	100,0	100,0	2 955	3 116

Q1 — Le salaire moyen, par agrégation (formule 3), les fréquences étant les **poids** : **2022** :

$0,684(3\,193) + 0,187(2\,632) + 0,129(2\,161) = 2\,184,0 + 492,2 + 278,8 = 2\,955,0$ € — **coïncide exactement** avec le tableau ✓
2023 : $0,687(3\,373) + 0,189(2\,720) + 0,124(2\,283) = 2\,317,3 + 514,1 + 283,1 = 3\,114,4$ € △ **Le tableau annonce 3 116 € : un écart de 1,6 €, soit 0,05 %**, expliqué par l'**arrondi des fréquences à une décimale**. Il faut le signaler, pas le masquer.

Q2 — La masse salariale, avec 1,8 million d'agents :

$$\sum x_i = N \times m = 1\,800\,000 \times 3\,116 = 5\,608\,800\,000 \text{ €}$$

soit **5,61 milliards d'euros par mois** et **67,3 milliards par an**. *Précisions attendues : masse nette, mensuelle avant multiplication, champ agents fonctionnaires en France hors Mayotte.*

POINT D'EXAMEN

La relation à retenir absolument : $\sum_{i=1}^N x_i = N \times m$ — **la somme est la moyenne multipliée par l'effectif**. Elle sert **trois fois** dans le chapitre : ici, à la diapositive 57 (variance par agrégation) et à la diapositive 60 (part de l'agrégat).

2.1.6 La médiane (d. 20 à 26)

FORMULE CLÉ — DÉFINITION ET CALCUL

Deux définitions équivalentes : la valeur qui partage la population **ordonnée** en deux effectifs égaux ; ou la valeur Me telle que $F(Me) = 0,5$.

Sur données brutes — **trier d'abord, toujours**. N **impair** → valeur de rang $\frac{N+1}{2}$. N **pair** → **moyenne des valeurs de rang** $\frac{N}{2}$ et $\frac{N}{2} + 1$: il n'existe pas d'observation centrale.

Sur une distribution groupée — **interpolation linéaire**, sous hypothèse de répartition uniforme dans la classe :

$$Me = b_{\text{inf}} + a \times \frac{0,5 - F(b_{\text{inf}})}{F(b_{\text{sup}}) - F(b_{\text{inf}})}$$

Le diagnostic d'asymétrie — **deux chiffres suffisent** : $Me < m_X \rightarrow$ **étalée à droite** (salaires, patrimoines) · $Me > m_X \rightarrow$ **étalée à gauche** · $Me \approx m_X \rightarrow$ **symétrique**.

CORRIGÉ — LES DENSITÉS DE POPULATION EN UNION EUROPÉENNE (D. 22-23) — TROIS QUESTIONS

Q1 — Les médianes. UE à 15 (15 pays, impair, rang 8) : **113 hab/km²**, le Portugal. **10 nouveaux pays** (pair, moyenne des rangs 5 et 6 — Slovénie 99 et Hongrie 109) : **104**. UE à 25 (25 pays, rang 13) : **109**, la Hongrie.

Q2 — Les moyennes. UE15 : **153,0** · 10 nouveaux : **203,0** · UE25 : **173,0** hab/km². △ **Compare** : la **moyenne des 10 nouveaux pays (203,0) dépasse celle de l'UE15 (153,0)**, alors que leur **médiane est plus basse (104 contre 113)**. C'est Malte, à 1 246 hab/km², qui tire la moyenne — illustration directe de la propriété ③.

Q3 — Si la densité de Malte est divisée par 2 ? Les médianes sont inchangées — Malte reste la valeur la plus haute, son **rang** ne change pas. **Les moyennes chutent** : – 31 % pour les 10 nouveaux pays, – 14 % pour l'UE25. **C'est la démonstration en une ligne de la différence entre rang et valeur**.

CORRIGÉ — LES REVENUS MÉDIANS PAR CSP (D. 24) — LA QUESTION QUI COMPTE

Catégorie socioprofessionnelle	Revenu salarial médian annuel
Cadres	45 552 €
Professions intermédiaires	29 640 €
Ouvriers	23 148 €
Employés	22 572 €

« Si je dispose de la part des CSP, puis-je calculer le salaire médian de l'ensemble ? » **NON** — et jamais, quels que soient les poids.

Contre-exemple, à savoir produire en trois lignes : $A = \{1;2;3\}$ donne $Me_A = 2$; $B = \{100;200;300\}$ donne $Me_B = 200$.
Moyenne des médianes = **101**. Vraie médiane de $A \cup B = \{1;2;3;100;200;300\}$: $(3+100)/2 = 51,5$. **Écart d'un facteur 2**.

La raison : la médiane dépend de la **position relative de toutes les valeurs** — information détruite par le résumé en médianes de groupe. **Ce qui repose sur des rangs ne s'agrège pas.**

CORRIGÉ — LES FAMILLES SELON LE NOMBRE D'ENFANTS (D. 26) — DEUX QUESTIONS, ET UN RÉSULTAT ABERRANT

Modalités	Effectifs (milliers) 2008	2023
0 enfant	8 225	9 340
1 enfant	3 821	4 085
2 enfants	3 449	3 594
3 enfants	1 241	1 219
4 enfants	396	442
Ensemble	17 132	18 680

Q1 — Éléments : population = les **familles** en France ; unité = **une famille** ; variable = nombre d'enfants, **quantitative discrète**.
(Ce tableau est exactement celui du chapitre 1, diapositive 22 — le chapitre 2 le **date** explicitement de 2008, ce qui confirme la déduction faite alors.)

Q2 — Fréquences cumulées et médiane. 2023 : $F(0) = 9\,340/18\,680 = 50,0\%$ exactement → la médiane est **0 enfant**. **2008 :** $F(0) = 8\,225/17\,132 = 48,0\%$; $F(1) = 70,3\%$. La classe médiane est donc « 1 enfant », et la **médiane vaut 1 enfant**.

PIÈGE FRÉQUENT

L'interpolation linéaire donne ici 0,09 enfant — et ce résultat est aberrant.

$$0 + \frac{(1-0)(0,50 - 0,480)}{0,703 - 0,480} = \frac{0,020}{0,223} = 0,09$$

Pourquoi c'est faux : l'interpolation suppose une **répartition uniforme à l'intérieur de la classe**, ce qui n'a aucun sens pour une variable **discrète** — il n'existe pas de famille à 0,09 enfant. **Sur une variable discrète, on applique la règle du rang, pas l'interpolation. Retiens le réflexe : un résultat non interprétable signale une hypothèse mal placée.**

2.2 — Résumer la dispersion (diapositives 27 à 58)

2.2.1 Pourquoi la position ne suffit pas, et l'étendue (d. 27-28)

DÉFINITION — LES QUATRE CAS, ET LE PREMIER INDICATEUR

Le support ouvre sur **quatre séries de même moyenne** et de formes radicalement différentes. **Une moyenne sans dispersion est une information incomplète.**

$$\text{étendue} = x_{\max} - x_{\min}$$

Faiblesse : elle ne dépend que des **deux valeurs extrêmes** — donc totalement détruite par une valeur aberrante, et muette sur la répartition entre les bornes. **Première approche, jamais seule.**

2.2.2 Quantiles et écarts inter-quantiles (d. 29 à 33)

FORMULE CLÉ — DÉFINITION, FAMILLES, ÉCARTS

Le quantile d'ordre p est la valeur Q_p telle que $F(Q_p) = p$: c'est l'**INVERSE** de la fonction de répartition, $Q_p = F^{-1}(p)$. Une proportion p de la population a une valeur inférieure ou égale à Q_p .

Famille	Parts	Valeurs qui les délimitent
Quartiles Q_1, Q_2, Q_3	4	3
Déciles D_1 à D_9	10	9
Centiles C_1 à C_{99}	100	99

Règle : n parts se délimitent par $n-1$ valeurs. Et $Q_1 = D_{2,5} \cdot Q_3 = D_{7,5} \cdot Me = Q_2 = D_5$.

Les trois écarts inter-quantiles :

Écart	Ce qu'il décrit	Unité
$Q_3 - Q_1$ — inter-quartile	L'étalement des 50 % centraux	Celle de X
$D_9 - D_1$ — inter-décile	L'étalement des 80 % centraux	Celle de X
D_9 / D_1 — rapport inter-décile	Le même en relatif	Sans unité — comparable entre populations
$C_{99} - C_1$ — inter-centile	Les 98 % centraux	Celle de X

△ **Écart inter-quartile** = un **nombre** ($Q_3 - Q_1$) ; **intervalle inter-quartile** = un **intervalle** ($[Q_1 ; Q_3]$). Ne pas confondre.

Sur une distribution, le quantile s'obtient par interpolation linéaire, exactement comme la médiane :

$$Q_p = b_{\inf} + a \times \frac{p - F(b_{\inf})}{F(b_{\sup}) - F(b_{\inf})}.$$

2.2.3 Interpréter des quantiles, et le boxplot (d. 34 à 38)

CORRIGÉ — LE NIVEAU DE VIE (D. 34) ET LE BOXPLOT (D. 36-37)

Le rapport inter-décile : $D_9/D_1 = 3,48$ — « les 10 % les plus aisés ont un niveau de vie au moins **3,48 fois** supérieur à celui des 10 % les plus modestes ».

△ **L'information la plus riche est dans les écarts entre déciles successifs**, qui **croissent** régulièrement : 3 730 → 2 860 → 9 800 → 12 640 €. **Des écarts croissants prouvent l'étalement à droite** de la distribution : le haut est bien plus étalé que le bas.

PIÈGE FRÉQUENT

Incohérence du support (d. 35). La diapositive s'intitule « **retraités, année 2008** » alors que **le tableau affiché est celui des niveaux de vie de 2024** de la diapositive 34. **Erreur de titre**, signalée.

Le boxplot : boîte de Q_1 à Q_3 (les 50 % centraux), **trait intérieur à la médiane**, **moustaches** jusqu'aux extrêmes — ou aux déciles selon la convention, **qu'il faut préciser**. On y lit d'un coup d'œil **le niveau** (position du trait), **la dispersion** (largeur de la boîte) et **l'asymétrie** : *si le trait n'est pas au centre de la boîte, la distribution est asymétrique.*

CORRIGÉ — LES QUANTILES PAR CSP (D. 38) — « DANS QUELLE CSP LES SALAIRES SONT-ILS LE PLUS DISPERSÉS ? »

	Ensemble	Cadres	Prof. interm.	Employés	Ouvriers
D_1	1 440	2 240	1 640	1 380	1 380
Q_1	1 660	2 810	1 940	1 510	1 570
D_5	2 090	3 620	2 360	1 730	1 830
Q_3	2 880	4 930	2 890	2 060	2 200
D_9	4 160	7 060	3 590	2 520	2 630
$D_9 - D_1$	2 720	4 820	1 950	1 140	1 250
D_9 / D_1	2,9	3,2	2,2	1,8	1,9

Réponse : les cadres sont les plus dispersés — en absolu (4 820 €) comme en relatif (3,2) ; les employés les moins dispersés (1 140 € et 1,8). Les deux indicateurs concordent ; s'ils divergeaient, il faudrait dire lequel répond à la question posée.

PIÈGE FRÉQUENT

Le fait remarquable, que le support ne commente pas : l'écart inter-décile de l'Ensemble (2 720 €) **dépasse celui de trois CSP sur quatre**. Comment un ensemble peut-il être plus dispersé que la plupart de ses parties ? **Parce qu'il contient la composante INTER** — l'écart entre un cadre médian à 3 620 € et un employé médian à 1 730 €. **On mesure ici, sans la nommer, la décomposition intra/inter du § 2.2.9.**

2.2.4 EAM, variance, écart-type (d. 39 à 43)

FORMULE CLÉ — LES TROIS INDICATEURS D'ÉCART À LA MOYENNE

$$EAM = \frac{1}{N} \sum_{i=1}^N |x_i - m_X| \quad V(X) = \sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - m_X)^2 \quad \sigma = \sqrt{V(X)}$$

Pourquoi la valeur absolue ou le carré ? Parce que la **somme des écarts simples est nulle** (propriété ① de la moyenne) : sans eux, l'indicateur vaudrait 0 pour toute distribution. **Pourquoi la racine ?** Parce que la variance est en **unité au carré**, donc **ininterprétable**. **L'écart-type est la réponse ; la variance est une étape**. **Pourquoi le carré a gagné sur la valeur absolue ?** Parce qu'il est **dérivable partout** — toute la statistique qui suit (moindres carrés, régression, R^2) en dépend. **Et toujours :** $EAM \leq \sigma$, le carré pénalisant davantage les grands écarts.

CORRIGÉ — LA SÉRIE DES 20 ÂGES (D. 42-43) — ET L'OMISSION DU SUPPORT

Le tableau de calcul du support donne, pour cette série :

$$m = 47,9 \text{ ans} \quad EAM = 5,7 \text{ ans} \quad \sigma^2 = 54,19 \text{ ans}^2$$

PIÈGE FRÉQUENT

⚠ Le support s'arrête à la variance. L'écart-type n'y figure jamais :

$$\sigma = \sqrt{54,19} = 7,36 \text{ ans}$$

C'est pourtant le seul chiffre interprétable. « La variance vaut 54,19 ans² » ne dit rien à personne ; « l'écart-type vaut 7,4 ans autour d'une moyenne de 47,9 ans » se lit immédiatement. **Ne rends jamais une copie qui s'arrête à la variance.**

Contrôle de cohérence : $EAM = 5,7 \leq \sigma = 7,36$ ✓, rapport 1,29.

2.2.5 Interpréter l'écart-type : Bienaymé-Tchebychev (d. 44) et la finance (d. 45-48)

FORMULE CLÉ — L'INÉGALITÉ DE BIENAYMÉ-TCHEBYCHEV

$$P(|X - m| \geq k\sigma) \leq \frac{1}{k^2} \quad \text{avec } k > 1$$

Au moins $1 - 1/k^2$ des observations se situent dans $[m - k\sigma ; m + k\sigma]$.

k	Au moins... dans l'intervalle
2	75 %
3	88,9 %
4	93,75 %

Sa force et sa faiblesse sont la même chose : elle est valable QUELLE QUE SOIT LA LOI, donc **très lâche**. Sous hypothèse de normalité, $\pm 2\sigma$ contiendrait environ 95 % des observations, contre 75 % garantis ici. ⚠ **Elle ne dit RIEN pour $k \leq 1$:** la borne vaudrait ≥ 1 , c'est-à-dire « au moins 0 % ».

PIÈGE FRÉQUENT — L'APPLICATION EN FINANCE (D. 45-48) : LES CONCLUSIONS DU SUPPORT NE SE RECONSTRUISENT PAS

Le support conclut à « 99 % de chances de faire des gains en périodes 1, 2, 3 et 5 ». Cette conclusion n'est pas démontrable avec les outils du chapitre, pour deux raisons :

- ① Bienaymé-Tchebychev exige $k > 1$, et dans les cinq périodes on a $m/\sigma < 1$: aucun k admissible ne permet d'encadrer le gain.
- ② La période 2 a une moyenne négative — on ne peut pas y conclure à un gain probable.

Ce que tu dois faire : signaler, ne pas recopier. Une copie qui affirme « 99 % de chances de gains » **sans démonstration est indéfendable** ; une copie qui écrit « l'inégalité de Bienaymé-Tchebychev exige $k > 1$, condition non satisfaite ici, la conclusion ne peut donc être établie par cette voie » **vaut des points**. → intégrale § 2.2.13 pour le détail par période.

Ce qui reste vrai et exigible : l'écart-type devient la volatilité, et elle s'annualise en **multipliant par $\sqrt{252}$** (rendements quotidiens) ou $\sqrt{12}$ (mensuels) — jamais par 252 ni par 12, **puisque ce sont les variances qui s'additionnent**. Et une série de n prix ne donne que $n-1$ rentabilités.

2.2.6 Koenig et les propriétés de la variance (d. 49 à 52)

FORMULE CLÉ — LE PROBLÈME, ET SA SOLUTION

Le problème (d. 49) : la moyenne se calcule par groupe — elle est linéaire. **L'écart-type, non.** On ne peut donc pas calculer facilement la volatilité annuelle à partir des volatilités mensuelles... « mais il y a un moyen ».

- ① **Formule de Koenig** — « la moyenne des carrés moins le carré de la moyenne » :

$$V(X) = \frac{1}{N} \sum_{i=1}^N x_i^2 - m_X^2$$

Pourquoi elle est utile : la formule de définition exige de connaître m_X **avant** de calculer les écarts — **deux passages** sur les données. Koenig ne demande que **deux sommes**, $\sum x_i$ et $\sum x_i^2$, calculables **en un seul passage**. **C'est ce qui rend l'agrégation possible : deux nombres suffisent à transmettre un groupe.** Δ **Contrôle instantané :** la variance étant positive, $\bar{x}^2 \geq (\bar{x})^2$. Une variance négative signale une inversion.

- ② **Invariance par translation :** $V(X + a) = V(X)$. Si $Y = X + a$ alors $m_Y = m_X + a$, donc $y_i - m_Y = x_i - m_X$: les écarts sont inchangés. **Ajouter 6 points à toutes les notes déplace la distribution sans la déformer.**

- ③ **Non-linéarité :** $V(aX) = a^2 V(X)$, donc $\sigma_{aX} = |a| \sigma_X$. Si $Y = aX$ alors $y_i - m_Y = a(x_i - m_X)$, et au carré $a^2 (x_i - m_X)^2$. Δ **L'erreur classique : écrire $V(aX) = a V(X)$.** Retiens : **a ajouté ne change rien, a multiplié change au carré.**

- ④ **Corollaire :** $V(-X) = V(X)$, avec $a = -1$.

2.2.7 Le coefficient de variation (d. 53)

FORMULE CLÉ — UN INDICATEUR RELATIF, SANS UNITÉ

$$CV = \frac{\sigma}{m_X}$$

Indispensable dès qu'on compare des séries d'unités ou d'ordres de grandeur différents. Un écart-type de 500 € ne signifie pas la même chose autour d'une moyenne de 1 000 € ($CV = 0,5$) et de 100 000 € ($CV = 0,005$). **En finance : CV est l'inverse du rapport m/σ , c'est-à-dire du ratio de Sharpe sans taux sans risque.**

2.2.8 La variance sur une distribution, et le choix de la formule (d. 54 à 56)

FORMULE CLÉ — LA FORMULE, ET L'ANOMALIE DU SUPPORT

$$V(X) = \sum_{i=1}^p f_i (x_i - m_X)^2 = \frac{1}{N} \sum_{i=1}^p n_i (x_i - m_X)^2$$

Chaque écart au carré est pondéré par l'effectif de sa modalité — l'oubli de la pondération est l'erreur numéro un sur ce calcul.

PIÈGE FRÉQUENT

△ **ANOMALIE** : le résultat du cas n° 4 (d. 55) est erroné. Le support annonce une variance de **10,4** et un écart-type de **3,2**. Le recalcul donne $\sigma^2 = 20,8$ et $\sigma = \sqrt{20,8} = 4,56$ — **exactement le double** : une division par 2 en trop. **Conséquence** : le classement des cas 2 et 4 par dispersion est inversé. → intégrale § 2.2.16 pour la vérification complète, ligne par ligne.

Formulation qui rapporte en examen : « En appliquant $V = \frac{1}{N} \sum n_i (x_i - m)^2$ j'obtiens 20,8 et non 10,4. L'écart d'un facteur 2 suggère une division supplémentaire par 2. Je retiens 20,8, soit $\sigma = 4,56$, ce qui modifie le classement des cas 2 et 4. »

L'arbre du choix de la formule (d. 56) : **Données brutes** ? → définition, ou **Koenig** si tu dois agréger ensuite. **Distribution** ? → $\sum f_i (x_i - m)^2$, ou Koenig : $\sum f_i x_i^2 - m^2$. **Plusieurs groupes** ? → **agrégation par Koenig**, ou **décomposition intra/inter**.

2.2.9 Agrégation et décomposition intra / inter (d. 57-58)

FORMULE CLÉ — LE COROLLAIRE LE PLUS IMPORTANT DU CHAPITRE

$$\sigma^2 = V_{\text{intra}} + V_{\text{inter}}$$

$$V_{\text{intra}} = \sum_{k=1}^K \frac{N_k}{N} \sigma_k^2 \quad V_{\text{inter}} = \sum_{k=1}^K \frac{N_k}{N} (m_{X_k} - m_X)^2$$

Composante	Ce qu'elle mesure	Question
V_{intra}	La dispersion moyenne à l'intérieur des groupes	« Les membres d'un même groupe se ressemblent-ils ? »
V_{inter}	La dispersion des moyennes de groupe	« Les groupes diffèrent-ils entre eux ? »

Deux cas extrêmes : $V_{\text{inter}} \approx 0 \rightarrow$ les groupes ont la même moyenne, **le découpage n'explique rien** ; $V_{\text{intra}} \approx 0 \rightarrow$ chaque groupe est homogène, **le découpage explique tout**.

Le rapport $V_{\text{inter}}/\sigma^2$ mesure le POUVOIR EXPLICATIF du découpage. C'est lui qui deviendra, au chapitre 4 puis en économétrie, le **rapport de corrélation** puis le R^2 .

ANALOGIE — MARCHÉS FINANCIERS

En gestion de portefeuille, c'est la décomposition du risque : risque **spécifique** (intra — ce qui bouge à l'intérieur de chaque secteur) et risque **systématique** (inter — ce qui fait bouger les secteurs entre eux). **La diversification agit sur le premier, jamais sur le second**. Même algèbre, autre objet.

2.3 — Résumer la concentration (diapositives 59 à 69)

2.3.1 Concentration et dispersion : deux questions différentes (d. 59)

DÉFINITION — LA DISTINCTION, ET LA CONDITION D'EXISTENCE

	Dispersion	Concentration
Objet du raisonnement	Les valeurs x_i	Les parts $x_i / \sum x_j$
Question	Les individus se ressemblent-ils ?	Le total est-il concentré sur quelques-uns ?
Référence	La moyenne	L' agrégat $\sum x_i$
Condition d'application	Variable quantitative	Variable quantitative dont la somme fait sens

Point commun : les deux mesurent des inégalités. Ce sont deux angles sur le même phénomène.

PIÈGE FRÉQUENT

La condition d'existence, que le support signale en une ligne et qu'il faut prendre au sérieux : « si la somme des revenus fait sens, ce n'est pas le cas de tous les caractères statistiques quantitatifs (**exemple : la taille**) ! »

Variable	Sa somme est...	Concentration ?
Salaire	La masse salariale	Oui
Patrimoine · chiffre d'affaires · émissions de CO ₂	Un stock ou un flux réel	Oui
Taille · note · température · âge	Rien	Non

La règle : la concentration exige une variable EXTENSIVE et ADDITIVE. Un Gini sur des notes se calcule numériquement mais **ne s'interprète pas** — et l'absence de vérification préalable est sanctionnée.

2.3.2 La part de l'agrégat (d. 60)

FORMULE CLÉ — LA RELATION FONDATRICE, ET LA SIMPLIFICATION DE N

L'**agrégat** = la somme de X sur la population. Pour les salaires : la **masse salariale**.

$$\sum_{i=1}^{N_k} x_i = N_k \cdot m_{X_k}$$

*Démonstration en une ligne : c'est la définition de la moyenne multipliée par N_k . « La somme = la moyenne $\times$ l'effectif » — c'est ce qui transforme une information *moyenne* (toujours publiée) en information *totale* (rarement publiée).*

La part de l'agrégat de la classe k :

$$p_k = \frac{N_k m_{X_k}}{\sum_j N_j m_{X_j}} = \frac{f_k m_{X_k}}{\sum_j f_j m_{X_j}} = \frac{f_k m_{X_k}}{m_X} = f_k \times \frac{m_{X_k}}{m_X}$$

Pourquoi l'effectif total disparaît : $N_k = f_k N$, et le facteur N est **commun au numérateur et au dénominateur**. Poser $N = 1$ n'est donc pas une approximation mais une **simplification exacte** — le support le suggère sans le démontrer. Et la **troisième écriture est la plus parlante** : la part d'une classe est **sa fréquence multipliée par son avantage relatif de moyenne**. Une classe de 20 % des salariés dont le salaire moyen vaut 2 fois la moyenne détient $0,20 \times 2 = 40$ % de la masse.

Contrôle obligatoire : la somme des parts doit valoir 100 %.

2.3.3 Les salaires en 2005 et 2021 (d. 61 à 63)

CORRIGÉ — LES DEUX TABLEAUX, RECALCULÉS

2005 — classes de salaires (quintiles, donc $f_k = 0,20$ pour tous) :

Proportion (%)	Borne inf.	Borne sup.	Salaire moyen	Part de la masse (%)
20	11 000	12 894	11 947	11,2
20	12 894	15 555	14 225	13,3
20	15 555	19 098	17 327	16,2
20	19 098	25 818	22 458	21,1
20	25 818	55 600	40 709	38,2
Ensemble			21 333	100,0

La moyenne générale. Les classes ayant le **même poids**, elle est la moyenne **simple** des cinq moyennes : $\sum m_k = 106\,666$, donc $m_x = 0,20 \times 106\,666 = 21\,333,2\,€$ ✓ △ **Ce n'est vrai QUE parce que les classes sont des quintiles.** Avec des fréquences inégales, il faudrait pondérer. **Les parts.** Les f_k se simplifiant aussi : $p_k = m_{x_k}/106\,666 \rightarrow 11,20 \cdot 13,34 \cdot 16,24 \cdot 21,05 \cdot 38,17\%$, total **100,00 %** ✓

PIÈGE FRÉQUENT

La colonne « estimation du salaire moyen » n'est jamais expliquée par le support : c'est le CENTRE DE CLASSE. Vérification : $(11\,000 + 12\,894)/2 = 11\,947$ ✓, et ainsi des cinq. **Le support applique donc l'hypothèse de répartition uniforme dans les classes — il fallait le dire, et tu dois le dire. Et il faut en mesurer la fragilité :** les quatre premières classes sont étroites (1 894 à 6 720 €) ; **la cinquième est large de 29 782 €.** Or les hauts salaires sont **massés près de la borne inférieure** : la vraie moyenne de cette classe est **vraisemblablement inférieure** à 40 709 €, donc **la part de 38,2 % surestime probablement la concentration.** *Je dis « vraisemblablement » : sans les données individuelles, l'écart n'est pas quantifiable. Signaler cette limite est ce qui distingue une copie excellente.*

2021 — mêmes classes, autre millésime :

Proportion (%)	Borne inf.	Borne sup.	Salaire moyen	Part (%)
20	1 333	6 709	4 021	3,9
20	6 709	15 110	10 910	10,6
20	15 110	22 942	19 026	18,4
20	22 942	32 124	27 533	26,7
20	32 124	51 490	41 807	40,5
Ensemble			20 659	100

$\Sigma m_k = 103\,297$, donc $m_x = 20\,659,4 \text{ €}$ ✓ ; parts exactes $3,89 \cdot 10,56 \cdot 18,42 \cdot 26,65 \cdot 40,47 \text{ \%}$. $\triangle$ **Détail d'arrondi que le support ne signale pas** : $3,9 + 10,6 + 18,4 + 26,7 + 40,5 = 100,1$, et non 100,0. Les cinq valeurs ont été arrondies **vers le haut**. Cet excédent se propage au tableau des cumuls et décale le Gini d'environ 0,0006. Négligeable, à mentionner.

Quintile	2005	2021	Variation	En relatif
1 ^{er} (les moins payés)	11,2	3,9	- 7,3	- 65 % — la part est divisée par 2,9
2 ^e	13,3	10,6	- 2,7	- 20 %
3 ^e	16,2	18,4	+ 2,2	+ 14 %
4 ^e	21,1	26,7	+ 5,6	+ 27 %
5 ^e (les mieux payés)	38,2	40,5	+ 2,3	+ 6 %

① **Le sens est sans ambiguïté : les inégalités ont augmenté.** Les deux quintiles du bas perdent, les trois du haut gagnent — **10 points de masse salariale ont changé de mains.** *Contrôle mécanique : la somme des variations doit être nulle, et elle l'est à 0,1 près.* ② **Le fait marquant n'est pas l'envol du haut (+ 6 % seulement) mais l'effondrement du bas.** ③ **Le rapport entre extrêmes : $38,2/11,2 = 3,41$ en 2005 contre $40,5/3,9 = 10,38$ en 2021 — multiplié par 3.**

PIÈGE FRÉQUENT

La prudence méthodologique obligatoire — et une limite que je ne peux pas lever. Le plancher passe de 11 000 à 1 333 € ($\div 8$), le plafond baisse (55 600 $\rightarrow$ 51 490) et le salaire moyen baisse en euros courants (21 333 $\rightarrow$ 20 659) alors que les salaires nominaux ont augmenté sur la période. **Ces trois faits ne sont pas compatibles avec deux mesures du même champ.** **L'explication la plus probable : un changement de champ statistique** — 2005 sur des postes en équivalent temps plein, 2021 sur l'ensemble des postes, temps partiels et années incomplètes compris. **Je ne peux pas le vérifier :** le support n'indique ni source, ni champ, ni définition. **À écrire en examen :** « La hausse de concentration est nette, mais la baisse simultanée du plancher, du plafond et du salaire moyen en euros courants suggère un changement de champ entre les deux millésimes ; une partie de l'écart pourrait être un artefact de mesure. » *Même réflexe qu'en finance : avant de comparer deux performances, on vérifie le périmètre, la devise et le traitement des dividendes.*

2.3.4 La courbe de Lorenz (d. 64 à 67)

DÉFINITION — DÉFINITION, CONSTRUCTION, PROPRIÉTÉS

En abscisse la fréquence cumulée de la **POPULATION** ; en ordonnée la part cumulée de l'**AGRÉGAT**, les individus étant rangés par valeur croissante de X . $\triangle$ Le classement croissant est une condition, pas un détail : sans lui la courbe n'est ni convexe, ni sous la diagonale, et le Gini n'a plus de sens. Le support ne le précise pas.

Phrase-type de lecture : « les ... % des salariés les moins payés perçoivent ... % de la masse salariale ».

Le tableau des cumuls (d. 65) :

Part cumulée des salariés (%)	Masse cumulée 2005 (%)	Masse cumulée 2021 (%)
20	11,2	3,9
40	24,5	14,5
60	40,7	32,9
80	61,8	59,6
100	100,0	100,0


$\triangle$ **Le support cumule des valeurs ARRONDIES**. En 2005, le cumul exact à 60 % vaut 40,78 $\rightarrow$ 40,8, mais 11,2+13,3+16,2 = 40,7. En 2021, le dernier cumul donne 100,1, forcé à 100,0. **Cumuler des arrondis n'est pas arrondir des cumuls — écris toujours ce que tu fais.**

LES QUATRE PROPRIÉTÉS, toutes démontrables : ① Elle passe par **(0 ; 0) et (100 ; 100)** — deux points imposés : si ta courbe ne les traverse pas, tu as une erreur de cumul. ② Elle est **croissante** — on cumule des parts positives. ③ Sa **PENTE** sur la classe k vaut m_{X_k}/m_X — le résultat le plus utile, et le support ne l'énonce pas :

$$\text{pente} = \frac{\Delta L}{\Delta F} = \frac{p_k}{f_k} = \frac{f_k m_{X_k}/m_X}{f_k} = \frac{m_{X_k}}{m_X}$$

Pente < 1 $\rightarrow$ la classe gagne moins que la moyenne, la courbe s'écarte de la diagonale. **Pente = 1** $\rightarrow$ elle gagne exactement la moyenne : **c'est le point où l'écart à la diagonale est maximal**. **Pente > 1** $\rightarrow$ la courbe revient vers la diagonale. *Vérification 2005 : pentes 0,56 · 0,67 · 0,81 · 1,05 · 1,91 — la pente franchit 1 entre le 3^e et le 4^e quintile, et c'est bien là que l'écart est maximal (19,3 points à $F = 60$).* ✓ ④ Elle est **convexe** — les pentes croissent, les classes étant ordonnées — **donc située sous la diagonale**, qui relie ses deux extrémités. **Cas limite** : si tout le monde gagne la même chose, toutes les pentes valent 1 : **la courbe EST la diagonale. La diagonale est la courbe de Lorenz de l'égalité parfaite.**

Le graphe (d. 66). Le support affiche les deux courbes **sans la diagonale** — or c'est l'écart à la diagonale qui porte toute l'information. **Le voici reconstruit, diagonale comprise.**



. . . diagonale d'égalité parfaite ($L(F) = F$)
o o o courbe de Lorenz 2005 — 0 = points calculés (20/40/60/80 %)
* * * courbe de Lorenz 2021 — # = points calculés (20/40/60/80 %)

DÉFINITION — INTERPRÉTER, ET COMPARER DEUX COURBES (D. 67)

① Plus la courbe s'éloigne de la diagonale, plus la concentration est forte. ② DOMINANCE DE LORENZ. Si une courbe est partout plus éloignée, l'inégalité est accrue pour tous les ordres de quantiles : tous les indicateurs convergent, aucun choix d'indicateur ne peut inverser la conclusion. ③ SI LES COURBES SE CROISENT, l'une est plus inégalitaire en bas, l'autre en haut : des indicateurs différents peuvent donner des conclusions opposées.

Contre-exemple chiffré, à savoir produire. Deux pays, parts par quintile :

Quintile	Pays A	Pays B	Cumul A	Cumul B
1 ^{er}	4	8	4	8
2 ^e	12	10	16	18
3 ^e	20	15	36	33
4 ^e	28	22	64	55
5 ^e	36	45	100	100

Les cumuls se croisent entre 40 % et 60 %. Alors : rapport $Q_3/Q_1 \rightarrow A = 9,0, B = 5,6$, A plus inégalitaire ; part du quintile supérieur $\rightarrow A = 36 \%, B = 45 \%$, B plus inégalitaire. Deux indicateurs, deux réponses opposées, mêmes données.

APPLICATION À 2005 / 2021 : y a-t-il croisement ?

F	2005	2021	Différence
20 %	11,2	3,9	- 7,3
40 %	24,5	14,5	- 10,0
60 %	40,7	32,9	- 7,8
80 %	61,8	59,6	- 2,2

La différence est négative partout : la courbe 2021 est partout sous celle de 2005. Pas de croisement — il y a dominance de Lorenz, et la conclusion est robuste. Δ Note où l'écart est maximal : à 40 % (- 10,0 points). L'aggravation se joue dans la première moitié, pas dans le haut — cohérent avec l'effondrement du premier quintile.

2.3.5 L'indice de Gini (d. 68-69)

FORMULE CLÉ — DÉFINITION, CONSTRUCTION, ET LE PIÈGE DU CHAPITRE

Géométriquement, le Gini est le DOUBLE de l'aire comprise entre la diagonale et la courbe (l'« aire de concentration ») :

$$G = 2 \times \text{aire} A \quad \text{avec} \quad G = 2 \left[\frac{1}{2} - \sum \frac{(b+B) \cdot h}{2} \right]$$

D'où vient la formule — quatre étapes : ① le carré unité a une aire de 1 ; ② la diagonale le coupe en deux, l'aire sous elle vaut 1/2 ; ③ l'aire de concentration s'obtient en retirant l'aire sous la courbe : $\text{aire} A = \frac{1}{2} - \text{aire} B$; ④ entre deux points la courbe est un segment, donc l'aire sous elle se découpe en trapèzes, d'aire $\frac{(b+B)h}{2}$ — b petite base, B grande base, h largeur de tranche.

PIÈGE FRÉQUENT

LE piège de calcul du chapitre : l'unité des aires. Le support affiche sur le graphe un trapèze d'aire 1 025 (avec $b = 40,7, B = 61,8, h = 20$) puis écrit $\text{aire} A = 0,5$ — aire des trapèzes. Ces deux nombres ne sont pas dans la même unité. Le 1 025 est calculé sur des axes gradués en pourcentages : dans cette unité le carré vaut $100 \times 100 = 10\,000$. Le 0,5 est en fractions, unité où le carré vaut 1.

$$\text{aire} A = \frac{1}{2} - \frac{\sum (b+B)h/2}{10\,000} \quad \text{si les cumuls sont en \%}$$

Contrôle systématique : $\text{aire} A \in [0 ; 0,5]$ et $G \in [0 ; 1]$. Si tu obtiens 0,5 - 3 764, tu as oublié la conversion.

CORRIGÉ — LE CALCUL COMPLET, LES DEUX ANNÉES

Astuce : $h = 20$ pour toutes les tranches, donc aire = $(b+B) \times 10$.

Tranche	2005 : $b \rightarrow B$	Aire	2021 : $b \rightarrow B$	Aire
0 → 20	0 → 11,2	112,0	0 → 3,9	39,0
20 → 40	11,2 → 24,5	357,0	3,9 → 14,5	184,0
40 → 60	24,5 → 40,7	652,0	14,5 → 32,9	474,0
60 → 80	40,7 → 61,8	1 025,0	32,9 → 59,6	925,0
80 → 100	61,8 → 100,0	1 618,0	59,6 → 100,0	1 596,0
Somme		3 764,0		3 218,0

Le trapèze 60 → 80 % vaut 1 025 — exactement la valeur affichée par le support ✓ : la méthode est validée.

$$\text{mathcal{A}}_{2005} = 0,5 - 0,3764 = 0,1236 \Rightarrow G_{2005} = \mathbf{0,2472}$$

$$\text{mathcal{A}}_{2021} = 0,5 - 0,3218 = 0,1782 \Rightarrow G_{2021} = \mathbf{0,3564}$$

Les trois phrases à écrire : ① « L'indice de Gini passe de **0,247 en 2005 à 0,356 en 2021**, soit + **11 points** ou + **44 % en relatif**. » ② « La concentration de la masse salariale s'est donc **fortement accrue**. » ③ « Ce diagnostic est **cohérent avec la courbe de Lorenz**, partout plus éloignée de la diagonale en 2021 : **dominance**, donc **aucun risque de contradiction entre indicateurs**. »

Et la réserve sur le changement de champ reste entière.

Avec les parts non arrondies on obtiendrait 0,2466 et 0,3570 — l'écart d'arrondi n'affecte que la troisième décimale et ne change aucune conclusion.

DÉFINITION — LES BORNES, ET COMMENT INTERPRÉTER UN GINI

$G = 0 \Leftrightarrow$ **égalité parfaite**. Cumuls 20/40/60/80/100 → trapèzes 200+600+1 000+1 400+1 800 = 5 000 →

$\text{mathcal{A}} = 0,5 - 0,5 = 0$ ✓ **La courbe est la diagonale**. $G \rightarrow 1 \Leftrightarrow$ **concentration totale** — un seul individu détient tout. Δ

Précision d'excellente copie : avec N individus, le maximum vaut $\frac{N-1}{N}$, non 1 — le dernier individu occupe une largeur $1/N$ sous laquelle subsiste un triangle d'aire $\frac{1}{2N}$.

Ordres de grandeur, pour le revenu disponible des ménages — repères, pas chiffres exacts : nordiques 0,25-0,28 · **France, Allemagne 0,29-0,32** · Royaume-Uni, Italie 0,33-0,36 · États-Unis 0,38-0,41 · Brésil 0,48-0,54 · Afrique du Sud $\approx 0,63$.

PIÈGE FRÉQUENT

Trois précautions avant toute comparaison de Gini. ① **Le concept mesuré change tout** — le Gini du **patrimoine** ($> 0,6$ en France) est bien supérieur à celui du **revenu** ($\approx 0,3$) : le patrimoine peut être nul ou négatif. ② **Avant ou après redistribution ?** L'écart entre le Gini des revenus **primaires** et celui du revenu **disponible** mesure l'effet du système socio-fiscal. ③ **Le Gini est peu sensible aux extrêmes** : il réagit surtout aux transferts autour du **milieu**. Un Gini stable peut masquer un décrochage du dernier centile — d'où l'accompagnement systématique par le **rapport D_9/D_1** et la **part du 1 % le plus riche**. Δ Nos deux valeurs portent sur les **SALAIRES**, pas sur le revenu disponible : elles ne sont pas comparables aux repères ci-dessus.

ANALOGIE — MARCHÉS FINANCIERS

La concentration en salle de marché. Trie tes positions par poids croissant et cumule : tu obtiens la courbe de Lorenz de ton exposition. L'indicateur du métier est l'**indice de Herfindahl-Hirschman $HHI = \sum_i w_i^2$** — $1/n$ pour n lignes équipondérées, et il tend vers 1 quand tout est sur une ligne. **Un mandat de gestion impose presque toujours un plafond de HHI ou un poids maximal par ligne.** Et sur le **P&L** : presque tous les *track records* montrent qu'une **minorité de trades fait la totalité du résultat** — ce n'est pas anormal, c'est la signature d'une asymétrie droite. **Ce qui est dangereux, c'est l'inverse** : une concentration venant de quelques **pertes** énormes compensées par beaucoup de petits gains. **La courbe de Lorenz de ton P&L distingue les deux en un coup d'œil ; la moyenne, non.**

2.4 — Récapitulons (diapositive 70)

SYNTHÈSE — LES TREIZE INDICATEURS DU CHAPITRE, EN UN TABLEAU

Famille	Indicateur	Formule	Unité	Sensible aux extrêmes ?	Quand le choisir
Position	Mode	Fréquence max (ou densité max si classes inégales)	Celle de X	Non	Seul indicateur valable sur une variable qualitative
	Moyenne	$\frac{1}{N} \sum x_i$	Celle de X	Oui	Distribution symétrique ; calculs ultérieurs (linéarité, agrégation)
	Médiane	$F(\text{Me}) = 0,5$	Celle de X	Non	Distribution asymétrique ; valeurs extrêmes
Dispersion	Étendue	$x_{\max} - x_{\min}$	Celle de X	Totalement	Première approche, jamais seule
	Écart inter-quartile	$Q_3 - Q_1$	Celle de X	Non	Accompagne la médiane ; base du <i>boxplot</i>
	Écart inter-décile	$D_9 - D_1 \cdot D_9/D_1$	Celle de X · sans unité	Peu	Comparaisons de niveaux de vie
	EAM	$\frac{1}{N} \sum x_i - m_x $	Celle de X	Oui	Lisible, mais non dérivable
	Variance	$\frac{1}{N} \sum (x_i - m_x)^2$	Au carré	Très	Étape de calcul , décompositions
	Écart-type	$\sigma = \sqrt{V}$	Celle de X	Très	L'indicateur de référence — volatilité en finance
	Coefficient de variation	$CV = \sigma/m_x$	Sans unité	Oui	Comparer des séries d'unités ou d'échelles différentes
Concentration	Part de l'agrégat	$p_k = f_k \cdot m_{x_k}/m_x$	Sans unité	—	Première lecture des inégalités
	Courbe de Lorenz	$L(F) = \text{part cumulée}$	Sans unité	—	Comparer deux distributions (dominance)
	Indice de Gini	$2 \left[\frac{1}{2} - \sum \frac{(b+B)h}{2} \right]$	Sans unité, [0;1]	Peu (milieu)	Résumer, classer, suivre une évolution

MÉTHODE — L'ARBRE DE DÉCISION : QUEL INDICATEUR, QUAND ?

Q1 — Type de variable ? Qualitative → mode uniquement. Ordinale → mode et médiane, pas de moyenne. Cardinale → tout est permis, va en Q2. **Q2 — Que veux-tu décrire ?** Le niveau typique → position (Q3). L'homogénéité → dispersion (Q4). Le partage d'un total → concentration, après avoir vérifié que la somme fait sens. **Q3 — La distribution est-elle symétrique ?** Oui → moyenne. Non, ou valeurs extrêmes → médiane, en donnant aussi la moyenne : l'écart entre les deux est le diagnostic d'asymétrie. **Q4 — Mêmes unités et mêmes ordres de grandeur ?** Oui → écart-type. Non → coefficient de variation. Résister aux extrêmes → écarts inter-quantiles et *boxplot*. **Q5 — Faut-il agréger ?** Moyenne → pondérée. Variance → Koenig ou intra/inter. Médiane, quantiles et Gini : JAMAIS.

PIÈGE FRÉQUENT

La phrase du support qu'on lit trop vite : « le choix d'indicateurs dépend du type de données mais aussi de ce que l'on veut en faire ». La seconde moitié est la plus importante. Le type de données élimine ; l'objectif tranche entre ceux qui restent. Mêmes données, trois objectifs, trois indicateurs : décrire le salaire typique d'une profession → médiane ; calculer la masse salariale à provisionner → moyenne (seule à s'agréger) ; vérifier qu'aucun salarié n'est décroché → écarts inter-déciles. Un correcteur attend que tu justifies ton choix — pas que tu calcules tout.

3. Points de vigilance

3.1 — Les confusions classiques

Vingt couples de notions voisines. Pour chacun, **le critère qui tranche**.

Notion A	Notion B	Le critère qui les sépare
Présenter (chapitre 1)	Résumer (chapitre 2)	Présenter conserve toute l'information ; résumer en perd volontairement pour produire un petit nombre de chiffres
Mode	Classe modale	Le mode est une valeur (variable discrète) ; la classe modale est un intervalle (variable continue). On ne dit jamais « le mode est [20 ; 30[»
Effectif le plus élevé	Densité la plus élevée	Quand les classes ont des amplitudes inégales , la classe modale est celle de densité maximale , pas d'effectif maximal
Amplitude	Densité	L'amplitude est la largeur de la classe ($b_{\text{sup}} - b_{\text{inf}}$) ; la densité est l'effectif rapporté à cette largeur (n_i / a_i)
Hauteur d'un histogramme	Hauteur d'un diagramme en barres	Dans un histogramme, c'est la densité et c'est l' aire qui représente l'effectif ; dans un diagramme en barres, la hauteur est l'effectif
Moyenne	Médiane	La moyenne est le centre de gravité (elle utilise toutes les valeurs) ; la médiane est le centre de l'effectif (elle n'utilise que le rang)
Médiane	Classe médiane	Même distinction que mode / classe modale : la classe médiane est l'intervalle qui contient la médiane, qu'on obtient ensuite par interpolation
Moyenne simple	Moyenne pondérée	On pondère dès que les groupes n'ont pas le même effectif . La moyenne simple des moyennes est fausse dans ce cas
Quantile	Quartile / décile / centile	Le quantile est le genre ; quartile (4 parts), décile (10), centile (100) sont les espèces
Q_1	D_1	Q_1 laisse 25 % de l'effectif en dessous, D_1 en laisse 10 % . $Q_1 = D_{2,5}$
Étendue	Écart inter-quartile	L'étendue utilise les deux extrêmes (donc totalement sensible aux valeurs aberrantes) ; l'inter-quartile ne décrit que les 50 % centraux
Écart inter-quartile	Intervalle inter-quartile	Le premier est un nombre ($Q_3 - Q_1$) ; le second est un intervalle ($[Q_1 ; Q_3]$)
EAM	Écart-type	L'EAM moyenne des valeurs absolues des écarts ; l'écart-type passe par les carrés . L'écart-type est toujours $\geq$ EAM
Variance	Écart-type	La variance est dans l' unité au carré (donc ininterprétable) ; l'écart-type est la racine de la variance, dans l'unité de X
Écart-type	Coefficient de variation	L'écart-type est absolu (avec une unité) ; le CV est relatif (sans unité), donc seul comparable entre séries d'unités différentes
Variance intra	Variance inter	L'intra est la moyenne des variances dans les groupes ; l'inter est la variance des moyennes de groupe. Somme des deux = variance totale
Dispersion	Concentration	La dispersion décrit la répartition des observations ; la concentration décrit la répartition de la somme
Part de l'agrégat	Fréquence	La fréquence est la part de la population ; la part de l'agrégat est la part de la masse (des salaires, du patrimoine...)
Courbe de Lorenz	Fonction de répartition	La courbe de Lorenz met la part cumulée de X en ordonnée ; la fonction de répartition met la fréquence cumulée en ordonnée, avec X en abscisse. Ce ne sont pas les mêmes axes
Indice de Gini	Aire de concentration	Le Gini est le double de l'aire de concentration. Confondre les deux divise le résultat par 2

3.2 — Les erreurs que commet la majorité des étudiants

1. **Confondre l'effectif et la densité pour trouver la classe modale.** Dès que les amplitudes diffèrent, il faut diviser. C'est l'erreur la plus fréquente du § 2.1.3.
2. **Faire la moyenne des moyennes sans pondérer.** Elle n'est exacte que si tous les groupes ont le même effectif — ce qui est rare. Deux classes de 10 et 30 élèves ne se moyennent pas à parts égales.
3. **Faire la moyenne des médianes.** Ce n'est jamais valable, même avec les bons poids. La médiane **ne s'agrège pas** — le contre-exemple $\{1;2;3\} \cup \{100;200;300\}$ du § 2.1.15 le prouve en trois lignes.
4. **Oublier de trier avant de chercher une médiane.** La médiane est définie sur la série **ordonnée**. Sur la série brute, elle n'a aucun sens.
5. **Se tromper de rang médian pour un effectif pair.** Avec N pair, il n'y a pas d'observation centrale : la médiane est **la moyenne des deux valeurs de rang $N/2$ et $N/2 + 1$.**
6. **Donner la variance comme réponse finale.** La variance est une **étape**. La réponse qu'on interprète est l'**écart-type**, avec son unité. Le support de la diapositive 43 s'arrête lui-même à la variance : il faut aller jusqu'à $\sigma = 7,36$.
7. **Oublier le carré dans les propriétés.** $V(aX) = a^2 V(X)$ et non $aV(X)$; en revanche $\sigma_{aX} = |a| \sigma_X$. Confondre les deux niveaux est sanctionné à chaque fois.
8. **Croire qu'ajouter une constante change la dispersion.** $V(X + a) = V(X)$. Ajouter 6 points à toutes les notes ne change **rien** à l'écart-type.
9. **Appliquer Bienaymé-Tchebychev avec $k \leq 1$.** L'inégalité ne dit rien pour $k \leq 1$: elle donnerait « au moins 0 % », ce qui est vide de sens. C'est exactement le problème de la diapositive 48 (§ 2.2.13).
10. **Comparer des écarts-types de séries d'unités ou d'échelles différentes.** Il faut alors le **coefficient de variation**. Comparer la volatilité en euros d'une action à 10 € et d'une action à 1 000 € n'a aucun sens.
11. **Utiliser Koenig sans élever la moyenne au carré.** $V = \overline{x^2} - m^2$, et non $\overline{x^2} - m$. L'homogénéité dimensionnelle suffit à détecter l'erreur.
12. **Calculer une concentration sur une variable dont la somme n'a pas de sens.** Un Gini sur des notes ou sur des âges se calcule numériquement mais **ne s'interprète pas**.
13. **Oublier de diviser les aires de trapèzes par 10 000** quand les cumuls sont en pourcentages. Le résultat sort alors complètement de l'intervalle $[0 ; 1]$ — et ce **contrôle-là est immédiat**.
14. **Confondre le complément à 100 par le haut et par le bas** dans la lecture d'une courbe de Lorenz. $100 - L(80)$ est la part **des 20 % les mieux payés**.
15. **Cumuler des valeurs déjà arrondies sans le dire.** L'erreur se propage ; elle est minime, mais un correcteur exigeant attend la mention.
16. **Comparer deux distributions sans vérifier l'homogénéité des champs.** Le cas 2005 / 2021 du § 2.3.5 en est l'illustration parfaite : les bornes trahissent un changement de périmètre.
17. **Conclure « les inégalités ont augmenté » à partir de deux courbes qui se croisent.** En cas de croisement, deux indicateurs peuvent donner des réponses opposées (§ 2.3.7).
18. **Interpréter un écart-type sans le rapporter à la moyenne.** « $\sigma = 500$ € » ne dit rien tant qu'on ne sait pas si la moyenne est 1 000 € ou 100 000 €.
19. **Prendre le centre de classe pour la vraie moyenne sans le signaler.** C'est une **hypothèse** (répartition uniforme dans la classe), et elle est d'autant plus fragile que la classe est large.
20. **Oublier que la somme des écarts à la moyenne est nulle.** C'est précisément pour cela qu'on prend des valeurs absolues (EAM) ou des carrés (variance) — et non par goût de la complication.

3.3 — Ce qui sépare une copie moyenne d'une excellente copie

La copie moyenne	La copie excellente
Donne le mode	Vérifie d'abord si les amplitudes sont égales, calcule les densités si elles ne le sont pas, et parle de classe modale pour une variable continue
Trace un histogramme	Rappelle que c'est l'aire qui représente l'effectif , et le démontre : densité $\times$ amplitude = effectif
Calcule une moyenne	Pondère par les effectifs, vérifie l'ordre de grandeur, et signale que la moyenne est sensible aux extrêmes
Donne la médiane	Précise le rang utilisé, dit si l'effectif est pair ou impair, et compare médiane et moyenne pour diagnostiquer l'asymétrie

La copie moyenne	La copie excellente
Calcule Q_1 et Q_3	Définit le quantile comme l'inverse de la fonction de répartition ($F(Q_p) = p$) et sait interpoler dans une classe
Calcule la variance	Va jusqu'à l'écart-type , donne son unité, et le rapporte à la moyenne (coefficient de variation)
Applique Koenig	Justifie pourquoi on l'utilise : un seul passage sur les données, donc agrégation possible avec deux nombres par groupe
Cite Bienaymé-Tchebychev	Vérifie que $k > 1$, précise que la borne est valable quelle que soit la loi , et donc très lâche en pratique
Calcule une variance par groupe	Écrit la décomposition intra / inter , interprète le rapport $V_{\text{inter}}/\sigma^2$ comme pouvoir explicatif du découpage , et annonce le lien avec le R^2
Calcule des parts de masse salariale	Vérifie que la somme fait 100 % et démontre que l'effectif total se simplifie
Trace une courbe de Lorenz	Trace d'abord la diagonale , justifie la convexité par la pente m_{x_k}/m_x , et écrit une phrase de lecture complète
Calcule un Gini	Contrôle l'unité des aires , vérifie que le résultat est dans $[0 ; 1]$, et donne un repère de comparaison
Conclut « les inégalités ont augmenté »	Vérifie qu'il n'y a pas de croisement des courbes (dominance de Lorenz), puis signale le risque de changement de champ entre les deux millésimes
Reprend les chiffres du support	Recalcule et signale les incohérences — comme la variance du cas 4 (diapositive 55) ou les conclusions non reconstituables de la diapositive 48
S'arrête au calcul	Termine par une phrase d'interprétation avec l'unité, la sous-population et le champ

3.4 — Les quatre anomalies du support à connaître

Ce chapitre contient quatre points où le support d'origine est fautif, incomplet ou non reconstituable. **Les connaître te protège** : si l'un d'eux tombe à l'examen, tu sauras que ce n'est pas toi qui te trompes.

Diapositive	Ce que le support affiche	Ce que donne le recalcul	Statut
55 (cas 4)	Variance = 10,4 ; écart-type = 3,2	Variance = 20,8 ; écart-type = 4,56	Erreur. Le support a divisé une fois de trop par 2. Conséquence : le classement des cas 2 et 4 par dispersion est inversé (§ 2.2.16)
48 (Sayna)	« 99 % de chances de faire des gains en périodes 1, 2, 3, 5 »	Non reconstituable. Bienaymé-Tchebychev exige $k > 1$, or $m/\sigma < 1$ dans les cinq périodes ; de plus la période 2 a une moyenne négative	Conclusion non démontrable avec les seuls outils du chapitre (§ 2.2.13)
35	Titre « retraités, année 2008 »	Le tableau affiché est celui des niveaux de vie de 2024 de la diapositive 34	Erreur de titre (§ 2.2.7)
43	S'arrête à la variance (54,19)	L'écart-type $\sigma = \sqrt{54,19} = 7,36$ ans n'est jamais calculé	Omission : c'est pourtant le seul chiffre interprétable (§ 2.2.11)

PIÈGE FRÉQUENT — COMMENT TRAITER UNE ERREUR DU SUPPORT EN EXAMEN

Ne recopie jamais un chiffre faux « parce qu'il est dans le cours ». Mais ne te contente pas non plus de le corriger en silence.

La formulation qui rapporte des points : « En appliquant la formule $V = \frac{1}{N} \sum n_i (x_i - m)^2$, j'obtiens 20,8 et non 10,4. L'écart d'un facteur 2 suggère une division supplémentaire par 2 dans le calcul du support. Je retiens 20,8, soit $\sigma = 4,56$, ce qui modifie le classement des cas 2 et 4. »

Tu montres trois choses en trois lignes : que tu sais calculer, que tu contrôles tes résultats, et que tu mesures les conséquences d'une erreur. **C'est exactement le profil qu'on attend d'un analyste.**

4. Système d'ancrage mémoriel

4.1 — Fiche de synthèse

SYNTHÈSE — CHAPITRE 2 « RÉSUMER POUR INFORMER » — L'ESSENTIEL SUR DEUX PAGES

LE PROJET DU CHAPITRE. Présenter (chapitre 1) conserve **toute** l'information. Résumer en **perd volontairement** pour produire quelques chiffres décisionnels. Trois familles : **position** (où ?), **dispersion** (à quel point c'est étalé ?), **concentration** (comment le total se partage-t-il ?).

① **POSITION — LE MODE.** La modalité de **fréquence maximale**. Variable continue → **classe modale**. $\triangle$ Si les amplitudes sont **inéga**les, la classe modale est celle de **densité maximale** : $d_i = n_i / a_i$ avec $a_i = b_{\text{sup}} - b_{\text{inf}}$. **Histogramme** : hauteur = densité, et **c'est l'aire qui représente l'effectif** ($d_i \times a_i = n_i$).

① **POSITION — LA MOYENNE.** Trois écritures du même objet : $m_X = \frac{1}{N} \sum_{i=1}^N x_i$ (données brutes) · $m_X = \sum_{i=1}^p f_i x_i$ (distribution) · $m_X = \sum_{k=1}^K \frac{N_k}{N} m_{X_k}$ (agrégation). **Trois propriétés** : ① $\sum (x_i - m_X) = 0$ — la somme des écarts est nulle ; ② **linéarité** $m_{aX+b} = a m_X + b$; ③ **sensibilité aux valeurs extrêmes**.

① **POSITION — LA MÉDIANE.** La valeur qui **partage l'effectif en deux** : $F(\text{Me}) = 0,5$. N impair → valeur de rang $(N+1)/2$; N pair → **moyenne** des rangs $N/2$ et $N/2+1$. Sur une distribution : classe médiane puis **interpolation linéaire**. $\triangle$ **La médiane ne s'agrége JAMAIS**.

DIAGNOSTIC D'ASYMÉTRIE. $\text{Me} < m_X \rightarrow$ distribution **étalée à droite** (salaires, patrimoines). $\text{Me} > m_X \rightarrow$ étalée à gauche. $\text{Me} \approx m_X \rightarrow$ symétrique.

② **DISPERSION — LES INDICATEURS D'ÉCART ENTRE POSITIONS.** **Étendue** $= x_{\text{max}} - x_{\text{min}}$ (totalement sensible aux extrêmes). **Quantile** Q_p : la valeur telle que $F(Q_p) = p$ — c'est **l'inverse de la fonction de répartition**. Quartiles (4 parts), déciles (10), centiles (100). **Écart inter-quartile** $= Q_3 - Q_1$ (50 % centraux) · **inter-décile** $= D_9 - D_1$ (80 % centraux) · **rapport inter-décile** $= D_9/D_1$ (sans unité). **Boxplot** : boîte de Q_1 à Q_3 , trait à la médiane, moustaches aux extrêmes.

② **DISPERSION — LES INDICATEURS D'ÉCART À LA MOYENNE.**

$$EAM = \frac{1}{N} \sum |x_i - m_X| \quad \sigma^2 = V(X) = \frac{1}{N} \sum (x_i - m_X)^2 \quad \sigma = \sqrt{V(X)}$$

Koenig : $V(X) = \frac{1}{N} \sum x_i^2 - m_X^2$ (« moyenne des carrés moins carré de la moyenne ») — **un seul passage sur les données, donc agrégation possible**. **Propriétés** : $V(X + a) = V(X)$ · $V(aX) = a^2 V(X)$ · $\sigma_{aX} = |a| \sigma_X$ · $V(-X) = V(X)$. **Coefficient de variation** $CV = \sigma / m_X$ — **sans unité**, seul comparable entre séries d'échelles différentes. **Bienaimé-Tchebychev** : $P(|x - m| \geq k\sigma) \leq 1/k^2$, **valable quelle que soit la loi**, donc **très lâche**. $\triangle$ **Ne dit rien pour $k \leq 1$** . **Décomposition** :

$\sigma^2 = V_{\text{intra}} + V_{\text{inter}}$ avec $V_{\text{intra}} = \sum \frac{N_k}{N} \sigma_k^2$ et $V_{\text{inter}} = \sum \frac{N_k}{N} (m_{X_k} - m_X)^2$. Le rapport $V_{\text{inter}}/\sigma^2$ mesure le **pouvoir explicatif du découpage**.

③ **CONCENTRATION — LA CONDITION D'EXISTENCE.** Elle n'existe que si **la somme de X a un sens** (salaires → masse salariale ✓ ; tailles, notes, âges ✗).

③ **CONCENTRATION — LA PART DE L'AGRÉGAT.** $\sum_{i=1}^{N_k} x_i = N_k m_{X_k}$ (« la somme = la moyenne × l'effectif »), d'où

$$p_k = \frac{N_k m_{X_k}}{\sum_j N_j m_{X_j}} = \frac{f_k m_{X_k}}{m_X} = f_k \times \frac{m_{X_k}}{m_X}$$

L'effectif total se simplifie : le calcul est possible à N inconnu.

③ **CONCENTRATION — LORENZ ET GINI.** La **courbe de Lorenz** met la **part cumulée de X** (ordonnée) en face de la **fréquence cumulée de la population** (abscisse), individus **rangés par X croissant**. Elle part de (0;0), arrive à (100;100), est **croissante et convexe**, et sa **pente sur la classe k vaut m_{X_k}/m_X** . La **diagonale** est la courbe de l'**égalité parfaite**. **Dominance de Lorenz** : une courbe partout plus éloignée de la diagonale → **tous** les indicateurs concluent à plus d'inégalité. **Croisement** → conclusions possiblement contradictoires.

$$G = 2 \times \text{mathcal{A}} = 2 \left[\frac{1}{2} - \sum \frac{(b+B)h}{2} \right], \quad 0 \leq G \leq 1$$

⚠ **Si les cumuls sont en %, diviser la somme des trapèzes par 10 000.** $G = 0 \rightarrow$ égalité parfaite · $G \rightarrow 1 \rightarrow$ concentration totale (max exact = $(N-1)/N$).

LES CHIFFRES DU CHAPITRE À CONNAÎTRE. Âges (diapo 42-43) : $m = 47,9$; $EAM = 5,7$; $\sigma^2 = 54,19$; $\sigma = 7,36$.

Niveau de vie 2024 : $D_9/D_1 = 3,48$. Salaires : $G_{2005} = 0,2472 \rightarrow G_{2021} = 0,3564$ (+ 44 %). Part du 1^{er} quintile : 11,2 % $\rightarrow$ 3,9 % (divisée par 2,9).

LE CHOIX DE L'INDICATEUR. Type de données **puis** objectif. Asymétrie $\rightarrow$ médiane. Agrégation $\rightarrow$ moyenne. Unités différentes $\rightarrow$ CV. Partage d'un total $\rightarrow$ Lorenz et Gini.

4.2 — Cartes de révision

Soixante-cinq cartes couvrant l'intégralité du chapitre. **Utilisation** : cache la réponse, formule la tienne à voix haute, puis compare. Une carte n'est acquise que si tu produis la réponse complète, pas si tu la reconnais.

Le projet du chapitre

Quelle est la différence de nature entre « présenter » (chapitre 1) et « résumer » (chapitre 2) ?

Présenter conserve toute l'information (série brute, distribution des effectifs : aucune donnée n'est perdue). **Résumer en perd volontairement** : on remplace N valeurs par quelques chiffres. **La perte est le prix de la décision** — on ne décide pas devant 1 200 nombres.

Quelles sont les trois familles d'indicateurs du chapitre, et la question de chacune ?

Position : où se situe la distribution ? (mode, moyenne, médiane). **Dispersion** : à quel point est-elle étalée ? (étendue, écarts inter-quantiles, EAM, variance, écart-type, CV). **Concentration** : comment le total se partage-t-il ? (part de l'agrégat, Lorenz, Gini).

Le mode

Définissez le mode.

La **modalité de fréquence (ou d'effectif) maximale**. C'est le seul indicateur de position calculable sur une variable qualitative.

Pourquoi parle-t-on de « classe modale » et non de « mode » pour une variable continue ?

Parce qu'une variable continue est regroupée en **classes** : l'indicateur désigne donc un **intervalle**, pas une valeur. Dire « le mode est [20 ; 30[» est un abus de langage sanctionné.

Comment détermine-t-on la classe modale quand les classes ont des amplitudes inégales ?

Par la **densité maximale**, pas par l'effectif maximal :

$$d_i = \frac{n_i}{a_i} \quad \text{avec } a_i = b_{\text{sup}} - b_{\text{inf}}$$

Une classe deux fois plus large contient mécaniquement plus d'individus sans être plus « dense ».

Dans un histogramme, que représentent la hauteur et l'aire d'un rectangle ?

La **hauteur** représente la **densité** $d_i = n_i/a_i$. **L'aire représente l'effectif** : aire = $d_i \times a_i = \frac{n_i}{a_i} \times a_i = n_i$. C'est la **propriété fondamentale de l'histogramme**, et elle le distingue du diagramme en barres où la hauteur est l'effectif.

Que se passe-t-il si l'on trace un histogramme en portant les effectifs en hauteur avec des classes d'amplitudes inégales ?

La figure ment. Les classes larges paraissent surreprésentées, puisque leur aire vaut $n_i \times a_i$ au lieu de n_i . La forme de la distribution est déformée proportionnellement aux amplitudes.

La moyenne

Donnez les trois écritures de la moyenne arithmétique et le cas d'usage de chacune.

① **Données brutes** : $m_X = \frac{1}{N} \sum_{i=1}^N x_i$. ② **Distribution** : $m_X = \sum_{i=1}^p f_i x_i$ (ou $\frac{1}{N} \sum n_i x_i$). ③ **Agrégation** : $m_X = \sum_{k=1}^K \frac{N_k}{N} m_{X_k}$.

Les trois donnent le même nombre : ce sont trois regroupements de la même somme.

Énoncez et démontrez la première propriété de la moyenne.

La somme des écarts à la moyenne est nulle : $\sum_{i=1}^N (x_i - m_X) = 0$. *Démonstration* : $\sum (x_i - m_X) = \sum x_i - N m_X = N m_X - N m_X = 0$, puisque $\sum x_i = N m_X$ par définition de la moyenne. **Conséquence** : on ne peut pas mesurer la dispersion par la moyenne des écarts — d'où les valeurs absolues (EAM) et les carrés (variance).

Énoncez la propriété de linéarité de la moyenne et ce qu'elle autorise.

$m_{aX+b} = a m_X + b$. Elle autorise l'agrégation : la moyenne d'un ensemble se reconstruit à partir des moyennes de ses parties, pondérées par les effectifs. C'est ce que l'écart-type ne permet pas (d'où Koenig).

Pourquoi la moyenne est-elle sensible aux valeurs extrêmes, et la médiane non ?

La moyenne utilise **la valeur** de chaque observation : une valeur très grande pèse proportionnellement à sa taille. La médiane n'utilise que **le rang** : remplacer la plus grande valeur par une valeur dix fois plus grande **ne change pas son rang**, donc ne change pas la médiane.

Quand la moyenne d'un ensemble est-elle égale à la moyenne simple des moyennes de groupe ?

Uniquement si tous les groupes ont le même effectif. Sinon il faut pondérer : $m_X = \sum \frac{N_k}{N} m_{X_k}$. C'est le cas des tableaux de quintiles (20 % chacun), où la pondération est uniforme — mais c'est une exception, pas la règle.

La médiane et les quantiles

Définissez la médiane de deux façons.

Définition par le partage : la valeur qui partage la population **ordonnée** en deux parties d'effectifs égaux — 50 % en dessous, 50 % au-dessus. **Définition par la fonction de répartition** : la valeur Me telle que $F(Me) = 0,5$.

Comment calcule-t-on la médiane sur données brutes selon la parité de N ?

Trier d'abord, toujours. N **impair** → la valeur de rang $\frac{N+1}{2}$. N **pair** → la **moyenne des valeurs de rang $\frac{N}{2}$ et $\frac{N}{2}+1$** (il n'existe pas d'observation centrale).

Comment obtient-on la médiane à partir d'une distribution groupée en classes ?

① Calculer les **fréquences cumulées**. ② Repérer la **classe médiane** : la première dont la fréquence cumulée atteint ou dépasse 0,5. ③ **Interpoler linéairement** dans cette classe, sous l'hypothèse de répartition uniforme :

$$Me = b_{\text{inf}} + a \times \frac{0,5 - F(b_{\text{inf}})}{F(b_{\text{sup}}) - F(b_{\text{inf}})}$$

Peut-on calculer la médiane d'un ensemble à partir des médianes de ses sous-groupes ?

Non, jamais — même avec les bons poids. *Contre-exemple* : $A = \{1;2;3\}$ ($Me = 2$), $B = \{100;200;300\}$ ($Me = 200$). Moyenne des médianes = 101. Vraie médiane de $A \cup B = \{1;2;3;100;200;300\}$: $(3+100)/2 = 51,5$. **Écart d'un facteur 2**. La médiane dépend de **la position relative de toutes les valeurs**, information détruite par le résumé en médianes de groupe.

Que signifie l'écart entre médiane et moyenne d'une distribution ?

$Me < m_X$ → distribution **étalée à droite** : quelques très grandes valeurs tirent la moyenne vers le haut (salaires, patrimoines, capitalisations). $Me > m_X$ → **étalée à gauche**. $Me \approx m_X$ → **symétrique**. C'est le **diagnostic d'asymétrie le moins coûteux qui existe** : deux chiffres.

Définissez un quantile d'ordre p .

La valeur Q_p telle que $F(Q_p) = p$: **une proportion p de la population a une valeur inférieure ou égale à Q_p** . Formellement, le quantile est l'inverse de la fonction de répartition : $Q_p = F^{-1}(p)$.

Quartiles, déciles, centiles : quelle est la logique commune, et combien de valeurs définissent chaque famille ?

On découpe la population ordonnée en parts d'effectifs égaux. **Quartiles** : 4 parts → **3 valeurs** ($Q_1, Q_2 = Me, Q_3$). **Déciles** : 10 parts → **9 valeurs** (D_1 à D_9). **Centiles** : 100 parts → **99 valeurs**. Règle : n parts se délimitent par $n - 1$ valeurs.

Que valent Q_1 et Q_3 exprimés en déciles ? Et Me ?

$Q_1 = D_{2,5}$ · $Q_3 = D_{7,5}$ · $Me = Q_2 = D_5$. **Tous les quantiles appartiennent à la même famille** : seuls les ordres changent.

Les indicateurs de dispersion

Pourquoi un indicateur de position ne suffit-il jamais à résumer une distribution ?

Parce que **deux distributions de même moyenne peuvent être radicalement différentes** (les quatre cas de la diapositive 27). La position dit **où** ; il faut la dispersion pour dire **à quel point les individus se ressemblent**. Une moyenne sans dispersion est une information incomplète — et en finance, dangereuse.

Définissez l'étendue et donnez sa faiblesse.

étendue = $x_{\max} - x_{\min}$. **Faiblesse** : elle ne dépend que des deux valeurs extrêmes, donc elle est totalement détruite par une valeur aberrante et ne dit rien de la répartition entre les deux bornes.

Citez les trois écarts inter-quantiles usuels et ce que chacun décrit.

Écart inter-quartile $Q_3 - Q_1$: l'étalement des **50 % centraux**. **Écart inter-décile** $D_9 - D_1$: l'étalement des **80 % centraux**. **Rapport inter-décile** D_9 / D_1 : le même en **relatif**, donc **sans unité** et comparable entre populations.

Décrivez la construction d'un *boxplot* et ce qu'on y lit immédiatement.

Boîte de Q_1 à Q_3 (les 50 % centraux), **trait intérieur** à la **médiane**, **moustaches** jusqu'aux valeurs extrêmes (ou aux déciles selon la convention). **Lecture immédiate** : le niveau (position du trait), la dispersion (largeur de la boîte), et l'**asymétrie** — si le trait n'est pas au centre de la boîte, la distribution est asymétrique.

Écrivez la formule de l'écart absolu moyen et expliquez pourquoi on prend la valeur absolue.

$$EAM = \frac{1}{N} \sum_{i=1}^N |x_i - m_x|$$

On prend la valeur absolue parce que la somme des écarts simples est nulle (propriété 1 de la moyenne) : sans valeur absolue, l'indicateur vaudrait 0 pour **toute** distribution.

Écrivez la variance et l'écart-type. Pourquoi passe-t-on de l'une à l'autre ?

$$V(X) = \sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - m_x)^2 \quad \sigma = \sqrt{V(X)}$$

Le carré résout le problème du signe (comme la valeur absolue) mais **change l'unité** : la variance est en unité **au carré**, donc ininterprétable. **La racine ramène l'indicateur dans l'unité de X** : c'est l'écart-type qu'on interprète et qu'on communique.

Pourquoi préfère-t-on la variance à l'EAM, alors que l'EAM est plus intuitif ?

Parce que **le carré est dérivable partout, la valeur absolue non**. Toute la statistique qui suit — moindres carrés, régression, décomposition intra/inter, R^2 — repose sur la dérivabilité. **L'EAM est plus lisible ; la variance est plus maniable, et c'est elle qui a gagné.**

Énoncez la formule de Koenig et dites pourquoi elle est utile.

$$V(X) = \frac{1}{N} \sum_{i=1}^N x_i^2 - m_X^2$$

« La moyenne des carrés moins le carré de la moyenne. » **Utilité** : la formule de définition exige de connaître m_X **avant** de calculer les écarts — deux passages sur les données. Koenig ne demande que **deux sommes** ($\sum x_i$ et $\sum x_i^2$), calculables en **un seul passage**. C'est ce qui rend l'agrégation possible : deux nombres suffisent à transmettre un groupe.

Donnez les trois propriétés de la variance et leur traduction sur l'écart-type.

① **Invariance par translation** : $V(X + a) = V(X)$ — ajouter une constante déplace la distribution sans la déformer. ② **Non-linéarité** : $V(aX) = a^2 V(X)$, donc $\sigma_{aX} = |a| \sigma_X$. ③ **Corollaire** : $V(-X) = V(X)$. **L'erreur classique** : écrire $V(aX) = aV(X)$.

Énoncez l'inégalité de Bienaymé-Tchebychev et ses deux conditions d'usage.

$$P(|X - m| \geq k \sigma) \leq \frac{1}{k^2}$$

Condition 1 : $k > 1$ — pour $k \leq 1$ la borne est ≥ 1 et ne dit rien. **Condition 2** : **aucune** sur la loi — et c'est sa force **et** sa faiblesse : valable pour toute distribution, donc **très lâche**. Pour $k = 2$ elle garantit 75 % ; une loi normale donnerait 95 %.

Définissez le coefficient de variation et dites quand il est indispensable.

$$CV = \frac{\sigma}{m_X}$$

Sans unité. Il est indispensable dès qu'on compare des séries d'**unités différentes** ou d'**ordres de grandeur différents** : un écart-type de 500 € ne signifie pas la même chose autour d'une moyenne de 1 000 € ($CV = 0,5$) et de 100 000 € ($CV = 0,005$).

Écrivez la variance calculée à partir d'une distribution.

$$V(X) = \sum_{i=1}^p f_i (x_i - m_X)^2 = \frac{1}{N} \sum_{i=1}^p n_i (x_i - m_X)^2$$

Chaque écart au carré est pondéré par l'effectif de sa modalité. L'oubli de la pondération est l'erreur numéro un sur ce calcul.

Écrivez la décomposition intra / inter de la variance.

$$\sigma^2 = V_{\text{intra}} + V_{\text{inter}}$$

$$V_{\text{intra}} = \sum_{k=1}^K \frac{N_k}{N} \sigma_k^2 \quad V_{\text{inter}} = \sum_{k=1}^K \frac{N_k}{N} (m_{X_k} - m_X)^2$$

Intra = dispersion **à l'intérieur** des groupes. **Inter** = dispersion **des moyennes** de groupe.

Que mesure le rapport $V_{\text{inter}} / \sigma^2$, et quels sont ses deux cas extrêmes ?

Il mesure le **pouvoir explicatif du découpage en groupes** — la part de la dispersion totale qu'explique l'appartenance à un groupe. $V_{\text{inter}} \approx 0 \rightarrow$ les groupes ont la même moyenne : **le découpage n'explique rien**. $V_{\text{intra}} \approx 0 \rightarrow$ chaque groupe est homogène : **le découpage explique tout**. C'est l'ancêtre du rapport de corrélation puis du R^2 .

La concentration

Quelle est la différence entre dispersion et concentration ?

La **dispersion** s'intéresse à la répartition **des observations** (x_i autour de m_X). La **concentration** s'intéresse à la répartition **de la somme** (quelle part du total chaque groupe détient-il ?). **Point commun** : les deux mesurent des inégalités. **Ce sont deux angles sur le même phénomène, pas deux versions du même outil**.

Quelle condition une variable doit-elle remplir pour qu'on puisse en mesurer la concentration ? Donnez deux exemples de chaque côté.

Sa somme doit désigner un objet réel (variable extensive et additive). **Oui** : salaires ($\rightarrow$ masse salariale), patrimoine ($\rightarrow$ patrimoine total), chiffre d'affaires, émissions de CO_2 . **Non** : taille, note, température, âge — additionner ces valeurs ne produit rien. **Le calcul reste numériquement possible ; le résultat ne s'interprète pas**.

Qu'est-ce que l'agrégat d'une variable ? Comment se calcule-t-il par groupe ?

L'**agrégat** est la **somme de X** sur la population : $\sum_{i=1}^N x_i$. Pour les salaires, c'est la **masse salariale**. Par groupe : $\sum_{i=1}^{N_k} x_i = N_k m_{X_k}$ — « la somme = la moyenne $\times$ l'effectif », qui n'est que la définition de la moyenne multipliée par N_k .

Écrivez la part de l'agrégat d'une classe, sous ses trois formes équivalentes.

$$p_k = \frac{N_k m_{X_k}}{\sum_j N_j m_{X_j}} = \frac{f_k m_{X_k}}{m_X} = f_k \times \frac{m_{X_k}}{m_X}$$

Troisième forme, la plus parlante : la part d'une classe est sa **fréquence multipliée par son avantage relatif de moyenne**.

Pourquoi peut-on calculer les parts de l'agrégat sans connaître l'effectif total ?

Parce que $N_k = f_k N$: le facteur N apparaît au numérateur **et** au dénominateur et **se simplifie**.

$$p_k = \frac{f_k N m_{X_k}}{\sum_j f_j N m_{X_j}} = \frac{f_k m_{X_k}}{\sum_j f_j m_{X_j}}$$

Poser $N = 1$ n'est donc pas une approximation : c'est une simplification exacte.

Quel contrôle doit-on faire systématiquement après avoir calculé des parts de l'agrégat ?

Leur somme doit valoir 100 % (aux arrondis près). Si elle ne les vaut pas, il y a une erreur — sauf écart de l'ordre du dixième, imputable aux arrondis, **qu'il faut alors signaler**.

Définissez la courbe de Lorenz : que porte-t-on sur chaque axe, et dans quel ordre range-t-on les individus ?

Abscisse : la **fréquence cumulée de la population**. **Ordonnée** : la **part cumulée de l'agrégat de X** . Les individus doivent être rangés par valeur croissante de X — sans cette condition, la courbe n'a aucune des propriétés qui la rendent utile.

Énoncez les quatre propriétés de la courbe de Lorenz.

① Elle **part de (0 ; 0) et arrive à (100 ; 100)**. ② Elle est **croissante** (on cumule des parts positives). ③ Sa **pente sur la classe k vaut m_{X_k}/m_X** . ④ Elle est **convexe** (les pentes croissent puisque les classes sont ordonnées), donc **située sous la diagonale**.

Que représente la pente de la courbe de Lorenz en un point, et que signifie une pente égale à 1 ?

$$\text{pente} = \frac{p_k}{f_k} = \frac{m_{x_k}}{m_x}$$

C'est le **rapport entre la moyenne locale et la moyenne générale**. **Pente < 1** → la classe gagne moins que la moyenne, la courbe s'écarte de la diagonale. **Pente = 1** → la classe gagne exactement la moyenne : **c'est le point où l'écart à la diagonale est maximal**. **Pente > 1** → la courbe revient vers la diagonale.

Que représente la diagonale sur un graphe de Lorenz, et pourquoi ?

La courbe de Lorenz de l'égalité parfaite. Si tout le monde a la même valeur, toutes les pentes valent $m_{x_k}/m_x = 1$: la courbe **est** la diagonale, et $f\%$ de la population détient exactement $f\%$ du total. **Sans elle, une courbe de Lorenz ne se lit pas** — c'est l'écart à la diagonale qui porte toute l'information.

Écrivez la phrase-type de lecture d'un point de la courbe de Lorenz, puis appliquez-la à $L(20) = 3,9$ en 2021.

Moule : « Les ... % des salariés les moins payés perçoivent ... % de la masse salariale. » **Application** : « En 2021, les **20 %** des salariés les moins payés perçoivent **3,9 %** de la masse salariale » — contre 11,2 % en 2005.

$L(80) = 61,8$. Quelle est la part des 20 % les mieux payés ? Quelle erreur guette ici ?

$100 - 61,8 = 38,2\%$ pour les 20 % les mieux payés. **L'erreur** : lire le complément comme la part des 20 % du bas. **La courbe de Lorenz se lit toujours en partant des plus pauvres ; ce qui reste au-dessus appartient aux plus riches.**

Qu'est-ce que la dominance de Lorenz, et qu'autorise-t-elle à conclure ?

Une distribution est **dominée au sens de Lorenz** par une autre si sa courbe est **partout** plus éloignée de la diagonale. Dans ce cas, **tous les indicateurs d'inégalité usuels convergent vers la même conclusion** — quel que soit l'ordre de quantile considéré, la première distribution est plus inégalitaire. **La conclusion est alors robuste au choix de l'indicateur.**

Que se passe-t-il quand deux courbes de Lorenz se croisent ?

L'une est plus inégalitaire **en bas** de la distribution, l'autre **en haut**. **Le classement dépend alors de l'indicateur choisi**, et deux indicateurs peuvent donner des réponses opposées sur les mêmes données. **On ne tranche pas : on décrit les deux phénomènes.**

Définissez l'indice de Gini géométriquement.

Le double de l'aire comprise entre la diagonale et la courbe de Lorenz (l'« aire de concentration ») :

$$G = 2 \times \text{aire}$$

Proche de **1** → concentration (inégalité) **forte**. Proche de **0** → concentration **faible**.

Écrivez la formule de calcul du Gini et expliquez d'où vient chaque terme.

$$G = 2 \left[\frac{1}{2} - \sum \frac{(b+B) \cdot h}{2} \right]$$

$\frac{1}{2}$ = **aire du triangle sous la diagonale** (le carré unité vaut 1, la diagonale le coupe en deux). $\sum \frac{(b+B)h}{2}$ = **aire sous la courbe**, découpée en **trapèzes** (la courbe est un segment entre deux points consécutifs) — b petite base, B grande base, h largeur de la tranche.

Quel est le piège d'unité du calcul du Gini, et quel contrôle le détecte ?

Si les cumuls sont exprimés en pourcentages (0 à 100), les aires de trapèzes sont en « points de % au carré » et le carré entier vaut 10 000 — il faut donc diviser la somme des trapèzes par 10 000 avant de la soustraire à 0,5. **Contrôle** : l'aire de concentration doit être dans [0 ; 0,5] et le Gini dans [0 ; 1]. Un résultat comme 0,5 – 3 764 signale immédiatement l'oubli.

Démontrez que $G = 0$ en cas d'égalité parfaite.

Si tout le monde a la même valeur, les cumuls sont 20 · 40 · 60 · 80 · 100. Les trapèzes valent 200 · 600 · 1 000 · 1 400 · 1 800, soit 5 000. $\text{mathcal{A}} = 0,5 - 5\,000/10\,000 = 0$, donc $G = 0$. **Géométriquement** : la courbe est la diagonale, l'aire entre les deux est nulle.

Pourquoi le Gini maximal d'une population de N individus vaut-il $(N-1)/N$ et non 1 ?

Parce que le dernier individu — celui qui détient tout — occupe une largeur $1/N$ **non nulle** en abscisse. Sous ce dernier segment subsiste un triangle d'aire $\frac{1}{2N}$. D'où $\text{mathcal{A}} = \frac{1}{2} - \frac{1}{2N}$ et $G = 1 - \frac{1}{N}$. **Pour** $N \rightarrow \infty$, $G \rightarrow 1$. En pratique on retient $0 \leq G \leq 1$.

Citez trois précautions avant de comparer deux indices de Gini.

① **Le concept mesuré** : Gini du patrimoine (> 0,6 en France) $\gg$ Gini du revenu ($\approx 0,3$). Ce ne sont pas les mêmes objets. ② **Avant ou après redistribution** : le Gini des revenus primaires est bien supérieur à celui du revenu disponible ; l'écart mesure l'effet du système socio-fiscal. ③ **Le champ** : même définition, même population, même période — sinon la comparaison est un artefact.

Pourquoi accompagne-t-on toujours un Gini d'autres indicateurs ?

Parce qu'il est **peu sensible aux extrêmes** : il réagit surtout aux transferts autour du **milieu** de la distribution. Un Gini stable peut masquer un décrochage du dernier centile. **On l'accompagne du rapport D_9/D_1 et de la part du 1 % le plus riche.**

Les applications chiffrées du chapitre

Série des 20 âges (diapositives 42-43) : donnez la moyenne, l'EAM, la variance et l'écart-type.

$m = 47,9$ ans · $EAM = 5,7$ ans · $\sigma^2 = 54,19$ ans² · $\sigma = \sqrt{54,19} = 7,36$ ans. $\triangle$ **Le support s'arrête à la variance : l'écart-type, seul chiffre interprétable, n'y figure pas.**

Niveau de vie 2024 : que vaut le rapport inter-décile et comment se lit-il ?

$D_9/D_1 = 3,48$: les 10 % les plus aisés ont un niveau de vie au moins 3,48 fois supérieur à celui des 10 % les plus modestes. Les écarts entre déciles successifs croissent (3 730 $\rightarrow$ 2 860 $\rightarrow$ 9 800 $\rightarrow$ 12 640 €), ce qui **prouve l'étalement à droite** de la distribution.

Salaires 2005 : quelle part de la masse salariale détient chaque quintile, et que vaut le Gini ?

Parts : 11,2 · 13,3 · 16,2 · 21,1 · 38,2 %. Cumuls : 11,2 · 24,5 · 40,7 · 61,8 · 100,0. Trapèzes : 112 · 357 · 652 · 1 025 · 1 618 $\rightarrow$ somme 3 764. $\text{mathcal{A}} = 0,5 - 0,3764 = 0,1236 \rightarrow G_{2005} = 0,2472$.

Salaires 2021 : mêmes questions.

Parts : 3,9 · 10,6 · 18,4 · 26,7 · 40,5 %. Cumuls : 3,9 · 14,5 · 32,9 · 59,6 · 100,0. Trapèzes : 39 · 184 · 474 · 925 · 1 596 $\rightarrow$ somme 3 218. $\text{mathcal{A}} = 0,5 - 0,3218 = 0,1782 \rightarrow G_{2021} = 0,3564$.

Comment ont évolué les inégalités salariales entre 2005 et 2021, et quelle réserve doit accompagner la réponse ?

Hausse forte et robuste : G passe de 0,247 à 0,356 (+ 44 %) ; la part du premier quintile est **divisée par 2,9** (11,2 % → 3,9 %) ; le rapport entre quintiles extrêmes passe de **3,4 à 10,4**. La courbe 2021 est **partout** sous celle de 2005 → **dominance de Lorenz**, donc pas de contradiction possible entre indicateurs. **Réserve** : le plancher (11 000 → 1 333 €), le plafond (55 600 → 51 490 €) et le salaire moyen en euros courants (21 333 → 20 659 €) **baissent tous les trois**, ce qui suggère un **changement de champ** entre les deux millésimes. Une partie de l'écart mesuré peut être un artefact.

Les anomalies du support

Diapositive 55, cas 4 : quelle est l'erreur du support et quelle en est la conséquence ?

Le support annonce une variance de **10,4** et un écart-type de **3,2**. Le recalcul donne $\sigma^2 = 20,8$ et $\sigma = 4,56$ — **exactement le double** : une division par 2 en trop. **Conséquence** : le classement des cas 2 et 4 par dispersion est inversé.

Diapositive 48 : pourquoi les conclusions du support ne sont-elles pas reconstituables ?

Elles annoncent « 99 % de chances de faire des gains » via Bienaymé-Tchebychev. Or l'inégalité **exige $k > 1$** , et ici $m/\sigma < 1$ dans **les cinq périodes** : aucun k admissible ne permet la conclusion. De plus **la période 2 a une moyenne négative**. **Conclusion non démontrable avec les outils du chapitre**.

Méthode et transfert

Donnez l'arbre de décision : quel indicateur choisir ?

① **Type de variable** : qualitative → mode seul ; quantitative → tout est ouvert. ② **Objectif** : niveau typique → position ; homogénéité → dispersion ; partage d'un total → concentration (après vérification que la somme fait sens). ③ **Symétrie** : symétrique → moyenne ; asymétrique ou valeurs extrêmes → **médiane**. ④ **Unités comparables** ? oui → écart-type ; non → **coefficient de variation**. ⑤ **Faut-il agréger** ? moyenne oui ; variance via Koenig ou intra/inter ; **médiane et Gini jamais**.

Traduisez les indicateurs du chapitre en vocabulaire de finance de marché.

Écart-type = **volatilité** (annualisée par $\sqrt{252}$ sur des rendements quotidiens). **Quantile** = **VaR** : la VaR à 99 % est le centile d'ordre 1 de la distribution des pertes. $m/\sigma \approx$ **ratio de Sharpe** (sans taux sans risque) — donc **CV $\approx$ son inverse**. **Décomposition intra/inter** = **risque spécifique / risque systématique** : la diversification agit sur l'intra, jamais sur l'inter. **Lorenz-Gini** = **concentration d'un portefeuille** (parent de l'indice de Herfindahl $HHI = \sum w_i^2$) ou d'un P&L.

Pourquoi une moyenne sans écart-type est-elle dangereuse en finance ?

Parce que **deux stratégies de même rendement moyen peuvent avoir des profils de risque opposés**. Un rendement moyen de 8 % avec $\sigma = 3\%$ et le même avec $\sigma = 40\%$ ne se gèrent pas de la même façon : la seconde peut ruiner un compte avant que la moyenne ne se réalise. **La moyenne décrit l'espérance ; l'écart-type décrit ce qu'il faut survivre pour l'atteindre**.

4.3 — Moyens mnémotechniques

MÉTHODE — LES HUIT ANCRAGES DU CHAPITRE


- ① « **P-D-C** » — les trois familles, dans l'ordre du cours. **P**osition (où ?) → **D**ispersion (à quel point étalé ?) → **C**oncentration (comment le total se partage ?). **Trois lettres, trois questions, trois sections.**
- ② « **MO-MÉ-MÉ** » — les trois indicateurs de position. **MO**de · **MÉ**diane · **MÉ**dium (la moyenne, le « milieu » de gravité). Et leur ordre de robustesse aux valeurs extrêmes : **mode et médiane résistent, moyenne non.**
- ③ « **L'AIRE FAIT L'EFFECTIF** » — l'**histogramme**. Dans un **histogramme**, on **hisse** la **densité** et on lit l'**aire**. Dans un diagramme en **barres**, la **barre** est l'**effectif**. **Un seul mot à retenir : dès qu'il y a des classes, il y a des aires.**
- ④ « **ZÉRO, DONC CARRÉ** » — **pourquoi la variance existe**. La somme des écarts à la moyenne vaut **zéro** → il faut casser les signes → **valeur absolue** (EAM, lisible mais non dérivable) ou **carré** (variance, dérivable donc gagnante). **Le zéro est la cause de tout le reste.**
- ⑤ « **KOENIG : LA MOYENNE DES CARRÉS MOINS LE CARRÉ DE LA MOYENNE.** » La phrase est sa propre formule. Ordre à ne pas inverser : **c'est toujours le gros moins le petit**, puisque la variance est positive — donc $\bar{x}^2 \geq (\bar{x})^2$. **Vérification instantanée : si tu obtiens une variance négative, tu as inversé.**
- ⑥ « **a AJOUTÉ NE CHANGE RIEN, a MULTIPLIÉ CHANGE AU CARRÉ.** » $V(X+a) = V(X)$ · $V(aX) = a^2V(X)$ · $\sigma_{aX} = |a| \sigma_X$. **Image : traduire une figure ne la déforme pas ; l'agrandir la déforme dans les deux dimensions, donc au carré.**
- ⑦ « **INTRA DANS, INTER ENTRE.** » V_{intra} = dispersion **dans** les groupes. V_{inter} = dispersion **entre** les groupes. Et le total est la somme : $\sigma^2 = V_{\text{intra}} + V_{\text{inter}}$. **En finance : intra = spécifique (diversifiable), inter = systématique (non diversifiable).**
- ⑧ « **LORENZ SOUS LA DIAGONALE, GINI DOUBLE DE L'AIRE.** » La courbe est **toujours** sous la diagonale (convexité). Le Gini est le **double** de l'aire qui les sépare — **le « 2 » est la faute la plus fréquente : sans lui, on divise le résultat par deux.** Et l'aire des trapèzes se divise par **10 000** quand les cumuls sont en %.

MÉTHODE — TROIS CONTRÔLES À FAIRE SYSTÉMATIQUEMENT — ILS DÉTECTENT 90 % DES ERREURS


Contrôle	Ce qu'il vérifie	Ce qu'il détecte
La somme des fréquences fait 1 (et celle des parts fait 100 %)	La cohérence de la distribution	Une modalité oubliée, un effectif mal reporté
L'indicateur est dans le bon intervalle	$0 \leq G \leq 1$ · $\sigma \geq 0$ · $EAM \leq \sigma$ · $x_{\min} \leq Me \leq x_{\max}$	Le piège des unités du Gini, un signe perdu, une racine oubliée
L'ordre de grandeur est plausible	Le résultat comparé à la moyenne et à l'étendue	Une erreur de facteur 10, une division en trop (le cas 4 de la diapositive 55)

Le troisième est le plus important et le plus négligé. Un écart-type supérieur à l'étendue est impossible. Un écart-type de 7,36 sur une série d'âges de moyenne 47,9 est plausible ; un écart-type de 73,6 ne l'est pas.

4.4 — Schéma récapitulatif



Le fil qui relie toute la section « dispersion » :



Et la traduction en salle de marché :

CE QUE CHAQUE FAMILLE DEVIENT EN FINANCE DE MARCHÉ

moyenne rendement espéré

écart-type VOLATILITÉ (annualisée : s x racine(252))

quantile VALUE AT RISK

m / s ratio de Sharpe (donc CV = son inverse)

intra / inter risque spécifique / risque systématique

Lorenz - Gini concentration d'un portefeuille (cf. Herfindahl)

5. Entraînement progressif

OBJECTIFS — COMMENT UTILISER CETTE PARTIE

Quatre niveaux, dans l'ordre, sans en sauter. Le niveau 1 vérifie que tu sais *dire* ; le niveau 2 que tu sais *calculer* ; le niveau 3 que tu sais *raisonner* ; le niveau 4 que tu sais *composer* dans les conditions de l'examen.

Règle absolue : traite chaque exercice sur papier, entièrement, avant de lire la correction. Lire une correction sans avoir cherché ne produit qu'une illusion de compétence — c'est exactement ce qui fait échouer les étudiants qui « ont l'impression de comprendre le cours ».

Niveau 1 — Restitution

Vingt-deux questions. Réponds sans rien regarder, puis compare.

- Q1.** Quelle est la différence de nature entre « présenter » et « résumer » des données ?
- Q2.** Citez les trois familles d'indicateurs et la question à laquelle chacune répond.
- Q3.** Définissez le mode. Sur quel type de variable est-il le seul indicateur de position disponible ?
- Q4.** Comment détermine-t-on la classe modale lorsque les classes ont des amplitudes inégales ? Donnez la formule.
- Q5.** Dans un histogramme, que représentent la hauteur et l'aire d'un rectangle ? Démontrez-le.
- Q6.** Donnez les trois écritures de la moyenne arithmétique.
- Q7.** Énoncez et démontrez la propriété « la somme des écarts à la moyenne est nulle ». Quelle conséquence a-t-elle sur la construction des indicateurs de dispersion ?
- Q8.** Comment calcule-t-on la médiane sur données brutes selon la parité de l'effectif ?
- Q9.** Peut-on calculer la médiane d'un ensemble à partir des médianes de ses sous-groupes ? Justifiez par un contre-exemple.
- Q10.** Que conclut-on de la comparaison entre médiane et moyenne ?
- Q11.** Définissez un quantile d'ordre p à l'aide de la fonction de répartition.
- Q12.** Combien de valeurs délimitent les quartiles ? les déciles ? les centiles ?
- Q13.** Citez les trois écarts inter-quantiles usuels et ce que chacun décrit.
- Q14.** Décrivez la construction d'un *boxplot* et les trois informations qu'on y lit.
- Q15.** Écrivez l'EAM, la variance et l'écart-type. Pourquoi passe-t-on de la variance à l'écart-type ?
- Q16.** Énoncez la formule de Koenig et expliquez pourquoi elle rend l'agrégation possible.
- Q17.** Donnez les trois propriétés de la variance et leur traduction sur l'écart-type.
- Q18.** Énoncez l'inégalité de Bienaymé-Tchebychev et ses conditions d'usage.
- Q19.** Écrivez la décomposition intra / inter et dites ce que mesure le rapport $V_{\text{inter}}/\sigma^2$.
- Q20.** Quelle condition une variable doit-elle remplir pour qu'on puisse mesurer sa concentration ? Donnez un exemple de chaque côté.
- Q21.** Définissez la courbe de Lorenz et énoncez ses quatre propriétés.
- Q22.** Écrivez la formule du Gini, expliquez d'où vient chaque terme et donnez le piège d'unité.

CORRIGÉ — RÉPONSES ATTENDUES

Q1. Présenter **conserve toute** l'information (série brute, distribution des effectifs). Résumer en **perd volontairement** pour produire quelques chiffres décisionnels. La perte est le prix de la décision.

Q2. Position — où se situe la distribution ? **Dispersion** — à quel point est-elle étalée ? **Concentration** — comment le total se partage-t-il ?

Q3. La modalité de **fréquence maximale**. C'est le **seul indicateur de position calculable sur une variable qualitative**.

Q4. Par la **densité maximale** : $d_i = n_i/a_i$ avec $a_i = b_{\text{sup}} - b_{\text{inf}}$. Une classe plus large contient mécaniquement plus d'individus sans être plus dense.

Q5. Hauteur = **densité** ; aire = **effectif**. Démonstration : aire = $d_i \times a_i = \frac{n_i}{a_i} \times a_i = n_i$.

Q6. $m_X = \frac{1}{N} \sum x_i$ (brutes) · $m_X = \sum f_i x_i$ (distribution) · $m_X = \sum \frac{N_k}{N} m_{X_k}$ (agrégation).

Q7. $\sum (x_i - m_X) = \sum x_i - N m_X = N m_X - N m_X = 0$. **Conséquence** : un indicateur de dispersion fondé sur la moyenne des écarts vaudrait 0 pour toute distribution — d'où le passage aux **valeurs absolues** (EAM) ou aux **carrés** (variance).

Q8. Trier d'abord. N impair $\rightarrow$ valeur de rang $(N+1)/2$. N pair $\rightarrow$ **moyenne des valeurs de rang $N/2$ et $N/2+1$** .

Q9. Non. Contre-exemple : {1;2;3} ($Me = 2$) et {100;200;300} ($Me = 200$) $\rightarrow$ moyenne des médianes = 101, vraie médiane de la réunion = $(3+100)/2 = 51,5$.

Q10. $Me < m \rightarrow$ étalée à **droite** ; $Me > m \rightarrow$ étalée à **gauche** ; $Me \approx m \rightarrow$ **symétrique**.

Q11. Q_p est la valeur telle que $F(Q_p) = p$: le quantile est **l'inverse de la fonction de répartition**, $Q_p = F^{-1}(p)$.

Q12. 3 valeurs pour les quartiles, 9 pour les déciles, 99 pour les centiles. Règle : n parts $\Rightarrow n-1$ valeurs.

Q13. $Q_3 - Q_1$ (50 % centraux) · $D_9 - D_1$ (80 % centraux) · D_9/D_1 (le même en relatif, **sans unité**).

Q14. Boîte de Q_1 à Q_3 , trait à la **médiane**, moustaches aux extrêmes. On y lit le **niveau**, la **dispersion** et l'**asymétrie** (trait décentré dans la boîte).

Q15. $EAM = \frac{1}{N} \sum |x_i - m|$ · $V = \frac{1}{N} \sum (x_i - m)^2$ · $\sigma = \sqrt{V}$. On passe à l'écart-type parce que la variance est en **unité au carré**, donc ininterprétable.

Q16. $V(X) = \frac{1}{N} \sum x_i^2 - m_X^2$. Elle ne demande que **deux sommes** calculables en **un seul passage** ; il suffit donc de transmettre deux nombres par groupe pour reconstituer la variance de l'ensemble.

Q17. $V(X+a) = V(X)$ · $V(aX) = a^2 V(X)$ · $V(-X) = V(X)$. Sur l'écart-type : $\sigma_{aX} = |a| \sigma_X$.

Q18. $P(|x - m| \geq k\sigma) \leq 1/k^2$, avec $k > 1$ et **sans aucune hypothèse sur la loi** — d'où une borne valable partout mais **très lâche**.

Q19. $\sigma^2 = V_{\text{intra}} + V_{\text{inter}}$ avec $V_{\text{intra}} = \sum \frac{N_k}{N} \sigma_k^2$ et $V_{\text{inter}} = \sum \frac{N_k}{N} (m_{X_k} - m_X)^2$. Le rapport $V_{\text{inter}}/\sigma^2$ mesure le **pouvoir explicatif du découpage**.

Q20. Sa **somme doit avoir un sens** (variable extensive). Oui : salaire $\rightarrow$ masse salariale. Non : taille, note, âge.

Q21. Abscisse = fréquence cumulée de la population ; ordonnée = part cumulée de l'agrégat ; individus rangés par X **croissant**. Propriétés : ① passe par (0;0) et (100;100) ; ② croissante ; ③ pente = m_{X_k}/m_X ; ④ convexe donc **sous la diagonale**.

Q22. $G = 2 \left[\frac{1}{2} - \sum \frac{(b+B)h}{2} \right]$. Le $\frac{1}{2}$ est l'aire du triangle sous la diagonale ; la somme est l'aire sous la courbe découpée en trapèzes ; le facteur 2 vient de la définition $G = 2 \text{mathcal{A}}$. **Piège d'unité** : si les cumuls sont en %, **diviser la somme des trapèzes par 10 000**.

Niveau 2 — Application chiffrée

Exercice 2.1 — Classe modale et histogramme

Une entreprise répartit ses 500 salariés selon leur ancienneté (en années) :

Ancienneté	Effectif
[0 ; 2[	120
[2 ; 5[	150
[5 ; 10[	130
[10 ; 20[	100
Total	500

a. Quelle classe a l'effectif le plus élevé ? b. Calculez les amplitudes et les densités. c. Quelle est la classe modale ? Commentez l'écart avec la réponse de la question a. d. Quelles hauteurs porteriez-vous sur un histogramme ?

CORRIGÉ — CORRIGÉ DE L'EXERCICE 2.1

a. La classe [2 ; 5[, avec 150 salariés.

b. Amplitude $a_i = b_{\text{sup}} - b_{\text{inf}}$; densité $d_i = n_i / a_i$.

Classe	n_i	a_i	$d_i = n_i / a_i$
[0 ; 2[	120	2	120/2 = 60,0
[2 ; 5[	150	3	150/3 = 50,0
[5 ; 10[	130	5	130/5 = 26,0
[10 ; 20[	100	10	100/10 = 10,0

c. La classe modale est [0 ; 2[, de densité 60 — **et non** [2 ; 5[. La classe [2 ; 5[compte plus de salariés (150 contre 120) **uniquement parce qu'elle est plus large** (3 ans contre 2). Rapportée à sa largeur, elle est **moins dense**. **Formulation attendue** : « L'ancienneté la plus fréquente se situe dans les deux premières années : la densité y est de 60 salariés par année d'ancienneté, contre 50 dans la classe suivante. »

d. **Les densités : 60 · 50 · 26 · 10.** Porter les effectifs (120 · 150 · 130 · 100) donnerait une figure fautive : la dernière classe, dix fois plus large que la première, occuperait une aire de $100 \times 10 = 1\,000$ au lieu de 100.

Contrôle : $\sum d_i \times a_i = 60(2) + 50(3) + 26(5) + 10(10) = 120 + 150 + 130 + 100 = 500$ ✓

Exercice 2.2 — Position et dispersion sur une distribution discrète

Le nombre de transactions exécutées chaque jour par un *desk*, observé sur 60 jours :

Transactions x_i	0	1	2	3	4	5
Nombre de jours n_i	5	12	18	14	8	3

a. Vérifiez l'effectif total et calculez les fréquences cumulées. b. Calculez la moyenne. c. Déterminez la médiane, Q_1 , Q_3 et l'écart inter-quartile. d. Calculez l'EAM. e. Calculez la variance **par la formule de définition puis par Koenig**, et l'écart-type. f. Calculez le coefficient de variation et vérifiez que $EAM \leq \sigma$. g. Que conclut-on de la comparaison entre médiane et moyenne ?

CORRIGÉ — CORRIGÉ DE L'EXERCICE 2.2

a. $N = 5+12+18+14+8+3 = 60$ ✓

x_i	0	1	2	3	4	5
n_i	5	12	18	14	8	3
Cumul N_i	5	17	35	49	57	60
F_i	0,0833	0,2833	0,5833	0,8167	0,9500	1,0000

b. $\sum n_i x_i = 0(5) + 1(12) + 2(18) + 3(14) + 4(8) + 5(3) = 0+12+36+42+32+15 = 137$.

$$m_x = \frac{137}{60} = 2,2833 \approx 2,28 \text{ transactions par jour}$$

c. $N = 60$ est **pair** : la médiane est la moyenne des valeurs de rang **30** et **31**. Le cumul atteint 35 à $x = 2$: les rangs 18 à 35 valent tous 2. Donc $Me = \frac{2+2}{2} = 2$. Q_1 : première valeur dont $F \geq 0,25 \rightarrow F(1) = 0,2833 \rightarrow Q_1 = 1$. Q_3 : première valeur dont $F \geq 0,75 \rightarrow F(2) = 0,5833$ (insuffisant), $F(3) = 0,8167 \rightarrow Q_3 = 3$. Écart inter-quartile = $3 - 1 = 2$ transactions.

d. $\sum n_i |x_i - m|$ avec $m = 2,2833$:

x_i	$ x_i - m $	n_i	Produit
0	2,2833	5	11,4167
1	1,2833	12	15,4000
2	0,2833	18	5,1000
3	0,7167	14	10,0333
4	1,7167	8	13,7333
5	2,7167	3	8,1500
Total		60	63,8333

$$EAM = \frac{63,8333}{60} = 1,0639 \text{ transaction}$$

e. Par définition : $\sum n_i (x_i - m)^2$:

x_i	$(x_i - m)^2$	n_i	Produit
0	5,2136	5	26,0681
1	1,6469	12	19,7633
2	0,0803	18	1,4450
3	0,5136	14	7,1906
4	2,9469	8	23,5756
5	7,3803	3	22,1408
Total		60	100,1833

$$V(X) = \frac{100,1833}{60} = 1,6697$$

Par Koenig : $\sum n_i x_i^2 = 0(5) + 1(12) + 4(18) + 9(14) + 16(8) + 25(3) = 0 + 12 + 72 + 126 + 128 + 75 = 413$.

$$V(X) = \frac{413}{60} - \left(\frac{137}{60}\right)^2 = 6,8833 - 5,2136 = 1,6697$$

Les deux méthodes donnent le même résultat ✓ — et Koenig a demandé **une seule colonne supplémentaire** au lieu de deux.

$$\sigma = \sqrt{1,6697} = 1,2922 \text{ transaction}$$

f. $CV = \frac{1,2922}{2,2833} = 0,566$, soit **56,6 %** : la dispersion représente plus de la moitié du niveau moyen — l'activité du *desk* est **très irrégulière**. Contrôle : $EAM = 1,064 \leq \sigma = 1,292$ ✓ (l'écart-type est toujours $\geq EAM$).

g. $Me = 2 < m = 2,28$: la distribution est **légèrement étalée à droite**. Les journées à 4 ou 5 transactions tirent la moyenne au-dessus de la valeur centrale, sans déplacer la médiane. **L'écart est faible (0,28) : l'asymétrie existe mais reste modérée.**

Exercice 2.3 — Décomposition intra / inter

Une salle de marché comprend deux *desks* :

Desk	Effectif N_k	P&L moyen annuel m_k (k€)	Écart-type σ_k (k€)
A — <i>flow</i>	30	12	5
B — <i>prop</i>	20	22	8

a. Calculez le P&L moyen de la salle. b. Calculez V_{intra} , V_{inter} , puis σ^2 et σ . c. Quelle part de la dispersion totale l'appartenance à un *desk* explique-t-elle ? d. Interprétez.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 2.3

a. $N = 30 + 20 = 50$; poids $30/50 = 0,6$ et $20/50 = 0,4$.

$$m_X = 0,6 \times 12 + 0,4 \times 22 = 7,2 + 8,8 = \mathbf{16 \text{ k€}}$$

b.

$$V_{\text{intra}} = 0,6 \times 5^2 + 0,4 \times 8^2 = 0,6(25) + 0,4(64) = 15 + 25,6 = \mathbf{40,6}$$

$$V_{\text{inter}} = 0,6 (12-16)^2 + 0,4 (22-16)^2 = 0,6(16) + 0,4(36) = 9,6 + 14,4 = \mathbf{24,0}$$

$$\sigma^2 = 40,6 + 24,0 = \mathbf{64,6} \quad \sigma = \sqrt{64,6} = \mathbf{8,04 \text{ k€}}$$

c. $\frac{V_{\text{inter}}}{\sigma^2} = \frac{24,0}{64,6} = \mathbf{0,372}$, soit **37,2 %**.

d. **Interprétation en trois temps.** ① L'écart-type de la salle (8,04 k€) est **supérieur à celui de chaque *desk* pris séparément** (5 et 8) : c'est la composante **inter** qui l'explique — les deux *desks* n'ont pas la même moyenne. ② **37,2 % de la dispersion des P&L s'explique par l'appartenance à un *desk*** ; les 62,8 % restants sont de la variabilité **entre traders d'un même *desk***. ③ **Conséquence managériale** : connaître le *desk* d'un trader ne permet de prédire qu'un tiers de la variabilité de son P&L.

L'essentiel se joue à l'intérieur des équipes — un argument contre une politique de rémunération fondée uniquement sur le *desk* d'affectation.

Exercice 2.4 — Part de l'agrégat, Lorenz et Gini

Le patrimoine net de 1 000 ménages, réparti en **quintiles** (200 ménages par quintile) :

Quintile	Patrimoine moyen (k€)
1 ^{er} (le plus modeste)	20
2 ^e	60
3 ^e	120
4 ^e	200
5 ^e (le plus aisé)	600

a. Peut-on mesurer la concentration de cette variable ? Justifiez. b. Calculez le patrimoine moyen d'ensemble. c. Calculez la part de l'agrégat de chaque quintile. Contrôlez la somme. d. Construisez le tableau des cumuls et calculez les pentes de la courbe de Lorenz. e. Calculez l'indice de Gini. f. Écrivez trois phrases de lecture.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 2.4

a. **Oui.** La somme des patrimoines a un sens : c'est le **patrimoine total** des 1 000 ménages, une grandeur économique réelle. La condition d'additivité est remplie.

b. Les quintiles ont tous le même poids (0,20), donc la moyenne générale est la **moyenne simple** des cinq moyennes :

$$S = 20 + 60 + 120 + 200 + 600 = 1\,000 \quad m_X = \frac{1\,000}{5} = 200 \text{ k€}$$

$$c. p_k = \frac{f_k m_k}{m_X} = \frac{0,20 \cdot m_k}{200} = \frac{m_k}{1\,000} :$$

Quintile	m_k	p_k	En %
1	20	0,02	2 %
2	60	0,06	6 %
3	120	0,12	12 %
4	200	0,20	20 %
5	600	0,60	60 %
Total	1 000	1,00	100 % ✓

d. Cumuls et pentes = m_k / m_X :

F (%)	Part cumulée (%)	Pente du segment	Lecture
0	0,0	—	—
20	2,0	20/200 = 0,10	très en dessous de la moyenne
40	8,0	60/200 = 0,30	en dessous
60	20,0	120/200 = 0,60	en dessous
80	40,0	200/200 = 1,00	exactement à la moyenne
100	100,0	600/200 = 3,00	trois fois la moyenne

Le 4^e quintile a une pente égale à 1 : son segment est parallèle à la diagonale. L'écart à la diagonale y est donc **constant et maximal** : à $F = 60$, $60 - 20 = 40$ points ; à $F = 80$, $80 - 40 = 40$ points. **C'est la vérification directe de la propriété 3 de la courbe de Lorenz.**

e. Trapèzes, tous de hauteur $h = 20$ (donc aire = $(b+B) \times 10$) :

Tranche	b	B	Aire
0 → 20	0	2	$2 \times 10 = 20$
20 → 40	2	8	$10 \times 10 = 100$
40 → 60	8	20	$28 \times 10 = 280$
60 → 80	20	40	$60 \times 10 = 600$
80 → 100	40	100	$140 \times 10 = 1\,400$
Somme			2 400

$$\text{mathcal{A}} = 0,5 - \frac{2\,400}{10\,000} = 0,5 - 0,24 = 0,26 \quad G = 2 \times 0,26 = 0,52$$

Contrôle : $0 \leq 0,52 \leq 1$ ✓

f. ① « Les **20 %** des ménages les plus modestes détiennent **2 %** du patrimoine total. » ② « Les **40 %** les plus modestes n'en détiennent que **8 %**, tandis que les **20 %** les plus aisés en détiennent **60 %** — soit **30 fois plus** que le premier quintile. » ③ « L'indice de Gini vaut **0,52** : la concentration est forte, ce qui est caractéristique du patrimoine, bien plus concentré que le revenu. »

Niveau 3 — Maîtrise

Ces six exercices ne se résolvent pas en appliquant une formule. Ils exigent de comprendre pourquoi les formules sont ce qu'elles sont.

Exercice 3.1 — Démontrer que $EAM \leq \sigma$

On a vérifié numériquement, à l'exercice 2.2, que l'EAM était inférieur à l'écart-type. **Démontrez que c'est toujours vrai.**

Indication : appliquez l'inégalité de Cauchy-Schwarz $(\sum a_i b_i)^2 \leq (\sum a_i^2)(\sum b_i^2)$ en posant $a_i = |x_i - m|$ et $b_i = 1$.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.1

Posons $d_i = |x_i - m| \geq 0$. Par définition :

$$EAM = \frac{1}{N} \sum_{i=1}^N d_i \quad \sigma^2 = \frac{1}{N} \sum_{i=1}^N d_i^2$$

(car $(x_i - m)^2 = |x_i - m|^2 = d_i^2$).

Cauchy-Schwarz avec $a_i = d_i$ et $b_i = 1$:

$$(\sum_{i=1}^N d_i \times 1)^2 \leq (\sum_{i=1}^N d_i^2)(\sum_{i=1}^N 1^2) = (\sum d_i^2) \times N$$

Or $\sum d_i = N \times EAM$ et $\sum d_i^2 = N \sigma^2$. En remplaçant :

$$(N \times EAM)^2 \leq N \sigma^2 \times N \implies N^2 EAM^2 \leq N^2 \sigma^2 \implies EAM^2 \leq \sigma^2$$

Les deux quantités étant positives, on peut prendre la racine :

$$\boxed{EAM \leq \sigma}$$

Cas d'égalité. Cauchy-Schwarz est une égalité si et seulement si les vecteurs (d_i) et (1) sont **colinéaires**, c'est-à-dire si **tous les d_i sont égaux** : tous les individus sont à la même distance de la moyenne. C'est le cas d'une série ne prenant que **deux valeurs, symétriques autour de la moyenne et d'effectifs égaux** — par exemple $\{-3; -3; 3; 3\}$: $m = 0$, $EAM = 3$, $\sigma = 3$.

Interprétation. L'écart-type est toujours **au moins aussi grand** que l'EAM parce que le carré **pénalise davantage les grands écarts** : une observation à 10 unités de la moyenne compte 10 fois plus qu'une observation à 1 unité dans l'EAM, mais **100 fois plus** dans la variance. **C'est pourquoi l'écart-type est plus sensible aux valeurs extrêmes que l'EAM** — et c'est aussi pourquoi, en gestion des risques, il sous-estime rarement le danger.

Vérification sur l'exercice 2.2 : $EAM = 1,0639 \leq \sigma = 1,2922$ ✓ — le rapport $\sigma/EAM = 1,21$.

Exercice 3.2 — Moyenne = médiane implique-t-il la symétrie ?

On lit souvent que « si la moyenne égale la médiane, la distribution est symétrique ». **Démontrez que c'est faux** en construisant un contre-exemple explicite.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.2

Contre-exemple : la série {0 ; 4 ; 5 ; 5 ; 11}.

Moyenne : $(0+4+5+5+11)/5 = 25/5 = 5$. **Médiane :** $N = 5$ impair, valeur de rang $(5+1)/2 = 3 \rightarrow$ série triée {0 ; 4 ; 5 ; 5 ; 11} $\rightarrow Me = 5$. **Donc $m = Me = 5$.**

Et pourtant la série n'est pas symétrique. Les écarts à la moyenne valent -5 ; -1 ; 0 ; 0 ; +6. Pour une série symétrique, l'ensemble des écarts serait invariant par changement de signe — or -5 n'a pas de contrepartie +5, et +6 pas de contrepartie -6.

Conclusion rigoureuse :

- « Distribution symétrique » $\implies$ « $m = Me$ » : **vrai**.
- « $m = Me$ » $\implies$ « distribution symétrique » : **faux**. La réciproque n'est pas valable.
- **L'égalité $m = Me$ est donc une condition nécessaire, pas suffisante.**

Ce qu'il faut écrire en examen : « L'écart entre moyenne et médiane est un **indice** d'asymétrie, pas une **preuve** de symétrie quand il est nul. Deux asymétries opposées peuvent se compenser. »

Pourquoi cela compte en finance. Une distribution de rendements peut avoir une moyenne égale à sa médiane et rester **fortement asymétrique** : beaucoup de petits gains compensés par quelques pertes rares mais énormes. C'est le profil de risque le plus dangereux qui soit, et **ni la moyenne ni la médiane ne le révèlent**. Il faut regarder la **distribution entière** — d'où les *boxplots*, les quantiles extrêmes et, plus tard, les mesures d'asymétrie.

Exercice 3.3 — Prime forfaitaire ou augmentation proportionnelle ?

On reprend les données de l'exercice 2.4 (patrimoines moyens par quintile : $20 \cdot 60 \cdot 120 \cdot 200 \cdot 600$ k€, $m = 200$, $G = 0,52$).

L'État hésite entre deux mesures :

- **Mesure A** : verser **100 k€ à chaque ménage** (forfait identique pour tous).
- **Mesure B** : augmenter **tous les patrimoines de 10 %** (mesure proportionnelle).

a. Calculez le nouveau Gini dans chaque cas. **b.** Démontrez le résultat général dans chaque cas. **c.** Que conclure ?

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.3

a. Mesure A — le forfait de 100 k€.

Nouvelles moyennes : $120 \cdot 160 \cdot 220 \cdot 300 \cdot 700$. Total = 1 500, donc $m' = 1\,500/5 = 300$ k€.

Quintile	m'_k	$p'_k = m'_k/1\,500$	En %	Cumul
1	120	0,0800	8,00	8,00
2	160	0,1067	10,67	18,67
3	220	0,1467	14,67	33,33
4	300	0,2000	20,00	53,33
5	700	0,4667	46,67	100,00

Trapèzes ($h = 20$, donc aire = $(b+B) \times 10$) : $80 \cdot 266,67 \cdot 520 \cdot 866,67 \cdot 1\,533,33 \rightarrow$ **somme = 3 266,67.**

$$G_A = 0,5 - 0,326667 = 0,173333 \quad G_A = \mathbf{0,347}$$

Le Gini chute de 0,52 à 0,347, soit une baisse d'exactement un tiers.

Mesure B — l'augmentation de 10 %.

Nouvelles moyennes : $22 \cdot 66 \cdot 132 \cdot 220 \cdot 660$. Total = 1 100, $m' = 220$ k€. Parts : $22/1\,100 = 2\%$ · $66/1\,100 = 6\%$ · $132/1\,100 = 12\%$ · $220/1\,100 = 20\%$ · $660/1\,100 = 60\%$. **Ce sont exactement les parts de départ.** La courbe de Lorenz est identique, donc

$$G_B = \mathbf{0,52} \quad \text{— inchangé.}$$

b. Les deux démonstrations.

Mesure B (proportionnelle) — le Gini est invariant d'échelle. Si $x'_i = a x_i$ avec $a > 0$, alors $m'_k = a m_k$ et $m' = a m$, donc

$$p'_k = \frac{f_k m'_k}{m'} = \frac{f_k a m_k}{a m} = \frac{f_k m_k}{m} = p_k$$

Toutes les parts sont inchangées, donc la courbe de Lorenz et le Gini aussi. **Le Gini est un indicateur relatif : il ne voit pas les niveaux, seulement les proportions.**

Mesure A (forfaitaire) — le Gini est réduit dans un rapport connu. Si $x'_i = x_i + c$ avec $c > 0$, alors $m' = m + c$, et les écarts entre individus sont inchangés : $x'_i - x'_j = x_i - x_j$. Or l'indice de Gini admet une écriture équivalente à sa définition géométrique :

$$G = \frac{\Delta}{2m} \quad \text{avec} \quad \Delta = \frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N |x_i - x_j|$$

où Δ est la **différence absolue moyenne** entre deux individus tirés au hasard. Comme Δ est inchangé et m augmenté de c :

$$G' = \frac{\Delta}{2(m+c)} = G \times \frac{m}{m+c}$$

Vérification numérique : $\Delta = 2mG = 2 \times 200 \times 0,52 = \mathbf{208}$. Après la mesure : $G' = 208/(2 \times 300) = 0,3467 \checkmark$ — **exactement la valeur trouvée par les trapèzes.** Et $G \times \frac{m}{m+c} = 0,52 \times \frac{200}{300} = 0,52 \times \frac{2}{3} = 0,3467 \checkmark$

PIÈGE FRÉQUENT

La formule $G = \Delta/(2m)$ n'est pas au programme du chapitre — le support ne donne que la définition géométrique. Je te la donne parce qu'elle **démontre en trois lignes** ce que les trapèzes ne montrent que numériquement, et parce qu'elle éclaire ce que le Gini mesure vraiment : **l'écart typique entre deux individus tirés au hasard, rapporté au niveau moyen. En examen, utilise la méthode des trapèzes** — mais si tu cites cette identité en remarque, elle vaut des points.

c. Conclusion.

	Effet sur le niveau moyen	Effet sur le Gini
Forfait de c	$m \rightarrow m + c$	$G \rightarrow G \times \frac{m}{m+c} — \text{baisse}$
Hausse de $a \%$	$m \rightarrow a m$	$G \rightarrow G — \text{inchangé}$

Une mesure forfaitaire réduit toujours les inégalités relatives ; une mesure proportionnelle ne les modifie jamais. C'est le fondement mathématique d'un débat de politique économique permanent — chèque énergie forfaitaire contre baisse proportionnelle de la TVA, augmentation générale en euros contre augmentation en pourcentage.

Et la limite à signaler : en valeur **absolue**, la mesure B donne 60 k€ au dernier quintile et 2 k€ au premier — **l'écart absolu se creuse de 58 k€** alors que le Gini ne bouge pas. **Le Gini mesure l'inégalité relative, pas l'écart absolu. Ne jamais confondre les deux.**

Exercice 3.4 — Deux courbes qui se croisent

Deux pays, chacun décrit par les parts de revenu de ses cinq quintiles :

Quintile	Pays X (%)	Pays Y (%)
1 ^{er}	10	2
2 ^e	10	13
3 ^e	10	20
4 ^e	10	25
5 ^e	60	40

a. Construisez les cumuls et montrez que les deux courbes de Lorenz se croisent. **b.** Calculez les deux indices de Gini. **c.** Calculez le rapport Q_5/Q_1 et la part du quintile supérieur dans chaque pays. **d.** Quel pays est « le plus inégalitaire » ? Rédigez la conclusion attendue.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.4

a. Cumuls :

F (%)	Pays X	Pays Y	X - Y
20	10	2	+ 8
40	20	15	+ 5
60	30	35	- 5
80	40	60	- 20
100	100	100	0

Le signe de l'écart change entre 40 % et 60 % : les deux courbes se croisent. Y est au-dessous de X dans le bas de la distribution (donc plus inégalitaire pour les plus pauvres) et au-dessus dans le haut (donc moins inégalitaire pour la classe moyenne supérieure).

b. Trapèzes ($h = 20$, aire = $(b+B) \times 10$) :

Tranche	X	Y
0 → 20	$(0+10) \times 10 = 100$	$(0+2) \times 10 = 20$
20 → 40	$(10+20) \times 10 = 300$	$(2+15) \times 10 = 170$
40 → 60	$(20+30) \times 10 = 500$	$(15+35) \times 10 = 500$
60 → 80	$(30+40) \times 10 = 700$	$(35+60) \times 10 = 950$
80 → 100	$(40+100) \times 10 = 1\,400$	$(60+100) \times 10 = 1\,600$
Somme	3 000	3 240

$\text{mathcal{A}}_X = 0,5 - 0,300 = 0,200 \Rightarrow G_X = \mathbf{0,400}$ $\text{mathcal{A}}_Y = 0,5 - 0,324 = 0,176 \Rightarrow G_Y = \mathbf{0,352}$ Selon le Gini, X est plus inégalitaire que Y.

c.

Indicateur	Pays X	Pays Y	Verdict
Rapport Q_5/Q_1	$60/10 = \mathbf{6,0}$	$40/2 = \mathbf{20,0}$	Y bien plus inégalitaire
Part du quintile supérieur	60 %	40 %	X plus inégalitaire
Indice de Gini	0,400	0,352	X plus inégalitaire

d. La conclusion attendue.

« Les deux courbes de Lorenz se croisent entre 40 % et 60 % : **il n'y a pas de dominance de Lorenz**, et les indicateurs ne peuvent donc pas converger mécaniquement. C'est précisément ce que l'on observe. Le rapport Q_5/Q_1 , qui met l'accent sur les **extrêmes**, désigne Y comme plus inégalitaire (20 contre 6), parce que son premier quintile ne perçoit que 2 % du revenu. La part du quintile supérieur et l'indice de Gini, qui pèsent davantage la **structure d'ensemble**, désignent X (60 % contre 40 % ; $G = 0,400$ contre $0,352$). **Les deux réponses sont exactes : elles ne mesurent pas la même chose.** X concentre le revenu au sommet ; Y laisse ses plus pauvres avec presque rien. Une réponse unique au classement des deux pays exigerait de fixer d'abord ce que l'on juge prioritaire — le sort des plus pauvres ou la part du sommet — ce qui est un **choix normatif, pas statistique**. »

C'est cette dernière phrase qui distingue une excellente copie. Le statisticien décrit ; il ne tranche pas un arbitrage de valeurs sans le dire.

Exercice 3.5 — Volatilité, annualisation et Bienaymé-Tchebychev

Les rendements mensuels d'un fonds sur douze mois, en pourcentage :

+2,1	-1,4	+3,2	+0,8	-2,6	+4,1
+1,5	-0,7	+2,9	-3,1	+1,8	+2,4

a. Calculez le rendement moyen mensuel. **b.** Calculez la variance (par Koenig) et l'écart-type mensuel. **c.** Annualisez le rendement et la volatilité. (*Rappel : la volatilité s'annualise en multipliant par $\sqrt{12}$ pour des données mensuelles.*) **d.** Calculez le coefficient de variation et le rapport m/σ annualisé. **e.** Appliquez Bienaymé-Tchebychev avec $k = 2$, puis confrontez la borne aux données observées. Que constatez-vous ?

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.5

a. $\sum x_i = 2,1 - 1,4 + 3,2 + 0,8 - 2,6 + 4,1 + 1,5 - 0,7 + 2,9 - 3,1 + 1,8 + 2,4 = 11,0$

$$m = \frac{11,0}{12} = 0,9167 \% \text{ par mois}$$

b. $\sum x_i^2 = 4,41 + 1,96 + 10,24 + 0,64 + 6,76 + 16,81 + 2,25 + 0,49 + 8,41 + 9,61 + 3,24 + 5,76 = 70,58$

$$V = \frac{70,58}{12} - (0,9167)^2 = 5,8817 - 0,8403 = 5,0414$$

$$\sigma = \sqrt{5,0414} = 2,2453 \% \text{ par mois}$$

c. Rendement annualisé (somme des douze mois, approximation additive) : $12 \times 0,9167 = 11,0 \%$. Volatilité annualisée : $\sigma_{an} = 2,2453 \times \sqrt{12} = 2,2453 \times 3,4641 = 7,78 \%$.

PIÈGE FRÉQUENT

Pourquoi $\sqrt{12}$ et non 12 ? Parce que **les variances s'additionnent, pas les écarts-types** — c'est la propriété $V(aX) = a^2V(X)$ appliquée à une somme de mois indépendants : $V_{an} = 12 V_{mens}$, donc $\sigma_{an} = \sqrt{12} \sigma_{mens}$. **C'est exactement le « moyen » annoncé par la diapositive 49 du support : la volatilité ne s'agrège pas linéairement.** (*L'hypothèse d'indépendance des rendements mensuels est une convention de marché ; elle est approximative mais universellement utilisée.*)

d. $CV = \frac{2,2453}{0,9167} = 2,449$ — la dispersion vaut près de 2,5 fois le rendement moyen mensuel. Rapport m/σ mensuel = 0,4083 ; annualisé = $0,4083 \times \sqrt{12} = 1,414$. **Lecture :** ce rapport est la structure du **ratio de Sharpe** (sans taux sans risque). Une valeur de 1,41 est bonne. **Et le CV en est l'inverse :** $1/2,449 = 0,408$ ✓ — la même information, lue à l'envers.

e. Avec $k = 2$: Bienaymé-Tchebychev garantit que **au moins $1 - 1/4 = 75 \%$** des observations se trouvent dans l'intervalle

$$[m - 2\sigma ; m + 2\sigma] = [0,9167 - 4,4906 ; 0,9167 + 4,4906] = [-3,57 \% ; +4,41 \%]$$

Confrontation aux données : le minimum observé est -3,1 et le maximum +4,1 — **les douze mois, soit 100 %, sont dans l'intervalle.**

Ce qu'il faut constater et écrire : « La borne garantit 75 % ; on observe 100 %. L'inégalité est donc **très lâche**, ce qui est normal : elle est valable **quelle que soit la loi** de la variable, y compris pour les distributions les plus défavorables. Son intérêt n'est pas la précision mais l'**universalité** — elle donne une garantie sans rien supposer. Si l'on acceptait l'hypothèse de normalité, l'intervalle à $\pm 2\sigma$ contiendrait environ 95 % des observations, ce qui serait bien plus informatif mais reposerait sur une hypothèse invérifiable sur douze points. »

En gestion des risques, c'est exactement l'arbitrage quotidien : une borne robuste et large, ou une borne étroite qui suppose une loi que le marché ne respecte pas dans les crises.

Exercice 3.6 — Que peut-on agréger ?

Une administration publique, pour chacune des trois régions d'un territoire, le tableau suivant :

Région	Effectif N_k	Revenu moyen m_k	Revenu médian	Écart-type σ_k	Gini G_k
A	400	24 000	21 000	9 000	0,28

Région	Effectif N_k	Revenu moyen m_k	Revenu médian	Écart-type σ_k	Gini G_k
B	350	31 000	27 500	14 000	0,33
C	250	19 000	18 000	6 000	0,22

Pour chacune des quatre grandeurs, dites si l'on peut calculer la valeur d'ensemble à partir de ce tableau seul. Si oui, calculez-la. Si non, expliquez précisément ce qui manque.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.6

$N = 400 + 350 + 250 = 1\,000$; poids $0,40 \cdot 0,35 \cdot 0,25$.

① Le revenu moyen — OUI, calculable. La moyenne est un opérateur linéaire :

$$m = 0,40(24\,000) + 0,35(31\,000) + 0,25(19\,000) = 9\,600 + 10\,850 + 4\,750 = 25\,200 \text{ €}$$

② Le revenu médian — NON. La médiane **ne s'agrège pas**, quels que soient les poids (§ 2.1.15). Elle dépend de la **position relative de toutes les observations**, information détruite par le résumé en trois médianes. **Ce qu'il faudrait : les distributions complètes** (ou au moins les fonctions de répartition) des trois régions, pour reconstituer la distribution d'ensemble puis y chercher le rang médian. (On peut seulement encadrer : la médiane d'ensemble est comprise entre 18 000 et 27 500 €.)

③ L'écart-type — OUI, calculable, via la décomposition intra / inter.

$$V_{\text{intra}} = 0,40(9\,000)^2 + 0,35(14\,000)^2 + 0,25(6\,000)^2$$

$$= 0,40 \times 81 \times 10^6 + 0,35 \times 196 \times 10^6 + 0,25 \times 36 \times 10^6 = 32,4 \times 10^6 + 68,6 \times 10^6 + 9,0 \times 10^6 = 110,0 \times 10^6$$

Écarts des moyennes à 25 200 : $-1\,200 \cdot +5\,800 \cdot -6\,200$.

$$V_{\text{inter}} = 0,40(1\,200)^2 + 0,35(5\,800)^2 + 0,25(6\,200)^2$$

$$= 0,40 \times 1,44 \times 10^6 + 0,35 \times 33,64 \times 10^6 + 0,25 \times 38,44 \times 10^6 = 0,576 \times 10^6 + 11,774 \times 10^6 + 9,610 \times 10^6 = 21,96 \times 10^6$$

$$\sigma^2 = 110,0 \times 10^6 + 21,96 \times 10^6 = 131,96 \times 10^6 \quad \sigma = 11\,487 \text{ €}$$

Remarque à faire : $V_{\text{inter}}/\sigma^2 = 21,96/131,96 = 16,6\%$ — la région d'appartenance n'explique qu'un sixième de la dispersion des revenus. **L'essentiel des inégalités est intra-régional.**

④ Le Gini d'ensemble — NON. Comme la médiane, le Gini repose sur le **classement de tous les individus** : la courbe de Lorenz d'ensemble exige de fusionner les trois populations et de les réordonner. Trois indices régionaux n'y suffisent pas. **Ce qu'il faudrait :** les distributions complètes, ou au minimum les parts de l'agrégat par quantile de chaque région **plus** les masses de revenu régionales. **Et un raisonnement à connaître :** le Gini d'ensemble est **supérieur** à la moyenne pondérée des Gini régionaux, parce qu'à l'inégalité interne de chaque région s'ajoute l'inégalité **entre** régions — même mécanique que la composante inter de la variance.

SYNTHÈSE — LA RÈGLE GÉNÉRALE À RETENIR

Grandeur	S'agrège ?	Pourquoi
Somme, effectif	Oui	Additivité directe
Moyenne	Oui (pondérée)	Opérateur linéaire
Variance, écart-type	Oui	Via Koenig ou intra/inter — deux nombres par groupe suffisent
Médiane, quantiles	Non	Dépendent du rang , pas de la valeur
Gini, courbe de Lorenz	Non	Dépendent du classement complet de la population
Mode	Non	Le mode d'ensemble peut n'être le mode d'aucun groupe

Le critère unificateur : ce qui repose sur des sommes s'agrège ; ce qui repose sur des rangs ne s'agrège pas.

Niveau 4 — Simulation d'examen

MÉTHODE — CONDITIONS DE PASSATION

Le support ne donne aucune indication sur le format ni sur la durée de l'épreuve. La simulation retient le format le plus courant pour un chapitre de cette densité : **2 heures**, sur **20 points**, **calculatrice autorisée**, **documents interdits**. Ce chapitre étant plus lourd que le chapitre 1 (trois familles d'indicateurs, plusieurs démonstrations), la durée retenue est supérieure aux 1 h 30 du chapitre précédent. **Ajuste ces paramètres dès que les modalités réelles seront annoncées.**

Chronomètre lancé. **Répartition du temps conseillée** : 25 min pour la partie A, 45 min pour la partie B, 30 min pour la partie C, 15 min pour la partie D, **5 min de relecture** — et la relecture n'est pas optionnelle : c'est là que se rattrapent les erreurs d'unité et de somme.

Sujet

PARTIE A — Questions de cours (5 points)

A.1 (1,5 pt) Énoncez la propriété « la somme des écarts à la moyenne est nulle » et démontrez-la. Expliquez en deux phrases pourquoi cette propriété **oblige** à construire les indicateurs de dispersion à partir de valeurs absolues ou de carrés.

A.2 (1,5 pt) Énoncez la formule de Koenig. Démontrez, à partir d'elle, que $\overline{x^2} \geq (\overline{x})^2$. Expliquez en une phrase pourquoi cette formule rend possible l'agrégation des variances.

A.3 (1 pt) Un étudiant calcule l'indice de Gini de la variable « note obtenue au partiel » sur les 1 200 étudiants de la promotion. Le calcul aboutit à $G = 0,14$. Commentez.

A.4 (1 pt) Deux courbes de Lorenz se croisent. Peut-on conclure que l'une des deux distributions est plus inégalitaire que l'autre ? Justifiez.

PARTIE B — Position et dispersion (7 points)

Les salaires mensuels nets des 200 salariés d'une PME se répartissent ainsi :

Salaire mensuel net (€)	Effectif
[1 200 ; 1 600[	40
[1 600 ; 2 000[	50
[2 000 ; 2 800[	60
[2 800 ; 4 400[	50
Total	200

B.1 (1 pt) Déterminez la classe modale. Justifiez votre méthode.

B.2 (1 pt) Calculez le salaire moyen. Précisez l'hypothèse que vous utilisez.

B.3 (1,5 pt) Calculez la médiane par interpolation linéaire.

B.4 (1,5 pt) Calculez Q_1 et Q_3 , puis l'écart inter-quartile.

B.5 (1,5 pt) Calculez la variance et l'écart-type.

B.6 (0,5 pt) Calculez le coefficient de variation et commentez la forme de la distribution en une phrase argumentée.

PARTIE C — Concentration (5 points)

On s'intéresse maintenant au partage de la **masse salariale** de cette même PME.

C.1 (0,5 pt) Justifiez qu'il est légitime de mesurer la concentration de cette variable.

C.2 (1,5 pt) Calculez la part de la masse salariale détenue par chaque classe. Arrondissez au dixième et contrôlez la somme.

C.3 (1 pt) Construisez le tableau des cumuls nécessaire à la courbe de Lorenz. **Attention aux hauteurs de tranche.**

C.4 (1,5 pt) Calculez l'indice de Gini.

C.5 (0,5 pt) Rédigez deux phrases d'interprétation.

PARTIE D — Application (3 points)

Les rendements mensuels d'un fonds sur six mois, en pourcentage :

+3,2	-1,8	+2,4	+0,6	-2,2	+1,8
------	------	------	------	------	------

D.1 (1 pt) Calculez le rendement moyen mensuel et l'écart-type mensuel (par Koenig).

D.2 (1 pt) Annualisez les deux grandeurs. Justifiez le facteur d'annualisation de la volatilité par une propriété du cours.

D.3 (1 pt) Un gérant affirme : « La volatilité annuelle est de 7 %, donc le fonds ne peut pas perdre plus de 7 % sur une année. » Réfutez cette affirmation en mobilisant précisément le cours.

CORRIGÉ — PARTIE A (5 POINTS)

A.1 (1,5 pt)

Énoncé (0,5 pt) : pour toute série $(x_1, \dots, x_N)$ de moyenne m_X , $\sum_{i=1}^N (x_i - m_X) = 0$.

Démonstration (0,5 pt) : par linéarité de la somme, $\sum_{i=1}^N (x_i - m_X) = \sum_{i=1}^N x_i - N m_X$. Or, par définition de la moyenne,

$$m_X = \frac{1}{N} \sum_{i=1}^N x_i, \text{ donc } \sum_{i=1}^N x_i = N m_X. \text{ D'où } \sum_{i=1}^N (x_i - m_X) = N m_X - N m_X = 0.$$

Conséquence (0,5 pt) : un indicateur de dispersion défini comme la moyenne des écarts à la moyenne vaudrait donc **0 pour toute distribution**, y compris la plus dispersée — il ne mesurerait rien. Il faut donc **supprimer les signes** avant de moyenniser : soit par la valeur absolue (écart absolu moyen), soit par le carré (variance), le carré ayant l'avantage décisif d'être **dérivable partout**.

A.2 (1,5 pt)

Énoncé (0,5 pt) : $V(X) = \frac{1}{N} \sum_{i=1}^N x_i^2 - m_X^2$, soit « la moyenne des carrés moins le carré de la moyenne ».

Démonstration de l'inégalité (0,5 pt) : la variance est une moyenne de carrés, donc $V(X) \geq 0$. En reportant dans Koenig : $\overline{x^2} - (\bar{x})^2 \geq 0$, donc $\overline{x^2} \geq (\bar{x})^2$. **L'égalité a lieu si et seulement si $V(X) = 0$** , c'est-à-dire si tous les x_i sont égaux.

Agrégation (0,5 pt) : Koenig ne fait intervenir que $\sum x_i$ et $\sum x_i^2$; il suffit donc de **transmettre deux nombres par groupe** (plus son effectif) pour reconstituer la variance de l'ensemble, sans jamais revenir aux données individuelles.

A.3 (1 pt)

Le calcul est **numériquement possible mais dépourvu de sens** (0,5 pt). La mesure de concentration porte sur la répartition de la **somme** de la variable ; elle exige donc que cette somme désigne un objet réel. Or **la somme des notes de 1 200 étudiants ne correspond à aucune grandeur** : ce n'est pas un stock que l'on se partagerait. La note est une variable quantitative, mais **non extensive** (0,5 pt).

Ce qu'il fallait faire : mesurer la **dispersion** des notes (écart-type, écarts inter-quartiles), qui elle est parfaitement définie, et non leur concentration.

A.4 (1 pt)

Non, pas de manière univoque (0,5 pt). Le croisement signifie que l'une des distributions est plus inégalitaire dans le **bas** de la distribution et l'autre dans le **haut**. Il n'y a donc **pas de dominance de Lorenz**, et le classement dépend du poids que l'indicateur choisi accorde à chaque zone : le rapport D_9/D_1 privilégie les extrêmes, l'indice de Gini la structure d'ensemble (0,5 pt).

Deux indicateurs peuvent donc classer les deux distributions en sens opposé, sans que l'un des deux soit faux. La réponse consiste à décrire les deux phénomènes, et à préciser que trancher exigerait un **critère normatif** extérieur à la statistique.

CORRIGÉ — PARTIE B (7 POINTS)

B.1 — Classe modale (1 pt)

Les classes ayant des **amplitudes inégales**, la classe modale est celle de **densité maximale**, et non d'effectif maximal (0,25 pt pour l'avoir dit). On rapporte chaque effectif à une amplitude de référence de 400 € :

Classe	n_i	a_i (€)	d_i (effectif par tranche de 400 €)
[1 200 ; 1 600[	40	400	$40 \times \frac{400}{400} = 40,0$
[1 600 ; 2 000[	50	400	50,0
[2 000 ; 2 800[	60	800	$60 \times \frac{400}{800} = 30,0$
[2 800 ; 4 400[	50	1 600	$50 \times \frac{400}{1 600} = 12,5$

La classe modale est [1 600 ; 2 000[(0,5 pt), de densité 50, alors que l'effectif maximal est celui de [2 000 ; 2 800[(60 salariés) (0,25 pt pour la remarque). Cette dernière ne doit son effectif qu'à une amplitude deux fois plus grande.

B.2 — Salaire moyen (1 pt)

Hypothèse (0,25 pt) : les salariés sont supposés **uniformément répartis à l'intérieur de chaque classe** ; on retient donc le **centre de classe** comme valeur représentative.

Classe	Centre c_i	n_i	f_i	$f_i c_i$
[1 200 ; 1 600[	1 400	40	0,20	280
[1 600 ; 2 000[	1 800	50	0,25	450
[2 000 ; 2 800[	2 400	60	0,30	720
[2 800 ; 4 400[	3 600	50	0,25	900
Total		200	1,00	2 350

$$m_X = \sum f_i c_i = 2 350 \text{ €} \quad (0,75 \text{ pt})$$

B.3 — Médiane (1,5 pt)

Fréquences cumulées (0,5 pt) : 0,20 · 0,45 · 0,75 · 1,00. La médiane est la valeur telle que $F(Me) = 0,50$. Elle se situe donc dans la classe [2 000 ; 2 800[, où F passe de 0,45 à 0,75 (0,25 pt).

Interpolation linéaire (0,75 pt) :

$$Me = 2 000 + 800 \times \frac{0,50 - 0,45}{0,75 - 0,45} = 2 000 + 800 \times \frac{0,05}{0,30} = 2 000 + 133,33 = 2 133,3 \text{ €}$$

Contrôle : $2 000 \leq 2 133,3 < 2 800$ ✓ — la médiane appartient bien à sa classe.

B.4 — Quartiles (1,5 pt)

Q_1 : $F = 0,25$ tombe dans [1 600 ; 2 000[(F passe de 0,20 à 0,45).

$$Q_1 = 1 600 + 400 \times \frac{0,25 - 0,20}{0,45 - 0,20} = 1 600 + 400 \times 0,20 = 1 680 \text{ €} \quad (0,5 \text{ pt})$$

Q_3 : $F(2 800) = 0,75$ **exactement** — aucune interpolation n'est nécessaire.

$$Q_3 = 2 800 \text{ €} \quad (0,5 \text{ pt, dont } 0,25 \text{ pour avoir vu que la borne est atteinte pile})$$

Écart inter-quartile = $2 800 - 1 680 = 1 120 \text{ €}$ (0,5 pt). **Lecture** : les 50 % de salariés situés au centre de la distribution sont répartis sur une plage de 1 120 €.

B.5 — Variance et écart-type (1,5 pt)

Par la formule de définition (1 pt) :

c_i	$c_i - m$	$(c_i - m)^2$	f_i	$f_i (c_i - m)^2$
1 400	- 950	902 500	0,20	180 500
1 800	- 550	302 500	0,25	75 625
2 400	+ 50	2 500	0,30	750
3 600	+ 1 250	1 562 500	0,25	390 625
Total			1,00	647 500

$$V(X) = 647\,500 \text{ €}^2$$

Vérification par Koenig (bonus de rigueur) : $\sum f_i c_i^2 = 0,20(1\,960\,000) + 0,25(3\,240\,000) + 0,30(5\,760\,000) + 0,25(12\,960\,000)$
 $= 392\,000 + 810\,000 + 1\,728\,000 + 3\,240\,000 = 6\,170\,000$; $m^2 = 2\,350^2 = 5\,522\,500$; $V = 6\,170\,000 - 5\,522\,500 = 647\,500$ ✓

$$\sigma = \sqrt{647\,500} = 804,7 \text{ €} \quad (0,5 \text{ pt})$$

⚠ Ne jamais s'arrêter à la variance : 647 500 « euros au carré » ne s'interprète pas.

B.6 — Coefficient de variation et commentaire (0,5 pt)

$$CV = \frac{804,7}{2\,350} = 0,342 \quad \text{soit } 34,2 \%$$

Commentaire attendu : « La dispersion représente 34 % du salaire moyen : l'éventail salarial est **modérément ouvert**.

Surtout, $Me = 2\,133 \text{ €} < m = 2\,350 \text{ €}$: la distribution est **étalée vers la droite**. Une minorité de salaires élevés — la classe [2 800 ; 4 400[regroupe un quart des salariés sur une amplitude quatre fois supérieure à celle de la première classe — tire la moyenne au-dessus de la valeur centrale. **La médiane décrit donc mieux le salarié typique que la moyenne.** »

CORRIGÉ — PARTIE C (5 POINTS)

C.1 — Légitimité (0,5 pt)

La somme des salaires a un sens économique précis : c'est la **masse salariale** de la PME, montant qu'elle verse effectivement chaque mois. La variable est **extensive et additive** : la mesure de concentration est donc légitime. (À l'inverse, une concentration d'âges ou de notes n'aurait pas de sens.)

C.2 — Parts de la masse salariale (1,5 pt)

$p_k = \frac{f_k c_k}{m_X}$, avec $m_X = 2\,350$ € — les produits $f_k c_k$ ont déjà été calculés en B.2.

Classe	$f_k c_k$	$p_k = f_k c_k / 2\,350$	En % (arrondi)
[1 200 ; 1 600[	280	0,11915	11,9
[1 600 ; 2 000[	450	0,19149	19,1
[2 000 ; 2 800[	720	0,30638	30,6
[2 800 ; 4 400[	900	0,38298	38,3
Total	2 350	1,00000	99,9 △

Contrôle et remarque attendue (0,25 pt) : la somme des parts exactes vaut exactement 100 %, mais la somme des parts arrondies au dixième vaut 99,9 %. **Il s'agit d'un écart d'arrondi, non d'une erreur** : chacune des quatre valeurs a été arrondie vers le bas. Je poursuis avec les valeurs arrondies en signalant que le résultat final en sera affecté à la troisième décimale.

C.3 — Tableau des cumuls (1 pt)

△ Les classes n'ont pas la même fréquence : les hauteurs de tranche ne sont donc pas toutes égales à 20 comme dans le cas des quintiles (0,25 pt pour l'avoir repéré).

Classe	f_k (%)	Cumul de population (%)	p_k (%)	Cumul de masse (%)
[1 200 ; 1 600[	20	20	11,9	11,9
[1 600 ; 2 000[	25	45	19,1	31,0
[2 000 ; 2 800[	30	75	30,6	61,6
[2 800 ; 4 400[	25	100	38,3	99,9 → 100,0

Hauteurs de tranche : $h_1 = 20$, $h_2 = 25$, $h_3 = 30$, $h_4 = 25$ (0,75 pt). Leur somme fait bien 100 ✓

C.4 — Indice de Gini (1,5 pt)

Tranche	b	B	h	Aire = $(b+B)h/2$
0 → 20	0,0	11,9	20	$11,9 \times 10 = 119,00$
20 → 45	11,9	31,0	25	$42,9 \times 12,5 = 536,25$
45 → 75	31,0	61,6	30	$92,6 \times 15 = 1\,389,00$
75 → 100	61,6	100,0	25	$161,6 \times 12,5 = 2\,020,00$
Somme			100	4 064,25

Conversion d'unité (0,5 pt — c'est le point le plus souvent perdu) : les cumuls étant exprimés en pourcentages, le carré de référence vaut $100 \times 100 = 10\,000$:

$$\text{mathcal{A}} = 0,5 - \frac{4\,064,25}{10\,000} = 0,5 - 0,406425 = 0,093575$$

$$G = 2 \times 0,093575 = \mathbf{0,187} \quad (0,5 \text{ pt})$$

Contrôles (0,5 pt) : $0 \leq 0,187 \leq 1$ ✓ ; la somme des hauteurs fait 100 ✓. (Avec les parts non arrondies, on obtiendrait 0,186 : l'écart d'arrondi annoncé en C.2 affecte bien la troisième décimale, sans conséquence sur l'interprétation.)

C.5 — Interprétation (0,5 pt)

① « Les 20 % de salariés les moins payés perçoivent **11,9 %** de la masse salariale, tandis que les 25 % les mieux payés en perçoivent **38,3 %** — soit un rapport de **3,2 pour 1**. » ② « L'indice de Gini vaut **0,187**, valeur **faible** : la masse salariale de cette PME est peu concentrée. C'est cohérent avec un coefficient de variation modéré (34 %) et avec l'absence de très hauts salaires — la distribution est bornée à 4 400 €. **Cette concentration est bien inférieure à celle observée sur l'ensemble des salaires français ($G = 0,356$ en 2021)**, ce qui s'explique par l'homogénéité d'une population d'entreprise unique. »

CORRIGÉ — PARTIE D (3 POINTS)

D.1 — Moyenne et écart-type mensuels (1 pt)

$$\sum x_i = 3,2 - 1,8 + 2,4 + 0,6 - 2,2 + 1,8 = 4,0$$

$$m = \frac{4,0}{6} = 0,667 \% \text{ par mois} \quad (0,25 \text{ pt})$$

$$\sum x_i^2 = 10,24 + 3,24 + 5,76 + 0,36 + 4,84 + 3,24 = 27,68$$

$$V = \frac{27,68}{6} - (0,667)^2 = 4,6133 - 0,4444 = 4,1689 \quad (0,5 \text{ pt})$$

$$\sigma = \sqrt{4,1689} = 2,042 \% \text{ par mois} \quad (0,25 \text{ pt})$$

D.2 — Annualisation (1 pt)

Rendement (0,25 pt) : $12 \times 0,667 = 8,0 \% \text{ par an}$ (approximation additive, usuelle pour de petits rendements).

Volatilité (0,25 pt) : $\sigma_{\text{an}} = 2,042 \times \sqrt{12} = 2,042 \times 3,464 = 7,07 \%$.

Justification (0,5 pt) : la propriété $V(aX) = a^2 V(X)$ montre que **les variances, et non les écarts-types, se cumulent**. Le rendement annuel étant la somme de douze rendements mensuels supposés indépendants, sa variance vaut $12 V_{\text{mens}}$, donc son écart-type vaut $\sqrt{12} \sigma_{\text{mens}}$. **Multiplier l'écart-type par 12 reviendrait à confondre la variance et l'écart-type — c'est l'erreur exacte que la propriété interdit.**

D.3 — Réfutation (1 pt)

L'affirmation est fausse pour trois raisons distinctes, à énoncer séparément.

① **L'écart-type n'est pas une borne, c'est une moyenne.** (0,4 pt) La volatilité mesure l'écart **typique** des rendements à leur moyenne, pas leur écart **maximal**. Rien dans sa définition n'interdit une réalisation à -3σ ou -5σ .

② **Le seul résultat du cours qui borne les écarts est l'inégalité de Bienaymé-Tchebychev — et c'est une borne de probabilité, pas de valeur.** (0,4 pt) Elle affirme $P(|\text{vert}X - m| \geq k\sigma) \leq 1/k^2$ pour $k > 1$: avec $k = 3$, au plus 11 % des observations s'écartent de plus de 3σ — soit ici plus de 21 points de rendement. **Elle autorise donc explicitement des pertes très supérieures à 7 %.**

③ **La perte maximale n'est pas bornée par la volatilité mais par la nature de l'actif.** (0,2 pt) Pour un fonds sans effet de levier, la perte maximale est de 100 % ; avec levier, elle peut la dépasser. La volatilité est **muette** sur ce point.

La formulation correcte serait : « La volatilité annuelle est de 7,07 %. Sous hypothèse de normalité — non vérifiée ici sur six observations —, environ deux tiers des années auraient un rendement dans un intervalle de ± 7 points autour de 8 %. Sans cette hypothèse, Bienaymé-Tchebychev garantit seulement qu'au plus 25 % des années s'écartent de plus de deux volatilités, soit plus de 14 points. »

POINT D'EXAMEN — GRILLE DE NOTATION ET SEUILS

Partie	Points	Ce qui est vérifié
A — Cours	5	Les démonstrations, et la capacité à refuser un calcul illégitime (A.3)
B — Position et dispersion	7	La densité, l'interpolation, la variance jusqu'à l'écart-type , le diagnostic d'asymétrie
C — Concentration	5	Les parts, les hauteurs de tranche inégales , la conversion d'unité du Gini
D — Application	3	L'annualisation en $\sqrt{12}$ et la distinction borne / moyenne
Total	20	

Les cinq points qui font basculer une copie : ① avoir calculé les **densités** en B.1 au lieu de lire l'effectif maximal ; ② avoir poussé jusqu'à l'**écart-type** en B.5 ; ③ avoir vu que les **hauteurs de tranche sont inégales** en C.3 ; ④ avoir **divisé par 10 000** en C.4 ; ⑤ avoir refusé le calcul du Gini sur des notes en A.3.

Barème d'auto-évaluation : moins de 10 → reprends la partie 2 en entier. Entre 10 et 13 → tu maîtrises les calculs mais pas les justifications : reprends les encadrés **Démonstration**. Entre 14 et 17 → niveau solide ; travaille les **Points de vigilance** (§ 3). Au-dessus de 17 → **c'est le niveau attendu pour viser les 3 % de tête**. Maintiens-le par le protocole de révision du § 6.3.

6. Auto-évaluation finale

6.1 — Liste de contrôle

Si l'une de ces questions reste sans réponse **sans regarder le document**, le chapitre n'est pas maîtrisé.

- ☐ J'explique la différence de nature entre « présenter » et « résumer », et je nomme les trois familles d'indicateurs avec leur question propre.
- ☐ Je définis le mode et j'explique pourquoi il faut parler de **classe modale** pour une variable continue.
- ☐ Je calcule une densité, je détermine une classe modale à amplitudes inégales, et j'explique en une phrase pourquoi l'effectif maximal ne suffit pas.
- ☐ Je démontre que **l'aire d'un rectangle d'histogramme est l'effectif** de sa classe.
- ☐ J'écris les **trois** formules de la moyenne et je dis dans quel cas chacune s'emploie.
- ☐ Je démontre que la somme des écarts à la moyenne est nulle et j'en tire la justification de l'EAM et de la variance.
- ☐ J'énonce la linéarité de la moyenne et j'explique pourquoi elle autorise l'agrégation.
- ☐ Je calcule une médiane sur données brutes (cas pair **et** impair) et sur une distribution par interpolation linéaire.
- ☐ Je démontre par un contre-exemple que **la médiane ne s'agrège pas**.
- ☐ Je déduis l'asymétrie d'une distribution de la comparaison entre médiane et moyenne, **et je sais que la réciproque est fausse**.
- ☐ Je définis un quantile comme **l'inverse de la fonction de répartition** et j'interpole un quantile dans une classe.
- ☐ Je cite les trois écarts inter-quantiles et je construis un *boxplot*.
- ☐ J'écris l'EAM, la variance et l'écart-type, et j'explique pourquoi on **ne s'arrête jamais à la variance**.
- ☐ J'énonce Koenig, je la démontre utile pour l'agrégation, et je l'applique sans erreur de signe.
- ☐ Je donne les **trois propriétés de la variance** et leur traduction sur l'écart-type.
- ☐ J'énonce Bienaymé-Tchebychev, **avec la condition $k > 1$** , et j'explique pourquoi la borne est lâche.
- ☐ Je définis le coefficient de variation et je dis dans quels cas l'écart-type ne suffit pas.
- ☐ J'écris la décomposition intra/inter et j'interprète le rapport $V_{\text{inter}}/\sigma^2$.
- ☐ Je vérifie qu'une variable est **additive** avant tout calcul de concentration, et je donne deux exemples de chaque côté.
- ☐ Je démontre que $\sum x_i = N_k m_k$ et que **l'effectif total se simplifie** dans le calcul des parts.
- ☐ Je construis une courbe de Lorenz, j'en énonce les **quatre propriétés** et je démontre que sa pente vaut m_{x_k}/m_x .
- ☐ Je calcule un indice de Gini **sans oublier la division par 10 000** et je contrôle qu'il est dans $[0 ; 1]$.
- ☐ J'explique ce qu'est la **dominance de Lorenz** et ce qui se passe quand deux courbes se croisent.
- ☐ Je récite l'arbre de décision : quel indicateur, dans quelle situation, et pourquoi.
- ☐ Je cite les **quatre anomalies du support** (diapositives 35, 43, 48, 55) et je dis ce que donne le recalcul.
- ☐ Je traduis chaque indicateur en vocabulaire de finance de marché : volatilité, VaR, Sharpe, risque spécifique et systématique, concentration de portefeuille.

6.2 — Grille de vérification chiffrée

Épreuve	Conditions	Seuil	Résultat obtenu	Décision si sous le seuil
Niveau 1 — restitution	Sans document	100 %	 / 22	Reprendre la section du §2 correspondante, refaire les cartes le jour même
Niveau 2 — application	Chronométré, sans document	80 %	 %	Refaire les exercices ratés à J+1, sans regarder le corrigé avant d'avoir cherché
Niveau 3 — maîtrise	Sans document	4 sur 6	 / 6	Approfondissement ciblé sur la notion en cause
Niveau 4 — simulation	2 h, sans document	14/20	 / 20	Nouvelle simulation à J+7 avec d'autres données chiffrées

Épreuve	Conditions	Seuil	Résultat obtenu	Décision si sous le seuil
Exposé blanc	À voix haute, 10 min, sans notes	Aucun blocage	<i>oui / non</i>	Le point de blocage est la notion mal comprise

Lecture des échecs. Échec au niveau 1 → défaut de **mémorisation**. Échec au niveau 2 alors que le 1 est acquis → défaut de **méthode de calcul**. Échec au niveau 3 alors que le 2 est acquis → défaut de **compréhension**. Échec au niveau 4 alors que 1, 2 et 3 sont acquis → défaut de **gestion du temps ou de rédaction**, pas de connaissance. **Quatre causes, quatre traitements différents — ne les confonds pas.**

MÉTHODE — L'EXPOSÉ BLANC POUR CE CHAPITRE — LE PLAN À TENIR EN 10 MINUTES

- (1 min)** Le projet : présenter conserve, résumer perd — et pourquoi cette perte est nécessaire. Les trois familles et leur question.
- (2 min)** La position : mode et classe modale (avec la densité), les trois écritures de la moyenne et ses trois propriétés, la médiane et l'interpolation. **Le diagnostic d'asymétrie en une phrase.**
- (4 min)** La dispersion : pourquoi la position ne suffit pas ; quantiles et écarts inter-quantiles ; **la somme des écarts est nulle donc valeur absolue ou carré** ; EAM, variance, écart-type ; Koenig et les trois propriétés, démontrées à voix haute ; Bienaymé-Tchebychev avec sa condition ; le coefficient de variation ; la décomposition intra/inter.
- (2 min)** La concentration : la condition d'additivité, la part de l'agrégat et la simplification de N , la courbe de Lorenz avec ses quatre propriétés, le Gini avec le piège d'unité.
- (1 min)** La clôture : l'arbre de décision, et la traduction en finance de marché.

Règle : si tu bloques plus de 5 secondes sur un point, note-le et continue. Le point noté est ta prochaine séance de travail.

6.3 — Protocole de révision daté

Document produit le **10 septembre 2026**. Les échéances sont donc :

Échéance	Date	Durée	Ce qui est révisé
J+1	11 septembre 2026	25 min	Fiche de synthèse (§4.1) + les 65 cartes (§4.2) + relecture du schéma (§4.4)
J+3	13 septembre 2026	35 min	Cartes échouées à J+1 + niveau 1 complet, chronométré + les huit ancrages (§4.3)
J+7	17 septembre 2026	60 min	Liste de contrôle à froid (§6.1) + exercices 2.2, 2.4 et 3.3 + relecture intégrale des points de vigilance (§3)
J+21	1 ^{er} octobre 2026	2 h 15	Simulation d'examen complète (niveau 4) en 2 h, puis auto-correction au barème

Règle de décision. Une carte échouée **deux fois de suite** relève de la compréhension, pas de la mémoire : reprends la section du §2 correspondante, et non la carte.

Règle d'entretien. Ce chapitre est **le socle calculatoire de toute la suite du cours** : le chapitre 3 (évolutions temporelles) et le chapitre 4 (croisement de variables) supposent la moyenne, la variance et la décomposition intra/inter acquises. **Une révision de 15 minutes avant chaque nouveau chapitre est un investissement, pas une perte de temps.**

Annexe — Tableau de couverture du support d'origine

Preuve de complétude, vérifiable en deux minutes. Le support d'origine — *CHAPITRE 2 : Résumer pour informer*, Hélène Couprie, 70 diapositives — est inventorié ci-dessous **diapositive par diapositive**, sans trou de numérotation.

Légende. ✓ traité intégralement — △ traité, mais support d'origine incomplet, ambigu ou erroné : la reconstruction est signalée à l'endroit exact — ✗ impossible à traiter, donnée manquante.

#	Élément du support d'origine	Nature	Traité dans	État
1	Page de titre : « CHAPITRE 2 : Résumer pour informer », Hélène Couprie	titre	En-tête du document	✓
2	Contenu et plan du chapitre (3 sections)	plan	§2, encadré d'ouverture	✓
3	Section 1 : résumer la position — mode, moyenne, médiane	plan de section	§2.1.1	✓
4	Illustration pour le mode : logements en Outre-mer, recensement 2023 — 3 questions posées, aucune réponse	tableau + questions	§2.1.2 : les 3 questions corrigées ; écart d'arrondi de ± 1 sur trois colonnes signalé	△
5	Illustration pour le mode : diagramme en barres horizontales groupées	image non commentée	§2.1.2 : figure décrite et interprétée, lien avec le chapitre 1 rétabli	△
6	Deuxième illustration : personnes incarcérées par tranche d'âge (graphique)	image non commentée	§2.1.3 : figure décrite, piège de la lecture directe explicité	△
7	Deuxième illustration : le tableau des personnes incarcérées	tableau	§2.1.3 : amplitudes et densités recalculées ligne par ligne	✓
8	Définitions : amplitude, densité, classe modale	définitions	§2.1.3 : les trois définies simple puis académique, avec démonstration	✓
9	Deuxième illustration : le même graphique avec la densité en ordonnée	image non commentée	§2.1.3 : comparaison des deux figures, effet de la correction montré	△
10	Histogramme : définitions	définitions	§2.1.4	✓
11	Deuxième illustration : l'histogramme	image non commentée	§2.1.4 : démonstration « aire = effectif », contrôle de la somme des aires	△
12	La moyenne arithmétique (données brutes)	formule	§2.1.5 : énoncée, expliquée terme à terme, illustrée	✓
13	Calcul de la moyenne à partir d'une distribution	formule	§2.1.6 : les deux écritures (n_i et f_i) démontrées équivalentes	✓
14	Calcul de la moyenne par agrégation	formule	§2.1.7 : démonstration complète	✓
15	Calcul par agrégation (suite) : l'avertissement sur la variable de découpage	mise en garde	§2.1.7 : traduite et transformée en repère opératoire	✓
16	Propriété 1 : la somme des écarts à la moyenne est nulle	propriété	§2.1.8 : démontrée, et conséquence tirée pour toute la section 2	✓
17	Propriété 2 : la moyenne est un opérateur linéaire	propriété	§2.1.9 : démontrée	✓

#	Élément du support d'origine	Nature	Traité dans	État
18	Illustration : salaires des fonctionnaires 2022-2023 — 2 questions posées, aucune réponse	tableau + questions	§2.1.10 : les 2 questions corrigées ; écart de 1,6 € sur 2023 (3 114,4 recalculé contre 3 116 annoncé) expliqué par l'arrondi des fréquences	⚠
19	Propriété 3 : la moyenne est sensible aux valeurs extrêmes	propriété	§2.1.11 : illustrée numériquement	✓
20	La médiane : définition	définition	§2.1.12 : deux définitions équivalentes	✓
21	Calcul de la médiane sur données brutes	méthode	§2.1.13 : cas pair et impair traités séparément	✓
22	Illustration : densités de population UE15 / UE25 — 1 question posée, aucune réponse	tableau + question	§2.1.14 : médianes des trois ensembles calculées et interprétées	⚠
23	Illustration (suite) — 2 questions posées, aucune réponse	questions	§2.1.14 : les 3 moyennes calculées ; effet de la division par 2 de Malte démontré sur médianes et moyennes	⚠
24	Illustration : revenus salariaux médians par CSP (graphique) — 2 questions posées, aucune réponse	image + questions	§2.1.15 : questions corrigées ; démonstration par contre-exemple que la médiane ne s'agrège pas	⚠
25	Calcul de la médiane à partir d'une distribution	méthode	§2.1.16 : interpolation linéaire démontrée, pas seulement énoncée	✓
26	Illustration : familles selon le nombre d'enfants — 2 questions posées, aucune réponse	tableau + questions	§2.1.17 : questions corrigées ; l'interpolation donne 0,09 enfant pour 2008, résultat aberrant expliqué et remplacé par la règle du rang	⚠
27	Section 2 : indicateurs de dispersion — les quatre cas d'introduction	plan de section	§2.2.1 : les quatre cas décrits et comparés	✓
28	L'étendue	définition	§2.2.2 : définie, limite explicitée	✓
29	Écart inter-centiles $C_1 - C_{99}$	définition	§2.2.3 : remplacé dans la famille des écarts inter-quantiles	✓
30	Les quantiles	définition	§2.2.4 : définition par F^{-1} reconstruite	✓
31	Interprétation d'un quantile	méthode	§2.2.4 : phrases-types de lecture produites	✓
32	Application aux cas de l'introduction	application	§2.2.5 : les quatre cas recalculés	✓
33	Calcul d'un quantile d'ordre α % à partir d'une distribution	méthode	§2.2.6 : interpolation démontrée	✓
34	Interprétons quelques quantiles : niveau de vie 2024	tableau	§2.2.7 : $D_9/D_1 = 3,48$ recalculé, écarts entre déciles successifs analysés	✓
35	« Version alternative »	tableau	§2.2.7 : le titre annonce « retraités, année 2008 » alors que le tableau affiché est celui des niveaux de vie 2024 de la diapositive 34 — incohérence signalée	⚠
36	Représentation graphique : le <i>boxplot</i>	définition	§2.2.8 : construction détaillée, conventions des moustaches précisées	✓
37	Exemple d'un <i>boxplot</i>	image non commentée	§2.2.8 : figure décrite et reliée aux quantiles calculés	⚠
38	Interprétons des quantiles, encore : quantiles par CSP — 1 question posée, aucune réponse	tableau + question	§2.2.9 : question corrigée ; explication de l'écart inter-décile de l'ensemble supérieur à celui de 3 CSP sur 4 (composante inter)	⚠
39	Section 2 (suite) : indicateurs de dispersion	plan	§2.2.10	✓

#	Élément du support d'origine	Nature	Traité dans	État
40	Calcul des indicateurs : EAM, variance, écart-type	formules	§2.2.10 : les trois énoncées, expliquées et justifiées l'une par l'autre	✓
41	Tableau de calcul de la moyenne des écarts sur données brutes	méthode	§2.2.10 : structure du tableau expliquée colonne par colonne	✓
42	Illustration du tableau de calcul : série de 20 âges	tableau	§2.2.11 : tableau intégralement recalculé ($m = 47,9$; $EAM = 5,7$)	✓
43	Calcul des indicateurs sur données brutes : résultats	résultats	§2.2.11 : le support s'arrête à la variance (54,19) et ne calcule jamais l'écart-type — $\sigma = 7,36$ ans ajouté, seul chiffre interprétable	⚠
44	Interprétation de l'écart-type : inégalité de Bienaymé-Tchebychev	théorème	§2.2.12 : énoncée avec sa condition $k > 1$, appliquée et commentée	✓
45	Application en finance (introduction)	application	§2.2.13	✓
46	Application en finance 1/3 : la série des rendements	application	§2.2.13 : données reprises et recalculées	✓
47	Application en finance 2/3 : moyennes et écarts-types par période	application	§2.2.13 : tous les chiffres vérifiés	✓
48	Application en finance 3/3 : « 99 % de chances de faire des gains en périodes 1, 2, 3, 5 »	conclusions	§2.2.13 : conclusions non reconstituables — Bienaymé-Tchebychev exige $k > 1$ or $m/\sigma < 1$ dans les cinq périodes, et la période 2 a une moyenne négative. Signalé, non masqué	⚠
49	Calculs d'agrégats : le problème posé	problématisation	§2.2.14 : les quatre points reformulés	✓
50	Propriétés de la variance : Koenig, translation, non-linéarité, corollaire	propriétés	§2.2.14 : les quatre démontrées, utilité de Koenig expliquée	✓
51	Illustration des propriétés : effet d'une translation (+ 6 points)	image non commentée	§2.2.14 : figure décrite, propriété vérifiée numériquement	⚠
52	Illustration des propriétés : effet d'une multiplication ($\times 2$)	image non commentée	§2.2.14 : figure décrite, $\sigma_{aX} = I \text{verta } r \text{verta } \sigma_X$ vérifiée	⚠
53	Coefficient de variation	définition	§2.2.15 : défini, cas d'usage précisés, lien avec le ratio de Sharpe	✓
54	Calcul de la variance à partir d'une distribution	formule	§2.2.16 : pondération par les effectifs démontrée	✓
55	Illustration : cas n° 1 à 4	tableau	§2.2.16 : la variance du cas 4 annoncée à 10,4 vaut en réalité 20,8 ($\sigma = 4,56$ et non 3,2) — une division par 2 en trop, qui inverse le classement des cas 2 et 4. Vérification complète fournie	⚠
56	Choix de la formule de calcul	méthode	§2.2.16 : arbre de décision reconstruit	✓
57	Calcul de la variance par agrégation (via Koenig)	formule	§2.2.17 : démonstration complète	✓
58	Corollaire : décomposition de la variance intra / inter	corollaire	§2.2.18 : les deux formules démontrées, cas extrêmes décrits, lien avec le R^2 annoncé	✓
59	Section 3 : résumer la concentration — dispersion contre concentration	plan de section	§2.3.1 : distinction reconstruite, condition d'additivité transformée en règle opératoire avec tableau de cas	✓
60	Calcul de la part de l'agrégat ; relation $\sum x_i = N_k m_{x_k}$	méthode	§2.3.2 : relation démontrée ; démonstration que l'effectif total se simplifie , ce que le support pose sans le prouver	✓

#	Élément du support d'origine	Nature	Traité dans	État
61	Illustration : classes de salaires en France en 2005	tableau	§2.3.3 : colonne (5) intégralement recalculée. La colonne (4) « estimation du salaire moyen » n'est jamais expliquée : il s'agit du centre de classe — hypothèse identifiée, vérifiée sur les cinq classes, et sa fragilité sur la classe haute discutée	⚠
62	Illustration : les mêmes classes en 2021	tableau	§2.3.4 : recalcul complet. La somme des cinq parts arrondies vaut 100,1 et non 100,0 — excédent d'arrondi identifié et suivi jusqu'au Gini	⚠
63	Illustration : comparaison 2005 / 2021 — 1 question posée, aucune réponse	tableau + question	§2.3.5 : réponse complète (variations en points, en relatif, rapport entre extrêmes de 3,4 à 10,4) et réserve méthodologique sur le changement probable de champ, que je ne peux pas lever avec les seules données du support	⚠
64	Courbe de Lorenz : définition	définition	§2.3.6 : définie ; la condition de classement croissant, absente du support, est ajoutée et justifiée	✓
65	Tableau de calcul de la courbe de Lorenz (cumuls 2005 et 2021)	tableau	§2.3.6 : cumuls refaits ligne par ligne. Le support cumule des valeurs arrondies (d'où 40,7 au lieu de 40,8 en 2005, et 100,1 ramené à 100,0 en 2021) — effet quantifié	⚠
66	Graphe de la courbe de Lorenz, 2005 et 2021	image non commentée	§2.3.6 : figure reconstruite en intégralité — la diagonale d'égalité, absente du support, est ajoutée , sans quoi la figure ne se lit pas. Les quatre propriétés de la courbe sont démontrées	⚠
67	Interprétation de la courbe de Lorenz ; dominance ; croisement	interprétation	§2.3.7 : les trois énoncés reformulés et démontrés ; contre-exemple chiffré du croisement construit ; absence de croisement vérifiée sur 2005/2021	✓
68	Calcul du GINI, année 2005 : graphe avec l'aire de concentration et un trapèze (1 025)	image	§2.3.8 : calcul complet des cinq trapèzes (le 1 025 du support retrouvé ✓). Le piège d'unité — diviser par 10 000 quand les cumuls sont en % — n'est pas signalé par le support : il l'est ici, avec son contrôle	⚠
69	Calcul de l'indice de GINI : définition géométrique, bornes, formule	formule	§2.3.8 : formule démontrée en quatre étapes (carré unité, triangle, soustraction, trapèzes) ; bornes 0 et 1 démontrées, raffinement $(N-1)/N$ ajouté	✓
70	Récapitulations	synthèse	§2.4 : tableau complet des treize indicateurs + arbre de décision en cinq questions	✓

Bilan de couverture : 70 diapositives inventoriées, 70 traitées — dont 46 ✓ et 24 ⚠, et aucune ✗.

La colonne « Traité dans » renvoie aux paragraphes de ce document. Chacun existe aussi, deux fois plus développé, dans *Résumer pour informer* — *version intégrale* : mêmes numéros, mêmes titres. **Quand un point de ce cours-ci ne suffit pas, ouvre l'intégrale au même numéro.** Les 24 ⚠ ne signalent aucune lacune de ce document : elles marquent les endroits où le support d'origine était elliptique (images non commentées, questions posées sans réponse, méthode implicite), incohérent ou erroné — et où la reconstruction est explicitement signalée à l'endroit exact.

Les quatre anomalies de fond — diapositives 35 (titre erroné), 43 (écart-type jamais calculé), 48 (conclusion non démontrable) et 55 (variance fausse d'un facteur

1. — sont récapitulées au § 3.4.