

Résumer pour informer

Position, dispersion, concentration — les trois familles d'indicateurs qui résument une distribution

Ce document reconstruit intégralement le deuxième chapitre de Techniques statistiques. Il couvre les 70 diapositives du support : les indicateurs de position (mode, classe modale, histogramme, moyenne, médiane), de dispersion (étendue, quantiles, boxplot, écart absolu moyen, variance, écart-type, Koenig, décomposition intra/inter) et de concentration (part de l'agrégat, courbe de Lorenz, indice de Gini), plus l'application en finance où l'écart-type devient la volatilité. Les quatorze questions posées en amphithéâtre y sont corrigées et tous les chiffres du support recalculés.

Date · 10 septembre 2026

Travail estimé · première lecture 4 h — maîtrise complète $\approx$ 12 h réparties sur 3 semaines

Version · 1.0

Document de travail autonome — il remplace le support de cours original, qu'il n'est pas nécessaire de relire. Toute notion évoquée dans le cours y est définie, démontrée et illustrée.

SOMMAIRE

1. Carte du chapitre

- 1.1 — Vue d'ensemble
- 1.2 — Les idées maîtresses
- 1.3 — Prérequis
- 1.4 — Lien avec la finance de marché

2. Le cours reconstruit

- 2.1 — Résumer la position des données
- 2.2 — Résumer la dispersion des données
- 2.3 — Résumer la concentration des données
- 2.4 — Récapitulons (diapositive 70)

3. Points de vigilance

- 3.1 — Les confusions classiques
- 3.2 — Les erreurs que commet la majorité des étudiants
- 3.3 — Ce qui sépare une copie moyenne d'une excellente copie
- 3.4 — Les quatre anomalies du support à connaître

4. Système d'ancrage mémoriel

- 4.1 — Fiche de synthèse
- 4.2 — Cartes de révision
- 4.3 — Moyens mnémotechniques
- 4.4 — Schéma récapitulatif

5. Entraînement progressif

- Niveau 1 — Restitution
- Niveau 2 — Application chiffrée
- Niveau 3 — Maîtrise
- Niveau 4 — Simulation d'examen

6. Auto-évaluation finale

- 6.1 — Liste de contrôle
- 6.2 — Grille de vérification chiffrée
- 6.3 — Protocole de révision daté

Annexe — Tableau de couverture du support d'origine

Chapitre 2 — Résumer pour informer

Ce document remplace le support de cours. Les 70 diapositives y sont couvertes, sans exception : le **tableau de couverture** en annexe permet de le vérifier ligne par ligne. Les quatorze questions posées à l'amphithéâtre sont **intégralement corrigées**, chaque formule est démontrée et illustrée par un calcul complet, et **tous les chiffres du support ont été recalculés** — ce qui a révélé deux points à signaler.

1. Carte du chapitre

1.1 — Vue d'ensemble

Le chapitre 1 apprenait à **présenter** une distribution sans rien perdre. Celui-ci apprend à la **résumer** — donc à perdre volontairement de l'information, en échange d'une capacité de comparaison et de décision. Le support l'annonce dès la première ligne : « les données contiennent souvent trop d'informations ; dans ce cas, la synthèse s'impose ». Résumer une distribution, c'est répondre à trois questions successives. **Où se situe la série ?** — les indicateurs de position : mode, moyenne, médiane. **Comment les données sont-elles réparties autour de ce centre ?** — les indicateurs de dispersion : étendue, écarts inter-quantiles, écart absolu moyen, variance, écart-type, coefficient de variation. **Comment la somme des données se répartit-elle entre les individus ?** — les indicateurs de concentration : part de l'agrégat, courbe de Lorenz, indice de Gini. Chacune de ces trois questions est indépendante : deux séries peuvent avoir la même moyenne et des dispersions opposées, ou la même dispersion et des concentrations différentes. Le chapitre se referme sur une règle qui vaut pour tout le cours : **le choix des indicateurs dépend du type de données, mais aussi de ce que l'on veut en faire.**

1.2 — Les idées maîtresses

1. **Résumer, c'est perdre de l'information volontairement** — et il faut savoir laquelle on perd. C'est l'opposé exact du chapitre 1.
2. **Trois familles d'indicateurs, trois questions distinctes** : position, dispersion, concentration. Aucune ne remplace les autres.
3. **Pour une variable continue découpée en classes, la classe modale se lit sur la densité — jamais sur l'effectif ni sur la fréquence.** C'est le point que le support met en rouge.
4. **Dans un histogramme, l'aire d'un rectangle est la fréquence de la classe** — et la somme des aires vaut 1. C'est ce qui distingue un histogramme d'un diagramme en colonnes.
5. **La moyenne est linéaire et sensible aux valeurs extrêmes ; la médiane n'est ni l'une ni l'autre.** C'est pourquoi on publie des revenus **médians**.
6. **La variance n'est pas linéaire** : $V(aX + b) = a^2 V(X)$. Ajouter une constante ne change rien, multiplier multiplie par le carré.
7. **L'écart-type est interprétable parce qu'il a l'unité des données** — et l'inégalité de Bienaymé-Tchebychev lui donne un sens chiffré : au moins 75 % des observations dans $m \pm 2\sigma$.
8. **En finance, l'écart-type porte un nom : la volatilité.** Le couple (rentabilité moyenne, volatilité) est le double indicateur du risque.
9. **Dispersion et concentration ne mesurent pas la même chose** : la dispersion regarde la répartition des **observations**, la concentration la répartition de la **somme**.
10. **La courbe de Lorenz et l'indice de Gini résument l'inégalité** — et quand deux courbes se croisent, les indicateurs peuvent se contredire.

1.3 — Prérequis

MÉTHODE — PRÉREQUIS 1 — CE QU'IL FAUT AVOIR RETENU DU CHAPITRE 1

Cinq notions sont utilisées sans être rappelées :

- **Population, unités statistiques, effectif total N ; variable X , modalités x_i , $i = 1, \dots, p$.**
- **Effectifs n_i et fréquences $f_i = n_i / N$, avec $\sum f_i = 1$.**
- **Fréquences cumulées $F(x_k) = \sum_{i=1}^k f_i$ — croissantes, de f_1 à 1. Tout le calcul des quantiles repose dessus.**
- **Type de variable** : qualitative (nominale, ordinale) / quantitative (discrète, continue). **Le type détermine les indicateurs autorisés** — c'est le fil du chapitre.
- **Série brute (raw data) contre distribution** : les formules diffèrent selon la présentation des données. Le support y revient explicitement (diapo 56).

MÉTHODE — PRÉREQUIS 2 — LES NOTATIONS MATHÉMATIQUES EMPLOYÉES

Symbole	Lecture	Où il sert
$\sum_{i=1}^N x_i$	Somme des x_i pour i de 1 à N	Moyenne sur données brutes
$\sum_{i=1}^p n_i x_i$	Somme sur les modalités , pondérée par les effectifs	Moyenne sur distribution
$ x_i - m $	Valeur absolue de l'écart : sa grandeur, sans son signe	Écart absolu moyen
$(x_i - m)^2$	Carré de l'écart : positif, et qui pénalise davantage les grands écarts	Variance
$\sqrt{\quad}$	Racine carrée : rend à la variance l'unité des données	Écart-type
m, σ^2, σ	Moyenne, variance, écart-type	Partout

Le piège d'indice, présent dans tout le chapitre : l'indice i désigne tantôt une **observation** (formules sur données brutes, i va de 1 à N), tantôt une **modalité** (formules sur distribution, i va de 1 à p). Le support le rappelle deux fois. Lire la borne de la somme suffit à savoir dans quel cas on est.

MÉTHODE — PRÉREQUIS 3 — OPÉRATEUR LINÉAIRE ET INTERPOLATION LINÉAIRE

Un **opérateur linéaire** transforme $Y = aX + b$ en $m_Y = a m_X + b$: la transformation « traverse » l'opérateur. La moyenne l'est ; la médiane et la variance ne le sont pas.

L'**interpolation linéaire** consiste à estimer une valeur intermédiaire en supposant que la variation est **régulière** entre deux points connus. Si l'on connaît deux points (x_a, F_a) et (x_b, F_b) et que l'on cherche le x correspondant à une valeur F comprise entre les deux :

$$x \approx x_a + (x_b - x_a) \times \frac{F - F_a}{F_b - F_a}$$

Lecture : on part de x_a et on avance sur le segment $[x_a ; x_b]$ d'une fraction égale à la **part du chemin déjà parcourue en ordonnée**. C'est le principe unique de toutes les formules de médiane et de quantiles du chapitre.

1.4 — Lien avec la finance de marché

Ce chapitre est, littéralement, le cours de gestion du risque que vous pratiquez déjà.

ANALOGIE — MARCHÉS FINANCIERS

- **L'écart-type EST la volatilité.** Le support le dit explicitement (diapo 45) : sur une série de rentabilités journalières, l'écart-type mesure la volatilité. Tout ce que le chapitre démontre sur σ — non-linéarité, formule de Koenig, insensibilité à l'ajout d'une constante — vaut donc pour la volatilité.
- **Le couple (moyenne, écart-type) est le couple (rendement, risque).** La diapositive 46 le formule ainsi : « on va donc avoir un **double indicateur** qui nous donnera nos chances de succès ». C'est le fondement de toute la théorie moderne du portefeuille.
- **Les quantiles sont la Value at Risk.** Le quantile d'ordre 5 % de la distribution des rentabilités est la perte que l'on ne dépasse que 5 fois sur 100. Le chapitre vous apprend à le calculer par interpolation.
- **L'inégalité de Bienaymé-Tchebychev est un majorant du risque sans hypothèse de loi.** Elle vaut pour **toute** distribution, y compris à queues épaisses — contrairement à la règle « 95 % dans $m \pm 2\sigma$ » qui suppose la normalité et qui, sur des rendements réels, sous-estime gravement les extrêmes. Retenez cette différence : c'est l'une des causes documentées des grandes pertes de marché.
- **Le coefficient de variation σ/m est l'inverse d'un ratio de Sharpe simplifié.** Comparer deux stratégies dont les rendements moyens diffèrent exige de rapporter le risque au rendement — c'est exactement ce que fait le CV, et c'est pourquoi le support insiste sur le fait qu'il est **sans unité**.
- **La décomposition intra/inter est celle du risque spécifique et du risque systématique.** La variance totale d'un ensemble se décompose en dispersion à l'**intérieur** des groupes et dispersion **entre** les groupes : c'est la structure même de l'analyse de la performance d'un portefeuille par secteurs.

2. Le cours reconstruit

L'ordre suit celui du support. Trois ajouts : les **quatorze questions posées à l'amphithéâtre** sont corrigées, les **tableaux présentés sous forme d'image** sont restitués en texte, et **tous les chiffres sont recalculés**.

OBJECTIFS — LE PROGRAMME ANNONCÉ (DIAPOSITIVE 2)

*Les données contiennent souvent **trop d'informations** (trop de variables, de modalités, etc.). Dans ce cas, la synthèse s'impose.*

Contenu : les différentes façons de résumer la distribution d'un caractère statistique **quantitatif**.

Plan :

1. **Indicateurs de position** (moyenne, mode) : où se situe la série de données ?
2. **Indicateurs de dispersion** (écart-type, variance) : comment les données sont-elles réparties ?
3. **Indicateurs de concentration** (mesure des inégalités) : comment la somme des données se répartit-elle ?

POINT D'EXAMEN — LE MOT LE PLUS IMPORTANT DE LA DIAPOSITIVE : « QUANTITATIF »

Le chapitre porte sur le résumé d'un caractère **quantitatif**. C'est une restriction, et elle est logique : on ne peut pas calculer la moyenne d'une variable qualitative (chapitre 1, test de la moyenne). **Une seule exception traverse le chapitre : le mode**, qui existe pour tout type de variable, y compris nominale.

Le plan lui-même est une réponse en trois questions, qu'il faut savoir énoncer : **où ? comment réparties ? comment la somme se répartit-elle ?**

2.1 — Résumer la position des données

2.1.1 Les trois indicateurs de position (diapositive 3)

DÉFINITION — LES TROIS RÉSUMÉS EN UNE SEULE VALEUR

- **Le mode** : la modalité qui présente la fréquence la plus élevée (ou l'effectif le plus fort).
- **La moyenne** : l'indicateur de tendance centrale le plus connu. Elle se calcule en **divisant la somme des observations par le nombre d'observations**.
- **La médiane** : plus spécialisée, elle indique un **centre de rang**.

DÉMONSTRATION — TROIS « CENTRES » QUI NE COÏNCIDENT PAS, ET POURQUOI

Ces trois indicateurs répondent à la même question — « où se situe la série ? » — par trois définitions incompatibles du centre.

Indicateur	Ce qu'il maximise ou équilibre	Sur quoi il porte
Mode	La fréquence : la valeur la plus souvent observée	Les effectifs
Moyenne	L' équilibre des écarts : la somme des écarts à la moyenne est nulle	Les valeurs
Médiane	L' équilibre des rangs : autant d'individus au-dessus qu'en dessous	Les rangs

Conséquence immédiate : sur une distribution symétrique, les trois coïncident ; sur une distribution asymétrique — la distribution des revenus, par exemple — ils divergent, et l'écart entre eux **mesure l'asymétrie**. C'est pourquoi le support précise que la médiane est « très utilisée pour les distributions de revenu » (diapo 20).

2.1.2 Le mode : première illustration (diapositives 4 et 5)

Le tableau du support — Distribution des logements selon le type en Outre-mer, recensement de la population 2023.

Type de logement	Guadeloupe	Martinique	Guyane	Réunion
Habitation de fortune	1 098	790	3 698	1 867
Case traditionnelle	2 322	578	1 798	23 062
Maison ou immeuble en bois	8 363	6 086	11 841	12 913
Maison ou immeuble en dur	168 050	164 290	71 089	321 445
Ensemble	179 833	171 743	88 425	359 288

CORRIGÉ — LES TROIS QUESTIONS POSÉES, CORRIGÉES

1. Population, unités statistiques, taille, caractères, types et sous-types.

- **Population** : l'ensemble des **logements** des quatre territoires d'Outre-mer recensés en 2023.
- **Unités statistiques** : un **logement**.
- **Taille** : elle est donnée **par territoire** — 179 833 en Guadeloupe, 171 743 en Martinique, 88 425 en Guyane, 359 288 à La Réunion. Pour l'ensemble : $N = 799\,289$ logements.
- **Les caractères statistiques — il y en a deux** :
 - le **type de logement**, **qualitatif nominal**, à 4 modalités (habitation de fortune, case traditionnelle, maison ou immeuble en bois, maison ou immeuble en dur) ;
 - la **zone géographique**, **qualitative nominale**, à 4 modalités (les quatre territoires).

2. A-t-on ici la représentation d'une distribution au sens classique du terme ? Non. Une distribution associe un effectif à chaque modalité d'une **seule** variable. Ici, deux variables sont croisées : le tableau contient **quatre distributions juxtaposées**, une par territoire. C'est exactement la situation « plusieurs distributions d'un même caractère statistique » du chapitre 1 — la **zone géographique** joue le rôle de variable de **découpage**, le **type de logement** celui de variable **étudiée**.

3. Quel est le mode de la distribution « type de logement » ? « Maison ou immeuble en dur » — dans les quatre territoires, et donc aussi pour l'ensemble. C'est la modalité au plus fort effectif, très loin devant les autres : elle représente à elle seule de 80 % (Guyane) à près de 94 % (Guadeloupe) des logements.

PIÈGE FRÉQUENT — UN DÉTAIL DE RIGUEUR : LES COLONNES NE BOUCLENT PAS EXACTEMENT

Recomptons les colonnes : Guadeloupe donne exactement 179 833 ✓ ; Martinique donne 171 744 contre 171 743 annoncés ; Guyane 88 426 contre 88 425 ; La Réunion 359 287 contre 359 288.

Trois écarts de une unité — ce n'est pas une erreur, c'est un effet d'arrondi. Les données de recensement sont des **estimations pondérées**, arrondies à l'unité ligne par ligne ; la somme des arrondis ne redonne pas l'arrondi de la somme. C'est exactement le phénomène observé au chapitre 1 sur les pourcentages qui totalisent 100,1 %.

Ce qu'il faut en faire : le signaler si l'on refait le calcul, et surtout **ne pas corriger le total** : c'est le total publié qui fait foi.

La représentation graphique (diapositive 5). Le support projette un **diagramme en barres horizontales groupées** : quatre groupes, un par territoire, et dans chaque groupe quatre barres, une par type de logement, avec les effectifs affichés en bout de barre. Le support commente : « on constate qu'il y a en fait **4 diagrammes colonnes horizontales juxtaposés** pour chaque valeur du caractère statistique *zone géographique* ».

POINT D'EXAMEN

Ce commentaire fait le lien avec le chapitre 1 : c'est un **diagramme groupé**, et le groupement se fait **par territoire**, donc l'œil compare les **types de logement** à l'intérieur de chaque territoire. Si la question portait sur l'évolution d'un type de logement d'un territoire à l'autre, il faudrait grouper par **type de logement**.

2.1.3 Le mode d'une variable continue : amplitude, densité, classe modale (diapositives 6 à 9)

La deuxième illustration porte sur les effectifs des personnes incarcérées suivant la classe d'âge. La diapositive 6 en donne un diagramme en colonnes groupées par année (2005, 2010, 2015, 2020), une couleur par classe d'âge, et pose « les mêmes questions que précédemment ».

Le tableau (diapositive 7) — Effectifs des personnes incarcérées suivant la classe d'âge en 2020 :

Classe d'âge	Effectif	Fréquence	Amplitude	Densité d'observations
De 16 ans à moins de 18 ans	819	819/79 788	2	0,0051
De 18 ans à moins de 21 ans	5 361	0,067	3	0,0224
De 21 ans à moins de 25 ans	11 444	0,143	4	0,0359
De 25 ans à moins de 30 ans	14 950	0,187	5	0,0375
De 30 ans à moins de 40 ans	23 979	0,301	10	0,0301
De 40 ans à moins de 50 ans	13 413	0,168	10	0,0168
De 50 ans à moins de 60 ans	6 501	0,081	10	0,0081
60 ans ou plus	3 321	0,042	20	0,0021
Ensemble	79 788			

DÉFINITION — AMPLITUDE, DENSITÉ, CLASSE MODALE (DIAPOSITIVE 8)

La distribution d'un caractère quantitatif **continu** peut être représentée en **discrétisant** ce caractère sous forme de **classes**.

Dans ce cas la classe modale est définie à partir de la densité — et non à partir de la fréquence ni de l'effectif de la classe ! (mis en rouge dans le support)

- L'**amplitude de classe** correspond à la **valeur maximale moins la valeur minimale** de la variable pour la classe considérée.
- La **densité d'une classe** est le **rapport entre la fréquence de la classe et l'amplitude de la classe**.
- La **classe modale** est la classe qui a la **densité d'observations la plus élevée**.

FORMULE CLÉ — LES DEUX FORMULES DE LA DIAPOSITIVE

$$\text{amplitude} = x_{\max} - x_{\min} \quad \text{densité} = \frac{\text{fréquence de la classe}}{\text{amplitude de la classe}}$$

DÉMONSTRATION — POURQUOI LA DENSITÉ ET NON L'EFFECTIF — LA DÉMONSTRATION PAR LE TABLEAU

C'est le point que le support met en rouge, et il se démontre sur ses propres chiffres.

Étape 1 — ce que dit l'effectif. La classe la plus nombreuse est « de 30 à moins de 40 ans », avec **23 979** personnes (fréquence 0,301). Conclusion naïve : ce serait la classe modale.

Étape 2 — pourquoi cette conclusion est fausse. Cette classe couvre **10 années**, alors que « de 25 à moins de 30 ans » n'en couvre que 5. À densité égale, une classe deux fois plus large contient deux fois plus de monde : son effectif élevé vient en partie de sa **largeur**, pas de sa **concentration**.

Étape 3 — neutraliser la largeur. C'est exactement ce que fait la densité : on divise la fréquence par l'amplitude, ce qui donne une **fréquence par année d'âge**.

— « 30 à 40 ans » : $0,301 / 10 = 0,0301$ par an.

— « 25 à 30 ans » : $0,187 / 5 = 0,0374$ par an — le support affiche 0,0375, écart d'arrondi sur la fréquence.

Conclusion : la classe modale est « de 25 ans à moins de 30 ans », avec la densité la plus forte (0,0375), et non la classe la plus nombreuse. **Le support le confirme diapositive 9.**

La règle à retenir : dès que les classes n'ont **pas la même amplitude**, comparer des effectifs revient à comparer des choses de tailles différentes. Seule la densité est comparable.

EXEMPLE CHIFFRÉ — VÉRIFIONS DEUX LIGNES DU TABLEAU

Ligne 1 — « de 16 à moins de 18 ans ». Le support laisse volontairement la fréquence sous forme de fraction : $819 / 79\,788 = 0,01026$. Amplitude : $18 - 16 = 2$ ans. Densité : $0,01026 / 2 = 0,00513$, soit **0,0051 ✓**

Dernière ligne — « 60 ans ou plus ». Fréquence : $3\,321 / 79\,788 = 0,0416$, soit 0,042 ✓ Amplitude : **20**. Or la classe est **ouverte** — « 60 ans ou plus » n'a pas de borne supérieure. Le support a donc **fixé** conventionnellement la borne à 80 ans. Densité : $0,042 / 20 = 0,0021$ ✓

Le point de méthode : une **classe ouverte** oblige à choisir une borne pour calculer amplitude et densité. Ce choix est **conventionnel** et doit être signalé — il influence la densité de cette classe, mais ici pas la conclusion, la classe étant de loin la moins dense.

La densité en graphique (diapositive 9). Le support reprend le diagramme en colonnes groupées de la diapositive 6, mais **en densité** au lieu des effectifs, pour les quatre années. Il conclut : « la classe modale est la tranche d'âge de **25 à 30 ans** » et « cette figure est **plus informative** ; mieux vaut tracer un **histogramme** ».

2.1.4 L'histogramme (diapositives 10 et 11)

DÉFINITION — L'HISTOGRAMME

- Un histogramme se construit en mettant **en abscisse les limites des classes** et **en ordonnée la densité des classes**.
- **La classe modale correspond au rectangle le plus haut** de l'histogramme.
- **L'aire de chaque rectangle correspond à la fréquence de la classe.**

DÉMONSTRATION — LA DÉMONSTRATION DU SUPPORT, LIGNE À LIGNE

$$\text{Aire} = \text{Base} \times \text{Hauteur} = \text{Amplitude} \times \text{Densité} \quad (1)$$

$$\text{Aire} = \text{Amplitude} \times \frac{\text{Fréquence}}{\text{Amplitude}} = \text{Fréquence} \quad (2)$$

Lecture pas à pas. (1) L'aire d'un rectangle est le produit de sa base par sa hauteur ; ici la base est l'**amplitude** de la classe et la hauteur sa **densité**. (2) Or la densité est **par définition** la fréquence divisée par l'amplitude ; en substituant, l'amplitude se simplifie et il reste la **fréquence**.

Conséquence, énoncée par le support : la somme des aires vaut 1, puisque la somme des fréquences vaut 1 (propriété démontrée au chapitre 1).

PIÈGE FRÉQUENT — HISTOGRAMME ET DIAGRAMME EN COLONNES — LA CONFUSION LA PLUS COÛTEUSE DU CHAPITRE

	Diagramme en colonnes	Histogramme
Variable	Qualitative ou quantitative discrète	Quantitative continue , découpée en classes
En ordonnée	L' effectif ou la fréquence	La densité
Ce qui porte l'information	La hauteur	L' aire
Espaces entre les barres	Oui — les modalités sont séparées	Non — les classes sont contiguës
Largeur des barres	Arbitraire et constante	L'amplitude de la classe — donc variable

La conséquence pratique : dans un histogramme à classes d'amplitudes inégales, mettre l'**effectif** en ordonnée produit un graphique **faux**, qui gonfle visuellement les classes larges. C'est précisément l'erreur que la démarche des diapositives 6 à 11 corrige, étape par étape.

L'histogramme du support (diapositive 11). Il porte en abscisse les âges de 0 à 85 ans, en ordonnée la densité de 0 à 0,050. On y lit immédiatement la forme de la distribution : une montée rapide entre 16 et 25 ans, un **maximum sur la classe 25-30 ans** (le rectangle le plus haut), puis une décroissance régulière — la queue s'étirant jusqu'à la classe très large et très peu dense des 60 ans et plus. Le support conclut : « la classe modale, correspondant au rectangle le plus haut (densité la plus forte), est la classe **de 25 à 30 ans** ».

2.1.5 La moyenne arithmétique (diapositive 12)

FORMULE CLÉ — LA MOYENNE SUR DONNÉES BRUTES

$$m = \frac{1}{N} \sum_{i=1}^N x_i = \frac{1}{N} (x_1 + x_2 + \dots + x_N) \quad (3)$$

- N : le **nombre d'observations** (l'effectif total).
- x_i : la valeur observée pour la **i -ème unité statistique** de la base.
- **L'indice i renvoie ici au numéro d'observation**, pas au numéro de modalité.

Ce calcul correspond à celui obtenu à partir de **données brutes** (*raw data*).

Le support ajoute l'avertissement décisif : **si les données sont disponibles uniquement sous forme de distribution — modalités et effectifs — alors la formule est différente.**

2.1.6 La moyenne à partir d'une distribution (diapositive 13)

FORMULE CLÉ — LES DEUX ÉCRITURES ÉQUIVALENTES

Pour un caractère X à p modalités, d'effectifs n_i et de fréquences f_i — **ici l'indice i renvoie au numéro de modalité** :

$$m = \frac{1}{N} \sum_{i=1}^p n_i x_i \quad (4)$$

ou, en plaçant le N dans la somme, de façon équivalente à partir des fréquences :

$$m = \sum_{i=1}^p \frac{n_i}{N} x_i = \sum_{i=1}^p f_i x_i \quad (5)$$

DÉMONSTRATION — POURQUOI CES FORMULES SONT LA MÊME QUE LA (3) — ET COMMENT PASSER DE L'UNE À L'AUTRE

Le raisonnement. Dans une série brute, une modalité qui apparaît n_i fois est additionnée n_i fois. Plutôt que d'écrire $x_i + x_i + \dots + x_i$ (n_i fois), on écrit directement $n_i x_i$. La somme des N observations devient donc une somme sur les p modalités, **pondérée par les effectifs** — c'est la formule (4).

Le passage de (4) à (5) est purement algébrique :

$$\frac{1}{N} \sum n_i x_i = \sum \frac{n_i}{N} x_i = \sum f_i x_i$$

puisque $f_i = n_i/N$ par définition.

La moyenne est donc une moyenne pondérée par les fréquences. C'est la lecture à retenir : chaque modalité compte à hauteur de sa fréquence.

Contrôle de cohérence, systématique : puisque $\sum f_i = 1$, la moyenne est nécessairement **comprise entre la plus petite et la plus grande modalité**. Un résultat qui sort de cet intervalle signale une erreur de calcul.

EXEMPLE CHIFFRÉ — LES DEUX FORMULES SUR UN MÊME EXEMPLE

Reprenons les 87 étudiants du chapitre 1 (nombre de frères et sœurs) : $0 \rightarrow 11$; $1 \rightarrow 33$; $2 \rightarrow 23$; $3 \rightarrow 7$; $4 \rightarrow 3$; $5 \rightarrow 4$; $6 \rightarrow 1$; $7 \rightarrow 2$; $9 \rightarrow 1$; $13 \rightarrow 1$; $14 \rightarrow 1$.

Par la formule (4) :

$$\sum n_i x_i = 0(11) + 1(33) + 2(23) + 3(7) + 4(3) + 5(4) + 6(1) + 7(2) + 9(1) + 13(1) + 14(1)$$

$= 0 + 33 + 46 + 21 + 12 + 20 + 6 + 14 + 9 + 13 + 14 = 188$. Donc $m = 188/87 = 2,16$ frères et sœurs.

Par la formule (5) : $0(0,1264) + 1(0,3793) + 2(0,2644) + \dots = 2,16$ ✓

Contrôle : $0 \leq 2,16 \leq 14$ ✓ La moyenne est bien dans l'intervalle des modalités.

Lecture : « Les 87 étudiants de la promotion déclarent en moyenne 2,16 frères et sœurs. » Notez que **la moyenne n'est pas une valeur observable** : personne n'a 2,16 frères et sœurs. C'est un résumé, pas une observation.

2.1.7 La moyenne par agrégation (diapositives 14 et 15)

FORMULE CLÉ — LA MOYENNE D'UNE POPULATION À PARTIR DES MOYENNES DE SES SOUS-POPULATIONS

Soient K sous-populations **disjointes** d'effectifs n_k , avec $N = \sum_{k=1}^K n_k$, et de moyennes respectives m_k . Alors :

$$m = \sum_{k=1}^K \frac{n_k}{N} m_k \quad (6)$$

Il s'agit d'une **moyenne pondérée par la part de la sous-population dans la population entière**, n_k / N .

PIÈGE FRÉQUENT — L'AVERTISSEMENT DU SUPPORT, À NE PAS MANQUER

« *Attention aux confusions car il s'agit de la fréquence du caractère statistique qui scinde la population en sous-groupes et non de la fréquence du caractère statistique X qui nous intéresse.* »

Traduction. Deux variables sont en jeu. La variable **étudiée** X (le salaire, par exemple) et la variable **de découpage** (la catégorie, la région, l'année). Les poids n_k/N de la formule (6) sont les fréquences de la **variable de découpage**.

L'erreur type : pondérer par les fréquences de X au lieu des effectifs des groupes. Le repère infallible : **on pondère toujours par des effectifs de population, jamais par des valeurs de la variable étudiée.**

DÉMONSTRATION — POURQUOI UNE MOYENNE DE MOYENNES SIMPLE EST FAUSSE

Deux groupes : 900 salariés à 2 000 € et 100 salariés à 4 000 €.

— **Moyenne des moyennes (fausse) :** $(2\,000 + 4\,000)/2 = 3\,000$ €.

— **Moyenne pondérée (juste) :** $\frac{900}{1000}(2\,000) + \frac{100}{1000}(4\,000) = 1\,800 + 400 = 2\,200$ €.

L'écart est de 800 €, soit 36 %. La moyenne simple traite les deux groupes comme s'ils avaient le même poids, alors que l'un est neuf fois plus nombreux. **Une moyenne de moyennes n'est valable que si les groupes ont le même effectif** — cas rarissime.

2.1.8 Propriété 1 : la somme des écarts à la moyenne est nulle (diapositive 16)

DÉMONSTRATION — LA DÉMONSTRATION DU SUPPORT, ÉTAPE PAR ÉTAPE

$$\sum_{i=1}^N (x_i - m) = \sum_{i=1}^N x_i - Nm = \sum_{i=1}^N x_i - N \frac{\sum_{i=1}^N x_i}{N} = 0 \quad (7)$$

1. On distribue la somme : la somme d'une différence est la différence des sommes. Le terme m étant constant, le sommer N fois donne Nm .
2. On remplace m par sa définition : $m = \frac{1}{N} \sum x_i$, donc $Nm = \sum x_i$ — « **N fois la moyenne correspond à la somme des observations** », comme l'écrit le support.
3. Il reste $\sum x_i - \sum x_i = 0$.

Ce que cela signifie, dans les termes du support : « les écarts positifs ou négatifs à la moyenne **se compensent avec la même force** ». La moyenne est le **point d'équilibre** de la distribution — au sens physique du centre de gravité.

Corollaire donné par le support : si la distribution est **symétrique**, l'axe de symétrie correspond à la moyenne, et la moyenne correspond à la médiane.

POINT D'EXAMEN — LA CONSÉQUENCE PRATIQUE LA PLUS IMPORTANTE

Puisque la somme des écarts est **toujours nulle**, l'écart moyen à la moyenne ne peut pas servir d'indicateur de dispersion : il vaudrait zéro pour toutes les séries.

C'est précisément pourquoi il faut passer par la valeur absolue (l'écart absolu moyen) **ou par le carré** (la variance). Cette propriété n'est pas une curiosité : elle **justifie l'existence** de tous les indicateurs de la partie 2 du chapitre.

2.1.9 Propriété 2 : la moyenne est un opérateur linéaire (diapositive 17)

FORMULE CLÉ — LINÉARITÉ

$$\text{si } Y = aX + b \text{ alors } m_Y = a m_X + b \quad (8)$$

- Multiplier toutes les valeurs par a multiplie la moyenne par a .
- Ajouter b à toutes les valeurs augmente la moyenne de b .
- **A fortiori**, la moyenne de la somme de deux variables est la somme des moyennes.

EXEMPLE CHIFFRÉ — LES TROIS USAGES CONCRETS

1. **Changement d'unité.** Des salaires mensuels moyens de 2 955 € donnent une moyenne annuelle de $12 \times 2\,955 = 35\,460$ € — sans recalculer quoi que ce soit.
2. **Augmentation uniforme.** Si tous les salaires augmentent de 50 €, la moyenne augmente de 50 € exactement.
3. **Augmentation en pourcentage.** Une hausse de 3 % pour tous s'écrit $Y = 1,03 X$: la moyenne est multipliée par 1,03.

Attention à la limite : la linéarité vaut pour une transformation **appliquée à toutes les observations**. Augmenter seulement certains salaires n'est pas une transformation linéaire, et la propriété ne s'applique pas.

2.1.10 Application : les salaires des fonctionnaires (diapositive 18)

Le tableau du support — Salaires mensuels nets moyens des fonctionnaires en 2022 et 2023 :

	Fréquence 2022 (%)	Fréquence 2023 (%)	Salaire moyen 2022 (€)	Salaire moyen 2023 (€)
Catégorie A	68,4	68,7	3 193	3 373
Catégorie B	18,7	18,9	2 632	2 720
Catégorie C	12,9	12,4	2 161	2 283
Titulaires A + B + C	100,0	100,0	2 955	3 116

CORRIGÉ — LES DEUX QUESTIONS POSÉES, CORRIGÉES

Question 1 — calculez le salaire mensuel net moyen en 2022 et en 2023.

C'est un calcul **par agrégation** (formule 6) : les catégories A, B, C sont trois sous-populations, les fréquences sont leurs **poids**, les salaires moyens leurs **moyennes de groupe**.

2022 :

$$\begin{aligned} m &= 0,684 \times 3\,193 + 0,187 \times 2\,632 + 0,129 \times 2\,161 \\ &= 2\,184,0 + 492,2 + 278,8 = \mathbf{2\,955,0\,€} \end{aligned}$$

Le résultat **coïncide exactement** avec la ligne « Titulaires A + B + C » du tableau ✓

2023 :

$$\begin{aligned} m &= 0,687 \times 3\,373 + 0,189 \times 2\,720 + 0,124 \times 2\,283 \\ &= 2\,317,3 + 514,1 + 283,1 = \mathbf{3\,114,4\,€} \end{aligned}$$

Le tableau annonce **3 116 €** : un écart de **1,6 €**, soit 0,05 %. Il s'explique par l'**arrondi des fréquences à une décimale** — les vraies parts ne sont pas exactement 68,7 / 18,9 / 12,4. **Il faut le signaler, pas le masquer.**

Contrôles. Les fréquences totalisent 100,0 % dans les deux colonnes ✓ Les moyennes obtenues sont comprises entre le minimum (2 161 €) et le maximum (3 193 €) des moyennes de groupe ✓

Question 2 — sachant qu'il y a 1,8 million d'agents des services de l'État en 2023, calculez la masse salariale.

La masse salariale est la **somme** des salaires, c'est-à-dire — propriété utilisée dans tout le chapitre — **la moyenne multipliée par l'effectif** :

$$\text{masse salariale} = N \times m = 1\,800\,000 \times 3\,116 = 5\,608\,800\,000\,€$$

Soit **5,61 milliards d'euros par mois**, et $\times 12 = \mathbf{67,3\,milliards\,d'euros\,par\,an.}$

Précisions attendues d'une bonne copie : il s'agit de la masse salariale **nette** (les salaires du tableau sont nets), **mensuelle** avant multiplication par 12, et pour le **champ** indiqué — agents fonctionnaires en France hors Mayotte. Sans ces trois précisions, le chiffre n'est pas interprétable.

POINT D'EXAMEN — LA RELATION À RETENIR ABSOLUMENT

$$\sum_{i=1}^N x_i = N \times m$$

La somme d'une variable est sa moyenne multipliée par l'effectif. Cette relation servira trois fois dans le chapitre : ici pour la masse salariale, à la diapositive 57 pour la variance par agrégation, et à la diapositive 60 pour la part de l'agrégat — le support la rappelle d'ailleurs explicitement à cet endroit.

2.1.11 Propriété 3 : la moyenne est sensible aux valeurs extrêmes (diapositive 19)

DÉFINITION — CE QUE DIT LE SUPPORT

- « Deux écarts à la moyenne de 5 comptent autant qu'un écart de 10. » En prenant l'exemple des notes : **pour quelqu'un qui a une moyenne de 10/20, avoir un 0/20 est aussi pénalisant qu'avoir deux 5/20.**
- Pour une distribution **non bornée et étalée à droite**, il suffit d'un écart important pour décaler la **moyenne de façon non négligeable**. Exemple : la distribution de revenu.
- **En cas de dissymétrie et de valeurs extrêmes, la médiane est un indicateur beaucoup plus stable.**

EXEMPLE CHIFFRÉ — LA DÉMONSTRATION CHIFFRÉE QUE LE SUPPORT SUGGÈRE SANS LA FAIRE

Dix salariés d'une petite entreprise, salaires mensuels en euros : 1 800, 1 850, 1 900, 1 950, 2 000, 2 050, 2 100, 2 200, 2 300, 2 500.

- **Moyenne** : $20\,650 / 10 = 2\,065$ € ; **médiane** : entre le 5^e et le 6^e rang, soit $(2\,000 + 2\,050)/2 = 2\,025$ €.

Le dirigeant, qui se verse **20 000 €**, rejoint l'effectif :

- **Nouvelle moyenne** : $40\,650/11 = 3\,695$ € — elle bondit de **1 630 €, soit +79 %**.
- **Nouvelle médiane** : le rang central des 11 valeurs est le 6^e, soit **2 050 €** — elle bouge de **25 €**.

Conclusion. Une seule observation extrême sur onze déplace la moyenne de 79 % et la médiane de 1,2 %.

Aucun des onze salariés ne gagne 3 695 € : la moyenne ne décrit plus personne. C'est exactement pourquoi l'Insee publie des revenus **médians**, et pourquoi la diapositive 24 s'intitule « revenus salariaux **médians** ».

2.1.12 La médiane (diapositive 20)

DÉFINITION — LA MÉDIANE

C'est la valeur (modalité) de la variable statistique X qui coupe la distribution de X en 2 parts égales, de telle sorte que la moitié de la population présente un caractère inférieur à la médiane tandis que l'autre moitié présente un caractère supérieur.

Trois précisions du support :

- Elle s'applique à un caractère **quantitatif ou qualitatif ordonné**.
- **À l'inverse de la moyenne, cet indicateur n'a pas la propriété de linéarité.**
- En économie-gestion, elle est **très utilisée pour les distributions de revenu**.

POINT D'EXAMEN — LES TROIS PRÉCISIONS SONT TROIS QUESTIONS D'EXAMEN

1. « **Quantitatif ou qualitatif ordonné** » — la médiane a besoin d'un **ordre**, pas de nombres. On peut donc calculer la médiane d'une appréciation (insuffisant < passable < bien < très bien), alors qu'on ne peut pas en calculer la moyenne. **C'est la seule différence de champ entre moyenne et médiane, et elle est régulièrement testée.**
2. « **Pas de linéarité** » — conséquence majeure, exploitée à la diapositive 24 : on **ne peut pas** agréger des médianes de sous-groupes comme on agrège des moyennes.
3. « **Très utilisée pour les distributions de revenu** » — parce que ces distributions sont asymétriques et à valeurs extrêmes (propriété 3 de la moyenne).

2.1.13 Calcul de la médiane sur données brutes (diapositive 21)

MÉTHODE — L'ALGORITHME

- **Il n'y a pas de formule de calcul.**
- L'algorithme repose sur un **tri préalable** de la série brute.
- La médiane est **la valeur de X de l'individu correspondant au rang central**.
- **En cas de nombre pair de rangs**, la médiane se situe à **mi-chemin entre les valeurs des rangs situés juste autour du rang central**.

EXEMPLE CHIFFRÉ — LES DEUX CAS, EN PRATIQUE

N impair — 7 valeurs : 3, 5, 8, 9, 12, 15, 40. Rang central : $(7+1)/2 = 4^e \rightarrow$ **médiane = 9.**

N pair — 8 valeurs : 3, 5, 8, 9, 12, 15, 22, 40. Rangs centraux : 4^e et 5^e , soit 9 et 12 $\rightarrow$ médiane $= (9+12)/2 = 10,5$.

Remarquez que dans le second cas la médiane **n'est pas une valeur observée** — comme la moyenne. Et que la valeur extrême 40 n'a **aucune influence** sur le résultat : elle occupe le dernier rang, quelle que soit sa grandeur. C'est toute la robustesse de la médiane.

2.1.14 Application : les densités de population en Union européenne (diapositives 22 et 23)

Le tableau du support — Densité de population en Union européenne à 15 et à 25, en habitants par km².

Union européenne à 15 (2003)	Densité	Rang	10 nouveaux pays (2004)	Densité	Rang
Finlande	15	1	Estonie	31	1
Suède	20	2	Lettonie	36	2
Irlande	57	3	Lituanie	54	3
Espagne	82	4	Chypre	97	4
Grèce	83	5	Slovénie	99	5
Autriche	98	6	Hongrie	109	6
France métropolitaine	108	7	Slovaquie	110	7
Portugal	113	8	Pologne	119	8
Danemark	125	9	République tchèque	129	9
Italie	190	10	Malte	1 246	10
Luxembourg	193	11			
Allemagne	231	12			
Royaume-Uni	242	13			
Belgique	341	14			
Pays-Bas	397	15			

Source : Tableaux de l'économie française (TEF), Insee 2004-2005, p. 11, d'après 2003, fiche de données sur la population mondiale, Population Reference Bureau (PRB).

CORRIGÉ — QUESTION 1 — ÉLÉMENTS STATISTIQUES, MÉDIANE ET PHRASE D'INTERPRÉTATION

Éléments statistiques.

- **Population** : les **pays** membres de l'Union européenne — 15 pays pour l'UE de 2003, 10 nouveaux entrants en 2004, 25 au total.
- **Unités statistiques** : **un pays**. (*Point de vigilance : ce ne sont pas des habitants — chaque pays compte pour un, quelle que soit sa population.*)
- **Effectif total** : $N = 15$, $N = 10$ ou $N = 25$ selon le champ retenu.
- **Caractère statistique** : la **densité de population** (habitants par km^2), **quantitatif continu**.

Médianes — la série étant déjà triée, il suffit de lire le rang central.

- **UE à 15** : $N = 15$, impair ; rang central $(15+1)/2 = 8 \rightarrow$ **médiane = 113 hab/ km^2 , le Portugal** (que le support met d'ailleurs en gras).
- **10 nouveaux pays** : $N = 10$, pair ; rangs centraux 5 et 6, soit la **Slovénie (99)** et la **Hongrie (109)** — toutes deux en gras dans le support $\rightarrow$ médiane = $(99 + 109)/2 = 104$ hab/ km^2 .
- **UE à 25** : en fusionnant et triant les 25 valeurs, le rang central est le 13^e $\rightarrow$ **médiane = 109 hab/ km^2 , la Hongrie**.

Phrase d'interprétation.

« En 2003, la moitié des quinze pays de l'Union européenne avaient une densité de population inférieure à 113 habitants par km^2 , et l'autre moitié une densité supérieure. »

CORRIGÉ — QUESTION 2 — DENSITÉ MOYENNE DANS CHAQUE CAS, ET L'EFFET DE MALTE

Les moyennes.

- **UE à 15 :**
 $(15 + 20 + 57 + 82 + 83 + 98 + 108 + 113 + 125 + 190 + 193 + 231 + 242 + 341 + 397)/15 = 2\,295/15 = \mathbf{153,0}$ hab/km².
- **10 nouveaux pays :** $(31 + 36 + 54 + 97 + 99 + 109 + 110 + 119 + 129 + 1\,246)/10 = 2\,030/10 = \mathbf{203,0}$ hab/km².
- **UE à 25 :** $(2\,295 + 2\,030)/25 = 4\,325/25 = \mathbf{173,0}$ hab/km².

Le constat qui doit sauter aux yeux. Chez les 10 nouveaux pays, la **moyenne (203)** est presque le double de la **médiane (104)**. Neuf pays sur dix ont une densité inférieure à 130 ; la moyenne est pourtant à 203. **C'est Malte, avec 1 246 hab/km², qui tire à elle seule la moyenne vers le haut** — illustration parfaite de la propriété 3 de la diapositive 19.

Si la densité de Malte est divisée par 2 (1 246 → 623) :

	Avant	Après	Variation
Médiane des 10 nouveaux	104	104	inchangée
Moyenne des 10 nouveaux	203,0	140,7	-62,3, soit -31 %
Médiane de l'UE à 25	109	109	inchangée
Moyenne de l'UE à 25	173,0	148,1	-24,9, soit -14 %

Pourquoi la médiane ne bouge pas. Malte reste le **dernier rang** après division par deux ($623 > 397$, le maximum de l'UE15). Or la médiane ne dépend **que du rang** de l'observation, pas de sa valeur. Tant que Malte reste au-dessus du rang central, on peut modifier sa densité comme on veut — la médiane est identique.

Pourquoi la moyenne s'effondre. La moyenne dépend de **toutes les valeurs** : diviser 1 246 par deux retire 623 de la somme, soit $623/10 = 62,3$ de la moyenne des dix nouveaux pays.

C'est la démonstration la plus nette du chapitre de ce que signifie « la moyenne est sensible aux valeurs extrêmes, la médiane est robuste ». À savoir refaire.

2.1.15 Application : les revenus salariaux médians par catégorie (diapositive 24)

Le graphique du support — Revenus salariaux **médians** annuels, en euros, des salariés d'un secteur privé en France métropolitaine en 2023 (diagramme en barres horizontales) :

Catégorie socioprofessionnelle	Revenu salarial médian annuel
Cadres	45 552 €
Professions intermédiaires	29 640 €

Catégorie socioprofessionnelle	Revenu salarial médian annuel
Ouvriers	23 148 €
Employés	22 572 €

CORRIGÉ — QUESTION 1 — ÉLÉMENTS STATISTIQUES ET INTERPRÉTATION

- **Population** : les **salariés** d'un secteur privé en France métropolitaine en 2023.
- **Unités statistiques** : un **salarié**.
- **Sous-populations** : les quatre **catégories socioprofessionnelles**.
- **Caractère statistique** : le **revenu salarial annuel, quantitatif continu**.
- **Ce qui est représenté** : non pas une distribution, mais **un indicateur de position — la médiane — calculé séparément pour chaque sous-population**.

Interprétation.

« En 2023, la moitié des cadres de ce secteur en France métropolitaine ont perçu un revenu salarial annuel inférieur à 45 552 €, l'autre moitié un revenu supérieur. »

Lecture d'ensemble : le revenu médian des cadres est **environ le double** de celui des employés (45 552 contre 22 572, soit un rapport de 2,02). Ouvriers et employés sont très proches (23 148 contre 22 572, soit 2,6 % d'écart) ; les professions intermédiaires se situent à mi-chemin.

CORRIGÉ — QUESTION 2 — PEUT-ON CALCULER LE SALAIRE MÉDIAN DE L'ENSEMBLE À PARTIR DES PARTS DES CSP ?

Non. Et c'est la question de la diapositive.

Pourquoi. La médiane **n'est pas un opérateur linéaire** — le support l'énonce diapositive 20. Contrairement à la moyenne, elle ne peut pas être agrégée en pondérant les médianes de sous-groupes par leurs effectifs. Écrire

$$\text{med} = \sum \frac{n_k}{N} \text{med}_k \text{ serait faux.}$$

La raison profonde : la médiane dépend du **rang** de chaque observation dans la distribution **d'ensemble**.

Fusionner deux groupes redistribue tous les rangs ; la position centrale du groupe fusionné n'a aucune raison de se situer entre les positions centrales des groupes.

Contre-exemple qui le prouve en trois lignes. Groupe A : 1, 2, 3 → médiane 2. Groupe B : 100, 200, 300 → médiane 200. Moyenne pondérée des médianes (effectifs égaux) : $(2 + 200)/2 = 101$. **Médiane réelle** de l'ensemble {1, 2, 3, 100, 200, 300} : entre le 3^e et le 4^e rang, soit $(3 + 100)/2 = 51,5$. **101 ≠ 51,5.**

Ce qu'il faudrait pour répondre : la **distribution complète** des salaires de l'ensemble de la population — ou au minimum les fréquences cumulées — et non les seules médianes par catégorie.

2.1.16 Calcul de la médiane à partir d'une distribution (diapositive 25)

FORMULE CLÉ — INTERPOLATION LINÉAIRE

Lorsque les données sont présentées sous forme de distribution intégrant les **fréquences cumulées** :

- si on dispose d'une valeur de X telle que $F(x_j) = 50 \%$, alors la médiane vaut x_j ;
- dans le cas contraire, on procède par interpolation linéaire. Si $F(x_a) < 50 \%$ et $F(x_b) > 50 \%$:

$$\text{med} \approx x_a + \frac{(x_b - x_a)(0,5 - F(x_a))}{F(x_b) - F(x_a)} \quad (9)$$

DÉMONSTRATION — LIRE LA FORMULE PLUTÔT QUE LA MÉMORISER

La formule est l'interpolation linéaire du §1.3, appliquée à F :

1. On part de x_a , la dernière modalité **avant** que la fréquence cumulée franchisse 50 %.
2. On avance sur le segment $[x_a ; x_b]$ d'une fraction égale à $\frac{0,5 - F(x_a)}{F(x_b) - F(x_a)}$: c'est **la part du chemin restant à parcourir en ordonnée pour atteindre 50 %, rapportée au chemin total du segment**.
3. Si $F(x_a)$ vaut déjà 50 %, la fraction est nulle : on reste en x_a — cohérent avec la première règle.

L'hypothèse cachée, à savoir énoncer : l'interpolation suppose que les individus sont **uniformément répartis** à l'intérieur de l'intervalle $[x_a ; x_b]$. C'est une hypothèse raisonnable pour une variable **continue découpée en classes**, beaucoup moins pour une variable **discrète** — voir l'application suivante.

2.1.17 Application : les familles selon le nombre d'enfants (diapositive 26)

Le tableau du support — Distribution des familles en France selon le nombre d'enfants :

Modalités	Effectifs (milliers) en 2008	Effectifs (milliers) en 2023
0 enfant	8 225	9 340
1 enfant	3 821	4 085
2 enfants	3 449	3 594
3 enfants	1 241	1 219
4 enfants	396	442
Ensemble	17 132	18 680

POINT D'EXAMEN — UNE CONFIRMATION QUI VAUT D'ÊTRE NOTÉE

Ce tableau est **exactement celui du chapitre 1, diapositive 22** — les cinq effectifs de 2008 sont identiques. Le chapitre 1 ne datait pas cette enquête ; **le chapitre 2 la date explicitement de 2008**, ce qui confirme la déduction faite alors par comparaison avec le diagramme de la diapositive 31. Les deux chapitres se recoupent : c'est un bon réflexe de le vérifier.

CORRIGÉ — LES DEUX QUESTIONS POSÉES, CORRIGÉES

Question 1 — les éléments statistiques.

- **Population** : les **familles** en France, en 2008 puis en 2023.
- **Unités statistiques** : **une famille**.
- **Effectif total** : 17 132 **milliers** de familles en 2008, 18 680 milliers en 2023. (*Attention à l'unité : des milliers, soit 17,1 puis 18,7 millions de familles.*)
- **Sous-populations** : les deux **années** — variable de découpage.
- **Caractère statistique** : le **nombre d'enfants, quantitatif discret**.
- **Contrôle** : $8\,225 + 3\,821 + 3\,449 + 1\,241 + 396 = 17\,132$ ✓ et $9\,340 + 4\,085 + 3\,594 + 1\,219 + 442 = 18\,680$ ✓

Question 2 — fréquences cumulées et médiane.

Modalité	f_i 2008 (%)	F_i 2008 (%)	f_i 2023 (%)	F_i 2023 (%)
0 enfant	48,0	48,0	50,0	50,0
1 enfant	22,3	70,3	21,9	71,9
2 enfants	20,1	90,4	19,2	91,1
3 enfants	7,2	97,7	6,5	97,6
4 enfants	2,3	100,0	2,4	100,0

Détail : $8\,225/17\,132 = 48,0\%$; $9\,340/18\,680 = 50,0\%$ — *exactement la moitié*.

Médiane 2023. $F(0) = 50,0\%$: on est dans le **premier cas** de la formule — il existe une modalité telle que $F(x_j) = 50\%$. Donc **la médiane vaut 0 enfant**. Lecture : « en 2023, la moitié des familles de France n'avaient aucun enfant ».

Médiane 2008. $F(0) = 48,0\% < 50\%$ et $F(1) = 70,3\% > 50\%$: on est dans le **second cas**. En appliquant la formule (9) avec $x_a = 0$, $x_b = 1$:

$$\text{med} \approx 0 + \frac{(1 - 0)(0,50 - 0,480)}{0,703 - 0,480} = \frac{0,020}{0,223} = 0,09$$

PIÈGE FRÉQUENT — LE RÉSULTAT 0,09 ENFANT DOIT VOUS ALERTER — ET VOICI POURQUOI

Aucune famille n'a 0,09 enfant. Le nombre d'enfants est une variable **quantitative discrète**, et l'interpolation linéaire suppose une répartition **continue et uniforme** entre 0 et 1 enfant — ce qui n'a aucun sens ici : il n'existe rien entre zéro et un enfant.

Les deux lectures, et celle qu'il faut retenir :

Méthode	Résultat 2008	Statut
Interpolation (formule 9 du cours)	0,09 enfant	La formule du cours, appliquée mécaniquement
Rang central (définition de la diapo 21)	1 enfant	Le rang central est le 8 566 ^e millier ; les 8 225 premiers ont 0 enfant, donc le rang central tombe dans « 1 enfant »

Conduite à tenir en examen : appliquez **la formule du cours** — c'est elle qui est enseignée et corrigée — mais **ajoutez la phrase qui montre que vous en connaissez la limite** : « l'interpolation suppose une répartition continue ; le caractère étant discret, la médiane au sens du rang central vaut 1 enfant ». C'est exactement ce qui distingue une copie mécanique d'une copie qui comprend.

Le même avertissement vaut pour 2023 : le cas $F = 50\%$ pile est un cas limite ; au sens du rang central avec N pair, on obtiendrait $(0+1)/2 = 0,5$. Le cours tranche pour **0 enfant**, et c'est cette réponse qu'il faut donner.

POINT D'EXAMEN — CE QUE LE TABLEAU RACONTE, AU-DELÀ DU CALCUL

Entre 2008 et 2023, la part des familles **sans enfant** passe de 48,0 % à 50,0 % — elle franchit la barre de la moitié. Celle des familles de **3 enfants** recule de 7,2 % à 6,5 %. **La médiane bascule de « 1 enfant » à « 0 enfant »** : c'est un basculement de structure que la moyenne aurait masqué. Une question de commentaire peut porter là-dessus ; la réponse mobilise les fréquences **et** l'indicateur de position.

2.2 — Résumer la dispersion des données

2.2.1 Pourquoi la position ne suffit pas : les quatre cas (diapositive 27)

DÉFINITION — L'EXPÉRIENCE DE PENSÉE DU SUPPORT

Une classe de **50 élèves**, dont la **moyenne est 12/20** dans les quatre cas :

- **Cas n° 1** : les 50 élèves ont obtenu 12/20.
- **Cas n° 2** : 5 élèves ont 7, 5 ont 8, 5 ont 9, 5 ont 10, 5 ont 11, 5 ont 13, 5 ont 14, 5 ont 15, 5 ont 16, 5 ont 17.
- **Cas n° 3** : 20 élèves ont eu 6, 20 élèves ont eu 18 et 10 élèves ont eu 12.
- **Cas n° 4** : 5 élèves ont eu 4, 10 ont eu 8, 10 ont eu 10, 10 ont eu 14, 10 ont eu 16 et 5 ont eu 20.

Dans quel cas la distribution des notes est-elle la plus dispersée ?

Le support conclut : « il y a **plusieurs façons d'envisager la mesure de la dispersion** d'une série de données — point de référence, pondération de la valeur des écarts, pondération des effectifs, etc. »

DÉMONSTRATION — VÉRIFIONS D'ABORD QUE LES QUATRE CAS ONT BIEN LA MÊME MOYENNE

C'est le point de départ de toute la partie 2 : **la position ne dit rien de la dispersion.**

- Cas 1 : $50 \times 12 / 50 = 12$ ✓
- Cas 2 : $5(7+8+9+10+11+13+14+15+16+17)/50 = 5 \times 120/50 = 12$ ✓
- Cas 3 : $(20 \times 6 + 20 \times 18 + 10 \times 12)/50 = 600/50 = 12$ ✓
- Cas 4 : $(5 \times 4 + 10 \times 8 + 10 \times 10 + 10 \times 14 + 10 \times 16 + 5 \times 20)/50 = 600/50 = 12$ ✓

Quatre classes, une seule moyenne, quatre réalités radicalement différentes : dans la première, personne n'est en difficulté ; dans la troisième, la classe est coupée en deux blocs qui ne se ressemblent pas. **Un enseignant qui ne connaîtrait que la moyenne ne verrait aucune différence.** C'est exactement la limite du chapitre sur la position.

2.2.2 L'étendue (diapositive 28)

DÉFINITION — L'ÉTENDUE

*L'étendue d'une série est la **différence entre le maximum et le minimum** de la série.*

- Exemple du support : les notes dans une classe vont de 3 à 17 → **l'étendue vaut 14.**
- Il s'agit d'une **amplitude calculée sur l'intégralité de la série.**
- Cet indicateur, **très simple, ne rend compte que des extrêmes.**
- Il est donc **par définition sensible aux grandeurs extrêmes.**

EXEMPLE CHIFFRÉ — LES ÉTENDUES DES QUATRE CAS

	Minimum	Maximum	Étendue
Cas 1	12	12	0
Cas 2	7	17	10
Cas 3	6	18	12
Cas 4	4	20	16

Selon l'étendue, le cas 4 est le plus dispersé. Retenez ce classement : les indicateurs suivants ne donneront **pas tous la même réponse**, et c'est précisément la leçon du support.

2.2.3 Les écarts inter-quantiles (diapositive 29)

DÉFINITION — L'ÉCART INTER-CENTILES ET SES VARIANTES

*L'écart inter-centiles correspond à un indicateur d'étendue d'une distribution tronquée (on a enlevé des données les 1 % les plus faibles et les 1 % les plus forts). C'est la différence entre le centile **C99** et le centile **C1**.*

- De façon équivalente, l'**écart inter-déciles D9 – D1**, auquel cas c'est **20 % de la population qui est sortie** de l'indicateur.
- Ou l'**écart inter-quartile Q3 – Q1**, qui s'intéresse à l'amplitude entre le maximum et le minimum des **50 % de la population situés au centre** de la distribution, autour de la médiane.
- Les écarts inter-quantiles peuvent aussi se calculer **de façon relative**, c'est-à-dire **sous forme de ratio** : D9/D1, etc.

DÉMONSTRATION — POURQUOI TRONQUER, ET CE QUE CHANGE LE PASSAGE À L'ÉCART RELATIF

Pourquoi tronquer. L'étendue est fondée sur deux observations seulement, les plus atypiques de la série. Une seule valeur aberrante — une erreur de saisie, un cas exceptionnel — la fait exploser. **Tronquer les extrêmes rend l'indicateur robuste** : c'est la même idée que la médiane, appliquée à la dispersion.

Combien on retire :

Indicateur	Part de la population exclue	Ce qui reste
Étendue	0 %	Toute la série, extrêmes compris
C99 – C1	2 % (1 % de chaque côté)	98 % du centre
D9 – D1	20 % (10 % de chaque côté)	80 % du centre
Q3 – Q1	50 % (25 % de chaque côté)	La moitié centrale

Écart absolu ou ratio ? L'écart D9 – D1 s'exprime **dans l'unité des données** (des euros) ; le ratio D9/D1 est **sans unité**. Conséquence pratique majeure : **seul le ratio permet de comparer des populations de niveaux très différents**. Comparer l'écart D9 – D1 des cadres et des employés mélange l'inégalité et le niveau de salaire ; comparer D9/D1 isole l'inégalité. On retrouvera cette idée avec le **coefficient de variation** (§2.2.13).

2.2.4 Les quantiles (diapositives 30 et 31)

DÉFINITION — LES QUANTILES, GÉNÉRALISATION DE LA MÉDIANE

Les quantiles se comprennent comme une *généralisation de la notion de médiane*.

Quantiles	Nombre de parts égales	Points de découpe
Médiane	2	50 % en dessous, 50 % au-dessus
Quartiles	4	25 % sous Q1, 25 % entre Q1 et Q2, 25 % entre Q2 et Q3, 25 % au-dessus de Q3
Déciles	10	10 % sous D1, ..., 10 % au-dessus de D9
Centiles	100	1 % sous C1, ..., 1 % au-dessus de C99

DÉFINITION — INTERPRÉTATION D'UN QUANTILE

Le quantile d'ordre x % correspond au **niveau de la variable X** tel que x % de la population dispose d'une modalité de la variable inférieure à q .

- Le quantile d'ordre 10 % est le premier décile **D1**.
- Le quantile d'ordre 50 % est la **médiane**.
- Le quantile d'ordre 75 % est le troisième quartile **Q3**.
- Le quantile d'ordre 4 % est le quatrième centile **C4**.
- **Si q est le quantile d'ordre α %, alors α % de la population a une valeur de X inférieure à q .**

Et le support ajoute la formulation la plus profonde du chapitre :

Il s'agit aussi de l'inverse de la fonction de répartition empirique. Si $F(q) = \alpha$ alors $q = F^{-1}(\alpha)$.

DÉMONSTRATION — « L'INVERSE DE LA FONCTION DE RÉPARTITION » — CE QUE CELA SIGNIFIE VRAIMENT

Le chapitre 1 a construit les **fréquences cumulées F** : on part d'une **valeur** et on obtient une **proportion**. « Quelle part de la population a au plus 2 frères et sœurs ? » $\rightarrow F(2) = 77$ %.

Le quantile fait **exactement le trajet inverse** : on part d'une **proportion** et on obtient une **valeur**. « Quelle valeur laisse 77 % de la population en dessous ? » $\rightarrow 2$.

$$F : \text{valeur} \longrightarrow \text{proportion} \qquad F^{-1} : \text{proportion} \longrightarrow \text{valeur}$$

Ce sont deux lectures de la même colonne — celle des fréquences cumulées — dans un sens puis dans l'autre. C'est pourquoi le calcul des quantiles (diapositive 33) est la même interpolation que celui de la médiane (diapositive 25) : la médiane **est** le quantile d'ordre 50 %.

ANALOGIE — MARCHÉS FINANCIERS

F^{-1} est l'outil quotidien de la gestion du risque. La *Value at Risk* à 99 % sur un horizon d'un jour est le **quantile d'ordre 1 %** de la distribution des variations quotidiennes : la perte qui n'est dépassée qu'un jour sur cent. Vous savez désormais la calculer par interpolation. La suite du raisonnement — pourquoi ce quantile est systématiquement sous-estimé sur données réelles — tient aux **queues épaisses** des distributions financières, et c'est là que l'inégalité de Bienaymé-Tchebychev (§2.2.10) devient précieuse : elle, elle ne suppose aucune loi.

2.2.5 Application des indicateurs aux quatre cas (diapositive 32)

DÉFINITION — LES RÉSULTATS DONNÉS PAR LE SUPPORT

- **Cas n° 1** : tous les indicateurs sont à 0 (aucune dispersion).
- **Cas n° 2** : l'étendue vaut $17 - 7 = 10$; $D9 - D1 = 16 - 7 = 9$; $Q3 - Q1 = 14,5 - 8,5 = 6$.
- **Cas n° 3** : l'étendue vaut $18 - 6 = 12$; **calcul des déciles par interpolation difficile car choix à faire sur le support.**
- **Cas n° 4** : l'étendue vaut $20 - 4 = 16$; $D9 - D1 = 16 - 4 = 12$; $Q3 - Q1 = 14,5 - 7 = 7,5$.

Conclusion du support : « on constate que les indicateurs ne vont pas tous dans le même sens, loin de là ! »

POINT D'EXAMEN — LA PHRASE LA PLUS IMPORTANTE DE LA PARTIE 2

« Les indicateurs ne vont pas tous dans le même sens. » Regardons :

	Étendue	D9 – D1	Q3 – Q1
Cas 2	10	9	6
Cas 3	12	(indéterminé)	(indéterminé)
Cas 4	16	12	7,5

Selon l'**étendue**, le cas 4 est le plus dispersé. Mais le cas 3 — deux blocs à 6 et 18 — est visiblement le plus **polarisé**, et c'est lui qui aura la plus forte **variance** (§2.2.12). **Chaque indicateur mesure une idée différente de la dispersion** : l'étendue mesure l'écartement des extrêmes, l'écart inter-quantiles la largeur du centre, la variance l'éloignement moyen à la moyenne.

Ce que dit le support sur le cas 3, et qu'il faut comprendre : « choix à faire sur le support ». Avec seulement trois valeurs distinctes (6, 12, 18), un décile tombe à l'intérieur d'un bloc d'observations identiques ; l'interpolation exige alors de décider quelle largeur attribuer à ce bloc — une convention, non un calcul. **C'est une limite des quantiles sur les distributions très discrètes**, à savoir signaler.

2.2.6 Calcul d'un quantile à partir d'une distribution (diapositive 33)

FORMULE CLÉ — LE QUANTILE D'ORDRE A %

Lorsque les données sont présentées sous forme de distribution intégrant les fréquences cumulées :

- **si** on dispose d'une valeur de X telle que $F(x_j) = \alpha \%$, **alors le quantile vaut x_j** ;
- **sinon**, par interpolation linéaire, si $F(x_a) < \alpha \%$ et $F(x_b) > \alpha \%$:

$$Q_{\alpha\%} \approx x_a + \frac{(x_b - x_a)(\alpha\% - F(x_a))}{F(x_b) - F(x_a)} \quad (10)$$

POINT D'EXAMEN — C'EST LA FORMULE (9), AVEC A À LA PLACE DE 50 %

Comparez les formules (9) et (10) : elles sont **identiques**, à ceci près que 0,5 est remplacé par $\alpha\%$. **Il n'y a donc qu'une seule formule à retenir dans tout le chapitre**, celle de l'interpolation linéaire — la médiane en est le cas particulier $\alpha = 50\%$.

Méthode en trois temps, valable pour tous les quantiles :

1. Construire la colonne des **fréquences cumulées**.
2. Repérer les deux modalités qui **encadrent** $\alpha\%$.
3. Appliquer l'interpolation.

2.2.7 Interpréter des quantiles : le niveau de vie (diapositives 34 et 35)

Le tableau du support — Répartition du niveau de vie en France, Enquête Revenus Fiscaux et Sociaux :

Indicateur	Niveau de vie en 2024 (€ par UC)
D1	13 970
D2	17 700
D3	20 980
D4	23 880
D5	26 740
D6	29 880
D7	33 680
D8	38 780
D9	48 580
C95 (ou P95)	61 220

MÉTHODE — « € PAR UC » — UN SIGLE NON EXPLICITÉ PAR LE SUPPORT

UC = unité de consommation. On ne compare pas directement les revenus de deux ménages de tailles différentes : un couple avec deux enfants n'a pas besoin de quatre fois le revenu d'une personne seule pour vivre aussi bien, parce que certaines dépenses sont partagées — logement, chauffage, équipement.

Le **niveau de vie** rapporte donc le revenu du ménage à un nombre d'**unités de consommation** qui pondère ses membres (par convention courante : 1 pour le premier adulte, 0,5 pour les autres personnes de 14 ans et plus, 0,3 pour les enfants de moins de 14 ans). **Tous les membres d'un même ménage ont ainsi le même niveau de vie.** C'est ce qui rend les déciles comparables d'un ménage à l'autre.

CORRIGÉ — INTERPRÉTER CES QUANTILES — CE QUE L'ORAL DÉVELOPPE

Trois phrases de lecture à savoir produire :

« En 2024, **10 % des personnes** ont un niveau de vie **inférieur à 13 970 €** par unité de consommation. » (D1)
« La moitié de la population a un niveau de vie inférieur à **26 740 €** — c'est la **médiane**. » (D5) « **5 % des personnes** ont un niveau de vie **supérieur à 61 220 €**. » (C95, lu par complément)

Le rapport inter-décile : $D9/D1 = 48\,580 / 13\,970 = 3,48$. Lecture : les 10 % les plus aisés ont un niveau de vie **au moins 3,5 fois supérieur** au plafond des 10 % les plus modestes.

L'asymétrie, que le support demande de déduire des écarts. Calculons les écarts entre déciles successifs :

Écart	Valeur (€)	Écart	Valeur (€)
D2 – D1	3 730	D6 – D5	3 140
D3 – D2	3 280	D7 – D6	3 800
D4 – D3	2 900	D8 – D7	5 100
D5 – D4	2 860	D9 – D8	9 800
		C95 – D9	12 640

Les écarts se resserrent jusqu'au milieu de la distribution (minimum de 2 860 € entre D4 et D5), puis **s'écartent brutalement vers le haut** : le passage de D8 à D9 vaut à lui seul plus de trois fois le passage de D4 à D5, et les cinq derniers centiles couvrent 12 640 €.

C'est la signature d'une distribution étalée à droite — asymétrique positive. Elle confirme la propriété 3 de la moyenne : sur une telle distribution, **la moyenne est supérieure à la médiane**, et c'est pourquoi on publie des niveaux de vie **médians**.

PIÈGE FRÉQUENT — UNE INCOHÉRENCE DE LA DIAPOSITIVE 35 — À CONNAÎTRE

La diapositive 35, intitulée « **Revenus déclarés par déciles et centiles des individus retraités, année 2008** », affiche un graphique dont le titre interne est « Niveau de vie par UC (en €) » et dont les **dix valeurs sont exactement celles du tableau de la diapositive 34** (13 970, 17 700, ..., 61 220), lesquelles portent sur **le niveau de vie de l'ensemble de la population en 2024**.

Le titre de la diapositive et les données affichées ne correspondent donc pas. Il s'agit très probablement d'un titre resté d'une version antérieure du diaporama.

Conduite à tenir : retenez les **valeurs** et la **méthode de lecture** — c'est cela qui est enseigné — et signalez à l'enseignante l'écart de titre. Ne construisez surtout pas une interprétation « sur les retraités en 2008 » à partir de ces chiffres.

2.2.8 La représentation graphique : le *boxplot* (diapositives 36 et 37)

DÉFINITION — LA BOÎTE À MOUSTACHES

Le graphique *boxplot* ou *boîte à moustaches* permet une **représentation résumée de la distribution** d'un caractère statistique.

- **Au centre de la boîte** : la médiane.
- **Les contours de la boîte** : les 1^{er} et 3^e quartiles.
- **Les moustaches** : peuvent varier selon les logiciels — 1,5 fois l'écart interquartile, déciles 1 et 9, etc.
- Ce graphique permet de **visualiser assez bien les asymétries** des distributions ; il est **intéressant pour comparer plusieurs distributions**.

Le **schéma du support** (diapositive 37) porte les annotations suivantes : la boîte est bornée par Q_1 et Q_3 , coupée par un trait vertical marqué **Mé** (la médiane) ; la largeur de la boîte est notée $IQR = Q_3 - Q_1$; une flèche indique $1,5 \times IQR$ au-delà de Q_3 ; les moustaches se terminent par un trait vertical ; et un point isolé, à droite, est étiqueté « **valeur atypique** ». L'axe horizontal est gradué de 30 à 80.

DÉMONSTRATION — LIRE UN BOXPLOT EN QUATRE INFORMATIONS

Ce que l'on regarde	Ce que cela dit
La position du trait central	La médiane — où se situe la distribution
La largeur de la boîte (IQR)	La dispersion des 50 % centraux
La position du trait central <i>dans</i> la boîte	L' asymétrie : décalé à gauche → distribution étalée à droite
Les points au-delà des moustaches	Les valeurs atypiques (<i>outliers</i>)

Sur le **schéma du support**, la médiane est légèrement décalée vers la droite de la boîte, et la moustache droite est plus longue que la gauche, avec une valeur atypique isolée vers 80.

La **règle des $1,5 \times IQR$** , très répandue, mérite d'être connue : les moustaches s'arrêtent à la dernière observation située à moins de $1,5 \times IQR$ du bord de la boîte ; au-delà, les points sont tracés individuellement comme atypiques. **Mais le support prévient que la convention varie selon les logiciels** — d'où la nécessité de toujours préciser, en légende, ce que représentent les moustaches.

ANALOGIE — MARCHÉS FINANCIERS

Le boxplot est l'outil standard de comparaison de distributions de rendements entre actifs, périodes ou stratégies : il montre d'un coup d'œil la médiane, la dispersion centrale, l'asymétrie et les points extrêmes. Sur des séries financières, **la queue des observations atypiques est précisément l'information la plus importante** — celle qu'un résumé par moyenne et écart-type efface.

2.2.9 Interpréter des quantiles par catégorie (diapositive 38)

Le tableau du support — salaires, source Insee, tous salariés en France hors Mayotte (* les chefs d'entreprise salariés sont inclus dans les cadres) :

	Ensemble	Cadres*	Professions intermédiaires	Employés	Ouvriers
D1	1 440	2 240	1 640	1 380	1 380
Q1	1 660	2 810	1 940	1 510	1 570
D5	2 090	3 620	2 360	1 730	1 830
Q3	2 880	4 930	2 890	2 060	2 200
D9	4 160	7 060	3 590	2 520	2 630
D9 – D1	2 720	4 820	1 950	1 140	1 250
D9/D1	2,9	3,2	2,2	1,8	1,9

CORRIGÉ — LA QUESTION POSÉE : DANS QUELLE CSP LES SALAIRES SONT-ILS LE PLUS DISPERSÉS ? LE MOINS ?

Les deux indicateurs concordent ici, ce qui n'est pas toujours le cas :

- **Les plus dispersés : les cadres.** Écart absolu le plus élevé ($D9 - D1 = 4\,820$ €) et ratio le plus élevé ($D9/D1 = 3,2$).
- **Les moins dispersés : les employés.** Écart absolu le plus faible ($1\,140$ €) et ratio le plus faible ($1,8$).

Vérification des calculs du tableau : cadres $7\,060 - 2\,240 = 4\,820$ ✓ et $7\,060/2\,240 = 3,15 \rightarrow 3,2$ ✓ ; employés $2\,520 - 1\,380 = 1\,140$ ✓ et $2\,520/1\,380 = 1,83 \rightarrow 1,8$ ✓

Pourquoi il faut regarder les deux indicateurs. L'écart absolu mélange **inégalité** et **niveau** : les cadres gagnent plus, donc leurs écarts en euros sont mécaniquement plus grands. Le ratio neutralise le niveau. Ici les deux classements coïncident, ce qui **renforce** la conclusion ; s'ils divergeaient, il faudrait dire lequel répond à la question posée.

POINT D'EXAMEN — LE DÉTAIL QUE PRESQUE PERSONNE NE RELÈVE — ET QUI VAUT BEAUCOUP

L'écart inter-décile de l'ensemble (2 720 €) est supérieur à celui de trois CSP sur quatre, et son ratio (2,9) est supérieur à celui de toutes les CSP sauf les cadres.

Pourquoi ? Parce que la dispersion de l'ensemble contient **deux sources** : la dispersion **à l'intérieur** de chaque catégorie **et** l'écart **entre** les catégories — un ouvrier médian gagne 1 830 €, un cadre médian 3 620 €, soit le double.

C'est exactement la décomposition intra / inter de la diapositive 58, rencontrée ici sans être nommée. Un total peut être plus inégalitaire que chacune de ses parties, parce que les parties diffèrent entre elles. Faire ce rapprochement dans une copie montre qu'on a lu le chapitre comme un tout.

2.2.10 Les indicateurs fondés sur les écarts à la moyenne (diapositives 39 à 41)

DÉFINITION — LE PLAN DE LA SECONDE MOITIÉ (DIAPOSITIVE 39)

*La notion de dispersion ayant un **contour flou**, il y a de multiples façons de la définir et de la mesurer.*

Après les indicateurs fondés sur les écarts entre 2 indicateurs — étendue, écart ou ratio interdéciles, écart ou ratio interquartiles — viennent **les indicateurs qui comparent l'ensemble des valeurs à la moyenne** : l'**écart absolu moyen**, la **variance**, l'**écart-type**.

DÉMONSTRATION — LA DIFFÉRENCE DE NATURE ENTRE LES DEUX FAMILLES

	Première famille (étendue, quantiles)	Seconde famille (EAM, variance, écart-type)
Combien d'observations utilisées	Deux (les deux bornes)	Toutes
Point de référence	Aucun — on compare deux quantiles entre eux	La moyenne
Robustesse	Forte pour les quantiles, nulle pour l'étendue	Faible : hérite de la sensibilité de la moyenne
Information utilisée	Les rangs	Les valeurs

Conséquence à retenir : une série peut avoir un faible écart inter-quartile — un centre très resserré — et une variance élevée, si quelques observations sont très éloignées. **Les deux familles ne sont pas redondantes : elles se complètent.**

DÉFINITION — LE PRINCIPE DU CALCUL (DIAPOSITIVE 40)

Le calcul peut se faire à partir de **données brutes** ou de données **représentées sous forme de distribution**.

- **Il y a donc plusieurs formules pour un même concept**, selon la façon dont les données sont présentées.
- Sur **données brutes** : une moyenne fondée sur **N écarts calculés observation par observation**.
- Sur **distribution** : une moyenne calculée sur l'ensemble des **p modalités, pondérée par les effectifs** observés pour chaque modalité.

FORMULE CLÉ — LES TROIS COLONNES DU TABLEAU DE CALCUL (DIAPOSITIVE 41)

Soit m_X la moyenne de X , et $i = 1, \dots, N$ observations x_i :

Colonne	Contenu	Notation
(1)	La série ordonnée	x_i
(2)	L' écart à la moyenne	$y_i = x_i - m_X$
(3)	L' écart absolu à la moyenne	$z_i = x_i - m_X $
(4)	Le carré de l'écart à la moyenne	$w_i = (x_i - m_X)^2$

« C'est ainsi que l'on obtient un tableau de calcul contenant N lignes. »

2.2.11 Le tableau de calcul en pratique (diapositives 42 et 43)

Le **tableau du support** porte sur une **série de 20 âges**. En voici le contenu intégral :

x_i	$y_i = x_i - m_X$	$z_i = x_i - m_X $	$w_i = (x_i - m_X)^2$
30,0	-17,9	17,9	320,4
36,0	-11,9	11,9	141,6
41,0	-6,9	6,9	47,6
42,0	-5,9	5,9	34,8
42,0	-5,9	5,9	34,8
44,0	-3,9	3,9	15,2
46,0	-1,9	1,9	3,6
47,0	-0,9	0,9	0,8
47,0	-0,9	0,9	0,8
47,0	-0,9	0,9	0,8
48,0	0,1	0,1	0,0
49,0	1,1	1,1	1,2
50,0	2,1	2,1	4,4
52,0	4,1	4,1	16,8
52,0	4,1	4,1	16,8

x_i	$y_i = x_i - m_x$	$z_i = x_i - m_x $	$w_i = (x_i - m_x)^2$
54,0	6,1	6,1	37,2
55,0	7,1	7,1	50,4
57,0	9,1	9,1	82,8
58,0	10,1	10,1	102,0
61,0	13,1	13,1	171,6
$m_x = 47,9$	$m_y = 0,0$	$m_z = 5,7$	$m_w = 54,2$

FORMULE CLÉ — LES TROIS INDICATEURS, LUS AU BAS DES COLONNES (DIAPOSITIVE 43)

Colonne 3 — l'écart absolu moyen :

$$EAM = \frac{1}{N} \sum_{i=1}^N |x_i - m_x| = 5,7$$

Lecture du support : « les âges s'écartent en moyenne de l'âge moyen (47,9 ans) de 5,7 années ».

Colonne 4 — la variance :

$$\sigma^2 = V(X) = \frac{1}{N} \sum_{i=1}^N (x_i - m_x)^2 = 54,2$$

« La variance vaut 54,2, elle **n'est pas d'une interprétation aisée** puisque les écarts d'âge sont mesurés **au carré**. »

L'écart-type :

$$\sigma = \sqrt{V(X)} = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - m_x)^2}$$

« est ici interprétable puisque mesuré en années ».

EXEMPLE CHIFFRÉ — VÉRIFICATION INTÉGRALE DES QUATRE COLONNES

J'ai recalculé la série complète : 30, 36, 41, 42, 42, 44, 46, 47, 47, 47, 48, 49, 50, 52, 52, 54, 55, 57, 58, 61.

- $N = 20$ observations ✓
- **Moyenne** : somme = 958, donc $m = 958/20 = 47,9$ ✓
- **Colonne 2** : moyenne des écarts = **0,0** ✓ — c'est la **propriété 1** de la diapositive 16, vérifiée numériquement.
- **Colonne 3** : EAM = **5,70** ✓
- **Colonne 4** : $\sigma^2 = 54,19$, arrondi à **54,2** ✓
- **Écart-type** : $\sigma = \sqrt{54,19} = 7,36$ ans — **le support ne le calcule pas, il faut le faire.**

Lecture complète, à savoir produire :

« L'âge moyen est de 47,9 ans, avec un écart-type de 7,4 ans. Les âges s'écartent donc de l'âge moyen d'environ 7 ans en ordre de grandeur. »

PIÈGE FRÉQUENT — EAM ET ÉCART-TYPE : POURQUOI 5,7 ET 7,4 DIFFÈRENT

Les deux mesurent « l'écart moyen », et pourtant ils ne donnent pas le même nombre. **L'écart-type est toujours supérieur ou égal à l'écart absolu moyen.**

La raison : le carré **pénalise davantage les grands écarts**. Un écart de 17,9 ans contribue 17,9 à l'EAM mais 320,4 à la variance, soit **56 fois plus** que l'écart de 0,1 an — alors qu'il n'est que 179 fois plus grand en valeur absolue... mais 32 000 fois plus grand une fois élevé au carré. **L'élévation au carré donne un poids disproportionné aux observations éloignées.**

Pourquoi alors préférer l'écart-type à l'EAM, qui est plus intuitif ? Trois raisons, dont la première est celle du cours :

1. La variance possède des **propriétés algébriques** que la valeur absolue n'a pas : formule de Koenig, décomposition intra/inter, additivité. On ne saurait rien démontrer avec l'EAM.
2. L'écart-type intervient dans l'**inégalité de Bienaymé-Tchebychev** (§2.2.12), qui lui donne une interprétation chiffrée.
3. C'est la convention universelle en finance et en économétrie.

2.2.12 L'interprétation de l'écart-type : l'inégalité de Bienaymé-Tchebychev (diapositive 44)

FORMULE CLÉ — L'INÉGALITÉ

C'est l'inégalité d'Irénée-Jules Bienaymé et Pafnouti Tchebychev qui va permettre d'interpréter l'écart-type en lien avec la moyenne.

Pour $k > 1$, l'intervalle $[m - k\sigma ; m + k\sigma]$ contient au moins $1 - 1/k^2$ des observations.

k	$1 - 1/k^2$	Énoncé
2	0,75	Au moins 75 % des observations sont dans $m \pm 2\sigma$
3	$\approx 0,89$	Au moins 89 % des observations sont dans $m \pm 3\sigma$

« C'est très pratique quand on ne nous donne qu'une moyenne et un écart-type pour résumer des données. »

DÉMONSTRATION — CE QUE L'INÉGALITÉ APPORTE, ET CE QU'ELLE N'APPORTE PAS

Ce qu'elle apporte — une garantie sans hypothèse. Elle est vraie pour n'importe quelle distribution : symétrique ou non, à une ou plusieurs bosses, à queues épaisses. C'est extrêmement rare en statistique, et c'est ce qui en fait un outil de sécurité.

Application sur la série des âges ($m = 47,9$, $\sigma = 7,36$) :

- $m \pm 2\sigma = [33,2 ; 62,6]$ → au moins 75 % des âges, soit 15 personnes sur 20, y sont. (Vérification : 19 des 20 âges y sont, soit 95 % — l'inégalité est bien respectée, et largement.)
- $m \pm 3\sigma = [25,8 ; 70,0]$ → au moins 89 %. (En fait 100 % ici.)

Ce qu'elle n'apporte pas — la précision. Le mot « au moins » est essentiel : l'inégalité donne un **minorant**, pas une valeur. Sur la série des âges, elle garantit 75 % là où la réalité est à 95 %. **Elle ne se trompe jamais, mais elle est très prudente.**

Et le piège à éviter absolument : ne confondez pas ces bornes avec la fameuse règle « 95 % dans $m \pm 2\sigma$ », qui suppose une distribution **normale**. Bienaymé-Tchebychev ne suppose rien et donne 75 % ; la loi normale suppose beaucoup et donne 95 %. **Sur des données réelles — en particulier financières — la première est fiable, la seconde optimiste.**

ANALOGIE — MARCHÉS FINANCIERS

Cette différence est l'une des causes documentées des grandes pertes de marché : les modèles de risque calibrés sur l'hypothèse normale attribuent aux mouvements extrêmes des probabilités infinitésimales, alors que les rendements réels présentent des **queues épaisses**. Bienaymé-Tchebychev, qui ne suppose aucune loi, fournit une borne toujours valable — au prix d'être très large. Retenir cette opposition « borne universelle mais large contre estimation précise mais conditionnelle » est plus utile, pour un professionnel du risque, que n'importe quelle formule du chapitre.

2.2.13 Application en finance : l'écart-type devient la volatilité (diapositives 45 à 48)

DÉFINITION — LE CADRE POSÉ PAR LE SUPPORT

L'écart-type, très utilisé, s'interprète comme un indicateur de volatilité des séries financières.

- La rentabilité journalière est le taux de variation entre le prix du jour et celui de la veille.
- Le risque associé peut se calculer sur un intervalle de jours (par exemple ici 22 jours).
- On va donc avoir un double indicateur qui nous donnera nos chances de succès.

La diapositive 45 projette un graphique à deux courbes sur la période : le **prix de l'action à la clôture en euros** (qui progresse d'environ 26 € à 40 €) et la **rentabilité journalière à la clôture en %**, qui oscille autour de zéro entre environ -7 % et +7 %.

FORMULE CLÉ — LA RENTABILITÉ JOURNALIÈRE

$$r_t = \frac{P_t - P_{t-1}}{P_{t-1}} \times 100$$

où P_t est le prix de clôture du jour et P_{t-1} celui de la veille.

Le tableau du support (diapositive 47) — Prix et rentabilité de l'action, extrait :

Date	Prix à la clôture (€)	Rentabilité à la clôture (%)
22/08/12	35,02	<i>incalculable</i>
23/08/12	34,78	-0,685
24/08/12	34,18	-1,725
27/08/12	34,90	2,106
28/08/12	34,53	-1,060
...	...	...
06/09/12	37,15	5,480
...	...	...
20/09/12	38,92	-1,543

EXEMPLE CHIFFRÉ — VÉRIFIONS TROIS LIGNES — ET COMPRENONS LA PREMIÈRE

Première ligne : « incalculable ». Le 22/08 est la première date de la série : il n'y a pas de veille, donc pas de P_{t-1} . **Une série de n prix ne donne que $n - 1$ rentabilités.** C'est une remarque de méthode qui vaut aussi pour les taux de croissance du chapitre 3.

Vérifications :

- 23/08 : $(34,78 - 35,02)/35,02 = -0,006853 \rightarrow -0,685 \% \checkmark$
- 24/08 : $(34,18 - 34,78)/34,78 = -0,017251 \rightarrow -1,725 \% \checkmark$
- 27/08 : $(34,90 - 34,18)/34,18 = +0,021065 \rightarrow +2,106 \% \checkmark$

Notez que les dates sautent le week-end : du 24/08 (vendredi) au 27/08 (lundi). La « rentabilité journalière » est donc une rentabilité **par séance de bourse**, pas par jour calendaire.

Le tableau de synthèse (diapositive 48) — Rentabilité journalière moyenne (en %) et volatilité (en %), année 2012 :

	Du 23/05 au 21/06	Du 22/06 au 23/07	Du 24/07 au 22/08	Du 23/08 au 21/09	Du 23/05 au 21/09
Jours	22	22	22	22	88
Rentabilité journalière moyenne	0,372	-0,307	1,244	0,587	0,474
Volatilité (écart-type)	2,555	3,374	3,128	1,954	2,861

PIÈGE FRÉQUENT — LES CONCLUSIONS DE LA DIAPOSITIVE 48 NE SE RECONSTRUISENT PAS — SIGNALÉ, NON MASQUÉ

Le support tire du tableau trois conclusions, reproduites ici **mot pour mot** :

« Il y a 99 % de chances de faire des gains en période 1, 2, 3, 5. Si l'on veut être plus prudent et s'assurer des gains 999 fois sur 1000, il ne fallait pas investir en période 1, 2, 4, 5. Bien entendu **rien ne garantit une rentabilité journalière positive à 100 %**. »

Le calcul qui les produit n'est pas montré, et je ne parviens pas à le reconstruire à partir de l'inégalité de la diapositive 44. Voici la vérification, pour que vous puissiez la refaire.

L'inégalité de Bienaymé-Tchebychev exige $k > 1$. Pour garantir un gain, il faudrait que la borne basse $m - k\sigma$ soit positive, donc que $k < m/\sigma$. Or :

Période	m	σ	$k_{\max} = m/\sigma$	Exploitable ?
1 (23/05-21/06)	0,372	2,555	0,15	Non : $k \leq 1$
2 (22/06-23/07)	-0,307	3,374	—	Moyenne négative
3 (24/07-22/08)	1,244	3,128	0,40	Non
4 (23/08-21/09)	0,587	1,954	0,30	Non
5 (23/05-21/09)	0,474	2,861	0,17	Non

Dans les cinq périodes, $m/\sigma < 1$: l'inégalité ne fournit aucune garantie de gain, à aucun seuil de confiance. Et la période 2, dont la rentabilité moyenne est **négative**, figure pourtant dans la liste des périodes à « 99 % de chances de gains » — ce qui est difficile à concilier avec n'importe quel calcul fondé sur la moyenne.

Conduite à tenir — et c'est important :

1. **Retenez ce qui est solide et enseigné** : la rentabilité journalière est un taux de variation ; l'écart-type des rentabilités est la **volatilité** ; le couple (rentabilité moyenne, volatilité) forme le **double indicateur** rendement / risque ; et Bienaymé-Tchebychev permet d'encadrer une distribution sans hypothèse de loi.
2. **Demandez à l'enseignante le détail du calcul des trois conclusions**. Il existe peut-être une étape faite « dans Excel » (le support l'indique : « on poursuit dans Excel... ») qui n'apparaît pas sur la diapositive — par exemple un raisonnement sur la rentabilité **cumulée** sur 22 séances plutôt que sur la rentabilité journalière.
3. **Ne reproduisez pas ces conclusions en examen sans le calcul qui les fonde**. Une copie qui affirme « 99 % de chances de gains » sans démonstration est indéfendable ; une copie qui écrit « la période 3 présente la meilleure rentabilité moyenne (1,244 %) mais aussi une volatilité élevée (3,128 %) ; la période 4 offre le meilleur rapport rendement/risque avec 0,587 % pour une volatilité de 1,954 % » est exacte et vérifiable.

EXEMPLE CHIFFRÉ — CE QUE LE TABLEAU PERMET DE DIRE, RIGOREUSEMENT

Comparons les périodes par le rapport rentabilité / volatilité — un rapport sans unité, directement inspiré du coefficient de variation de la diapositive 53 :

Période	m (%)	σ (%)	m/σ	Lecture
1	0,372	2,555	0,15	Rendement faible, risque moyen
2	-0,307	3,374	< 0	Rendement négatif et risque le plus élevé
3	1,244	3,128	0,40	Meilleur rendement , risque élevé
4	0,587	1,954	0,30	Rendement correct, risque le plus faible
5 (ensemble)	0,474	2,861	0,17	La moyenne des quatre sous-périodes

Deux observations solides :

1. **La période 2 est la seule à rentabilité négative**, et c'est aussi la plus volatile : elle est dominée par toutes les autres.
2. **La volatilité de l'ensemble (2,861) n'est pas la moyenne des volatilités des sous-périodes** — laquelle vaut $(2,555 + 3,374 + 3,128 + 1,954)/4 = 2,753$. **L'écart-type ne s'agrège pas linéairement**, et c'est précisément le problème que pose la diapositive 49.

2.2.14 Le problème de l'agrégation et la formule de Koenig (diapositives 49 et 50)

DÉFINITION — LE PROBLÈME POSÉ (DIAPOSITIVE 49)

- **La moyenne (arithmétique) peut se calculer par groupe** — c'est un opérateur linéaire.
- **L'écart-type n'est pas linéaire.**
- **On ne peut pas calculer facilement la volatilité annuelle.**
- **... mais il y a un moyen.**

FORMULE CLÉ — LES PROPRIÉTÉS DE LA VARIANCE (DIAPOSITIVE 50)

1. Formule de Koenig. La variance se calcule aussi comme :

$$V(X) = \frac{1}{N} \sum_{i=1}^N x_i^2 - m_X^2$$

(« la moyenne des carrés moins le carré de la moyenne »)

2. Invariance par translation. Si j'ajoute le même nombre a à toutes les valeurs de X , la **variance est inchangée** : $V(a + X) = V(X)$.

3. Non-linéarité. Si je multiplie tous les éléments par a , la **variance est multipliée par a^2** : $V(aX) = a^2 V(X)$.

4. Corollaire : $V(-X) = V(X)$.

DÉMONSTRATION — POURQUOI CES TROIS PROPRIÉTÉS, ET POURQUOI ELLES RÈGENT LE PROBLÈME

Koenig — pourquoi elle est utile. La formule de définition exige de connaître la moyenne **avant** de pouvoir calculer chaque écart : deux passages sur les données. La formule de Koenig ne demande que **deux sommes** — celle des x_i et celle des x_i^2 — calculables en un seul passage. **C'est ce qui rend l'agrégation possible** (diapositive 57) : il suffit de transmettre deux nombres par groupe.

Vérification sur la série des âges : moyenne des carrés = 2 348,1 ; carré de la moyenne = $47,9^2 = 2 294,41$; différence = **54,19** — identique au calcul par les écarts ✓

Invariance par translation — la démonstration. Si $Y = X + a$, alors $m_Y = m_X + a$ (linéarité de la moyenne), donc $y_i - m_Y = (x_i + a) - (m_X + a) = x_i - m_X$: **les écarts sont inchangés**, donc la variance aussi. **Traduction concrète** : **ajouter 6 points à toutes les notes déplace la distribution sans la déformer.**

Non-linéarité — la démonstration. Si $Y = aX$, alors $m_Y = a m_X$, donc $y_i - m_Y = a(x_i - m_X)$, et en élevant au carré : $(y_i - m_Y)^2 = a^2 (x_i - m_X)^2$. D'où $V(aX) = a^2 V(X)$. **Sur l'écart-type**, cela donne $\sigma_{aX} = |a| \sigma_X$ — l'écart-type, lui, est multiplié par $|a|$, et c'est ce qui le rend interprétable.

Corollaire $V(-X) = V(X)$: avec $a = -1$, $a^2 = 1$. Retourner une série ne change pas sa dispersion — évident intuitivement, et démontré en une ligne.

Les illustrations du support (diapositives 51 et 52). Deux graphiques superposent la distribution de **115 notes** et sa transformée :

- **Diapositive 51 — 115 notes augmentées de 6 points.** La distribution initiale, de moyenne **7,25**, est translatée vers la droite ; la nouvelle moyenne est **13,25** ($7,25 + 6$). **La forme est rigoureusement identique** : même hauteurs, mêmes écarts. **La variance est inchangée.**
- **Diapositive 52 — 115 notes multipliées par 2.** La moyenne passe de **7,25** à **14,50** ($7,25 \times 2$), mais **la distribution s'étale** : les barres s'écartent les unes des autres. **La variance est multipliée par 4**, l'écart-type par 2.

POINT D'EXAMEN — LES DEUX GRAPHIQUES DISENT TOUT — SAVOIR LES DÉCRIRE VAUT UNE DÉMONSTRATION

Placez côte à côte les deux illustrations : **l'une translate, l'autre dilate.**

- Ajouter une constante → la distribution **glisse** → moyenne décalée, **dispersion identique**.
- Multiplier par une constante → la distribution **s'étire** → moyenne multipliée, **dispersion multipliée par le carré** (variance) ou par la constante (écart-type).

Application immédiate en notation : ajouter 2 points à toute une classe ne réduit pas les écarts entre élèves ; multiplier les notes par 1,2 les augmente. **Deux façons de « remonter » une classe, deux effets opposés sur l'inégalité des notes.**

2.2.15 Le coefficient de variation (diapositive 53)

FORMULE CLÉ — LE COEFFICIENT DE VARIATION

- Les mesures de la variance et de l'écart-type sont **sensibles à la conversion d'unités de mesure** (changement de monnaie, de métrique, etc.).
- Le coefficient de variation est **exprimé sans unité**, en pourcentage.
- Il permet des **comparaisons d'indicateurs de dispersion entre caractères mesurés différemment**.

$$CV = \frac{\sigma_X}{m_X}$$

DÉMONSTRATION — POURQUOI IL FAUT UN INDICATEUR SANS UNITÉ — LA DÉMONSTRATION PAR L'EXEMPLE

Le problème. Un écart-type de 500 est-il grand ? Impossible de répondre sans savoir de quoi il s'agit.

- Sur des salaires mensuels de moyenne 2 000 € : $CV = 500/2\,000 = 25\%$ — dispersion considérable.
- Sur des salaires annuels de moyenne 24 000 € : $CV = 500/24\,000 = 2,1\%$ — dispersion faible.

Le même nombre décrit deux réalités opposées. La propriété 3 de la variance l'explique : passer du mensuel à l'annuel multiplie les valeurs par 12, donc l'écart-type par 12. Le CV, lui, est **invariant** par ce changement d'unité : $CV_{aX} = |a|\sigma_X / (a m_X) = CV_X$.

Les deux usages :

1. Comparer la dispersion de **deux variables différentes** — des salaires et des âges, par exemple, ce qu'aucun écart-type ne permet.
2. Comparer la dispersion de **deux populations de niveaux très différents** — même logique que le ratio $D9/D1$ contre l'écart $D9 - D1$ (§2.2.3).

ANALOGIE — MARCHÉS FINANCIERS

σ/m est exactement l'inverse d'un **ratio de Sharpe** simplifié — lequel rapporte le rendement excédentaire à la volatilité, $(m - r_f)/\sigma$. La logique est identique : **un rendement ne se juge jamais seul, il se rapporte au risque pris pour l'obtenir**. Le tableau du §2.2.13 en donne l'application : la période 3 a le meilleur rendement brut, la période 4 le meilleur rapport rendement/risque. Ce sont deux réponses à deux questions différentes.

2.2.16 La variance à partir d'une distribution (diapositives 54 à 56)

FORMULE CLÉ — LES QUATRE ÉCRITURES ÉQUIVALENTES

Lorsqu'on n'a pas les données brutes mais un **tableau de distribution** — p modalités, effectifs n_i , fréquences f_i , l'indice i renvoyant au **numéro de modalité** :

À partir des effectifs :

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^p n_i (x_i - m)^2 = \frac{1}{N} \sum_{i=1}^p n_i x_i^2 - m^2 \quad (11)$$

À partir des fréquences :

$$\sigma^2 = \sum_{i=1}^p f_i (x_i - m)^2 = \sum_{i=1}^p f_i x_i^2 - m^2 \quad (12)$$

POINT D'EXAMEN — QUATRE FORMULES, UNE SEULE IDÉE

Les quatre écritures ne sont **pas quatre formules à mémoriser** : ce sont deux choix indépendants.

1. **Effectifs ou fréquences** ? $\frac{1}{N} \sum n_i \dots$ ou $\sum f_i \dots$ — simple passage de n_i à $f_i = n_i/N$.

2. **Écarts ou Koenig** ? $\sum (x_i - m)^2$ ou $\sum x_i^2 - m^2$.

$2 \times 2 = 4$ écritures, **une seule variance**. En pratique : Koenig avec les fréquences est le plus rapide à la main, les écarts sont plus sûrs quand la moyenne tombe juste.

PIÈGE FRÉQUENT — LE RÉSULTAT DU CAS N° 4 (DIAPOSITIVE 55) EST ERRONÉ — VÉRIFICATION COMPLÈTE

Le support donne, pour les quatre cas de l'introduction :

Cas 1 : $\sigma^2 = 0$ et $\sigma = 0$ — Cas 2 : $\sigma^2 = 11$ et $\sigma = 3,3$ — Cas 3 : $\sigma^2 = 28,8$ et $\sigma = 5,4$ — Cas 4 : $\sigma^2 = 10,4$ et $\sigma = 3,2$.

J'ai refait les quatre calculs. Les trois premiers sont exacts ; le quatrième ne l'est pas.

Cas 2 (5 élèves à chacune des notes 7, 8, 9, 10, 11, 13, 14, 15, 16, 17) :

$$\sigma^2 = \frac{5}{50} [25+16+9+4+1+1+4+9+16+25] = \frac{5 \times 110}{50} = 11 \checkmark \quad \sigma = 3,32 \checkmark$$

$$\text{Cas 3 (20 à 6, 20 à 18, 10 à 12)} : \sigma^2 = \frac{20(36) + 20(36) + 10(0)}{50} = \frac{1\,440}{50} = 28,8 \checkmark \quad \sigma = 5,37 \checkmark$$

Cas 4 (5 à 4, 10 à 8, 10 à 10, 10 à 14, 10 à 16, 5 à 20) :

$$\begin{aligned} \sigma^2 &= \frac{5(4-12)^2 + 10(8-12)^2 + 10(10-12)^2 + 10(14-12)^2 + 10(16-12)^2 + 5(20-12)^2}{50} \\ &= \frac{5(64) + 10(16) + 10(4) + 10(4) + 10(16) + 5(64)}{50} = \frac{320+160+40+40+160+320}{50} = \frac{1\,040}{50} = 20,8 \end{aligned}$$

d'où $\sigma = \sqrt{20,8} = 4,56$.

La valeur du support (10,4) est exactement la moitié de 20,8 — l'écart évoque une division par 100 au lieu de 50, ou une somme partielle.

Ce que l'erreur change — et c'est pourquoi il faut le savoir. Le classement des dispersions n'est pas le même :

	Variance du support	Variance recalculée
Cas 1	0	0
Cas 2	11	11
Cas 3	28,8	28,8
Cas 4	10,4	20,8
Classement	3 > 2 > 4 > 1	3 > 4 > 2 > 1

La réponse à la question d'introduction — « dans quel cas la distribution est-elle la plus dispersée ? » — reste **le cas 3** dans les deux versions. Mais la place relative des cas 2 et 4 s'inverse. **Et le classement corrigé est cohérent avec l'étendue** (cas 4 : 16 contre cas 2 : 10), ce qui n'était pas le cas de la version du support.

Conduite à tenir : refaites le calcul, il prend deux minutes ; signalez-le à l'enseignante. Si la question tombe en examen, présentez le calcul détaillé — un résultat justifié ligne à ligne ne peut pas être compté faux.

MÉTHODE — CHOISIR LA BONNE FORMULE (DIAPOSITIVE 56)

Pour déterminer quel type de calcul adopter, il faut identifier **les éléments statistiques et le mode de représentation des données** choisies :

- **données brutes** (raw data) : toutes les observations individuelles sont disponibles ;
- **données sous forme de distribution** : toutes les modalités sont disponibles ainsi que les effectifs et les fréquences ;
- **données présentées sous forme agrégée par sous-groupes** : certains indicateurs peuvent être agrégés si l'on dispose de suffisamment d'informations.

L'arbre de décision, à appliquer avant tout calcul :

Ce dont je dispose	Formule de la moyenne	Formule de la variance
Les N observations	$\frac{1}{N} \sum_{i=1}^N x_i$ (3)	$\frac{1}{N} \sum (x_i - m)^2$
Modalités + effectifs	$\frac{1}{N} \sum_{i=1}^p n_i x_i$ (4)	$\frac{1}{N} \sum n_i x_i^2 - m^2$ (11)
Modalités + fréquences	$\sum f_i x_i$ (5)	$\sum f_i x_i^2 - m^2$ (12)
Moyennes et variances par groupe	$\sum \frac{n_k}{N} m_k$ (6)	Agrégation par Koenig (§2.2.17)

C'est la question à se poser en premier devant un exercice : de quelle forme sont mes données ? Se tromper de formule est l'erreur la plus fréquente en devoir.

2.2.17 La variance par agrégation (diapositive 57)

FORMULE CLÉ — LA VARIANCE AGRÉGÉE PAR LA FORMULE DE KOENIG

Soient K sous-groupes d'effectifs N_k , de moyennes m_{X_k} et de variances σ_k^2 , avec $\sum_{k=1}^K N_k = N$:

- **Moyenne agrégée** : $m_X = \frac{1}{N} \sum_{k=1}^K N_k m_{X_k}$
- **Pour chaque groupe**, la formule de Koenig donne : $\sum_{i=1}^{N_k} x_i^2 = [\sigma_k^2 + m_{X_k}^2] N_k$
- **Au niveau agrégé** : $\sum_{i=1}^N x_i^2 = \sum_{k=1}^K \sum_{i=1}^{N_k} x_i^2$
- **D'où la variance agrégée** :

$$\sigma^2 = \frac{1}{N} \sum_{k=1}^K [\sigma_k^2 + m_{X_k}^2] N_k - m_X^2$$

DÉMONSTRATION — LA CHAÎNE DU RAISONNEMENT, MAILLON PAR MAILLON

Le support enchaîne quatre lignes sans les commenter. Voici pourquoi chacune est nécessaire.

1. **Le problème.** La variance globale demande $\sum x_i^2$ sur toute la population — or on ne dispose que d'indicateurs par groupe, pas des observations.
2. **Koenig retourné.** Pour un groupe k , $\sigma_k^2 = \frac{1}{N_k} \sum x_i^2 - m_k^2$. En isolant la somme des carrés :
 $\sum_{i \in k} x_i^2 = (\sigma_k^2 + m_k^2) N_k$. **C'est le maillon décisif : la somme des carrés d'un groupe se reconstitue à partir de sa moyenne, de sa variance et de son effectif — trois nombres.**
3. **On additionne les groupes.** La somme des carrés sur toute la population est la somme des sommes de carrés des groupes, ces derniers étant **disjoints**.
4. **On applique Koenig à l'ensemble.** $\sigma^2 = \frac{1}{N} \sum x_i^2 - m_X^2$, où la somme a été reconstituée à l'étape 3.

C'était l'annonce de la diapositive 49 : « on ne peut pas calculer facilement la volatilité annuelle... mais il y a un moyen ». **Le moyen, c'est Koenig.** Il faut connaître, pour chaque période, **trois nombres seulement** : l'effectif, la moyenne, la variance.

2.2.18 Corollaire : la décomposition de la variance (diapositive 58)

FORMULE CLÉ — VARIANCE INTRA, VARIANCE INTER, VARIANCE TOTALE

*La connaissance des variances par groupe et de la variance globale permet de mesurer l'importance des variations dites **intra** et **inter** groupes dans la variation totale.*

Variance intra-groupe — la dispersion à l'intérieur des groupes :

$$V_{\text{intra}} = \sum_{k=1}^K \frac{N_k}{N} \sigma_k^2$$

Variance inter-groupe — la dispersion des moyennes entre groupes :

$$V_{\text{inter}} = \sum_{k=1}^K \frac{N_k}{N} (m_{X_k} - m_X)^2 = \sum_{k=1}^K \frac{N_k}{N} m_{X_k}^2 - m_X^2$$

Et la relation fondamentale :

$$\boxed{\sigma^2 = V_{\text{intra}} + V_{\text{inter}}}$$

DÉMONSTRATION — CE QUE LA DÉCOMPOSITION SIGNIFIE — ET POURQUOI C'EST L'OUTIL LE PLUS PUISSANT DU CHAPITRE

L'idée. Deux personnes peuvent différer pour deux raisons : parce qu'elles n'appartiennent pas au même groupe (un cadre et un ouvrier), ou parce qu'à l'intérieur de leur groupe elles ne sont pas identiques (deux cadres). **La variance totale additionne exactement ces deux sources.**

Composante	Ce qu'elle mesure	Question à laquelle elle répond
V_{intra}	La dispersion moyenne à l'intérieur des groupes	« Les membres d'un même groupe se ressemblent-ils ? »
V_{inter}	La dispersion des moyennes de groupe autour de la moyenne générale	« Les groupes diffèrent-ils entre eux ? »

Deux cas extrêmes, à savoir décrire :

- $V_{\text{inter}} \approx 0$: les groupes ont la même moyenne — **le découpage n'explique rien**, toute la dispersion est interne.
- $V_{\text{intra}} \approx 0$: chaque groupe est homogène — **le découpage explique tout**, connaître le groupe d'un individu suffit à prédire sa valeur.

Le rapport $V_{\text{inter}} / \sigma^2$ mesure donc le pouvoir explicatif du découpage. C'est ce rapport qui deviendra, au chapitre 4 et en économétrie, le **rapport de corrélation** puis le R^2 .

Application immédiate au tableau de la diapositive 38 : l'écart inter-décile de l'ensemble (2 720 €) dépasse celui de trois CSP sur quatre précisément parce qu'il **contient la composante inter** — l'écart entre un cadre médian à 3 620 € et un employé médian à 1 730 €. On mesurait déjà la décomposition, sans la nommer.

ANALOGIE — MARCHÉS FINANCIERS

En gestion de portefeuille, c'est la décomposition du risque : la variance d'un ensemble de positions se sépare en risque **spécifique** (intra — ce qui bouge à l'intérieur de chaque secteur) et risque **systématique** (inter — ce qui fait bouger les secteurs les uns par rapport aux autres). La diversification agit sur le premier, jamais sur le second. C'est la même algèbre, appliquée à un autre objet.

2.3 — Résumer la concentration des données

OBJECTIFS — CE QUE CETTE TROISIÈME FAMILLE AJOUTE

La position dit **où** se situe la distribution. La dispersion dit **à quel point elle s'étale**. La concentration répond à une troisième question, qui n'est ni l'une ni l'autre : **comment le total se partage-t-il entre les individus ?**

Trois notions à maîtriser à la fin de cette section : la **part de l'agrégat**, la **courbe de Lorenz**, l'**indice de Gini**. Et une chose que le support ne dit jamais : **ces indicateurs ne s'appliquent pas à toutes les variables quantitatives**.

2.3.1 Concentration et dispersion : deux questions différentes (diapositive 59)

Le support pose la question sous forme de « points communs et différences ». Reprenons-la proprement, parce que la confusion entre les deux familles est l'une des plus fréquentes en examen.

DÉFINITION — DISPERSION ET CONCENTRATION

La dispersion s'intéresse à la **répartition des observations** d'une variable : les valeurs sont-elles serrées autour de la moyenne, ou éparpillées ? Elle raisonne sur les x_i eux-mêmes.

La concentration s'intéresse à la **répartition de la somme** de la variable : sur combien d'individus le total est-il concentré ? Elle raisonne sur les parts $x_i / \sum_j x_j$.

Le point commun : les deux familles servent à **mesurer des inégalités** d'un caractère statistique quantitatif. Ce sont deux angles d'attaque du même phénomène.

PIÈGE FRÉQUENT — LA CONDITION D'EXISTENCE QUE LE SUPPORT SIGNALA EN UNE LIGNE ET QU'IL FAUT PRENDRE AU SÉRIEUX

« Si la somme des revenus fait sens, ce n'est pas le cas de tous les caractères statistiques quantitatifs (exemple : la taille) ! »

Cette phrase est une condition d'application, pas une remarque anecdotique.

La concentration se calcule à partir de l'**agrégat**, c'est-à-dire la somme $\sum_{i=1}^N x_i$. Pour que les indicateurs de concentration aient un sens, il faut que cette somme désigne **un objet réel**.

Variable	Somme sur la population	Cette somme a-t-elle un sens ?	Concentration calculable ?
Salaire	La masse salariale	Oui : c'est un montant que l'on verse réellement	Oui
Patrimoine	Le patrimoine total du pays	Oui : c'est un stock de richesse existant	Oui
Chiffre d'affaires	Le CA total du secteur	Oui : c'est la taille du marché	Oui
Émissions de CO ₂	Les émissions totales	Oui : c'est ce qui arrive dans l'atmosphère	Oui
Taille (cm)	La somme des tailles	Non : additionner des tailles ne produit rien	Non
Note sur 20	La somme des notes	Non : aucun objet ne correspond à ce total	Non
Température	La somme des températures	Non	Non
Âge	La somme des âges	Non (aucun objet réel)	Non

La règle en une phrase : la concentration exige une variable **extensive et additive** — une variable dont le total est lui-même une grandeur économique. La dispersion, elle, s'applique à **toute** variable quantitative.

Erreur d'examen classique : calculer un Gini sur des notes ou sur des âges. Le calcul « marche » numériquement — rien dans l'algèbre ne l'empêche — mais **le résultat ne s'interprète pas**. Un correcteur exigeant sanctionne l'absence de vérification préalable.

SYNTHÈSE — LE TABLEAU DE DÉPARTAGE

	Dispersion	Concentration
Objet du raisonnement	Les valeurs x_i	Les parts $x_i / \sum x_j$
Question posée	Les individus se ressemblent-ils ?	Le total est-il concentré sur quelques-uns ?
Référence	La moyenne m_X	L'agrégat $\sum x_i$
Indicateurs	Étendue, écarts inter-quantiles, EAM, variance, écart-type, CV	Part de l'agrégat, courbe de Lorenz, indice de Gini
Unité du résultat	Celle de X (sauf CV, sans unité)	Sans unité (des parts, des %)
Condition d'application	Variable quantitative	Variable quantitative dont la somme fait sens
Phrase-type d'interprétation	« L'écart-type vaut 7,4 ans »	« Les 20 % les moins payés perçoivent 3,9 % de la masse salariale »

2.3.2 La part de l'agrégat (diapositive 60)

DÉFINITION — L'AGRÉGAT ET SA PART

L'**agrégat** d'un caractère X est la **somme de X sur toute la population** : $\sum_{i=1}^N x_i$. Dans le cas des salaires, cet agrégat porte un nom que tu connais déjà : la **masse salariale**.

La **part de l'agrégat de la classe k** est la fraction de ce total détenue par les individus de la classe k :

$$p_k = \frac{\text{somme de } X \text{ sur la classe } k}{\text{somme de } X \text{ sur toute la population}}$$

Le support énonce ensuite une relation qu'il présente comme « utile à savoir ». Elle n'est pas seulement utile : **c'est elle qui rend tout le calcul possible**. Elle mérite donc une démonstration.

FORMULE CLÉ — LA SOMME = LA MOYENNE × L'EFFECTIF

$$\sum_{i=1}^{N_k} x_i = N_k \cdot m_{X_k}$$

où N_k est l'effectif de la classe k et m_{X_k} la moyenne de X dans cette classe.

En mots : la somme d'une variable sur un groupe est égale à la moyenne du groupe multipliée par la taille du groupe. Dans le cas des salaires :

$$\text{masse salariale de la classe} = \text{salaire moyen de la classe} \times \text{effectif de la classe}$$

DÉMONSTRATION — LA DÉMONSTRATION, EN UNE LIGNE

Par définition, la moyenne de la classe k est :

$$m_{X_k} = \frac{1}{N_k} \sum_{i=1}^{N_k} x_i$$

Il suffit de multiplier les deux membres par N_k :

$$N_k \cdot m_{X_k} = \sum_{i=1}^{N_k} x_i$$

C'est tout. **La relation n'est rien d'autre que la définition de la moyenne lue à l'envers** — et c'est précisément pour cela qu'elle est si puissante : elle transforme une information *moyenne* (que l'on publie toujours) en une information *totale* (que l'on publie rarement).

Reste la difficulté annoncée par le support : dans le tableau qui suit, **les effectifs ne sont pas connus**. On ne connaît que des **proportions** (20 % par classe) et des **moyennes**. Le support affirme que le calcul reste possible et suggère de « poser l'effectif total à 1 ». Voici pourquoi cette astuce est légitime.

DÉMONSTRATION — POURQUOI L'EFFECTIF TOTAL DISPARAÎT DU CALCUL

Écrivons la part de la classe k avec la relation qu'on vient de démontrer :

$$p_k = \frac{N_k m_{X_k}}{\sum_{j=1}^K N_j m_{X_j}}$$

Or l'effectif d'une classe s'écrit $N_k = f_k N$, où f_k est la **fréquence** de la classe et N l'effectif total. En remplaçant :

$$p_k = \frac{f_k N m_{X_k}}{\sum_{j=1}^K f_j N m_{X_j}} = \frac{N \cdot f_k m_{X_k}}{N \cdot \sum_{j=1}^K f_j m_{X_j}}$$

Le facteur N est **commun au numérateur et au dénominateur** : il se simplifie.

$$\boxed{p_k} = \frac{f_k m_{X_k}}{\sum_{j=1}^K f_j m_{X_j}} = \frac{f_k m_{X_k}}{m_X}$$

Deux conséquences à retenir.

1. **La part de l'agrégat ne dépend que des fréquences et des moyennes de classe.** L'effectif total est inutile — d'où l'astuce « poser $N = 1$ », qui n'est pas une approximation mais une simplification exacte.
2. Le dénominateur $\sum_j f_j m_{X_j}$ **est la moyenne générale** m_X — c'est la formule de la moyenne par agrégation, vue en 2.1.7.

On retrouve donc :

$$p_k = f_k \times \frac{m_{X_k}}{m_X}$$

La part d'une classe est sa fréquence multipliée par son avantage relatif de moyenne. Une classe qui rassemble 20 % des salariés et dont le salaire moyen vaut 2 fois la moyenne générale détient $0,20 \times 2 = 40$ % de la masse salariale.

MÉTHODE — CALCULER UNE PART DE L'AGRÉGAT — LES QUATRE ÉTAPES

1. **Vérifier que la somme de X a un sens.** Sinon, s'arrêter là.
2. **Partir du tableau des fréquences** de X , avec la moyenne de chaque classe. Si les classes sont données par leurs bornes et que la moyenne n'est pas fournie, prendre le **centre de classe** (et le dire).
3. **Calculer $f_k \times m_{X_k}$ pour chaque classe**, puis leur somme — qui est la moyenne générale m_X .
4. **Diviser chaque produit par cette somme**, et exprimer en pourcentage. **Contrôle obligatoire : la somme des parts doit faire 100 %** (aux arrondis près).

2.3.3 Illustration : les salaires en France en 2005 (diapositive 61)

Le support donne le tableau suivant. Je le reproduis intégralement, puis je reconstruis chaque colonne — y compris celles que le support affiche sans dire d'où elles viennent.

Classes de salaires dans les entreprises en France en 2005

(1) Proportion de salariés en %	(2) Borne inférieure du salaire	(3) Borne supérieure du salaire	(4) Estimation du salaire moyen de la classe	(5) Part de la masse salariale en %
20	11 000	12 894	11 947	11,2
20	12 894	15 555	14 225	13,3
20	15 555	19 098	17 327	16,2
20	19 098	25 818	22 458	21,1
20	25 818	55 600	40 709	38,2
Ensemble			21 333	100

PIÈGE FRÉQUENT — COLONNE (4) : D'OÙ SORTENT CES « ESTIMATIONS » ? LE SUPPORT NE LE DIT JAMAIS

Le support intitule la colonne « estimation du salaire moyen de la classe » sans indiquer la méthode. **Vérifions-la par le calcul :**

Classe	Bornes	Centre de classe $\frac{\text{borne inf} + \text{borne sup}}{2}$	Valeur du support
1	11 000 – 12 894	$(11\,000 + 12\,894)/2 = 11\,947,0$	11 947 ✓
2	12 894 – 15 555	$(12\,894 + 15\,555)/2 = 14\,224,5$	14 225 ✓
3	15 555 – 19 098	$(15\,555 + 19\,098)/2 = 17\,326,5$	17 327 ✓
4	19 098 – 25 818	$(19\,098 + 25\,818)/2 = 22\,458,0$	22 458 ✓
5	25 818 – 55 600	$(25\,818 + 55\,600)/2 = 40\,709,0$	40 709 ✓

Conclusion : la colonne (4) est le centre de chaque classe. Le support applique donc l'**hypothèse de répartition uniforme à l'intérieur des classes** — exactement l'hypothèse déjà utilisée pour la médiane (§ 2.1.16) et pour la moyenne à partir d'une distribution (§ 2.1.6). **Il fallait le dire, et tu dois le dire dans une copie.**

Et il faut en mesurer la fragilité. Les quatre premières classes sont étroites (1 894 €, 2 661 €, 3 543 €, 6 720 €) : l'hypothèse y est bénigne. La cinquième est large de **29 782 €**, soit 16 fois la première. Or, à l'intérieur de la tranche haute des salaires, les effectifs ne sont pas répartis uniformément : ils sont **massés près de la borne inférieure** et se raréfient vers le haut (distribution étalée à droite, § 2.1.11). La vraie moyenne de cette classe est donc **vraisemblablement inférieure à 40 709 €**, et par conséquent **la part de 38,2 % surestime probablement la concentration réelle**. Je dis « vraisemblablement » et non « certainement » : sans les données individuelles, je ne peux pas quantifier l'écart. **Signaler cette limite est exactement ce qui distingue une copie excellente d'une copie moyenne.**

CORRIGÉ — RECONSTRUCTION COMPLÈTE DE LA COLONNE (5)

Étape 1 — L'agrégat. Les classes ont toutes la même fréquence $f_k = 0,20$. La moyenne générale vaut donc :

$$m_X = \sum_{k=1}^5 f_k m_{X_k} = 0,20 \times (11\,947 + 14\,225 + 17\,327 + 22\,458 + 40\,709)$$

Somme des cinq moyennes : $11\,947 + 14\,225 = 26\,172$; $+ 17\,327 = 43\,499$; $+ 22\,458 = 65\,957$;
 $+ 40\,709 = 106\,666$.

$$m_X = 0,20 \times 106\,666 = 21\,333,2 \text{ €}$$

Le support annonce 21 333 € ✓.

PIÈGE FRÉQUENT

Pourquoi ici la moyenne générale est la moyenne simple des cinq moyennes de classe. Uniquement parce que les cinq classes ont **le même poids** (20 % chacune). C'est le cas ici parce que les classes sont des **quintiles**, construits pour contenir chacun un cinquième de la population. **Si les fréquences étaient inégales, il faudrait impérativement pondérer** — c'est précisément le piège de l'agrégation vu en § 2.1.7.

Étape 2 — Les parts. Comme tous les f_k valent 0,20, ils se simplifient eux aussi :

$$p_k = \frac{0,20 \times m_{X_k}}{0,20 \times 106\,666} = \frac{m_{X_k}}{106\,666}$$

Classe	m_{X_k}	$p_k = m_{X_k} / 106\,666$	En %	Support
1	11 947	0,112003	11,20 %	11,2 ✓
2	14 225	0,133360	13,34 %	13,3 ✓
3	17 327	0,162441	16,24 %	16,2 ✓
4	22 458	0,210545	21,05 %	21,1 ✓
5	40 709	0,381650	38,17 %	38,2 ✓
Total	106 666	1,000000	100,00 %	100 ✓

Le contrôle de somme est vérifié : les cinq parts totalisent exactement 100 %.

Étape 3 — L'interprétation, phrase par phrase.

- Les **20 % les moins payés** perçoivent **11,2 %** de la masse salariale : un peu plus de la moitié de ce qu'ils toucheraient dans une répartition parfaitement égalitaire (20 %).
- Les **20 % les mieux payés** en perçoivent **38,2 %**, soit **près du double** de la part égalitaire, et **3,4 fois** la part des 20 % du bas.

- La classe médiane (la 3^e) détient 16,2 %, encore en dessous de 20 % : **la médiane est sous la moyenne**, signature d'une distribution étalée à droite — cohérent avec tout ce qu'on a établi sur les salaires au § 2.2.7.

2.3.4 Illustration : les mêmes salaires en 2021 (diapositive 62)

Classes de salaires dans les entreprises en France en 2021

(1) Proportion de salariés en %	(2) Borne inférieure du salaire	(3) Borne supérieure du salaire	(4) Estimation du salaire moyen de la classe	(5) Part de la masse salariale en %
20	1 333	6 709	4 021	3,9
20	6 709	15 110	10 910	10,6
20	15 110	22 942	19 026	18,4
20	22 942	32 124	27 533	26,7
20	32 124	51 490	41 807	40,5
Ensemble			20 659	100

CORRIGÉ — RECONSTRUCTION COMPLÈTE — MÊME MÉTHODE, MÊMES CONTRÔLES

Vérification de la colonne (4) — centres de classe : $(1\,333+6\,709)/2 = 4\,021,0$ ✓ · $(6\,709+15\,110)/2 = 10\,909,5$ ✓ · $(15\,110+22\,942)/2 = 19\,026,0$ ✓ · $(22\,942+32\,124)/2 = 27\,533,0$ ✓ · $(32\,124+51\,490)/2 = 41\,807,0$ ✓ — même hypothèse de répartition uniforme.

L'agrégat : $4\,021 + 10\,910 = 14\,931$; $+ 19\,026 = 33\,957$; $+ 27\,533 = 61\,490$; $+ 41\,807 = 103\,297$.

$$m_X = 0,20 \times 103\,297 = 20\,659,4 \text{ €}$$

Le support annonce 20 659 € ✓.

Les parts : $p_k = m_{X_k} / 103\,297$.

Classe	m_{X_k}	p_k	En %	Support
1	4 021	0,038926	3,89 %	3,9 ✓
2	10 910	0,105617	10,56 %	10,6 ✓
3	19 026	0,184187	18,42 %	18,4 ✓
4	27 533	0,266542	26,65 %	26,7 ✓
5	41 807	0,404726	40,47 %	40,5 ✓
Total	103 297	1,000000	100,00 %	100 ✓

PIÈGE FRÉQUENT — UN DÉTAIL D'ARRONDI QUE LE SUPPORT NE SIGNALE PAS — ET QUI VA SE PROPAGER

Additionne les cinq pourcentages **arrondis** du support :

$$3,9 + 10,6 + 18,4 + 26,7 + 40,5 = \mathbf{100,1}$$

Pas 100,0. Le tableau affiche pourtant « Ensemble : 100 ». Il n'y a **aucune erreur de fond** : les parts exactes totalisent bien 1, mais chacune a été arrondie **vers le haut** au dixième ($3,893 \rightarrow 3,9$; $10,562 \rightarrow 10,6$; $18,419 \rightarrow 18,4$; $26,654 \rightarrow 26,7$; $40,473 \rightarrow 40,5$), et cinq arrondis vers le haut produisent un excédent de 0,1.

Pourquoi je te le signale : parce que cet excédent **se propage au tableau des cumuls** de la diapositive 65 (voir § 2.3.6) et modifie le Gini à la troisième décimale. En examen, **écris toujours si tu cumules des valeurs arrondies ou des valeurs exactes** — la différence est petite mais un correcteur exigeant la voit.

2.3.5 Comparaison 2005 / 2021 : les inégalités ont-elles augmenté ? (diapositive 63)

Le support pose la question et affiche le tableau. **Il ne donne pas la réponse.** La voici, construite.

Comparaison des agrégats de salaire entre 2005 et 2021

Proportion de salariés en %	Part de la masse salariale en % en 2005	Part de la masse salariale en % en 2021	Variation en points
20 (les moins payés)	11,2	3,9	– 7,3
20	13,3	10,6	– 2,7
20 (médiants)	16,2	18,4	+ 2,2
20	21,1	26,7	+ 5,6
20 (les mieux payés)	38,2	40,5	+ 2,3
Ensemble	100,0	100,0	0,0

CORRIGÉ — LA RÉPONSE COMPLÈTE À LA QUESTION DE LA DIAPOSITIVE

1. Le sens de l'évolution est sans ambiguïté : les inégalités ont augmenté.

Les deux quintiles du bas **perdent** ($-7,3$ et $-2,7$ points), les trois quintiles du haut **gagnent** ($+2,2$, $+5,6$ et $+2,3$ points). Le transfert net des deux premiers vers les trois derniers est de **10,0 points de masse salariale** — un dixième de toute la masse salariale a changé de mains entre quintiles.

PIÈGE FRÉQUENT

La somme des variations doit être nulle, et elle l'est : $-7,3 - 2,7 + 2,2 + 5,6 + 2,3 = 0,1$... à 0,1 près, résidu de l'excédent d'arrondi identifié en § 2.3.4. **C'est un contrôle mécanique : les parts totalisant 100 % les deux années, ce qu'un quintile gagne, un autre le perd nécessairement.** Si tes variations ne totalisent pas 0, tu as une erreur de calcul.

2. L'ampleur : la lecture en variation relative est bien plus parlante.

Quintile	2005	2021	Variation relative
1 ^{er}	11,2	3,9	$3,9/11,2 - 1 = -65,2\%$ — la part est divisée par 2,9
2 ^e	13,3	10,6	$-20,3\%$
3 ^e	16,2	18,4	$+13,6\%$
4 ^e	21,1	26,7	$+26,5\%$
5 ^e	38,2	40,5	$+6,0\%$

Le fait marquant n'est pas l'envol du haut — le dernier quintile ne gagne que 6 % — mais l'effondrement du bas : la part du premier quintile est divisée par près de trois.

3. Le rapport entre extrêmes.

— 2005 : $38,2 / 11,2 = 3,41$ — le quintile du haut perçoit 3,4 fois la masse du quintile du bas.

— 2021 : $40,5 / 3,9 = 10,38$ — il en perçoit **plus de 10 fois** autant.

Le rapport a été multiplié par 3. C'est le chiffre à retenir.

PIÈGE FRÉQUENT — LA PRUDENCE MÉTHODOLOGIQUE OBLIGATOIRE — ET UNE LIMITE QUE JE NE PEUX PAS LEVER

Avant de conclure « les inégalités salariales ont explosé en France entre 2005 et 2021 », **regarde les bornes des deux tableaux :**

	2005	2021
Borne inférieure de la 1 ^{re} classe	11 000 €	1 333 €
Borne supérieure de la dernière	55 600 €	51 490 €
Salaire moyen d'ensemble	21 333 €	20 659 €

Trois anomalies apparentes :

1. Le plancher passe de 11 000 € à 1 333 € — **il est divisé par 8** en seize ans.
2. Le plafond **baisse** (55 600 → 51 490).
3. Le salaire moyen **baisse en euros courants** (21 333 → 20 659), alors qu'entre 2005 et 2021 les salaires nominaux en France ont nettement augmenté.

Ces trois faits ne sont pas compatibles avec deux mesures du même champ. L'explication la plus probable est un **changement de champ statistique** : le tableau 2005 semble porter sur des salaires en équivalent temps plein (ou sur les seuls postes à temps complet en année pleine), le tableau 2021 sur l'ensemble des postes — y compris temps partiels et années incomplètes, qui produisent mécaniquement de très petits salaires annuels.

Je dois être explicite : je ne peux pas le vérifier. Le support n'indique ni la source, ni le champ, ni la définition exacte du salaire (net ou brut, annuel, en EQTP ou tous postes). **Je ne dispose que des deux tableaux.**

Ce qu'il faut donc écrire en examen : « Les données montrent une forte hausse de la concentration de la masse salariale entre 2005 et 2021. Cette hausse doit toutefois être interprétée avec prudence : la baisse simultanée du plancher, du plafond et du salaire moyen en euros courants suggère un changement de champ entre les deux millésimes. Une partie de l'écart mesuré pourrait donc être un artefact de mesure et non une évolution réelle. »

Cette phrase-là vaut des points. Elle prouve que tu ne calcules pas en aveugle. Le raisonnement est le même qu'en finance : avant de comparer deux performances, on vérifie que les deux séries couvrent le même périmètre, la même devise et le même traitement des dividendes. **Une comparaison de chiffres non homogènes ne vaut rien, même parfaitement calculée.**

2.3.6 La courbe de Lorenz (diapositives 64 à 66)

DÉFINITION — LA COURBE DE LORENZ

La **courbe de Lorenz** représente la **part cumulée de la variable X** en fonction de la **fréquence cumulée de la population**, les individus étant classés **par valeur croissante de X** .

- **En abscisse** : la fréquence cumulée de la population, notée F — de 0 % à 100 %.
- **En ordonnée** : la part cumulée de l'agrégat de X , notée $L(F)$ — de 0 % à 100 %.

Dans le cas des salaires, la courbe met en correspondance la **part cumulée de la masse salariale** et la **part cumulée de la population salariée**. Elle se lit directement en une phrase :

« Les ... % des salariés les moins payés perçoivent ... % de la masse salariale. »

PIÈGE FRÉQUENT — LE CLASSEMENT PAR ORDRE CROISSANT EST UNE CONDITION, PAS UN DÉTAIL

Le support écrit la définition sans préciser que les individus doivent être **rangés par valeur croissante de X** . Sans cette condition, la courbe n'a aucune propriété : elle n'est ni convexe, ni située sous la diagonale, et le Gini calculé dessus n'a plus de sens.

C'est le classement croissant qui fait toute la construction. Dans les tableaux des diapositives 61 et 62, il est déjà satisfait : les classes de salaires sont rangées du plus bas au plus haut. Vérifie-le systématiquement avant de cumuler.

Tableau de calcul (diapositive 65). On cumule les parts calculées en § 2.3.3 et § 2.3.4.

Agrégats cumulés des salaires, années 2005 et 2021

Part cumulée des salariés en %	Part cumulée de la masse salariale en % en 2005	Part cumulée de la masse salariale en % en 2021
20	11,2	3,9
40	24,5	14,5
60	40,7	32,9
80	61,8	59,6
100	100,0	100,0

CORRIGÉ — RECONSTRUCTION DES CUMULS, LIGNE PAR LIGNE

2005 — on additionne $11,2 \cdot 13,3 \cdot 16,2 \cdot 21,1 \cdot 38,2$:

Ligne	Calcul	Cumul
20 %	11,2	11,2 ✓
40 %	11,2 + 13,3	24,5 ✓
60 %	24,5 + 16,2	40,7 ✓
80 %	40,7 + 21,1	61,8 ✓
100 %	61,8 + 38,2	100,0 ✓

2021 — on additionne $3,9 \cdot 10,6 \cdot 18,4 \cdot 26,7 \cdot 40,5$:


Ligne	Calcul	Cumul
20 %	3,9	3,9 ✓
40 %	3,9 + 10,6	14,5 ✓
60 %	14,5 + 18,4	32,9 ✓
80 %	32,9 + 26,7	59,6 ✓
100 %	59,6 + 40,5	100,1 $\triangle$ — le support écrit 100,0

Le support a cumulé les parts *arrondies*, puis a forcé la dernière ligne à 100,0. C'est l'excédent d'arrondi de 0,1 identifié en § 2.3.4. Ce n'est pas une faute : c'est une convention d'affichage. Mais elle a une conséquence chiffrée que je détaille en § 2.3.8 — elle décale le Gini d'environ 0,0006. **Négligeable pour la conclusion, à mentionner pour la rigueur.**

Le même effet existe en 2005 : les cumuls exacts sont $11,200 \cdot 24,536 \cdot 40,780 \cdot 61,835 \cdot 100,000$. Le support affiche 40,7 parce qu'il a cumulé $11,2 + 13,3 + 16,2 = 40,7$, alors que l'arrondi du cumul exact donnerait 40,8.

Retiens la règle : cumuler des arrondis n'est pas la même chose qu'arrondir des cumuls.

Le graphe (diapositive 66). Le support affiche les deux courbes. Le voici reconstruit, avec l'élément que le support omet et sans lequel la figure ne se lit pas : la diagonale d'égalité parfaite.



Part cumulée de la masse salariale (ordonnée)
en fonction de la part cumulée des salariés (abscisse)

. . . diagonale d'égalité parfaite ($L(F) = F$)
o o o courbe de Lorenz 2005 — 0 = points calculés (20/40/60/80 %)
* * * courbe de Lorenz 2021 — # = points calculés (20/40/60/80 %)

PIÈGE FRÉQUENT — LA DIAGONALE MANQUE SUR LE GRAPHE DU SUPPORT

La figure de la diapositive 66 affiche les deux courbes **sans la diagonale**. Or **toute la lecture d'une courbe de Lorenz consiste à mesurer son écart à la diagonale**. Sans elle, on voit deux courbes croissantes et convexes, et rien d'autre.

Réflexe à acquérir : quand tu traces une courbe de Lorenz, tu traces d'abord la diagonale. Un correcteur qui voit une courbe de Lorenz sans droite d'égalité sait que le concept n'est pas compris.

DÉMONSTRATION — LES QUATRE PROPRIÉTÉS DE LA COURBE DE LORENZ — TOUTES DÉMONSTRABLES

Propriété 1 — Elle part de (0 ; 0) et arrive à (100 ; 100). En 0 % de la population, on a cumulé 0 % de la masse : $L(0) = 0$. En 100 % de la population, on a cumulé toute la masse : $L(100) = 100$. **Ce sont deux points imposés : si ta courbe ne passe pas par eux, tu as une erreur de cumul.**

Propriété 2 — Elle est croissante. Passer de la fréquence cumulée F_k à F_{k+1} ajoute la part $p_{k+1} \geq 0$: un cumul de quantités positives ne peut pas décroître. **Une courbe de Lorenz qui redescend est mathématiquement impossible.**

Propriété 3 — Sa pente sur la classe k vaut m_{x_k} / m_X . C'est le résultat le plus utile de toute la section, et le support ne l'énonce pas. Sur le segment correspondant à la classe k :

$$\text{pente} = \frac{\Delta L}{\Delta F} = \frac{p_k}{f_k} = \frac{f_k \cdot m_{x_k} / m_X}{f_k} = \frac{m_{x_k}}{m_X}$$

Lecture : en chaque point, la pente de la courbe de Lorenz est le **rapport entre le salaire moyen local et le salaire moyen général**. Trois conséquences immédiates :

- **Pente < 1** $\Leftrightarrow$ la classe gagne moins que la moyenne $\Leftrightarrow$ la courbe s'écarte de la diagonale.
- **Pente = 1** $\Leftrightarrow$ la classe gagne exactement la moyenne $\Leftrightarrow$ la courbe est parallèle à la diagonale : c'est le point **le plus bas** par rapport à la diagonale, donc l'endroit où l'écart est maximal.
- **Pente > 1** $\Leftrightarrow$ la classe gagne plus que la moyenne $\Leftrightarrow$ la courbe revient vers la diagonale.

Vérification sur 2005 : pentes = 11 947/21 333 = 0,56 ; 14 225/21 333 = 0,67 ; 17 327/21 333 = 0,81 ; 22 458/21 333 = 1,05 ; 40 709/21 333 = 1,91. La pente franchit 1 **entre le 3^e et le 4^e quintile** : c'est là que se situe le salaire moyen, et c'est là que l'écart à la diagonale est maximal (à 60 % : 60 - 40,7 = 19,3 points, contre 18,2 à 80 % et 15,5 à 40 %). ✓

Propriété 4 — Elle est convexe, et située sous la diagonale. La convexité découle de la propriété 3 : les classes étant rangées par m_{x_k} croissant, les pentes m_{x_k} / m_X sont croissantes — **une courbe dont la pente croît est convexe**. Et comme elle relie (0 ; 0) à (100 ; 100) en étant convexe, **elle passe nécessairement sous la corde qui joint ces deux points, c'est-à-dire sous la diagonale**.

Le cas limite : si tout le monde gagne la même chose, toutes les pentes valent 1, la courbe **est** la diagonale. **La diagonale est donc la courbe de Lorenz de l'égalité parfaite** — d'où son nom de « droite d'égalité ».

EXEMPLE CHIFFRÉ — LES PHRASES DE LECTURE À SAVOIR PRODUIRE

À partir du tableau des cumuls, **quatre phrases par année**, toutes construites sur le même moule :

2005

- Les **20 %** des salariés les moins payés perçoivent **11,2 %** de la masse salariale.
- Les **40 %** les moins payés en perçoivent **24,5 %**.
- Les **60 %** les moins payés en perçoivent **40,7 %** — donc les **40 % les mieux payés en perçoivent 59,3 %**.
- Les **80 %** les moins payés en perçoivent **61,8 %** — donc les **20 % les mieux payés en perçoivent 38,2 %**.

2021

- Les **20 %** les moins payés perçoivent **3,9 %** de la masse salariale.
- Les **40 %** les moins payés en perçoivent **14,5 %**.
- Les **60 %** les moins payés en perçoivent **32,9 %** — les **40 % du haut en perçoivent 67,1 %**.
- Les **80 %** les moins payés en perçoivent **59,6 %** — les **20 % du haut en perçoivent 40,4 %**.

PIÈGE FRÉQUENT

Le complément à 100 se lit toujours par le haut. $100 - L(80)$ n'est pas « la part des 20 % du bas » mais **la part des 20 % du haut**. Inverser les deux est l'erreur de lecture la plus fréquente. **Repère mental : la courbe de Lorenz se lit toujours en partant des plus pauvres ; tout ce qui reste au-dessus appartient aux plus riches.**

2.3.7 Interpréter et comparer deux courbes de Lorenz (diapositive 67)

DÉFINITION — LES TROIS ÉNONCÉS DU SUPPORT, REFORMULÉS

1. **Plus la courbe s'éloigne de la diagonale, plus la concentration est forte** et plus les inégalités sont prégnantes.
2. **Si une courbe est partout plus éloignée de la diagonale qu'une autre**, l'inégalité est accrue **pour tous les ordres de quantiles** : tous les indicateurs d'inégalité convergent alors vers la même conclusion. On dit que la première distribution est **dominée au sens de Lorenz** par la seconde.
3. **Si les deux courbes se croisent**, on peut encore mesurer l'aire séparant chaque courbe de la diagonale (c'est l'indice de Gini), mais **des indicateurs différents peuvent alors donner des conclusions contradictoires**.

DÉMONSTRATION — POURQUOI LA DOMINANCE DE LORENZ EST UN RÉSULTAT FORT — ET POURQUOI LE CROISEMENT CASSE TOUT

Le cas de la dominance. Si $L_A(F) \leq L_B(F)$ pour **toutes** les valeurs de F , alors pour n'importe quel seuil que tu choisis — les 10 % du bas, les 25 % du bas, la moitié du bas — la distribution A donne toujours moins que B.

Aucun choix d'indicateur ne peut inverser la conclusion, parce que tout indicateur d'inégalité usuel se construit à partir de ces parts cumulées. C'est ce que signifie « tous les indicateurs convergent ».

Le cas du croisement. Si les courbes se croisent, A est plus inégalitaire **en bas** de la distribution et B plus inégalitaire **en haut** (ou l'inverse). Le classement dépend alors de **ce à quoi l'indicateur choisi accorde du poids**.

Contre-exemple chiffré, à savoir produire. Deux pays, cinq quintiles, parts de la masse salariale :

Quintile	Pays A	Pays B	Cumul A	Cumul B
1 ^{er}	4	8	4	8
2 ^e	12	10	16	18
3 ^e	20	15	36	33
4 ^e	28	22	64	55
5 ^e	36	45	100	100
Total	100	100		

Les cumuls se croisent : A est en dessous à 20 % ($4 < 8$) mais au-dessus à 60 % ($36 > 33$) et à 80 % ($64 > 55$).

Les courbes se croisent entre 40 % et 60 %.

Conclusion selon l'indicateur retenu :

- **Rapport inter-quintile Q_5/Q_1 :** $A = 36/4 = 9,0$; $B = 45/8 = 5,6$ → **A est plus inégalitaire.**
- **Part du quintile supérieur :** $A = 36\%$; $B = 45\%$ → **B est plus inégalitaire.**

Deux indicateurs, deux réponses opposées, sur les mêmes données. C'est exactement ce que prévient le support. **La leçon : en cas de croisement, on ne tranche pas — on décrit les deux phénomènes.**

CORRIGÉ — APPLICATION AU CAS 2005 / 2021 : Y A-T-IL CROISEMENT ?

On compare les cumuls point par point :

F	L_{2005}	L_{2021}	$L_{2021} - L_{2005}$
20 %	11,2	3,9	- 7,3
40 %	24,5	14,5	- 10,0
60 %	40,7	32,9	- 7,8
80 %	61,8	59,6	- 2,2
100 %	100,0	100,0	0,0

La différence est négative à chaque point intérieur : la courbe 2021 est partout sous la courbe 2005. Il n'y a pas de croisement.

Conclusion, formulée comme en examen : « La courbe de Lorenz de 2021 est partout située en dessous de celle de 2005 : la distribution de 2021 est dominée au sens de Lorenz par celle de 2005. La concentration de la masse salariale s'est donc accrue, et cette conclusion est robuste — tous les indicateurs d'inégalité usuels donneront le même verdict. »

Note l'endroit où l'écart est maximal : à 40 % (– 10,0 points). L'aggravation ne se joue donc pas dans le haut de la distribution (où l'écart n'est que de – 2,2 points à 80 %) mais **dans la première moitié** — cohérent avec l'effondrement de la part du premier quintile identifié en § 2.3.5.

2.3.8 L'indice de Gini (diapositives 68 et 69)

La courbe de Lorenz est une image. **L'indice de Gini est le nombre qui la résume.**

DÉFINITION — L'INDICE DE GINI

Géométriquement, l'indice de Gini **correspond à 2 fois l'aire comprise entre la courbe de Lorenz et la diagonale**. Cette aire est appelée **aire de concentration**.

$$G = 2 \times \text{aire} \quad \text{avec } \text{aire} = \text{aire entre la diagonale et la courbe}$$

- **Plus G est proche de 1**, plus la concentration (l'inégalité) est **forte**.
- **Plus G est proche de 0**, plus la concentration (l'inégalité) est **faible**.

FORMULE CLÉ — LA FORMULE DE CALCUL (DIAPOSITIVE 69)

$$G = 2 \left[\frac{1}{2} - \sum \frac{(b + B) \cdot h}{2} \right]$$

où, pour chaque tranche : b est la **petite base** (la valeur cumulée à gauche), B la **grande base** (la valeur cumulée à droite) et h la **hauteur** — c'est-à-dire la largeur de la tranche en abscisse.

DÉMONSTRATION — D'OÙ VIENT CETTE FORMULE — LA CONSTRUCTION COMPLÈTE

Le support donne la formule sans la construire. Elle repose sur trois idées enchaînées.

Idée 1 — L'aire du carré unité vaut 1. La courbe de Lorenz vit dans un carré de côté 1 (ou 100 %). L'aire totale du carré vaut $1 \times 1 = 1$.

Idée 2 — L'aire sous la diagonale vaut 1/2. La diagonale coupe le carré en deux triangles rectangles isocèles identiques. L'aire du triangle sous la diagonale vaut donc $\frac{1 \times 1}{2} = \frac{1}{2}$.

Idée 3 — L'aire de concentration est une soustraction. L'aire entre la diagonale et la courbe s'obtient en retirant, du triangle sous la diagonale, l'aire située **sous la courbe** :

$$\text{mathcal{A}} = \underbrace{\frac{1}{2}}_{\text{aire sous la diagonale}} - \underbrace{\text{mathcal{B}}}_{\text{aire sous la courbe de Lorenz}}$$

Idée 4 — L'aire sous la courbe se découpe en trapèzes. Entre deux points consécutifs de la courbe, celle-ci est un **segment de droite**. La surface comprise entre ce segment, l'axe des abscisses et les deux verticales est donc un **trapèze**. Rappel de l'aire d'un trapèze :

$$\text{aire} = \frac{(\text{petite base} + \text{grande base}) \times \text{hauteur}}{2} = \frac{(b + B) \cdot h}{2}$$

En sommant sur toutes les tranches : $\text{mathcal{B}} = \sum \frac{(b+B) \cdot h}{2}$.

Assemblage final :

$$G = 2\text{mathcal{A}} = 2 \left[\frac{1}{2} - \sum \frac{(b+B) \cdot h}{2} \right]$$

C'est exactement la formule du support — mais maintenant tu sais pourquoi.

PIÈGE FRÉQUENT — LE PIÈGE DE CALCUL DU CHAPITRE : L'UNITÉ DES AIRES

Le support affiche, sur le graphe de la diapositive 68, un trapèze avec $b = 40,7$, $B = 61,8$, $h = 20$ et l'aire **1 025**. Puis il écrit $A = 0,5$ – aire des trapèzes.

Ces deux nombres ne sont pas dans la même unité, et si tu les soustrais tels quels tu obtiens une aberration.

— Le 1 025 est calculé avec des **axes gradués en pourcentages** (de 0 à 100). Il est donc exprimé en « points de pourcentage au carré ». Dans cette unité, **le carré entier vaut $100 \times 100 = 10\,000$** , et le triangle sous la diagonale vaut **5 000**.

— Le 0,5 de la formule est exprimé en **fractions** (de 0 à 1), unité dans laquelle **le carré vaut 1**.

Il faut donc ramener les trapèzes à l'unité « fraction » en divisant par 10 000 — ou, de manière équivalente, appliquer la formule avec des cumuls exprimés en fractions (0,112 au lieu de 11,2) et des hauteurs de 0,20 au lieu de 20.

$$A = \frac{1}{2} \times \frac{\sum(b+B) \cdot h}{10\,000} \quad \text{si les cumuls sont en \%}$$

Test de cohérence à faire systématiquement : l'aire de concentration doit toujours être comprise **entre 0 et 0,5**, et le Gini **entre 0 et 1**. Si tu obtiens 0,5 – 3 764, tu sais immédiatement que tu as oublié la conversion.

CORRIGÉ — CALCUL COMPLET DU GINI 2005

Les cumuls (diapositive 65) : $0 \rightarrow 11,2 \rightarrow 24,5 \rightarrow 40,7 \rightarrow 61,8 \rightarrow 100,0$. Chaque tranche a une hauteur $h = 20$ (en abscisse, chaque quintile occupe 20 points de pourcentage).

Tranche	b (cumul gauche)	B (cumul droit)	h	Aire = $(b+B) \times h / 2$
0 → 20 %	0,0	11,2	20	$(0 + 11,2) \times 20 / 2 = 112,0$
20 → 40 %	11,2	24,5	20	$(11,2 + 24,5) \times 20 / 2 = 357,0$
40 → 60 %	24,5	40,7	20	$(24,5 + 40,7) \times 20 / 2 = 652,0$
60 → 80 %	40,7	61,8	20	$(40,7 + 61,8) \times 20 / 2 = 1\,025,0$
80 → 100 %	61,8	100,0	20	$(61,8 + 100,0) \times 20 / 2 = 1\,618,0$
Somme				3 764,0

Le trapèze 60 → 80 % vaut 1 025 — c'est exactement la valeur affichée sur le graphe du support ✓. La méthode est donc validée.

Conversion : $3\,764 / 10\,000 = 0,3764$.

Aire de concentration : $A = 0,5 - 0,3764 = 0,1236$.

Indice de Gini : $G_{2005} = 2 \times 0,1236 = 0,2472$.

CORRIGÉ — CALCUL COMPLET DU GINI 2021

Les cumuls : $0 \rightarrow 3,9 \rightarrow 14,5 \rightarrow 32,9 \rightarrow 59,6 \rightarrow 100,0$, avec $h = 20$.

Tranche	b	B	h	Aire = $(b+B) \times h / 2$
0 → 20 %	0,0	3,9	20	$(0 + 3,9) \times 10 = 39,0$
20 → 40 %	3,9	14,5	20	$(3,9 + 14,5) \times 10 = 184,0$
40 → 60 %	14,5	32,9	20	$(14,5 + 32,9) \times 10 = 474,0$
60 → 80 %	32,9	59,6	20	$(32,9 + 59,6) \times 10 = 925,0$
80 → 100 %	59,6	100,0	20	$(59,6 + 100,0) \times 10 = 1\,596,0$
Somme				3 218,0

Conversion : $3\,218 / 10\,000 = 0,3218$.

Aire de concentration : $A = 0,5 - 0,3218 = 0,1782$.

Indice de Gini : $G_{2021} = 2 \times 0,1782 = 0,3564$.

PIÈGE FRÉQUENT

Astuce de calcul : puisque $h = 20$ pour toutes les tranches, $(b+B) \times 20 / 2 = (b+B) \times 10$. **Multiplier par 10 au lieu de diviser par 2 après avoir multiplié par 20 :** deux opérations en moins par ligne, et autant d'erreurs évitées.

EXEMPLE CHIFFRÉ — LE RÉSULTAT, ET SA LECTURE

	2005	2021	Évolution
Aire sous la courbe	0,3764	0,3218	– 0,0546
Aire de concentration mathcalA	0,1236	0,1782	+ 0,0546
Indice de Gini	0,2472	0,3564	+ 0,1092
En variation relative			+ 44,2 %

Les trois phrases à écrire :

1. « L'indice de Gini des salaires passe de **0,247 en 2005 à 0,356 en 2021**, soit une hausse de **près de 11 points**, ou **+ 44 % en relatif**. »
2. « La concentration de la masse salariale s'est donc **fortement accrue** sur la période. »
3. « Ce diagnostic est **cohérent avec la courbe de Lorenz**, qui est partout plus éloignée de la diagonale en 2021 qu'en 2005 (dominance de Lorenz, § 2.3.7) : il n'y a pas de croisement, donc pas de risque de contradiction entre indicateurs. »

Et la réserve méthodologique du § 2.3.5 reste entière : une partie de cette hausse peut provenir d'un changement de champ entre les deux millésimes. Le Gini mesure ce qu'on lui donne à mesurer.

PIÈGE FRÉQUENT — L'ÉCART ENTRE LE GINI « DU TABLEAU » ET LE GINI EXACT

Si l'on refait les deux calculs avec les parts **non arrondies** (§ 2.3.3 et § 2.3.4) au lieu des cumuls arrondis du support, on obtient :

	Gini calculé sur le tableau du support	Gini calculé sur les parts exactes	Écart
2005	0,2472	0,2466	0,0006
2021	0,3564	0,3570	0,0006
Hausse	+ 0,1092	+ 0,1104	0,0012

Trois enseignements.

1. **L'écart est de l'ordre du millième** : il ne change **aucune** conclusion. Un Gini s'annonce à trois décimales au plus, souvent à deux.
2. **Il va dans le sens qui sous-estime la hausse** : le calcul du support donne + 0,1092 là où le calcul exact donne + 0,1104. L'arrondi n'a donc pas fabriqué le résultat.
3. **La bonne pratique** : mener les calculs intermédiaires avec le maximum de décimales et n'arrondir qu'au dernier moment. **En examen, si tu utilises le tableau fourni, tu utilises ses valeurs — et tu écris une ligne pour dire que les arrondis affectent la 3^e décimale.**

DÉMONSTRATION — POURQUOI $0 \leq G \leq 1$ — LES DEUX BORNES DÉMONTRÉES

Borne inférieure : $G = 0 \Leftrightarrow$ égalité parfaite. Si tout le monde a la même valeur, chaque tranche de $f\%$ de la population détient $f\%$ de l'agrégat : la courbe est la diagonale. L'aire entre les deux est nulle, donc $\mathcal{A} = 0$ et $G = 0$.

Vérification par la formule : les cumuls sont $20 \cdot 40 \cdot 60 \cdot 80 \cdot 100$, d'où les trapèzes $(0+20) \times 10 = 200$; $(20+40) \times 10 = 600$; $(40+60) \times 10 = 1\,000$; $(60+80) \times 10 = 1\,400$; $(80+100) \times 10 = 1\,800$; somme = $5\,000$.
 $\mathcal{A} = 0,5 - 5\,000/10\,000 = 0$, donc $G = 0$ ✓

Borne supérieure : $G \rightarrow 1 \Leftrightarrow$ concentration totale. Si un seul individu détient tout l'agrégat, la courbe reste collée à l'axe horizontal ($L = 0$) sur toute la population sauf le dernier individu, puis saute à 100% . L'aire sous la courbe tend vers 0 , donc $\mathcal{A} \rightarrow 0,5$ et $G \rightarrow 1$.

PIÈGE FRÉQUENT

Précision que l'on attend d'une excellente copie : avec une population finie de N individus, le

maximum n'est pas exactement 1 mais $\frac{N-1}{N}$. Le dernier individu occupe en effet une largeur $1/N$ non

nulle, sous laquelle subsiste un petit triangle d'aire $\frac{1}{2N}$. On a alors $\mathcal{A} = \frac{1}{2} - \frac{1}{2N}$ et

$G = 1 - \frac{1}{N}$. Pour $N = 100$, le maximum atteignable vaut $0,99$; pour $N \rightarrow \infty$, il tend vers 1 . **En pratique on retient $0 \leq G \leq 1$; savoir d'où vient la nuance est un bonus.**

EXEMPLE CHIFFRÉ — DES ORDRES DE GRANDEUR POUR INTERPRÉTER UN GINI

Un Gini nu ne dit rien : il faut une échelle de comparaison. **Ordres de grandeur usuels pour le revenu disponible des ménages** (à retenir comme repères, pas comme chiffres exacts — ils varient selon l'année, la source et le concept mesuré) :

Situation	Gini approximatif
Pays nordiques (Danemark, Norvège, Suède)	0,25 – 0,28
France, Allemagne, Pays-Bas	0,29 – 0,32
Royaume-Uni, Italie	0,33 – 0,36
États-Unis	0,38 – 0,41
Brésil, Colombie	0,48 – 0,54
Afrique du Sud	≈ 0,63

PIÈGE FRÉQUENT

Trois précautions avant toute comparaison de Gini.

1. **Le concept mesuré change tout.** Le Gini du **patrimoine** est toujours bien plus élevé que celui du **revenu** (le patrimoine peut être nul ou négatif, pas le revenu du travail) : en France, on est autour de 0,3 pour le revenu disponible et **au-delà de 0,6** pour le patrimoine. Comparer les deux n'a aucun sens.
2. **Avant ou après redistribution ?** Le Gini des revenus **primaires** (avant impôts et prestations) est nettement supérieur au Gini du revenu **disponible**. La différence entre les deux mesure précisément l'effet redistributif du système socio-fiscal.
3. **Le Gini est peu sensible aux extrêmes.** Il réagit surtout aux transferts autour du **milieu** de la distribution et beaucoup moins à ce qui se passe dans le tout dernier centile. C'est pourquoi on l'accompagne toujours d'indicateurs de queue : **rapport D9/D1** et **part du 1 % le plus riche**. Un Gini stable peut parfaitement masquer un décrochage du sommet.

Nos deux valeurs (0,247 et 0,356) portent sur les salaires, pas sur le revenu disponible : elles ne sont pas directement comparables aux chiffres du tableau ci-dessus. Les salaires excluent les revenus du capital, les prestations sociales et l'impôt.

Le raisonnement de Lorenz-Gini s'applique tel quel dès qu'on partage un total.

1. La concentration d'un portefeuille. Trie tes positions par poids croissant, cumule : tu obtiens la courbe de Lorenz de ton exposition. Un portefeuille dont 20 % des lignes portent 80 % du risque a un Gini élevé — c'est une **concentration**, donc une fragilité. L'indicateur standard du métier est l'**indice de Herfindahl-Hirschman** $HHI = \sum_i w_i^2$ (somme des carrés des poids), qui répond à la même question par une autre algèbre : $HHI = 1/n$ pour n positions équipondérées, et tend vers 1 quand tout est sur une ligne. **Un mandat de gestion impose presque toujours un plafond de HHI ou un poids maximal par ligne : c'est une contrainte de concentration.**

2. La concentration du P&L. Trie tes trades par résultat croissant et cumule. Presque tous les track records révèlent la même chose : **une petite minorité de trades fait la totalité du résultat.** Ce n'est pas anormal — c'est la signature d'une stratégie à espérance positive et asymétrie droite. **Ce qui est dangereux, c'est l'inverse** : un P&L dont la concentration vient de quelques **pertes** énormes compensées par beaucoup de petits gains — le profil « ramasser des pièces devant un rouleau compresseur ». **La courbe de Lorenz de ton P&L distingue les deux en un coup d'œil ; la moyenne, non.**

3. La concentration du marché. Part des dix premières capitalisations dans un indice, part des trois premiers courtiers sur un carnet d'ordres, part des deux premiers clients dans le chiffre d'affaires d'une société que tu analyses : **c'est la même part de l'agrégat.** En analyse crédit, la concentration clientèle est un facteur de risque explicitement noté.

Le lien conceptuel avec la dispersion est le même que dans tout le chapitre : l'écart-type te dit de combien les positions varient, le Gini te dit si le total repose sur quelques-unes. **Deux questions différentes, deux outils différents, et aucun ne remplace l'autre.**

2.4 — Récapitulons (diapositive 70)

Le support conclut en trois lignes : tu sais résumer une distribution à l'aide d'indicateurs de **position** (mode, moyenne, médiane), de **dispersion** (EAM, variance, écart-type, coefficient de variation) et de **concentration** (courbe de Lorenz, indice de Gini), et **le choix dépend du type de données mais aussi de ce que l'on veut en faire**.

Cette conclusion est juste, mais elle est trop courte pour servir de récapitulatif. Voici le tableau complet du chapitre.

SYNTHÈSE — LES TREIZE INDICATEURS DU CHAPITRE, EN UN TABLEAU

Famille	Indicateur	Formule	Ce qu'il mesure	Unité	Sensible aux extrêmes ?	Quand le choisir
Position	Mode	Modalité de fréquence max (ou densité max si classes inégales)	La valeur la plus fréquente	Celle de X	Non	Seul indicateur valable pour une variable qualitative
	Moyenne	$m_X = \frac{1}{N} \sum x_i$	Le centre de gravité	Celle de X	Oui, fortement	Distribution symétrique ; calculs ultérieurs (linéarité, agrégation)
	Médiane	$F(\text{Me}) = 0,5$	La valeur qui coupe l'effectif en deux	Celle de X	Non	Distribution asymétrique ; présence de valeurs extrêmes
Dispersion	Étendue	$x_{\max} - x_{\min}$	L'amplitude totale	Celle de X	Oui, totalement	Première approche, jamais seule
	Écart inter-quartile	$Q_3 - Q_1$	L'étalement des 50 % centraux	Celle de X	Non	Accompagne la médiane ; base du <i>boxplot</i>
	Écart inter-décile	$D_9 - D_1$	L'étalement des 80 % centraux	Celle de X	Peu	Comparaisons de niveaux de vie
	EAM	$\frac{1}{N} \sum x_i - m_X $	L'écart moyen à la moyenne	Celle de X	Oui	Interprétation directe ; peu utilisé car non dérivable

Famille	Indicateur	Formule	Ce qu'il mesure	Unité	Sensible aux extrêmes ?	Quand le choisir
	Variance	$\frac{1}{N} \sum (x_i - m_x)^2$	La dispersion quadratique	Celle de X au carré	Oui, très	Étape de calcul, décompositions
	Écart-type	$\sigma = \sqrt{V}$	La dispersion, en unité lisible	Celle de X	Oui, très	L'indicateur de référence ; volatilité en finance
	Coefficient de variation	$CV = \sigma / m_x$	La dispersion relative	Sans unité	Oui	Comparer des séries d'unités ou d'échelles différentes
Concentration	Part de l'agrégat	$p_k = f_k m_{x_k} / m_x$	La part du total détenue par une classe	Sans unité (%)	—	Première lecture des inégalités
	Courbe de Lorenz	$L(F) = \text{part cumulée de } X$	Le partage complet du total	Sans unité	—	Comparer deux distributions (dominance)
	Indice de Gini	$G = 2 \left[\frac{1}{2} - \sum \frac{(b+B)h}{2} \right]$	La concentration en un nombre	Sans unité, entre 0 et 1	Peu (milieu surtout)	Résumer, classer, suivre une évolution

MÉTHODE — L'ARBRE DE DÉCISION : QUEL INDICATEUR, QUAND ?

Question 1 — Quel est le type de la variable ?

- **Qualitative** → **mode uniquement**. Ni moyenne, ni médiane, ni variance, ni Gini.
- **Quantitative ordinale** (rangs, échelles) → mode et médiane ; **pas de moyenne** au sens strict.
- **Quantitative cardinale** → tout est permis. Passe à la question 2.

Question 2 — Que veux-tu décrire ?

- **Le niveau typique** → position. Passe à la question 3.
- **L'homogénéité de la population** → dispersion. Passe à la question 4.
- **Le partage d'un total** → concentration. Vérifie d'abord que la somme fait sens (§ 2.3.1), puis part de l'agrégat → Lorenz → Gini.

Question 3 — La distribution est-elle symétrique ?

- **Oui** → moyenne (et médiane $\approx$ moyenne, ce qui le confirme).
- **Non, ou valeurs extrêmes présentes** → **médiane**, en donnant aussi la moyenne pour montrer l'asymétrie.
Écart médiane / moyenne = diagnostic d'asymétrie.

Question 4 — Compares-tu des séries de même unité et de même ordre de grandeur ?

- **Oui** → écart-type.
- **Non** (unités différentes, ou moyennes très différentes) → **coefficient de variation**.
- **Tu veux résister aux valeurs extrêmes** → écarts inter-quantiles et *boxplot*.

Question 5 — Le résultat doit-il être agrégé ou décomposé ?

- **Agrégation de moyennes** → moyenne pondérée par les effectifs (§ 2.1.7).
- **Agrégation de variances** → Koenig, ou décomposition intra/inter (§ 2.2.17 et § 2.2.18).
- **Jamais** d'agrégation de médianes ni de Gini (§ 2.1.15).

PIÈGE FRÉQUENT — LA PHRASE DU SUPPORT À NE PAS LIRE TROP VITE

« Le choix d'indicateurs dépend du type de données *mais aussi de ce que l'on veut en faire.* »

La seconde moitié de la phrase est la plus importante, et c'est celle qu'on oublie. Le type de données élimine des indicateurs (on ne calcule pas une moyenne de couleurs). **L'objectif, lui, tranche entre ceux qui restent.**

Trois exemples où les données autorisent tout et où seul l'objectif décide :

- **Décrire le salaire « typique » d'une profession** → médiane (l'asymétrie rend la moyenne trompeuse).
- **Calculer la masse salariale à provisionner** → moyenne (× effectif : c'est la seule qui ait la propriété d'agrégation).
- **Vérifier qu'aucun salarié n'est décroché** → écarts inter-déciles et part du premier quintile.

Mêmes données, trois indicateurs différents, trois questions différentes. Un correcteur attend que tu justifies ton choix — pas que tu calcules tout.

3. Points de vigilance

3.1 — Les confusions classiques

Vingt couples de notions voisines. Pour chacun, **le critère qui tranche**.

Notion A	Notion B	Le critère qui les sépare
Présenter (chapitre 1)	Résumer (chapitre 2)	Présenter conserve toute l'information ; résumer en perd volontairement pour produire un petit nombre de chiffres
Mode	Classe modale	Le mode est une valeur (variable discrète) ; la classe modale est un intervalle (variable continue). On ne dit jamais « le mode est [20 ; 30[»
Effectif le plus élevé	Densité la plus élevée	Quand les classes ont des amplitudes inégales , la classe modale est celle de densité maximale , pas d'effectif maximal
Amplitude	Densité	L'amplitude est la largeur de la classe ($b_{\text{sup}} - b_{\text{inf}}$) ; la densité est l'effectif rapporté à cette largeur (n_i / a_i)
Hauteur d'un histogramme	Hauteur d'un diagramme en barres	Dans un histogramme, c'est la densité et c'est l' aire qui représente l'effectif ; dans un diagramme en barres, la hauteur est l'effectif
Moyenne	Médiane	La moyenne est le centre de gravité (elle utilise toutes les valeurs) ; la médiane est le centre de l'effectif (elle n'utilise que le rang)
Médiane	Classe médiane	Même distinction que mode / classe modale : la classe médiane est l'intervalle qui contient la médiane, qu'on obtient ensuite par interpolation
Moyenne simple	Moyenne pondérée	On pondère dès que les groupes n'ont pas le même effectif . La moyenne simple des moyennes est fausse dans ce cas
Quantile	Quartile / décile / centile	Le quantile est le genre ; quartile (4 parts), décile (10), centile (100) sont les espèces
Q_1	D_1	Q_1 laisse 25 % de l'effectif en dessous, D_1 en laisse 10 % . $Q_1 = D_{2,5}$
Étendue	Écart inter-quartile	L'étendue utilise les deux extrêmes (donc totalement sensible aux valeurs aberrantes) ; l'inter-quartile ne décrit que les 50 % centraux
Écart inter-quartile	Intervalle inter-quartile	Le premier est un nombre ($Q_3 - Q_1$) ; le second est un intervalle ($[Q_1 ; Q_3]$)
EAM	Écart-type	L'EAM moyenne des valeurs absolues des écarts ; l'écart-type passe par les carrés . L'écart-type est toujours $\geq$ EAM
Variance	Écart-type	La variance est dans l' unité au carré (donc ininterprétable) ; l'écart-type est la racine de la variance, dans l'unité de X

Notion A	Notion B	Le critère qui les sépare
Écart-type	Coefficient de variation	L'écart-type est absolu (avec une unité) ; le CV est relatif (sans unité), donc seul comparable entre séries d'unités différentes
Variance intra	Variance inter	L'intra est la moyenne des variances dans les groupes ; l'inter est la variance des moyennes de groupe. Somme des deux = variance totale
Dispersion	Concentration	La dispersion décrit la répartition des observations ; la concentration décrit la répartition de la somme
Part de l'agrégat	Fréquence	La fréquence est la part de la population ; la part de l'agrégat est la part de la masse (des salaires, du patrimoine...)
Courbe de Lorenz	Fonction de répartition	La courbe de Lorenz met la part cumulée de X en ordonnée ; la fonction de répartition met la fréquence cumulée en ordonnée, avec X en abscisse. Ce ne sont pas les mêmes axes
Indice de Gini	Aire de concentration	Le Gini est le double de l'aire de concentration. Confondre les deux divise le résultat par 2

3.2 — Les erreurs que commet la majorité des étudiants

1. **Confondre l'effectif et la densité pour trouver la classe modale.** Dès que les amplitudes diffèrent, il faut diviser. C'est l'erreur la plus fréquente du § 2.1.3.
2. **Faire la moyenne des moyennes sans pondérer.** Elle n'est exacte que si tous les groupes ont le même effectif — ce qui est rare. Deux classes de 10 et 30 élèves ne se moyennent pas à parts égales.
3. **Faire la moyenne des médianes.** Ce n'est jamais valable, même avec les bons poids. La médiane **ne s'agrége pas** — le contre-exemple $\{1;2;3\} \cup \{100;200;300\}$ du § 2.1.15 le prouve en trois lignes.
4. **Oublier de trier avant de chercher une médiane.** La médiane est définie sur la série **ordonnée**. Sur la série brute, elle n'a aucun sens.
5. **Se tromper de rang médian pour un effectif pair.** Avec N pair, il n'y a pas d'observation centrale : la médiane est **la moyenne des deux valeurs de rang $N/2$ et $N/2 + 1$.**
6. **Donner la variance comme réponse finale.** La variance est une **étape**. La réponse qu'on interprète est l'**écart-type**, avec son unité. Le support de la diapositive 43 s'arrête lui-même à la variance : il faut aller jusqu'à $\sigma = 7,36$.
7. **Oublier le carré dans les propriétés.** $V(aX) = a^2 V(X)$ et non $aV(X)$; en revanche $\sigma_{aX} = |a| \sigma_X$. Confondre les deux niveaux est sanctionné à chaque fois.
8. **Croire qu'ajouter une constante change la dispersion.** $V(X + a) = V(X)$. Ajouter 6 points à toutes les notes ne change **rien** à l'écart-type.
9. **Appliquer Bienaymé-Tchebychev avec $k \leq 1$.** L'inégalité ne dit rien pour $k \leq 1$: elle donnerait « au moins 0 % », ce qui est vide de sens. C'est exactement le problème de la diapositive 48 (§ 2.2.13).
10. **Comparer des écarts-types de séries d'unités ou d'échelles différentes.** Il faut alors le **coefficient de variation**. Comparer la volatilité en euros d'une action à 10 € et d'une action à 1 000 € n'a aucun sens.
11. **Utiliser Koenig sans élever la moyenne au carré.** $V = \overline{x^2} - m^2$, et non $\overline{x^2} - m$. L'homogénéité dimensionnelle suffit à détecter l'erreur.

12. **Calculer une concentration sur une variable dont la somme n'a pas de sens.** Un Gini sur des notes ou sur des âges se calcule numériquement mais **ne s'interprète pas**.
13. **Oublier de diviser les aires de trapèzes par 10 000** quand les cumuls sont en pourcentages. Le résultat sort alors complètement de l'intervalle $[0 ; 1]$ — et **ce contrôle-là est immédiat**.
14. **Confondre le complément à 100 par le haut et par le bas** dans la lecture d'une courbe de Lorenz. $100 - L(80)$ est la part **des 20 % les mieux payés**.
15. **Cumuler des valeurs déjà arrondies sans le dire.** L'erreur se propage ; elle est minime, mais un correcteur exigeant attend la mention.
16. **Comparer deux distributions sans vérifier l'homogénéité des champs.** Le cas 2005 / 2021 du § 2.3.5 en est l'illustration parfaite : les bornes trahissent un changement de périmètre.
17. **Conclure « les inégalités ont augmenté » à partir de deux courbes qui se croisent.** En cas de croisement, deux indicateurs peuvent donner des réponses opposées (§ 2.3.7).
18. **Interpréter un écart-type sans le rapporter à la moyenne.** « $\sigma = 500 \text{ €}$ » ne dit rien tant qu'on ne sait pas si la moyenne est 1 000 € ou 100 000 €.
19. **Prendre le centre de classe pour la vraie moyenne sans le signaler.** C'est une **hypothèse** (répartition uniforme dans la classe), et elle est d'autant plus fragile que la classe est large.
20. **Oublier que la somme des écarts à la moyenne est nulle.** C'est précisément pour cela qu'on prend des valeurs absolues (EAM) ou des carrés (variance) — et non par goût de la complication.

3.3 — Ce qui sépare une copie moyenne d'une excellente copie

La copie moyenne	La copie excellente
Donne le mode	Vérifie d'abord si les amplitudes sont égales, calcule les densités si elles ne le sont pas, et parle de classe modale pour une variable continue
Trace un histogramme	Rappelle que c'est l'aire qui représente l'effectif , et le démontre : densité $\times$ amplitude = effectif
Calcule une moyenne	Pondère par les effectifs, vérifie l'ordre de grandeur, et signale que la moyenne est sensible aux extrêmes
Donne la médiane	Précise le rang utilisé, dit si l'effectif est pair ou impair, et compare médiane et moyenne pour diagnostiquer l'asymétrie
Calcule Q_1 et Q_3	Définit le quantile comme l'inverse de la fonction de répartition ($F(Q_p) = p$) et sait interpoler dans une classe
Calcule la variance	Va jusqu'à l'écart-type , donne son unité, et le rapporte à la moyenne (coefficient de variation)
Applique Koenig	Justifie pourquoi on l'utilise : un seul passage sur les données, donc agrégation possible avec deux nombres par groupe
Cite Bienaymé-Tchebychev	Vérifie que $k > 1$, précise que la borne est valable quelle que soit la loi , et donc très lâche en pratique

La copie moyenne	La copie excellente
Calcule une variance par groupe	Écrit la décomposition intra / inter , interprète le rapport $V_{\text{inter}}/\sigma^2$ comme pouvoir explicatif du découpage , et annonce le lien avec le R^2
Calcule des parts de masse salariale	Vérifie que la somme fait 100 % et démontre que l'effectif total se simplifie
Trace une courbe de Lorenz	Trace d'abord la diagonale , justifie la convexité par la pente m_{X_k}/m_{X_i} , et écrit une phrase de lecture complète
Calcule un Gini	Contrôle l'unité des aires , vérifie que le résultat est dans $[0 ; 1]$, et donne un repère de comparaison
Conclut « les inégalités ont augmenté »	Vérifie qu'il n'y a pas de croisement des courbes (dominance de Lorenz), puis signale le risque de changement de champ entre les deux millésimes
Reprend les chiffres du support	Recalcule et signale les incohérences — comme la variance du cas 4 (diapositive 55) ou les conclusions non reconstituables de la diapositive 48
S'arrête au calcul	Termine par une phrase d'interprétation avec l'unité, la sous-population et le champ

3.4 — Les quatre anomalies du support à connaître

Ce chapitre contient quatre points où le support d'origine est fautif, incomplet ou non reconstituable. **Les connaître te protège** : si l'un d'eux tombe à l'examen, tu sauras que ce n'est pas toi qui te trompes.

Diapositive	Ce que le support affiche	Ce que donne le recalcul	Statut
55 (cas 4)	Variance = 10,4 ; écart-type = 3,2	Variance = 20,8 ; écart-type = 4,56	Erreur . Le support a divisé une fois de trop par 2. Conséquence : le classement des cas 2 et 4 par dispersion est inversé (§ 2.2.16)
48 (Sayna)	« 99 % de chances de faire des gains en périodes 1, 2, 3, 5 »	Non reconstituable . Bienaimé-Tchebychev exige $k > 1$, or $m/\sigma < 1$ dans les cinq périodes ; de plus la période 2 a une moyenne négative	Conclusion non démontrable avec les seuls outils du chapitre (§ 2.2.13)
35	Titre « retraités, année 2008 »	Le tableau affiché est celui des niveaux de vie de 2024 de la diapositive 34	Erreur de titre (§ 2.2.7)
43	S'arrête à la variance (54,19)	L'écart-type $\sigma = \sqrt{54,19} = 7,36$ ans n'est jamais calculé	Omission : c'est pourtant le seul chiffre interprétable (§ 2.2.11)

PIÈGE FRÉQUENT — COMMENT TRAITER UNE ERREUR DU SUPPORT EN EXAMEN

Ne recopie jamais un chiffre faux « parce qu'il est dans le cours ». Mais ne te contente pas non plus de le corriger en silence.

La formulation qui rapporte des points : « En appliquant la formule $V = \frac{1}{N} \sum n_i (x_i - m)^2$, j'obtiens 20,8 et non 10,4. L'écart d'un facteur 2 suggère une division supplémentaire par 2 dans le calcul du support. Je retiens 20,8, soit $\sigma = 4,56$, ce qui modifie le classement des cas 2 et 4. »

Tu montres trois choses en trois lignes : que tu sais calculer, que tu contrôles tes résultats, et que tu mesures les conséquences d'une erreur. **C'est exactement le profil qu'on attend d'un analyste.**

4. Système d'ancrage mémoriel

4.1 — Fiche de synthèse

SYNTHÈSE — CHAPITRE 2 « RÉSUMER POUR INFORMER » — L'ESSENTIEL SUR DEUX PAGES

LE PROJET DU CHAPITRE. Présenter (chapitre 1) conserve **toute** l'information. Résumer en **perd volontairement** pour produire quelques chiffres décisionnels. Trois familles : **position** (où ?), **dispersion** (à quel point c'est étalé ?), **concentration** (comment le total se partage-t-il ?).

① **POSITION — LE MODE.** La modalité de **fréquence maximale**. Variable continue → **classe modale**. Δ Si les amplitudes sont **inégaux**, la classe modale est celle de **densité maximale** : $d_i = n_i / a_i$ avec $a_i = b_{\text{sup}} - b_{\text{inf}}$. **Histogramme** : hauteur = densité, et **c'est l'aire qui représente l'effectif** ($d_i \times a_i = n_i$).

① **POSITION — LA MOYENNE.** Trois écritures du même objet : $m_X = \frac{1}{N} \sum_{i=1}^N x_i$ (données brutes) ·

$m_X = \sum_{i=1}^p f_i x_i$ (distribution) · $m_X = \sum_{k=1}^K \frac{N_k}{N} m_{X_k}$ (agrégation). **Trois propriétés** : ① $\sum (x_i - m_X) = 0$ — la somme des écarts est nulle ; ② **linéarité** $m_{aX+b} = a m_X + b$; ③ **sensibilité aux valeurs extrêmes**.

① **POSITION — LA MÉDIANE.** La valeur qui **partage l'effectif en deux** : $F(Me) = 0,5$. N impair → valeur de rang $(N+1)/2$; N pair → **moyenne** des rangs $N/2$ et $N/2+1$. Sur une distribution : classe médiane puis **interpolation linéaire**. Δ **La médiane ne s'agrège JAMAIS**.

DIAGNOSTIC D'ASYMÉTRIE. $Me < m_X$ → distribution **étalée à droite** (salaires, patrimoines). $Me > m_X$ → étalée à gauche. $Me \approx m_X$ → symétrique.

② **DISPERSION — LES INDICATEURS D'ÉCART ENTRE POSITIONS.** **Étendue** = $x_{\text{max}} - x_{\text{min}}$ (totalement sensible aux extrêmes). **Quantile** Q_p : la valeur telle que $F(Q_p) = p$ — c'est **l'inverse de la fonction de répartition**. Quartiles (4 parts), déciles (10), centiles (100). **Écart inter-quartile** = $Q_3 - Q_1$ (50 % centraux) · **inter-décile** = $D_9 - D_1$ (80 % centraux) · **rapport inter-décile** = D_9/D_1 (sans unité). **Boxplot** : boîte de Q_1 à Q_3 , trait à la médiane, moustaches aux extrêmes.

② **DISPERSION — LES INDICATEURS D'ÉCART À LA MOYENNE.**

$$EAM = \frac{1}{N} \sum |x_i - m_X| \quad \sigma^2 = V(X) = \frac{1}{N} \sum (x_i - m_X)^2 \quad \sigma = \sqrt{V(X)}$$

Koenig : $V(X) = \frac{1}{N} \sum x_i^2 - m_X^2$ (« moyenne des carrés moins carré de la moyenne ») — **un seul passage sur les données, donc agrégation possible**. **Propriétés** : $V(X + a) = V(X)$ · $V(aX) = a^2 V(X)$ · $\sigma_{aX} = |a| \sigma_X$ · $V(-X) = V(X)$. **Coefficient de variation** $CV = \sigma / m_X$ — **sans unité**, seul comparable entre séries d'échelles différentes. **Bienaymé-Tchebychev** : $P(|x - m| \geq k\sigma) \leq 1/k^2$, **valable quelle que soit la loi**, donc **très**

lâche. Δ **Ne dit rien pour $k \leq 1$** . **Décomposition** : $\sigma^2 = V_{\text{intra}} + V_{\text{inter}}$ avec $V_{\text{intra}} = \sum \frac{N_k}{N} \sigma_k^2$ et

$V_{\text{inter}} = \sum \frac{N_k}{N} (m_{X_k} - m_X)^2$. Le rapport $V_{\text{inter}}/\sigma^2$ mesure le **pouvoir explicatif du découpage**.

③ **CONCENTRATION — LA CONDITION D'EXISTENCE.** Elle n'existe que si **la somme de X a un sens** (salaires → masse salariale ✓ ; tailles, notes, âges ✗).

③ **CONCENTRATION — LA PART DE L'AGRÉGAT.** $\sum_{i=1}^{N_k} x_i = N_k m_{X_k}$ (« la somme = la moyenne × l'effectif »), d'où

$$p_k = \frac{N_k m_{X_k}}{\sum_j N_j m_{X_j}} = \frac{f_k m_{X_k}}{m_X} = f_k \times \frac{m_{X_k}}{m_X}$$

L'effectif total se simplifie : le calcul est possible à N inconnu.

③ **CONCENTRATION — LORENZ ET GINI.** La **courbe de Lorenz** met la **part cumulée de X** (ordonnée) en face de la **fréquence cumulée de la population** (abscisse), individus **rangés par X croissant**. Elle part de (0;0), arrive à (100;100), est **croissante** et **convexe**, et sa **pente sur la classe k** vaut m_{X_k}/m_X . La **diagonale** est la courbe de l'**égalité parfaite**. **Dominance de Lorenz** : une courbe partout plus éloignée de la diagonale → **tous** les indicateurs concluent à plus d'inégalité. **Croisement** → conclusions possiblement contradictoires.

$$G = 2 \times \text{mathcal{A}} = 2 \left[\frac{1}{2} - \sum \frac{(b+B)h}{2} \right], \quad 0 \leq G \leq 1$$

△ **Si les cumuls sont en %, diviser la somme des trapèzes par 10 000.** $G = 0$ → égalité parfaite · $G \rightarrow 1$ → concentration totale (max exact = $(N-1)/N$).

LES CHIFFRES DU CHAPITRE À CONNAÎTRE. Âges (diapo 42-43) : $m = 47,9$; $EAM = 5,7$; $\sigma^2 = 54,19$; $\sigma = 7,36$. Niveau de vie 2024 : $D_9/D_1 = 3,48$. Salaires : $G_{2005} = 0,2472 \rightarrow G_{2021} = 0,3564$ (+ 44 %). Part du 1^{er} quintile : 11,2 % → 3,9 % (divisée par 2,9).

LE CHOIX DE L'INDICATEUR. Type de données **puis** objectif. Asymétrie → médiane. Agrégation → moyenne. Unités différentes → CV. Partage d'un total → Lorenz et Gini.

4.2 — Cartes de révision

Soixante-cinq cartes couvrant l'intégralité du chapitre. **Utilisation** : cache la réponse, formule la tienne à voix haute, puis compare. Une carte n'est acquise que si tu produis la réponse complète, pas si tu la reconnais.

Le projet du chapitre

Quelle est la différence de nature entre « présenter » (chapitre 1) et « résumer » (chapitre 2) ?

Présenter conserve toute l'information (série brute, distribution des effectifs : aucune donnée n'est perdue).
Résumer en perd volontairement : on remplace N valeurs par quelques chiffres. **La perte est le prix de la décision** — on ne décide pas devant 1 200 nombres.

Quelles sont les trois familles d'indicateurs du chapitre, et la question de chacune ?

Position : où se situe la distribution ? (mode, moyenne, médiane). **Dispersion** : à quel point est-elle étalée ? (étendue, écarts inter-quantiles, EAM, variance, écart-type, CV). **Concentration** : comment le total se partage-t-il ? (part de l'agrégat, Lorenz, Gini).

Le mode

Définissez le mode.

La **modalité de fréquence (ou d'effectif) maximale**. C'est le seul indicateur de position calculable sur une variable qualitative.

Pourquoi parle-t-on de « classe modale » et non de « mode » pour une variable continue ?

Parce qu'une variable continue est regroupée en **classes** : l'indicateur désigne donc un **intervalle**, pas une valeur. Dire « le mode est [20 ; 30[» est un abus de langage sanctionné.

Comment détermine-t-on la classe modale quand les classes ont des amplitudes inégales ?

Par la **densité maximale**, pas par l'effectif maximal :

$$d_i = \frac{n_i}{a_i} \quad \text{avec } a_i = b_{\text{sup}} - b_{\text{inf}}$$

Une classe deux fois plus large contient mécaniquement plus d'individus sans être plus « dense ».

Dans un histogramme, que représentent la hauteur et l'aire d'un rectangle ?

La **hauteur** représente la **densité** $d_i = n_i/a_i$. L'**aire** représente l'**effectif** : $\text{aire} = d_i \times a_i = \frac{n_i}{a_i} \times a_i = n_i$. C'est la **propriété fondamentale de l'histogramme**, et elle le distingue du diagramme en barres où la hauteur est l'effectif.

Que se passe-t-il si l'on trace un histogramme en portant les effectifs en hauteur avec des classes d'amplitudes inégales ?

La figure ment. Les classes larges paraissent surreprésentées, puisque leur aire vaut $n_i \times a_i$ au lieu de n_i . La forme de la distribution est déformée proportionnellement aux amplitudes.

La moyenne

Donnez les trois écritures de la moyenne arithmétique et le cas d'usage de chacune.

① **Données brutes** : $m_X = \frac{1}{N} \sum_{i=1}^N x_i$. ② **Distribution** : $m_X = \sum_{i=1}^p f_i x_i$ (ou $\frac{1}{N} \sum n_i x_i$). ③ **Agrégation** : $m_X = \sum_{k=1}^K \frac{N_k}{N} m_{X_k}$. **Les trois donnent le même nombre** : ce sont trois regroupements de la même somme.

Énoncez et démontrez la première propriété de la moyenne.

La somme des écarts à la moyenne est nulle : $\sum_{i=1}^N (x_i - m_X) = 0$. *Démonstration* : $\sum (x_i - m_X) = \sum x_i - N m_X = N m_X - N m_X = 0$, puisque $\sum x_i = N m_X$ par définition de la moyenne. **Conséquence** : on ne peut pas mesurer la dispersion par la moyenne des écarts — d'où les valeurs absolues (EAM) et les carrés (variance).

Énoncez la propriété de linéarité de la moyenne et ce qu'elle autorise.

$m_{aX+b} = a m_X + b$. Elle autorise l'**agrégation** : la moyenne d'un ensemble se reconstruit à partir des moyennes de ses parties, pondérées par les effectifs. **C'est ce que l'écart-type ne permet pas** (d'où Koenig).

Pourquoi la moyenne est-elle sensible aux valeurs extrêmes, et la médiane non ?

La moyenne utilise **la valeur** de chaque observation : une valeur très grande pèse proportionnellement à sa taille. La médiane n'utilise que **le rang** : remplacer la plus grande valeur par une valeur dix fois plus grande **ne change pas son rang**, donc ne change pas la médiane.

Quand la moyenne d'un ensemble est-elle égale à la moyenne simple des moyennes de groupe ?

Uniquement si tous les groupes ont le même effectif. Sinon il faut pondérer : $m_X = \sum \frac{N_k}{N} m_{X_k}$. C'est le cas des tableaux de quintiles (20 % chacun), où la pondération est uniforme — mais c'est une exception, pas la règle.

La médiane et les quantiles

Définissez la médiane de deux façons.

Définition par le partage : la valeur qui partage la population **ordonnée** en deux parties d'effectifs égaux — 50 % en dessous, 50 % au-dessus. **Définition par la fonction de répartition** : la valeur Me telle que $F(Me) = 0,5$.

Comment calcule-t-on la médiane sur données brutes selon la parité de N ?

Trier d'abord, toujours. N **impair** → la valeur de rang $\frac{N+1}{2}$. N **pair** → la moyenne des valeurs de rang $\frac{N}{2}$ et $\frac{N}{2} + 1$ (il n'existe pas d'observation centrale).

Comment obtient-on la médiane à partir d'une distribution groupée en classes ?

① Calculer les **fréquences cumulées**. ② Repérer la **classe médiane** : la première dont la fréquence cumulée atteint ou dépasse 0,5. ③ **Interpoler linéairement** dans cette classe, sous l'hypothèse de répartition uniforme :

$$Me = b_{\text{inf}} + a \times \frac{0,5 - F(b_{\text{inf}})}{F(b_{\text{sup}}) - F(b_{\text{inf}})}$$

Peut-on calculer la médiane d'un ensemble à partir des médianes de ses sous-groupes ?

Non, jamais — même avec les bons poids. *Contre-exemple* : $A = \{1;2;3\}$ ($Me = 2$), $B = \{100;200;300\}$ ($Me = 200$). Moyenne des médianes = 101. Vraie médiane de $A \cup B = \{1;2;3;100;200;300\}$: $(3+100)/2 = 51,5$. **Écart d'un facteur 2**. La médiane dépend de **la position relative de toutes les valeurs**, information détruite par le résumé en médianes de groupe.

Que signifie l'écart entre médiane et moyenne d'une distribution ?

$Me < m_X$ → distribution **étalée à droite** : quelques très grandes valeurs tirent la moyenne vers le haut (salaires, patrimoines, capitalisations). $Me > m_X$ → **étalée à gauche**. $Me \approx m_X$ → **symétrique**. C'est le diagnostic d'asymétrie le moins coûteux qui existe : deux chiffres.

Définissez un quantile d'ordre p .

La valeur Q_p telle que $F(Q_p) = p$: **une proportion p de la population a une valeur inférieure ou égale à Q_p .**
Formellement, **le quantile est l'inverse de la fonction de répartition** : $Q_p = F^{-1}(p)$.

Quartiles, déciles, centiles : quelle est la logique commune, et combien de valeurs définissent chaque famille ?

On découpe la population ordonnée en parts d'effectifs égaux. **Quartiles** : 4 parts → **3 valeurs** (Q_1 , $Q_2 = Me$, Q_3).
Déciles : 10 parts → **9 valeurs** (D_1 à D_9). **Centiles** : 100 parts → **99 valeurs**. **Règle** : **n parts se délimitent par $n - 1$ valeurs.**

Que valent Q_1 et Q_3 exprimés en déciles ? Et Me ?

$Q_1 = D_{2,5}$ · $Q_3 = D_{7,5}$ · $Me = Q_2 = D_5$. **Tous les quantiles appartiennent à la même famille** : seuls les ordres changent.

Les indicateurs de dispersion

Pourquoi un indicateur de position ne suffit-il jamais à résumer une distribution ?

Parce que **deux distributions de même moyenne peuvent être radicalement différentes** (les quatre cas de la diapositive 27). La position dit **où** ; il faut la dispersion pour dire **à quel point les individus se ressemblent**. Une moyenne sans dispersion est une information incomplète — et en finance, dangereuse.

Définissez l'étendue et donnez sa faiblesse.

étendue = $x_{\max} - x_{\min}$. **Faiblesse** : **elle ne dépend que des deux valeurs extrêmes**, donc elle est totalement détruite par une valeur aberrante et ne dit rien de la répartition entre les deux bornes.

Citez les trois écarts inter-quantiles usuels et ce que chacun décrit.

Écart inter-quartile $Q_3 - Q_1$: l'étalement des **50 % centraux**. **Écart inter-décile** $D_9 - D_1$: l'étalement des **80 % centraux**. **Rapport inter-décile** D_9 / D_1 : le même en **relatif**, donc **sans unité** et comparable entre populations.

Décrivez la construction d'un boxplot et ce qu'on y lit immédiatement.

Boîte de Q_1 à Q_3 (les 50 % centraux), **trait intérieur** à la **médiane**, **moustaches** jusqu'aux valeurs extrêmes (ou aux déciles selon la convention). **Lecture immédiate** : le niveau (position du trait), la dispersion (largeur de la boîte), et l'**asymétrie** — si le trait n'est pas au centre de la boîte, la distribution est asymétrique.

Écrivez la formule de l'écart absolu moyen et expliquez pourquoi on prend la valeur absolue.

$$EAM = \frac{1}{N} \sum_{i=1}^N |x_i - m_X|$$

On prend la valeur absolue parce que la somme des écarts simples est nulle (propriété 1 de la moyenne) : sans valeur absolue, l'indicateur vaudrait 0 pour toute distribution.

Écrivez la variance et l'écart-type. Pourquoi passe-t-on de l'une à l'autre ?

$$V(X) = \sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - m_X)^2 \quad \sigma = \sqrt{V(X)}$$

Le carré résout le problème du signe (comme la valeur absolue) mais change l'unité : la variance est en unité au carré, donc ininterprétable. La racine ramène l'indicateur dans l'unité de X : c'est l'écart-type qu'on interprète et qu'on communique.

Pourquoi préfère-t-on la variance à l'EAM, alors que l'EAM est plus intuitif ?

Parce que le carré est dérivable partout, la valeur absolue non. Toute la statistique qui suit — moindres carrés, régression, décomposition intra/inter, R^2 — repose sur la dérivabilité. L'EAM est plus lisible ; la variance est plus maniable, et c'est elle qui a gagné.

Énoncez la formule de Koenig et dites pourquoi elle est utile.

$$V(X) = \frac{1}{N} \sum_{i=1}^N x_i^2 - m_X^2$$

« La moyenne des carrés moins le carré de la moyenne. » **Utilité** : la formule de définition exige de connaître m_X avant de calculer les écarts — deux passages sur les données. Koenig ne demande que deux sommes ($\sum x_i$ et $\sum x_i^2$), calculables en un seul passage. C'est ce qui rend l'agrégation possible : deux nombres suffisent à transmettre un groupe.

Donnez les trois propriétés de la variance et leur traduction sur l'écart-type.

- ① **Invariance par translation** : $V(X + a) = V(X)$ — ajouter une constante déplace la distribution sans la déformer.
- ② **Non-linéarité** : $V(aX) = a^2 V(X)$, donc $\sigma_{aX} = |a| \sigma_X$.
- ③ **Corollaire** : $V(-X) = V(X)$. **L'erreur classique** : écrire $V(aX) = aV(X)$.

Énoncez l'inégalité de Bienaymé-Tchebychev et ses deux conditions d'usage.

$$P(|X - m| \geq k\sigma) \leq \frac{1}{k^2}$$

Condition 1 : $k > 1$ — pour $k \leq 1$ la borne est ≥ 1 et ne dit rien. **Condition 2 : aucune** sur la loi — et c'est sa force et sa faiblesse : valable pour toute distribution, donc **très lâche**. Pour $k = 2$ elle garantit 75 % ; une loi normale donnerait 95 %.

Définissez le coefficient de variation et dites quand il est indispensable.

$$CV = \frac{\sigma}{m_X}$$

Sans unité. Il est indispensable dès qu'on compare des séries d'**unités différentes** ou d'**ordres de grandeur différents** : un écart-type de 500 € ne signifie pas la même chose autour d'une moyenne de 1 000 € ($CV = 0,5$) et de 100 000 € ($CV = 0,005$).

Écrivez la variance calculée à partir d'une distribution.

$$V(X) = \sum_{i=1}^p f_i (x_i - m_X)^2 = \frac{1}{N} \sum_{i=1}^p n_i (x_i - m_X)^2$$

Chaque écart au carré est pondéré par l'effectif de sa modalité. L'oubli de la pondération est l'erreur numéro un sur ce calcul.

Écrivez la décomposition intra / inter de la variance.

$$\sigma^2 = V_{\text{intra}} + V_{\text{inter}}$$

$$V_{\text{intra}} = \sum_{k=1}^K \frac{N_k}{N} \sigma_k^2 \quad V_{\text{inter}} = \sum_{k=1}^K \frac{N_k}{N} (m_{X_k} - m_X)^2$$

Intra = dispersion à l'intérieur des groupes. **Inter** = dispersion des moyennes de groupe.

Que mesure le rapport $V_{\text{inter}} / \sigma^2$, et quels sont ses deux cas extrêmes ?

Il mesure le **pouvoir explicatif du découpage en groupes** — la part de la dispersion totale qu'explique l'appartenance à un groupe. $V_{\text{inter}} \approx 0 \rightarrow$ les groupes ont la même moyenne : **le découpage n'explique rien**. $V_{\text{intra}} \approx 0 \rightarrow$ chaque groupe est homogène : **le découpage explique tout**. C'est l'ancêtre du rapport de corrélation puis du R^2 .

La concentration

Quelle est la différence entre dispersion et concentration ?

La **dispersion** s'intéresse à la répartition **des observations** (x_i autour de m_X). La **concentration** s'intéresse à la répartition **de la somme** (quelle part du total chaque groupe détient-il ?). **Point commun** : les deux mesurent des inégalités. **Ce sont deux angles sur le même phénomène, pas deux versions du même outil**.

Quelle condition une variable doit-elle remplir pour qu'on puisse en mesurer la concentration ? Donnez deux exemples de chaque côté.

Sa somme doit désigner un objet réel (variable extensive et additive). **Oui** : salaires ($\rightarrow$ masse salariale), patrimoine ($\rightarrow$ patrimoine total), chiffre d'affaires, émissions de CO_2 . **Non** : taille, note, température, âge — additionner ces valeurs ne produit rien. **Le calcul reste numériquement possible ; le résultat ne s'interprète pas**.

Qu'est-ce que l'agrégat d'une variable ? Comment se calcule-t-il par groupe ?

L'**agrégat** est la **somme de X** sur la population : $\sum_{i=1}^N x_i$. Pour les salaires, c'est la **masse salariale**. Par groupe : $\sum_{i=1}^{N_k} x_i = N_k m_{X_k}$ — « **la somme = la moyenne $\times$ l'effectif** », qui n'est que la définition de la moyenne multipliée par N_k .

Écrivez la part de l'agrégat d'une classe, sous ses trois formes équivalentes.

$$p_k = \frac{N_k m_{X_k}}{\sum_j N_j m_{X_j}} = \frac{f_k m_{X_k}}{m_X} = f_k \times \frac{m_{X_k}}{m_X}$$

Troisième forme, la plus parlante : la part d'une classe est **sa fréquence multipliée par son avantage relatif de moyenne**.

Pourquoi peut-on calculer les parts de l'agrégat sans connaître l'effectif total ?

Parce que $N_k = f_k N$: le facteur N apparaît au numérateur **et** au dénominateur et **se simplifie**.

$$p_k = \frac{f_k N m_{X_k}}{\sum_j f_j N m_{X_j}} = \frac{f_k m_{X_k}}{\sum_j f_j m_{X_j}}$$

Poser $N = 1$ n'est donc pas une approximation : c'est une simplification exacte.

Quel contrôle doit-on faire systématiquement après avoir calculé des parts de l'agrégat ?

Leur somme doit valoir 100 % (aux arrondis près). Si elle ne les vaut pas, il y a une erreur — sauf écart de l'ordre du dixième, imputable aux arrondis, **qu'il faut alors signaler**.

Définissez la courbe de Lorenz : que porte-t-on sur chaque axe, et dans quel ordre range-t-on les individus ?

Abscisse : la fréquence cumulée de la population. **Ordonnée** : la part cumulée de l'agrégat de X . Les individus doivent être rangés par valeur croissante de X — sans cette condition, la courbe n'a aucune des propriétés qui la rendent utile.

Énoncez les quatre propriétés de la courbe de Lorenz.

① Elle part de **(0 ; 0)** et arrive à **(100 ; 100)**. ② Elle est **croissante** (on cumule des parts positives). ③ Sa **pente sur la classe k vaut m_{X_k}/m_X** . ④ Elle est **convexe** (les pentes croissent puisque les classes sont ordonnées), donc située sous la diagonale.

Que représente la pente de la courbe de Lorenz en un point, et que signifie une pente égale à 1 ?

$$\text{pente} = \frac{p_k}{f_k} = \frac{m_{X_k}}{m_X}$$

C'est le **rapport entre la moyenne locale et la moyenne générale**. **Pente < 1** → la classe gagne moins que la moyenne, la courbe s'écarte de la diagonale. **Pente = 1** → la classe gagne exactement la moyenne : **c'est le point où l'écart à la diagonale est maximal**. **Pente > 1** → la courbe revient vers la diagonale.

Que représente la diagonale sur un graphe de Lorenz, et pourquoi ?

La courbe de Lorenz de l'égalité parfaite. Si tout le monde a la même valeur, toutes les pentes valent $m_{X_k}/m_X = 1$: la courbe **est** la diagonale, et $f\%$ de la population détient exactement $f\%$ du total. **Sans elle, une courbe de Lorenz ne se lit pas** — c'est l'écart à la diagonale qui porte toute l'information.

Écrivez la phrase-type de lecture d'un point de la courbe de Lorenz, puis appliquez-la à $L(20) = 3,9$ en 2021.

Moule : « Les ... % des salariés les moins payés perçoivent ... % de la masse salariale. » **Application :** « En 2021, les **20** % des salariés les moins payés perçoivent **3,9** % de la masse salariale » — contre 11,2 % en 2005.

$L(80) = 61,8$. Quelle est la part des 20 % les mieux payés ? Quelle erreur guette ici ?

$100 - 61,8 = 38,2$ % pour les 20 % les mieux payés. L'erreur : lire le complément comme la part des 20 % du bas. La courbe de Lorenz se lit toujours en partant des plus pauvres ; ce qui reste au-dessus appartient aux plus riches.

Qu'est-ce que la dominance de Lorenz, et qu'autorise-t-elle à conclure ?

Une distribution est **dominée au sens de Lorenz** par une autre si sa courbe est **partout** plus éloignée de la diagonale. Dans ce cas, **tous les indicateurs d'inégalité usuels convergent vers la même conclusion** — quel que soit l'ordre de quantile considéré, la première distribution est plus inégalitaire. **La conclusion est alors robuste au choix de l'indicateur.**

Que se passe-t-il quand deux courbes de Lorenz se croisent ?

L'une est plus inégalitaire **en bas** de la distribution, l'autre **en haut**. **Le classement dépend alors de l'indicateur choisi**, et deux indicateurs peuvent donner des réponses opposées sur les mêmes données. **On ne tranche pas : on décrit les deux phénomènes.**

Définissez l'indice de Gini géométriquement.

Le double de l'aire comprise entre la diagonale et la courbe de Lorenz (l'« aire de concentration ») :

$$G = 2 \times \text{aire}$$

Proche de **1** → concentration (inégalité) **forte**. Proche de **0** → concentration **faible**.

Écrivez la formule de calcul du Gini et expliquez d'où vient chaque terme.

$$G = 2 \left[\frac{1}{2} - \sum \frac{(b+B) \cdot h}{2} \right]$$

$\frac{1}{2}$ = **aire du triangle sous la diagonale** (le carré unité vaut 1, la diagonale le coupe en deux). $\sum \frac{(b+B)h}{2}$ = **aire sous la courbe**, découpée en **trapèzes** (la courbe est un segment entre deux points consécutifs) — b petite base, B grande base, h largeur de la tranche.

Quel est le piège d'unité du calcul du Gini, et quel contrôle le détecte ?

Si les cumuls sont exprimés en pourcentages (0 à 100), les aires de trapèzes sont en « points de % au carré » et le carré entier vaut 10 000 — il faut donc diviser la somme des trapèzes par 10 000 avant de la soustraire à 0,5. **Contrôle** : l'aire de concentration doit être dans [0 ; 0,5] et le Gini dans [0 ; 1]. Un résultat comme 0,5 – 3 764 signale immédiatement l'oubli.

Démontrez que $G = 0$ en cas d'égalité parfaite.

Si tout le monde a la même valeur, les cumuls sont 20 · 40 · 60 · 80 · 100. Les trapèzes valent 200 · 600 · 1 000 · 1 400 · 1 800, soit 5 000. $\text{mathcal{A}} = 0,5 - 5\,000/10\,000 = 0$, donc $G = 0$. **Géométriquement** : la courbe est la diagonale, l'aire entre les deux est nulle.

Pourquoi le Gini maximal d'une population de N individus vaut-il $(N-1)/N$ et non 1 ?

Parce que le dernier individu — celui qui détient tout — occupe une largeur $1/N$ **non nulle** en abscisse. Sous ce dernier segment subsiste un triangle d'aire $\frac{1}{2N}$. D'où $\text{mathcal{A}} = \frac{1}{2} - \frac{1}{2N}$ et $G = 1 - \frac{1}{N}$. **Pour** $N \rightarrow \infty$, $G \rightarrow 1$. En pratique on retient $0 \leq G \leq 1$.

Citez trois précautions avant de comparer deux indices de Gini.

① **Le concept mesuré** : Gini du patrimoine ($> 0,6$ en France) $\gg$ Gini du revenu ($\approx 0,3$). Ce ne sont pas les mêmes objets. ② **Avant ou après redistribution** : le Gini des revenus primaires est bien supérieur à celui du revenu disponible ; l'écart mesure l'effet du système socio-fiscal. ③ **Le champ** : même définition, même population, même période — sinon la comparaison est un artefact.

Pourquoi accompagne-t-on toujours un Gini d'autres indicateurs ?

Parce qu'il est **peu sensible aux extrêmes** : il réagit surtout aux transferts autour du **milieu** de la distribution. Un Gini stable peut masquer un décrochage du dernier centile. **On l'accompagne du rapport D_9/D_1 et de la part du 1 % le plus riche.**

Les applications chiffrées du chapitre

Série des 20 âges (diapositives 42-43) : donnez la moyenne, l'EAM, la variance et l'écart-type.

$m = 47,9$ ans · $EAM = 5,7$ ans · $\sigma^2 = 54,19$ ans² · $\sigma = \sqrt{54,19} = 7,36$ ans. **⚠ Le support s'arrête à la variance : l'écart-type, seul chiffre interprétable, n'y figure pas.**

Niveau de vie 2024 : que vaut le rapport inter-décile et comment se lit-il ?

$D_9/D_1 = 3,48$: les 10 % les plus aisés ont un niveau de vie au moins 3,48 fois supérieur à celui des 10 % les plus modestes. Les écarts entre déciles successifs croissent (3 730 → 2 860 → 9 800 → 12 640 €), ce qui **prouve l'étalement à droite** de la distribution.

Salaires 2005 : quelle part de la masse salariale détient chaque quintile, et que vaut le Gini ?

Parts : 11,2 · 13,3 · 16,2 · 21,1 · 38,2 %. Cumuls : 11,2 · 24,5 · 40,7 · 61,8 · 100,0. Trapèzes : 112 · 357 · 652 · 1 025 · 1 618 → somme 3 764. $\text{mathcal{A}} = 0,5 - 0,3764 = 0,1236 \rightarrow G_{2005} = 0,2472$.

Salaires 2021 : mêmes questions.

Parts : 3,9 · 10,6 · 18,4 · 26,7 · 40,5 %. Cumuls : 3,9 · 14,5 · 32,9 · 59,6 · 100,0. Trapèzes : 39 · 184 · 474 · 925 · 1 596 → somme 3 218. $\text{mathcal{A}} = 0,5 - 0,3218 = 0,1782 \rightarrow G_{2021} = 0,3564$.

Comment ont évolué les inégalités salariales entre 2005 et 2021, et quelle réserve doit accompagner la réponse ?

Hausse forte et robuste : G passe de 0,247 à 0,356 (+ 44 %) ; la part du premier quintile est **divisée par 2,9** (11,2 % → 3,9 %) ; le rapport entre quintiles extrêmes passe de **3,4 à 10,4**. La courbe 2021 est **partout** sous celle de 2005 → **dominance de Lorenz**, donc pas de contradiction possible entre indicateurs. **Réserve** : le plancher (11 000 → 1 333 €), le plafond (55 600 → 51 490 €) et le salaire moyen en euros courants (21 333 → 20 659 €) **baissent tous les trois**, ce qui suggère un **changement de champ** entre les deux millésimes. Une partie de l'écart mesuré peut être un artefact.

Les anomalies du support

Diapositive 55, cas 4 : quelle est l'erreur du support et quelle en est la conséquence ?

Le support annonce une variance de **10,4** et un écart-type de **3,2**. Le recalcul donne $\sigma^2 = 20,8$ et $\sigma = 4,56$ — **exactement le double** : une division par 2 en trop. **Conséquence** : le classement des cas 2 et 4 par dispersion est **inversé**.

Diapositive 48 : pourquoi les conclusions du support ne sont-elles pas reconstituables ?

Elles annoncent « 99 % de chances de faire des gains » via Bienaymé-Tchebychev. Or l'inégalité **exige $k > 1$** , et ici $m/\sigma < 1$ dans **les cinq périodes** : aucun k admissible ne permet la conclusion. De plus **la période 2 a une moyenne négative**. Conclusion non démontrable avec les outils du chapitre.

Méthode et transfert

Donnez l'arbre de décision : quel indicateur choisir ?

① **Type de variable** : qualitative → mode seul ; quantitative → tout est ouvert. ② **Objectif** : niveau typique → position ; homogénéité → dispersion ; partage d'un total → concentration (après vérification que la somme fait sens). ③ **Symétrie** : symétrique → moyenne ; asymétrique ou valeurs extrêmes → **médiane**. ④ **Unités comparables ?** oui → écart-type ; non → **coefficient de variation**. ⑤ **Faut-il agréger ?** moyenne oui ; variance via Koenig ou intra/inter ; **médiane et Gini jamais**.

Traduisez les indicateurs du chapitre en vocabulaire de finance de marché.

Écart-type = volatilité (annualisée par $\sigma\sqrt{252}$ sur des rendements quotidiens). **Quantile = VaR** : la VaR à 99 % est le centile d'ordre 1 de la distribution des pertes. $m/\sigma \approx$ **ratio de Sharpe** (sans taux sans risque) — donc **CV $\approx$ son inverse**. **Décomposition intra/inter = risque spécifique / risque systématique** : la diversification agit sur l'intra, jamais sur l'inter. **Lorenz-Gini = concentration d'un portefeuille** (parent de l'indice de Herfindahl $HHI = \sum w_i^2$) ou d'un P&L.

Pourquoi une moyenne sans écart-type est-elle dangereuse en finance ?

Parce que **deux stratégies de même rendement moyen peuvent avoir des profils de risque opposés**. Un rendement moyen de 8 % avec $\sigma = 3\%$ et le même avec $\sigma = 40\%$ ne se gèrent pas de la même façon : la seconde peut ruiner un compte avant que la moyenne ne se réalise. **La moyenne décrit l'espérance ; l'écart-type décrit ce qu'il faut survivre pour l'atteindre.**

4.3 — Moyens mnémotechniques

MÉTHODE — LES HUIT ANCRAGES DU CHAPITRE

① « **P-D-C** » — **les trois familles, dans l'ordre du cours.** Position (où ?) → Dispersion (à quel point étalé ?) → Concentration (comment le total se partage ?). **Trois lettres, trois questions, trois sections.**

② « **MO-MÉ-MÉ** » — **les trois indicateurs de position.** MOde · MÉdiane · MÉdium (la moyenne, le « milieu » de gravité). Et leur ordre de robustesse aux valeurs extrêmes : **mode et médiane résistent, moyenne non.**

③ « **L'AIRE FAIT L'EFFECTIF** » — **l'histogramme.** Dans un **histogramme**, on **hisse** la **densité** et on lit **l'aire**. Dans un diagramme en **barres**, la **barre** est l'effectif. **Un seul mot à retenir : dès qu'il y a des classes, il y a des aires.**

④ « **ZÉRO, DONC CARRÉ** » — **pourquoi la variance existe.** La somme des écarts à la moyenne vaut **zéro** → il faut casser les signes → **valeur absolue** (EAM, lisible mais non dérivable) ou **carré** (variance, dérivable donc gagnante). **Le zéro est la cause de tout le reste.**

⑤ « **KOENIG : LA MOYENNE DES CARRÉS MOINS LE CARRÉ DE LA MOYENNE.** » La phrase est sa propre formule. Ordre à ne pas inverser : **c'est toujours le gros moins le petit**, puisque la variance est positive — donc $\overline{x^2} \geq (\overline{x})^2$. **Vérification instantanée : si tu obtiens une variance négative, tu as inversé.**

⑥ « **a AJOUTÉ NE CHANGE RIEN, a MULTIPLIÉ CHANGE AU CARRÉ.** » $V(X+a) = V(X)$ · $V(aX) = a^2V(X)$ · $\sigma_{aX} = |a|\sigma_X$. **Image : traduire une figure ne la déforme pas ; l'agrandir la déforme dans les deux dimensions, donc au carré.**

⑦ « **INTRA DANS, INTER ENTRE.** » V_{intra} = dispersion **dans** les groupes. V_{inter} = dispersion **entre** les groupes. Et le total est la somme : $\sigma^2 = V_{\text{intra}} + V_{\text{inter}}$. **En finance : intra = spécifique (diversifiable), inter = systématique (non diversifiable).**


⑧ « **LORENZ SOUS LA DIAGONALE, GINI DOUBLE DE L'AIRE.** » La courbe est **toujours** sous la diagonale (convexité). Le Gini est le **double** de l'aire qui les sépare — **le « 2 » est la faute la plus fréquente : sans lui, on divise le résultat par deux.** Et l'aire des trapèzes se divise par **10 000** quand les cumuls sont en %.

MÉTHODE — TROIS CONTRÔLES À FAIRE SYSTÉMATIQUEMENT — ILS DÉTECTENT 90 % DES ERREURS

Contrôle	Ce qu'il vérifie	Ce qu'il détecte
La somme des fréquences fait 1 (et celle des parts fait 100 %)	La cohérence de la distribution	Une modalité oubliée, un effectif mal reporté
L'indicateur est dans le bon intervalle	$0 \leq G \leq 1 \cdot \sigma \geq 0 \cdot EAM \leq \sigma \cdot$ $x_{\min} \leq Me \leq x_{\max}$	Le piège des unités du Gini, un signe perdu, une racine oubliée
L'ordre de grandeur est plausible	Le résultat comparé à la moyenne et à l'étendue	Une erreur de facteur 10, une division en trop (le cas 4 de la diapositive 55)


Le troisième est le plus important et le plus négligé. Un écart-type supérieur à l'étendue est impossible. Un écart-type de 7,36 sur une série d'âges de moyenne 47,9 est plausible ; un écart-type de 73,6 ne l'est pas.

4.4 — Schéma récapitulatif



Le fil qui relie toute la section « dispersion » :

LE FIL QUI RELIE TOUT : la somme des écarts à la moyenne est NULLE



Et la traduction en salle de marché :

CE QUE CHAQUE FAMILLE DEVIENT EN FINANCE DE MARCHÉ

moyenne rendement espéré

écart-type VOLATILITÉ (annualisée : $s \times \text{racine}(252)$)

quantile VALUE AT RISK

m / s ratio de Sharpe (donc CV = son inverse)

intra / inter risque spécifique / risque systématique

Lorenz - Gini concentration d'un portefeuille (cf. Herfindahl)

5. Entraînement progressif

OBJECTIFS — COMMENT UTILISER CETTE PARTIE

Quatre niveaux, dans l'ordre, sans en sauter. Le niveau 1 vérifie que tu sais *dire* ; le niveau 2 que tu sais *calculer* ; le niveau 3 que tu sais *raisonner* ; le niveau 4 que tu sais *composer* dans les conditions de l'examen.

Règle absolue : traite chaque exercice sur papier, entièrement, avant de lire la correction. Lire une correction sans avoir cherché ne produit qu'une illusion de compétence — c'est exactement ce qui fait échouer les étudiants qui « ont l'impression de comprendre le cours ».

Niveau 1 — Restitution

Vingt-deux questions. Réponds sans rien regarder, puis compare.

- Q1.** Quelle est la différence de nature entre « présenter » et « résumer » des données ?
- Q2.** Citez les trois familles d'indicateurs et la question à laquelle chacune répond.
- Q3.** Définissez le mode. Sur quel type de variable est-il le seul indicateur de position disponible ?
- Q4.** Comment détermine-t-on la classe modale lorsque les classes ont des amplitudes inégales ? Donnez la formule.
- Q5.** Dans un histogramme, que représentent la hauteur et l'aire d'un rectangle ? Démontrez-le.
- Q6.** Donnez les trois écritures de la moyenne arithmétique.
- Q7.** Énoncez et démontrez la propriété « la somme des écarts à la moyenne est nulle ». Quelle conséquence a-t-elle sur la construction des indicateurs de dispersion ?
- Q8.** Comment calcule-t-on la médiane sur données brutes selon la parité de l'effectif ?
- Q9.** Peut-on calculer la médiane d'un ensemble à partir des médianes de ses sous-groupes ? Justifiez par un contre-exemple.
- Q10.** Que conclut-on de la comparaison entre médiane et moyenne ?
- Q11.** Définissez un quantile d'ordre p à l'aide de la fonction de répartition.
- Q12.** Combien de valeurs délimitent les quartiles ? les déciles ? les centiles ?
- Q13.** Citez les trois écarts inter-quantiles usuels et ce que chacun décrit.
- Q14.** Décrivez la construction d'un *boxplot* et les trois informations qu'on y lit.
- Q15.** Écrivez l'EAM, la variance et l'écart-type. Pourquoi passe-t-on de la variance à l'écart-type ?
- Q16.** Énoncez la formule de Koenig et expliquez pourquoi elle rend l'agrégation possible.
- Q17.** Donnez les trois propriétés de la variance et leur traduction sur l'écart-type.

Q18. Énoncez l'inégalité de Bienaymé-Tchebychev et ses conditions d'usage.

Q19. Écrivez la décomposition intra / inter et dites ce que mesure le rapport $V_{\text{inter}}/\sigma^2$.

Q20. Quelle condition une variable doit-elle remplir pour qu'on puisse mesurer sa concentration ? Donnez un exemple de chaque côté.

Q21. Définissez la courbe de Lorenz et énoncez ses quatre propriétés.

Q22. Écrivez la formule du Gini, expliquez d'où vient chaque terme et donnez le piège d'unité.

CORRIGÉ — RÉPONSES ATTENDUES

Q1. Présenter **conserve toute** l'information (série brute, distribution des effectifs). Résumer en **perdre volontairement** pour produire quelques chiffres décisionnels. La perte est le prix de la décision.

Q2. Position — où se situe la distribution ? **Dispersion** — à quel point est-elle étalée ? **Concentration** — comment le total se partage-t-il ?

Q3. La modalité de **fréquence maximale**. C'est le **seul indicateur de position calculable sur une variable qualitative**.

Q4. Par la **densité maximale** : $d_i = n_i/a_i$ avec $a_i = b_{\text{sup}} - b_{\text{inf}}$. Une classe plus large contient mécaniquement plus d'individus sans être plus dense.

Q5. Hauteur = **densité** ; aire = **effectif**. Démonstration : aire = $d_i \times a_i = \frac{n_i}{a_i} \times a_i = n_i$.

Q6. $m_X = \frac{1}{N} \sum x_i$ (brutes) · $m_X = \sum f_i x_i$ (distribution) · $m_X = \sum \frac{N_k}{N} m_{X_k}$ (agrégation).

Q7. $\sum (x_i - m_X) = \sum x_i - N m_X = N m_X - N m_X = 0$. **Conséquence** : un indicateur de dispersion fondé sur la moyenne des écarts vaudrait 0 pour toute distribution — d'où le passage aux **valeurs absolues** (EAM) ou aux **carrés** (variance).

Q8. Trier d'abord. N impair $\rightarrow$ valeur de rang $(N+1)/2$. N pair $\rightarrow$ **moyenne des valeurs de rang $N/2$ et $N/2+1$** .

Q9. Non. Contre-exemple : $\{1;2;3\}$ ($Me = 2$) et $\{100;200;300\}$ ($Me = 200$) $\rightarrow$ moyenne des médianes = 101, vraie médiane de la réunion = $(3+100)/2 = 51,5$.

Q10. $Me < m \rightarrow$ étalée à **droite** ; $Me > m \rightarrow$ étalée à **gauche** ; $Me \approx m \rightarrow$ **symétrique**.

Q11. Q_p est la valeur telle que $F(Q_p) = p$: le quantile est **l'inverse de la fonction de répartition**, $Q_p = F^{-1}(p)$.

Q12. **3** valeurs pour les quartiles, **9** pour les déciles, **99** pour les centiles. Règle : n parts $\Rightarrow n-1$ valeurs.

Q13. $Q_3 - Q_1$ (50 % centraux) · $D_9 - D_1$ (80 % centraux) · D_9/D_1 (le même en relatif, **sans unité**).

Q14. Boîte de Q_1 à Q_3 , trait à la **médiane**, moustaches aux extrêmes. On y lit le **niveau**, la **dispersion** et **l'asymétrie** (trait décentré dans la boîte).

Q15. $EAM = \frac{1}{N} \sum |x_i - m|$ · $V = \frac{1}{N} \sum (x_i - m)^2$ · $\sigma = \sqrt{V}$. On passe à l'écart-type parce que la variance est en **unité au carré**, donc ininterprétable.

Q16. $V(X) = \frac{1}{N} \sum x_i^2 - m_X^2$. Elle ne demande que **deux sommes** calculables en **un seul passage** ; il suffit donc de transmettre deux nombres par groupe pour reconstituer la variance de l'ensemble.

Q17. $V(X+a) = V(X)$ · $V(aX) = a^2 V(X)$ · $V(-X) = V(X)$. Sur l'écart-type : $\sigma_{aX} = |a| \sigma_X$.

Q18. $P(|X - m| \geq k\sigma) \leq 1/k^2$, avec $k > 1$ et **sans aucune hypothèse sur la loi** — d'où une borne valable partout mais **très lâche**.

Q19. $\sigma^2 = V_{\text{intra}} + V_{\text{inter}}$ avec $V_{\text{intra}} = \sum \frac{N_k}{N} \sigma_k^2$ et $V_{\text{inter}} = \sum \frac{N_k}{N} (m_{X_k} - m_X)^2$. Le rapport $V_{\text{inter}}/\sigma^2$ mesure le **pouvoir explicatif du découpage**.

Q20. Sa somme doit avoir un sens (variable extensive). Oui : salaire $\rightarrow$ masse salariale. Non : taille, note, âge.

Q21. Abscisse = fréquence cumulée de la population ; ordonnée = part cumulée de l'agrégat ; individus rangés par X **croissant**. Propriétés : ① passe par (0;0) et (100;100) ; ② croissante ; ③ pente = m_{X_k}/m_X ; ④ convexe donc **sous la diagonale**.

Q22. $G = 2\left[\frac{1}{2} - \sum \frac{(b+B)h}{2}\right]$. Le $\frac{1}{2}$ est l'aire du triangle sous la diagonale ; la somme est l'aire sous la courbe découpée en trapèzes ; le facteur 2 vient de la définition $G = 2\text{mathcal{A}}$. **Piège d'unité** : si les cumuls sont en %, **diviser la somme des trapèzes par 10 000**.

Niveau 2 — Application chiffrée

Exercice 2.1 — Classe modale et histogramme

Une entreprise répartit ses 500 salariés selon leur ancienneté (en années) :

Ancienneté	Effectif
[0 ; 2[	120
[2 ; 5[	150
[5 ; 10[	130
[10 ; 20[	100
Total	500

a. Quelle classe a l'effectif le plus élevé ? **b.** Calculez les amplitudes et les densités. **c.** Quelle est la classe modale ? Commentez l'écart avec la réponse de la question a. **d.** Quelles hauteurs porteriez-vous sur un histogramme ?

CORRIGÉ — CORRIGÉ DE L'EXERCICE 2.1

a. La classe [2 ; 5[, avec 150 salariés.

b. Amplitude $a_i = b_{\text{sup}} - b_{\text{inf}}$; densité $d_i = n_i / a_i$.

Classe	n_i	a_i	$d_i = n_i/a_i$
[0 ; 2[	120	2	$120/2 = 60,0$
[2 ; 5[	150	3	$150/3 = 50,0$
[5 ; 10[	130	5	$130/5 = 26,0$
[10 ; 20[	100	10	$100/10 = 10,0$

c. La classe modale est [0 ; 2[, de densité 60 — **et non** [2 ; 5[. La classe [2 ; 5[compte plus de salariés (150 contre 120) **uniquement parce qu'elle est plus large** (3 ans contre 2). Rapportée à sa largeur, elle est **moins dense**. **Formulation attendue** : « L'ancienneté la plus fréquente se situe dans les deux premières années : la densité y est de 60 salariés par année d'ancienneté, contre 50 dans la classe suivante. »

d. Les densités : 60 · 50 · 26 · 10. Porter les effectifs (120 · 150 · 130 · 100) donnerait une figure fautive : la dernière classe, dix fois plus large que la première, occuperait une aire de $100 \times 10 = 1\,000$ au lieu de 100.

Contrôle : $\sum d_i \times a_i = 60(2) + 50(3) + 26(5) + 10(10) = 120 + 150 + 130 + 100 = 500$ ✓

Exercice 2.2 — Position et dispersion sur une distribution discrète

Le nombre de transactions exécutées chaque jour par un *desk*, observé sur 60 jours :

Transactions x_i	0	1	2	3	4	5
Nombre de jours n_i	5	12	18	14	8	3

a. Vérifiez l'effectif total et calculez les fréquences cumulées. **b.** Calculez la moyenne. **c.** Déterminez la médiane, Q_1 , Q_3 et l'écart inter-quartile. **d.** Calculez l'EAM. **e.** Calculez la variance **par la formule de définition puis par Koenig**, et l'écart-type. **f.** Calculez le coefficient de variation et vérifiez que $EAM \leq \sigma$. **g.** Que conclut-on de la comparaison entre médiane et moyenne ?

CORRIGÉ — CORRIGÉ DE L'EXERCICE 2.2

a. $N = 5+12+18+14+8+3 = 60$ ✓

x_i	0	1	2	3	4	5
n_i	5	12	18	14	8	3
Cumul N_i	5	17	35	49	57	60
F_i	0,0833	0,2833	0,5833	0,8167	0,9500	1,0000

b. $\sum n_i x_i = 0(5) + 1(12) + 2(18) + 3(14) + 4(8) + 5(3) = 0+12+36+42+32+15 = 137$.

$$m_X = \frac{137}{60} = 2,2833 \approx 2,28 \text{ transactions par jour}$$

c. $N = 60$ est **pair** : la médiane est la moyenne des valeurs de rang **30** et **31**. Le cumul atteint 35 à $x = 2$: les rangs 18 à 35 valent tous 2. Donc $Me = \frac{2+2}{2} = 2$. Q_1 : première valeur dont $F \geq 0,25 \rightarrow F(1) = 0,2833 \rightarrow Q_1 = 1$. Q_3 : première valeur dont $F \geq 0,75 \rightarrow F(2) = 0,5833$ (insuffisant), $F(3) = 0,8167 \rightarrow Q_3 = 3$. Écart inter-quartile $= 3 - 1 = 2$ transactions.

d. $\sum n_i |x_i - m|$ avec $m = 2,2833$:

x_i	$ x_i - m $	n_i	Produit
0	2,2833	5	11,4167
1	1,2833	12	15,4000
2	0,2833	18	5,1000
3	0,7167	14	10,0333
4	1,7167	8	13,7333
5	2,7167	3	8,1500
Total		60	63,8333

$$EAM = \frac{63,8333}{60} = 1,0639 \text{ transaction}$$

e. Par définition : $\sum n_i (x_i - m)^2$:

x_i	$(x_i - m)^2$	n_i	Produit
0	5,2136	5	26,0681

x_i	$(x_i - m)^2$	n_i	Produit
1	1,6469	12	19,7633
2	0,0803	18	1,4450
3	0,5136	14	7,1906
4	2,9469	8	23,5756
5	7,3803	3	22,1408
Total		60	100,1833

$$V(X) = \frac{100,1833}{60} = \mathbf{1,6697}$$

Par Koenig : $\sum n_i x_i^2 = 0(5) + 1(12) + 4(18) + 9(14) + 16(8) + 25(3) = 0 + 12 + 72 + 126 + 128 + 75 = 413$.

$$V(X) = \frac{413}{60} - \left(\frac{137}{60}\right)^2 = 6,8833 - 5,2136 = \mathbf{1,6697}$$

Les deux méthodes donnent le même résultat ✓ — et Koenig a demandé **une seule colonne supplémentaire** au lieu de deux.

$$\sigma = \sqrt{1,6697} = \mathbf{1,2922} \text{ transaction}$$

f. $CV = \frac{1,2922}{2,2833} = \mathbf{0,566}$, soit **56,6 %** : la dispersion représente plus de la moitié du niveau moyen — l'activité du *desk* est **très irrégulière**. Contrôle : $EAM = 1,064 \leq \sigma = 1,292$ ✓ (l'écart-type est toujours $\geq EAM$).

g. $Me = 2 < m = 2,28$: la distribution est **légèrement étalée à droite**. Les journées à 4 ou 5 transactions tirent la moyenne au-dessus de la valeur centrale, sans déplacer la médiane. **L'écart est faible (0,28) : l'asymétrie existe mais reste modérée.**

Exercice 2.3 — Décomposition intra / inter

Une salle de marché comprend deux *desks* :

Desk	Effectif N_k	P&L moyen annuel m_k (k€)	Écart-type σ_k (k€)
A — <i>flow</i>	30	12	5
B — <i>prop</i>	20	22	8

a. Calculez le P&L moyen de la salle. **b.** Calculez V_{intra} , V_{inter} , puis σ^2 et σ . **c.** Quelle part de la dispersion totale l'appartenance à un *desk* explique-t-elle ? **d.** Interprétez.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 2.3

a. $N = 30 + 20 = 50$; poids $30/50 = 0,6$ et $20/50 = 0,4$.

$$m_X = 0,6 \times 12 + 0,4 \times 22 = 7,2 + 8,8 = \mathbf{16 \text{ k€}}$$

b.

$$V_{\text{intra}} = 0,6 \times 5^2 + 0,4 \times 8^2 = 0,6(25) + 0,4(64) = 15 + 25,6 = \mathbf{40,6}$$

$$V_{\text{inter}} = 0,6 (12-16)^2 + 0,4 (22-16)^2 = 0,6(16) + 0,4(36) = 9,6 + 14,4 = \mathbf{24,0}$$

$$\sigma^2 = 40,6 + 24,0 = \mathbf{64,6} \quad \sigma = \sqrt{64,6} = \mathbf{8,04 \text{ k€}}$$

c. $\frac{V_{\text{inter}}}{\sigma^2} = \frac{24,0}{64,6} = \mathbf{0,372}$, soit **37,2 %**.

d. Interprétation en trois temps. ① L'écart-type de la salle (8,04 k€) est **supérieur à celui de chaque *desk* pris séparément** (5 et 8) : c'est la composante **inter** qui l'explique — les deux *desks* n'ont pas la même moyenne. ② **37,2 % de la dispersion des P&L s'explique par l'appartenance à un *desk*** ; les 62,8 % restants sont de la variabilité **entre traders d'un même *desk***. ③ **Conséquence managériale** : connaître le *desk* d'un trader ne permet de prédire qu'un tiers de la variabilité de son P&L. **L'essentiel se joue à l'intérieur des équipes** — un argument contre une politique de rémunération fondée uniquement sur le *desk* d'affectation.

Exercice 2.4 — Part de l'agrégat, Lorenz et Gini

Le patrimoine net de 1 000 ménages, réparti en **quintiles** (200 ménages par quintile) :

Quintile	Patrimoine moyen (k€)
1 ^{er} (le plus modeste)	20
2 ^e	60
3 ^e	120

Quintile	Patrimoine moyen (k€)
4 ^e	200
5 ^e (le plus aisé)	600

a. Peut-on mesurer la concentration de cette variable ? Justifiez. **b.** Calculez le patrimoine moyen d'ensemble. **c.** Calculez la part de l'agrégat de chaque quintile. Contrôlez la somme. **d.** Construisez le tableau des cumuls et calculez les pentes de la courbe de Lorenz. **e.** Calculez l'indice de Gini. **f.** Écrivez trois phrases de lecture.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 2.4

a. Oui. La somme des patrimoines a un sens : c'est le **patrimoine total** des 1 000 ménages, une grandeur économique réelle. La condition d'additivité est remplie.

b. Les quintiles ont tous le même poids (0,20), donc la moyenne générale est la **moyenne simple** des cinq moyennes :

$$S = 20 + 60 + 120 + 200 + 600 = 1\,000 \quad m_X = \frac{1\,000}{5} = 200 \text{ k€}$$

$$\text{c. } p_k = \frac{f_k m_k}{m_X} = \frac{0,20 m_k}{200} = \frac{m_k}{1\,000} :$$

Quintile	m_k	p_k	En %
1	20	0,02	2 %
2	60	0,06	6 %
3	120	0,12	12 %
4	200	0,20	20 %
5	600	0,60	60 %
Total	1 000	1,00	100 % ✓

d. Cumuls et pentes = m_k / m_X :

F (%)	Part cumulée (%)	Pente du segment	Lecture
0	0,0	—	—
20	2,0	$20/200 = 0,10$	très en dessous de la moyenne
40	8,0	$60/200 = 0,30$	en dessous
60	20,0	$120/200 = 0,60$	en dessous
80	40,0	$200/200 = 1,00$	exactement à la moyenne
100	100,0	$600/200 = 3,00$	trois fois la moyenne

Le 4^e quintile a une pente égale à 1 : son segment est parallèle à la diagonale. L'écart à la diagonale y est donc **constant et maximal** : à $F = 60$, $60 - 20 = 40$ points ; à $F = 80$, $80 - 40 = 40$ points. **C'est la vérification directe de la propriété 3 de la courbe de Lorenz.**

e. Trapèzes, tous de hauteur $h = 20$ (donc aire = $(b+B) \times 10$) :

Tranche	b	B	Aire
0 → 20	0	2	$2 \times 10 = 20$
20 → 40	2	8	$10 \times 10 = 100$
40 → 60	8	20	$28 \times 10 = 280$
60 → 80	20	40	$60 \times 10 = 600$
80 → 100	40	100	$140 \times 10 = 1\,400$
Somme			2 400

$$\text{mathcal{A}} = 0,5 - \frac{2\,400}{10\,000} = 0,5 - 0,24 = 0,26 \quad G = 2 \times 0,26 = 0,52$$

Contrôle : $0 \leq 0,52 \leq 1$ ✓

f. ① « Les **20 %** des ménages les plus modestes détiennent **2 %** du patrimoine total. » ② « Les **40 %** les plus modestes n'en détiennent que **8 %**, tandis que les **20 %** les plus aisés en détiennent **60 %** — soit **30 fois plus** que le premier quintile. » ③ « L'indice de Gini vaut **0,52** : la concentration est forte, ce qui est caractéristique du patrimoine, bien plus concentré que le revenu. »

Niveau 3 — Maîtrise

Ces six exercices ne se résolvent pas en appliquant une formule. Ils exigent de comprendre pourquoi les formules sont ce qu'elles sont.

Exercice 3.1 — Démontrer que $EAM \leq \sigma$

On a vérifié numériquement, à l'exercice 2.2, que l'EAM était inférieur à l'écart-type. **Démontrez que c'est toujours vrai.**

Indication : appliquez l'inégalité de Cauchy-Schwarz $(\sum a_i b_i)^2 \leq (\sum a_i^2)(\sum b_i^2)$ en posant $a_i = \text{lvert}x_i - m \text{ rvert}$ et $b_i = 1$.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.1

Posons $d_i = \text{lvert}x_i - m \text{ rvert} \geq 0$. Par définition :

$$EAM = \frac{1}{N} \sum_{i=1}^N d_i \quad \sigma^2 = \frac{1}{N} \sum_{i=1}^N d_i^2$$

(car $(x_i - m)^2 = \text{lvert}x_i - m \text{ rvert}^2 = d_i^2$).

Cauchy-Schwarz avec $a_i = d_i$ et $b_i = 1$:

$$(\sum_{i=1}^N d_i \times 1)^2 \leq (\sum_{i=1}^N d_i^2)(\sum_{i=1}^N 1^2) = (\sum d_i^2) \times N$$

Or $\sum d_i = N \times EAM$ et $\sum d_i^2 = N \sigma^2$. En remplaçant :

$$(N \times EAM)^2 \leq N \sigma^2 \times N \quad \implies \quad N^2 EAM^2 \leq N^2 \sigma^2 \quad \implies \quad EAM^2 \leq \sigma^2$$

Les deux quantités étant positives, on peut prendre la racine :

$$\boxed{EAM \leq \sigma}$$

Cas d'égalité. Cauchy-Schwarz est une égalité si et seulement si les vecteurs (d_i) et (1) sont **colinéaires**, c'est-à-dire si **tous les d_i sont égaux** : tous les individus sont à la même distance de la moyenne. C'est le cas d'une série ne prenant que **deux valeurs, symétriques autour de la moyenne et d'effectifs égaux** — par exemple $\{-3; -3; 3; 3\}$: $m = 0$, $EAM = 3$, $\sigma = 3$.

Interprétation. L'écart-type est toujours **au moins aussi grand** que l'EAM parce que le carré **pénalise davantage les grands écarts** : une observation à 10 unités de la moyenne compte 10 fois plus qu'une observation à 1 unité dans l'EAM, mais **100 fois plus** dans la variance. **C'est pourquoi l'écart-type est plus sensible aux valeurs extrêmes que l'EAM** — et c'est aussi pourquoi, en gestion des risques, il sous-estime rarement le danger.

Vérification sur l'exercice 2.2 : $EAM = 1,0639 \leq \sigma = 1,2922$ ✓ — le rapport $\sigma/EAM = 1,21$.

Exercice 3.2 — Moyenne = médiane implique-t-il la symétrie ?

On lit souvent que « si la moyenne égale la médiane, la distribution est symétrique ». **Démontrez que c'est faux** en construisant un contre-exemple explicite.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.2

Contre-exemple : la série {0 ; 4 ; 5 ; 5 ; 11}.

Moyenne : $(0+4+5+5+11)/5 = 25/5 = 5$. **Médiane :** $N = 5$ impair, valeur de rang $(5+1)/2 = 3 \rightarrow$ série triée {0 ; 4 ; 5 ; 5 ; 11} $\rightarrow Me = 5$. **Donc $m = Me = 5$.**

Et pourtant la série n'est pas symétrique. Les écarts à la moyenne valent -5 ; -1 ; 0 ; 0 ; +6. Pour une série symétrique, l'ensemble des écarts serait invariant par changement de signe — or -5 n'a pas de contrepartie +5, et +6 pas de contrepartie -6.

Conclusion rigoureuse :

- « Distribution symétrique » $\implies$ « $m = Me$ » : **vrai**.
- « $m = Me$ » $\implies$ « distribution symétrique » : **faux**. La réciproque n'est pas valable.
- **L'égalité $m = Me$ est donc une condition nécessaire, pas suffisante.**

Ce qu'il faut écrire en examen : « L'écart entre moyenne et médiane est un **indice** d'asymétrie, pas une **preuve** de symétrie quand il est nul. Deux asymétries opposées peuvent se compenser. »

Pourquoi cela compte en finance. Une distribution de rendements peut avoir une moyenne égale à sa médiane et rester **fortement asymétrique** : beaucoup de petits gains compensés par quelques pertes rares mais énormes. C'est le profil de risque le plus dangereux qui soit, et **ni la moyenne ni la médiane ne le révèlent**. Il faut regarder la **distribution entière** — d'où les *boxplots*, les quantiles extrêmes et, plus tard, les mesures d'asymétrie.

Exercice 3.3 — Prime forfaitaire ou augmentation proportionnelle ?

On reprend les données de l'exercice 2.4 (patrimoines moyens par quintile : $20 \cdot 60 \cdot 120 \cdot 200 \cdot 600$ k€, $m = 200$, $G = 0,52$).

L'État hésite entre deux mesures :

- **Mesure A** : verser **100 k€ à chaque ménage** (forfait identique pour tous).
- **Mesure B** : augmenter **tous les patrimoines de 10 %** (mesure proportionnelle).

a. Calculez le nouveau Gini dans chaque cas. **b.** Démontrez le résultat général dans chaque cas. **c.** Que conclure ?

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.3

a. Mesure A — le forfait de 100 k€.

Nouvelles moyennes : $120 \cdot 160 \cdot 220 \cdot 300 \cdot 700$. Total = 1 500, donc $m' = 1\,500/5 = 300$ k€.

Quintile	m'_k	$p'_k = m'_k/1\,500$	En %	Cumul
1	120	0,0800	8,00	8,00
2	160	0,1067	10,67	18,67
3	220	0,1467	14,67	33,33
4	300	0,2000	20,00	53,33
5	700	0,4667	46,67	100,00

Trapezes ($h = 20$, donc aire = $(b+B) \times 10$) : $80 \cdot 266,67 \cdot 520 \cdot 866,67 \cdot 1\,533,33 \rightarrow$ **somme = 3 266,67.**

$$\text{mathcal{A}} = 0,5 - 0,326667 = 0,173333 \quad G_A = \mathbf{0,347}$$

Le Gini chute de 0,52 à 0,347, soit une baisse d'exactement un tiers.

Mesure B — l'augmentation de 10 %.

Nouvelles moyennes : $22 \cdot 66 \cdot 132 \cdot 220 \cdot 660$. Total = 1 100, $m' = 220$ k€. Parts : $22/1\,100 = 2\%$ · $66/1\,100 = 6\%$ · $132/1\,100 = 12\%$ · $220/1\,100 = 20\%$ · $660/1\,100 = 60\%$. **Ce sont exactement les parts de départ.** La courbe de Lorenz est **identique**, donc

$$G_B = \mathbf{0,52} \quad \text{— inchangé.}$$

b. Les deux démonstrations.

Mesure B (proportionnelle) — le Gini est invariant d'échelle. Si $x'_i = a x_i$ avec $a > 0$, alors $m'_k = a m_k$ et $m' = a m$, donc

$$p'_k = \frac{f_k m'_k}{m'} = \frac{f_k a m_k}{a m} = \frac{f_k m_k}{m} = p_k$$

Toutes les parts sont inchangées, donc la courbe de Lorenz et le Gini aussi. Le Gini est un indicateur *relatif* : il ne voit pas les niveaux, seulement les proportions.

Mesure A (forfaitaire) — le Gini est réduit dans un rapport connu. Si $x'_i = x_i + c$ avec $c > 0$, alors $m' = m + c$, et les **écarts entre individus sont inchangés** : $x'_i - x'_j = x_i - x_j$. Or l'indice de Gini admet une écriture équivalente à sa définition géométrique :

$$G = \frac{\Delta}{2m} \quad \text{avec} \quad \Delta = \frac{1}{N^2} \sum_{i=1}^N \sum_{j=1}^N |x_i - x_j|$$

où Δ est la **différence absolue moyenne** entre deux individus tirés au hasard. Comme Δ est inchangé et m augmenté de c :

$$G' = \frac{\Delta}{2(m+c)} = G \times \frac{m}{m+c}$$

Vérification numérique : $\Delta = 2mG = 2 \times 200 \times 0,52 = 208$. Après la mesure : $G' = 208/(2 \times 300) = 0,3467$ ✓ —
exactement la valeur trouvée par les trapèzes. Et $G \times \frac{m}{m+c} = 0,52 \times \frac{200}{300} = 0,52 \times \frac{2}{3} = 0,3467$ ✓

PIÈGE FRÉQUENT

La formule $G = \Delta/(2m)$ n'est pas au programme du chapitre — le support ne donne que la définition géométrique. Je te la donne parce qu'elle **démontre en trois lignes** ce que les trapèzes ne montrent que numériquement, et parce qu'elle éclaire ce que le Gini mesure vraiment : **l'écart typique entre deux individus tirés au hasard, rapporté au niveau moyen**. En examen, utilise la méthode des trapèzes — mais si tu cites cette identité en remarque, elle vaut des points.

c. Conclusion.

	Effet sur le niveau moyen	Effet sur le Gini
Forfait de c	$m \rightarrow m + c$	$G \rightarrow G \times \frac{m}{m+c}$ — baisse
Hausse de a %	$m \rightarrow a m$	$G \rightarrow G$ — inchangé

Une mesure forfaitaire réduit toujours les inégalités relatives ; une mesure proportionnelle ne les modifie jamais. C'est le fondement mathématique d'un débat de politique économique permanent — chèque énergie forfaitaire contre baisse proportionnelle de la TVA, augmentation générale en euros contre augmentation en pourcentage.

Et la limite à signaler : en valeur absolue, la mesure B donne 60 k€ au dernier quintile et 2 k€ au premier — l'écart absolu se creuse de 58 k€ alors que le Gini ne bouge pas. Le Gini mesure l'inégalité relative, pas l'écart absolu. Ne jamais confondre les deux.

Exercice 3.4 — Deux courbes qui se croisent

Deux pays, chacun décrit par les parts de revenu de ses cinq quintiles :

Quintile	Pays X (%)	Pays Y (%)
1 ^{er}	10	2
2 ^e	10	13
3 ^e	10	20
4 ^e	10	25
5 ^e	60	40

a. Construisez les cumuls et montrez que les deux courbes de Lorenz se croisent. **b.** Calculez les deux indices de Gini. **c.** Calculez le rapport Q_5/Q_1 et la part du quintile supérieur dans chaque pays. **d.** Quel pays est « le plus inégalitaire » ? Rédigez la conclusion attendue.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.4

a. Cumuls :

F (%)	Pays X	Pays Y	X - Y
20	10	2	+ 8
40	20	15	+ 5
60	30	35	- 5
80	40	60	- 20
100	100	100	0

Le signe de l'écart change entre 40 % et 60 % : les deux courbes se croisent. Y est au-dessous de X dans le bas de la distribution (donc plus inégalitaire pour les plus pauvres) et au-dessus dans le haut (donc moins inégalitaire pour la classe moyenne supérieure).

b. Trapèzes ($h = 20$, aire = $(b+B) \times 10$) :

Tranche	X	Y
0 → 20	$(0+10) \times 10 = 100$	$(0+2) \times 10 = 20$
20 → 40	$(10+20) \times 10 = 300$	$(2+15) \times 10 = 170$
40 → 60	$(20+30) \times 10 = 500$	$(15+35) \times 10 = 500$
60 → 80	$(30+40) \times 10 = 700$	$(35+60) \times 10 = 950$
80 → 100	$(40+100) \times 10 = 1\,400$	$(60+100) \times 10 = 1\,600$
Somme	3 000	3 240

$A_X = 0,5 - 0,300 = 0,200 \Rightarrow G_X = 0,400$ $A_Y = 0,5 - 0,324 = 0,176 \Rightarrow G_Y = 0,352$ Selon le Gini, X est plus inégalitaire que Y.

c.

Indicateur	Pays X	Pays Y	Verdict
Rapport Q_5/Q_1	$60/10 = 6,0$	$40/2 = 20,0$	Y bien plus inégalitaire
Part du quintile supérieur	60 %	40 %	X plus inégalitaire
Indice de Gini	0,400	0,352	X plus inégalitaire

d. La conclusion attendue.

« Les deux courbes de Lorenz se croisent entre 40 % et 60 % : **il n'y a pas de dominance de Lorenz**, et les indicateurs ne peuvent donc pas converger mécaniquement. C'est précisément ce que l'on observe. Le rapport Q_5/Q_1 , qui met l'accent sur les **extrêmes**, désigne Y comme plus inégalitaire (20 contre 6), parce que son premier quintile ne perçoit que 2 % du revenu. La part du quintile supérieur et l'indice de Gini, qui pèsent davantage la **structure d'ensemble**, désignent X (60 % contre 40 % ; $G = 0,400$ contre 0,352). **Les deux réponses sont exactes : elles ne mesurent pas la même chose**. X concentre le revenu au sommet ; Y laisse ses plus pauvres avec presque rien. Une réponse unique au classement des deux pays exigerait de fixer d'abord ce que l'on juge prioritaire — le sort des plus pauvres ou la part du sommet — ce qui est un **choix normatif, pas statistique**. »

C'est cette dernière phrase qui distingue une excellente copie. Le statisticien décrit ; il ne tranche pas un arbitrage de valeurs sans le dire.

Exercice 3.5 — Volatilité, annualisation et Bienaymé-Tchebychev

Les rendements mensuels d'un fonds sur douze mois, en pourcentage :

+2,1	-1,4	+3,2	+0,8	-2,6	+4,1
+1,5	-0,7	+2,9	-3,1	+1,8	+2,4

a. Calculez le rendement moyen mensuel. **b.** Calculez la variance (par Koenig) et l'écart-type mensuel. **c.** Annualisez le rendement et la volatilité. (*Rappel : la volatilité s'annualise en multipliant par $\sqrt{12}$ pour des données mensuelles.*) **d.** Calculez le coefficient de variation et le rapport m/σ annualisé. **e.** Appliquez Bienaymé-Tchebychev avec $k = 2$, puis comparez la borne aux données observées. Que constatez-vous ?

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.5

a. $\sum x_i = 2,1 - 1,4 + 3,2 + 0,8 - 2,6 + 4,1 + 1,5 - 0,7 + 2,9 - 3,1 + 1,8 + 2,4 = 11,0$

$$m = \frac{11,0}{12} = 0,9167 \% \text{ par mois}$$

b. $\sum x_i^2 = 4,41 + 1,96 + 10,24 + 0,64 + 6,76 + 16,81 + 2,25 + 0,49 + 8,41 + 9,61 + 3,24 + 5,76 = 70,58$

$$V = \frac{70,58}{12} - (0,9167)^2 = 5,8817 - 0,8403 = 5,0414$$

$$\sigma = \sqrt{5,0414} = 2,2453 \% \text{ par mois}$$

c. Rendement annualisé (somme des douze mois, approximation additive) : $12 \times 0,9167 = 11,0 \%$. Volatilité annualisée : $\sigma_{\text{an}} = 2,2453 \times \sqrt{12} = 2,2453 \times 3,4641 = 7,78 \%$.

PIÈGE FRÉQUENT

Pourquoi $\sqrt{12}$ et non 12 ? Parce que **les variances s'additionnent, pas les écarts-types** — c'est la propriété $V(aX) = a^2V(X)$ appliquée à une somme de mois indépendants : $V_{\text{an}} = 12 V_{\text{mens}}$, donc $\sigma_{\text{an}} = \sqrt{12} \sigma_{\text{mens}}$. **C'est exactement le « moyen » annoncé par la diapositive 49 du support : la volatilité ne s'aggrave pas linéairement.** (L'hypothèse d'indépendance des rendements mensuels est une convention de marché ; elle est approximative mais universellement utilisée.)

d. $CV = \frac{2,2453}{0,9167} = 2,449$ — **la dispersion vaut près de 2,5 fois le rendement moyen mensuel.** Rapport m/σ mensuel = 0,4083 ; annualisé = $0,4083 \times \sqrt{12} = 1,414$. **Lecture :** ce rapport est la structure du **ratio de Sharpe** (sans taux sans risque). Une valeur de 1,41 est bonne. **Et le CV en est l'inverse :** $1/2,449 = 0,408$ ✓ — la même information, lue à l'envers.

e. Avec $k = 2$: Bienaymé-Tchebychev garantit que **au moins $1 - 1/4 = 75 \%$** des observations se trouvent dans l'intervalle

$$[m - 2\sigma ; m + 2\sigma] = [0,9167 - 4,4906 ; 0,9167 + 4,4906] = [-3,57 \% ; +4,41 \%]$$

Confrontation aux données : le minimum observé est -3,1 et le maximum +4,1 — **les douze mois, soit 100 %, sont dans l'intervalle.**

Ce qu'il faut constater et écrire : « La borne garantit 75 % ; on observe 100 %. L'inégalité est donc **très lâche**, ce qui est normal : elle est valable **quelle que soit la loi** de la variable, y compris pour les distributions les plus défavorables. Son intérêt n'est pas la précision mais l'**universalité** — elle donne une garantie sans rien supposer. Si l'on acceptait l'hypothèse de normalité, l'intervalle à $\pm 2\sigma$ contiendrait environ 95 % des observations, ce qui serait bien plus informatif mais reposerait sur une hypothèse invérifiable sur douze points. »

En gestion des risques, c'est exactement l'arbitrage quotidien : une borne robuste et large, ou une borne étroite qui suppose une loi que le marché ne respecte pas dans les crises.

Exercice 3.6 — Que peut-on agréger ?

Une administration publique, pour chacune des trois régions d'un territoire, le tableau suivant :

Région	Effectif N_k	Revenu moyen m_k	Revenu médian	Écart-type σ_k	Gini G_k
A	400	24 000	21 000	9 000	0,28
B	350	31 000	27 500	14 000	0,33
C	250	19 000	18 000	6 000	0,22

Pour chacune des quatre grandeurs, dites si l'on peut calculer la valeur d'ensemble à partir de ce tableau seul. Si oui, calculez-la. Si non, expliquez précisément ce qui manque.

CORRIGÉ — CORRIGÉ DE L'EXERCICE 3.6

$N = 400 + 350 + 250 = 1\,000$; poids $0,40 \cdot 0,35 \cdot 0,25$.

① **Le revenu moyen — OUI, calculable.** La moyenne est un opérateur linéaire :

$$m = 0,40(24\,000) + 0,35(31\,000) + 0,25(19\,000) = 9\,600 + 10\,850 + 4\,750 = \mathbf{25\,200\,€}$$

② **Le revenu médian — NON.** La médiane **ne s'agrège pas**, quels que soient les poids (§ 2.1.15). Elle dépend de la **position relative de toutes les observations**, information détruite par le résumé en trois médianes. **Ce qu'il faudrait : les distributions complètes** (ou au moins les fonctions de répartition) des trois régions, pour reconstituer la distribution d'ensemble puis y chercher le rang médian. *(On peut seulement encadrer : la médiane d'ensemble est comprise entre 18 000 et 27 500 €.)*

③ **L'écart-type — OUI, calculable, via la décomposition intra / inter.**

$$V_{\text{intra}} = 0,40(9\,000)^2 + 0,35(14\,000)^2 + 0,25(6\,000)^2$$

$$= 0,40 \times 81 \times 10^6 + 0,35 \times 196 \times 10^6 + 0,25 \times 36 \times 10^6 = 32,4 \times 10^6 + 68,6 \times 10^6 + 9,0 \times 10^6 = \mathbf{110,0 \times 10^6}$$

Écarts des moyennes à 25 200 : $-1\,200 \cdot +5\,800 \cdot -6\,200$.

$$V_{\text{inter}} = 0,40(1\,200)^2 + 0,35(5\,800)^2 + 0,25(6\,200)^2$$

$$= 0,40 \times 1,44 \times 10^6 + 0,35 \times 33,64 \times 10^6 + 0,25 \times 38,44 \times 10^6$$

$$= 0,576 \times 10^6 + 11,774 \times 10^6 + 9,610 \times 10^6 = \mathbf{21,96 \times 10^6}$$

$$\sigma^2 = 110,0 \times 10^6 + 21,96 \times 10^6 = 131,96 \times 10^6 \quad \sigma = \mathbf{11\,487\,€}$$

Remarque à faire : $V_{\text{inter}}/\sigma^2 = 21,96/131,96 = \mathbf{16,6\, \%}$ — la région d'appartenance n'explique qu'un sixième de la dispersion des revenus. **L'essentiel des inégalités est intra-régional.**

④ **Le Gini d'ensemble — NON.** Comme la médiane, le Gini repose sur le **classement de tous les individus** : la courbe de Lorenz d'ensemble exige de fusionner les trois populations et de les réordonner. Trois indices régionaux n'y suffisent pas. **Ce qu'il faudrait :** les distributions complètes, ou au minimum les parts de l'agrégat par quantile de chaque région **plus** les masses de revenu régionales. **Et un raisonnement à connaître :** le Gini d'ensemble est **supérieur** à la moyenne pondérée des Gini régionaux, parce qu'à l'inégalité interne de chaque région s'ajoute l'inégalité **entre** régions — même mécanique que la composante inter de la variance.

SYNTHÈSE — LA RÈGLE GÉNÉRALE À RETENIR

Grandeur	S'agrège ?	Pourquoi
Somme, effectif	Oui	Additivité directe
Moyenne	Oui (pondérée)	Opérateur linéaire
Variance, écart-type	Oui	Via Koenig ou intra/inter — deux nombres par groupe suffisent
Médiane, quantiles	Non	Dépendent du rang , pas de la valeur
Gini, courbe de Lorenz	Non	Dépendent du classement complet de la population
Mode	Non	Le mode d'ensemble peut n'être le mode d'aucun groupe

Le critère unificateur : ce qui repose sur des sommes s'agrège ; ce qui repose sur des rangs ne s'agrège pas.

Niveau 4 — Simulation d'examen

MÉTHODE — CONDITIONS DE PASSATION

Le support ne donne aucune indication sur le format ni sur la durée de l'épreuve. La simulation retient le format le plus courant pour un chapitre de cette densité : **2 heures**, sur **20 points**, **calculatrice autorisée**, **documents interdits**. Ce chapitre étant plus lourd que le chapitre 1 (trois familles d'indicateurs, plusieurs démonstrations), la durée retenue est supérieure aux 1 h 30 du chapitre précédent. **Ajuste ces paramètres dès que les modalités réelles seront annoncées.**

Chronomètre lancé. **Répartition du temps conseillée** : 25 min pour la partie A, 45 min pour la partie B, 30 min pour la partie C, 15 min pour la partie D, **5 min de relecture** — et la relecture n'est pas optionnelle : c'est là que se rattrapent les erreurs d'unité et de somme.

Sujet

PARTIE A — Questions de cours (5 points)

A.1 (1,5 pt) Énoncez la propriété « la somme des écarts à la moyenne est nulle » et démontrez-la. Expliquez en deux phrases pourquoi cette propriété **oblige** à construire les indicateurs de dispersion à partir de valeurs absolues ou de carrés.

A.2 (1,5 pt) Énoncez la formule de Koenig. Démontrez, à partir d'elle, que $\overline{x^2} \geq (\bar{x})^2$. Expliquez en une phrase pourquoi cette formule rend possible l'agrégation des variances.

A.3 (1 pt) Un étudiant calcule l'indice de Gini de la variable « note obtenue au partiel » sur les 1 200 étudiants de la promotion. Le calcul aboutit à $G = 0,14$. Commentez.

A.4 (1 pt) Deux courbes de Lorenz se croisent. Peut-on conclure que l'une des deux distributions est plus inégalitaire que l'autre ? Justifiez.

PARTIE B — Position et dispersion (7 points)

Les salaires mensuels nets des 200 salariés d'une PME se répartissent ainsi :

Salaire mensuel net (€)	Effectif
[1 200 ; 1 600[	40
[1 600 ; 2 000[	50
[2 000 ; 2 800[	60
[2 800 ; 4 400[	50
Total	200

B.1 (1 pt) Déterminez la classe modale. Justifiez votre méthode.

B.2 (1 pt) Calculez le salaire moyen. Précisez l'hypothèse que vous utilisez.

B.3 (1,5 pt) Calculez la médiane par interpolation linéaire.

B.4 (1,5 pt) Calculez Q_1 et Q_3 , puis l'écart inter-quartile.

B.5 (1,5 pt) Calculez la variance et l'écart-type.

B.6 (0,5 pt) Calculez le coefficient de variation et commentez la forme de la distribution en une phrase argumentée.

PARTIE C — Concentration (5 points)

On s'intéresse maintenant au partage de la **masse salariale** de cette même PME.

C.1 (0,5 pt) Justifiez qu'il est légitime de mesurer la concentration de cette variable.

C.2 (1,5 pt) Calculez la part de la masse salariale détenue par chaque classe. Arrondissez au dixième et contrôlez la somme.

C.3 (1 pt) Construisez le tableau des cumuls nécessaire à la courbe de Lorenz. **Attention aux hauteurs de tranche.**

C.4 (1,5 pt) Calculez l'indice de Gini.

C.5 (0,5 pt) Rédigez deux phrases d'interprétation.

PARTIE D — Application (3 points)

Les rendements mensuels d'un fonds sur six mois, en pourcentage :

+3,2	-1,8	+2,4	+0,6	-2,2	+1,8
------	------	------	------	------	------

D.1 (1 pt) Calculez le rendement moyen mensuel et l'écart-type mensuel (par Koenig).

D.2 (1 pt) Annualisez les deux grandeurs. Justifiez le facteur d'annualisation de la volatilité par une propriété du cours.

D.3 (1 pt) Un gérant affirme : « La volatilité annuelle est de 7 %, donc le fonds ne peut pas perdre plus de 7 % sur une année. » Réfutez cette affirmation en mobilisant précisément le cours.

CORRIGÉ — PARTIE A (5 POINTS)

A.1 (1,5 pt)

Énoncé (0,5 pt) : pour toute série $(x_1, \dots, x_N)$ de moyenne m_X , $\sum_{i=1}^N (x_i - m_X) = 0$.

Démonstration (0,5 pt) : par linéarité de la somme, $\sum_{i=1}^N (x_i - m_X) = \sum_{i=1}^N x_i - N m_X$. Or, par définition de la moyenne, $m_X = \frac{1}{N} \sum x_i$, donc $\sum x_i = N m_X$. D'où $\sum (x_i - m_X) = N m_X - N m_X = 0$.

Conséquence (0,5 pt) : un indicateur de dispersion défini comme la moyenne des écarts à la moyenne vaudrait donc **0 pour toute distribution**, y compris la plus dispersée — il ne mesurerait rien. Il faut donc **supprimer les signes** avant de moyenner : soit par la valeur absolue (écart absolu moyen), soit par le carré (variance), le carré ayant l'avantage décisif d'être **dérivable partout**.

A.2 (1,5 pt)

Énoncé (0,5 pt) : $V(X) = \frac{1}{N} \sum_{i=1}^N x_i^2 - m_X^2$, soit « la moyenne des carrés moins le carré de la moyenne ».

Démonstration de l'inégalité (0,5 pt) : la variance est une moyenne de carrés, donc $V(X) \geq 0$. En reportant dans Koenig : $\overline{x^2} - (\bar{x})^2 \geq 0$, donc $\overline{x^2} \geq (\bar{x})^2$. **L'égalité a lieu si et seulement si $V(X) = 0$** , c'est-à-dire si tous les x_i sont égaux.

Agrégation (0,5 pt) : Koenig ne fait intervenir que $\sum x_i$ et $\sum x_i^2$; il suffit donc de **transmettre deux nombres par groupe** (plus son effectif) pour reconstituer la variance de l'ensemble, sans jamais revenir aux données individuelles.

A.3 (1 pt)

Le calcul est **numériquement possible mais dépourvu de sens** (0,5 pt). La mesure de concentration porte sur la répartition de la **somme** de la variable ; elle exige donc que cette somme désigne un objet réel. Or **la somme des notes de 1 200 étudiants ne correspond à aucune grandeur** : ce n'est pas un stock que l'on se partagerait. La note est une variable quantitative, mais **non extensive** (0,5 pt).

Ce qu'il fallait faire : mesurer la **dispersion** des notes (écart-type, écarts inter-quartiles), qui elle est parfaitement définie, et non leur concentration.

A.4 (1 pt)

Non, pas de manière univoque (0,5 pt). Le croisement signifie que l'une des distributions est plus inégalitaire dans le **bas** de la distribution et l'autre dans le **haut**. Il n'y a donc **pas de dominance de Lorenz**, et le classement dépend du poids que l'indicateur choisi accorde à chaque zone : le rapport D_9/D_1 privilégie les extrêmes, l'indice de Gini la structure d'ensemble (0,5 pt).

*Deux indicateurs peuvent donc classer les deux distributions en sens opposé, sans que l'un des deux soit faux. La réponse consiste à décrire les deux phénomènes, et à préciser que trancher exigerait un **critère normatif** extérieur à la statistique.*

CORRIGÉ — PARTIE B (7 POINTS)

B.1 — Classe modale (1 pt)

Les classes ayant des **amplitudes inégales**, la classe modale est celle de **densité maximale**, et non d'effectif maximal (0,25 pt pour l'avoir dit). On rapporte chaque effectif à une amplitude de référence de **400 €** :

Classe	n_i	a_i (€)	d_i (effectif par tranche de 400 €)
[1 200 ; 1 600[	40	400	$40 \times \frac{400}{400} = 40,0$
[1 600 ; 2 000[	50	400	50,0
[2 000 ; 2 800[	60	800	$60 \times \frac{400}{800} = 30,0$
[2 800 ; 4 400[	50	1 600	$50 \times \frac{400}{1 600} = 12,5$

La classe modale est [1 600 ; 2 000[(0,5 pt), de densité 50, alors que l'effectif maximal est celui de [2 000 ; 2 800[(60 salariés) (0,25 pt pour la remarque). Cette dernière ne doit son effectif qu'à une amplitude deux fois plus grande.

B.2 — Salaire moyen (1 pt)

Hypothèse (0,25 pt) : les salariés sont supposés **uniformément répartis** à l'intérieur de chaque classe ; on retient donc le **centre de classe** comme valeur représentative.

Classe	Centre c_i	n_i	f_i	$f_i c_i$
[1 200 ; 1 600[	1 400	40	0,20	280
[1 600 ; 2 000[	1 800	50	0,25	450
[2 000 ; 2 800[	2 400	60	0,30	720
[2 800 ; 4 400[	3 600	50	0,25	900
Total		200	1,00	2 350

$$m_X = \sum f_i c_i = 2\,350 \text{ €} \quad (0,75 \text{ pt})$$

B.3 — Médiane (1,5 pt)

Fréquences cumulées (0,5 pt) : 0,20 · 0,45 · **0,75** · 1,00. La médiane est la valeur telle que $F(\text{Me}) = 0,50$. Elle se situe donc dans la classe [2 000 ; 2 800[, où F passe de 0,45 à 0,75 (0,25 pt).

Interpolation linéaire (0,75 pt) :

$$Me = 2\,000 + 800 \times \frac{0,50 - 0,45}{0,75 - 0,45} = 2\,000 + 800 \times \frac{0,05}{0,30} = 2\,000 + 133,33 = \mathbf{2\,133,3\,€}$$

Contrôle : $2\,000 \leq 2\,133,3 < 2\,800$ ✓ — la médiane appartient bien à sa classe.

B.4 — Quartiles (1,5 pt)

Q_1 : $F = 0,25$ tombe dans $[1\,600 ; 2\,000[$ (F passe de 0,20 à 0,45).

$$Q_1 = 1\,600 + 400 \times \frac{0,25 - 0,20}{0,45 - 0,20} = 1\,600 + 400 \times 0,20 = \mathbf{1\,680\,€} \quad (0,5\,pt)$$

Q_3 : $F(2\,800) = 0,75$ **exactement** — aucune interpolation n'est nécessaire.

$$Q_3 = \mathbf{2\,800\,€} \quad (0,5\,pt, \text{ dont } 0,25 \text{ pour avoir vu que la borne est atteinte pile})$$

Écart inter-quartile = $2\,800 - 1\,680 = \mathbf{1\,120\,€}$ (0,5 pt). **Lecture :** les 50 % de salariés situés au centre de la distribution sont répartis sur une plage de $\mathbf{1\,120\,€}$.

B.5 — Variance et écart-type (1,5 pt)

Par la formule de définition (1 pt) :

c_i	$c_i - m$	$(c_i - m)^2$	f_i	$f_i (c_i - m)^2$
1 400	− 950	902 500	0,20	180 500
1 800	− 550	302 500	0,25	75 625
2 400	+ 50	2 500	0,30	750
3 600	+ 1 250	1 562 500	0,25	390 625
Total			1,00	647 500

$$V(X) = \mathbf{647\,500\,€^2}$$

Vérification par Koenig (bonus de rigueur) :

$$\begin{aligned} \sum f_i c_i^2 &= 0,20(1\,960\,000) + 0,25(3\,240\,000) + 0,30(5\,760\,000) + 0,25(12\,960\,000) \\ &= 392\,000 + 810\,000 + 1\,728\,000 + 3\,240\,000 = 6\,170\,000 ; m^2 = 2\,350^2 = 5\,522\,500 ; \\ V &= 6\,170\,000 - 5\,522\,500 = 647\,500 \quad \checkmark \end{aligned}$$

$$\sigma = \sqrt{647\,500} = \mathbf{804,7\,€} \quad (0,5\,pt)$$

⚠ Ne jamais s'arrêter à la variance : 647 500 « euros au carré » ne s'interprète pas.

B.6 — Coefficient de variation et commentaire (0,5 pt)

$$CV = \frac{804,7}{2\,350} = \mathbf{0,342} \quad \text{soit } 34,2\,\%$$

Commentaire attendu : « La dispersion représente 34 % du salaire moyen : l'éventail salarial est **modérément ouvert**. Surtout, $Me = 2\,133\text{ €} < m = 2\,350\text{ €}$: la distribution est **étalée vers la droite**. Une minorité de salaires élevés — la classe $[2\,800 ; 4\,400[$ regroupe un quart des salariés sur une amplitude quatre fois supérieure à celle de la première classe — tire la moyenne au-dessus de la valeur centrale. **La médiane décrit donc mieux le salarié typique que la moyenne.** »

CORRIGÉ — PARTIE C (5 POINTS)

C.1 — Légitimité (0,5 pt)

La somme des salaires a un sens économique précis : c'est la **masse salariale** de la PME, montant qu'elle verse effectivement chaque mois. La variable est **extensive et additive** : la mesure de concentration est donc légitime. (À l'inverse, une concentration d'âges ou de notes n'aurait pas de sens.)

C.2 — Parts de la masse salariale (1,5 pt)

$p_k = \frac{f_k c_k}{m_X}$, avec $m_X = 2\,350$ € — les produits $f_k c_k$ ont déjà été calculés en B.2.

Classe	$f_k c_k$	$p_k = f_k c_k / 2\,350$	En % (arrondi)
[1 200 ; 1 600[	280	0,11915	11,9
[1 600 ; 2 000[	450	0,19149	19,1
[2 000 ; 2 800[	720	0,30638	30,6
[2 800 ; 4 400[	900	0,38298	38,3
Total	2 350	1,00000	99,9 $\triangle$

Contrôle et remarque attendue (0,25 pt) : la somme des parts **exactes** vaut exactement 100 %, mais la somme des parts **arrondies au dixième** vaut 99,9 %. **Il s'agit d'un écart d'arrondi, non d'une erreur** : chacune des quatre valeurs a été arrondie vers le bas. Je poursuis avec les valeurs arrondies en signalant que le résultat final en sera affecté à la troisième décimale.

C.3 — Tableau des cumuls (1 pt)

$\triangle$ **Les classes n'ont pas la même fréquence** : les hauteurs de tranche ne sont donc **pas** toutes égales à 20 comme dans le cas des quintiles (0,25 pt pour l'avoir repéré).

Classe	f_k (%)	Cumul de population (%)	p_k (%)	Cumul de masse (%)
[1 200 ; 1 600[	20	20	11,9	11,9
[1 600 ; 2 000[	25	45	19,1	31,0
[2 000 ; 2 800[	30	75	30,6	61,6
[2 800 ; 4 400[	25	100	38,3	99,9 $\rightarrow$ 100,0

Hauteurs de tranche : $h_1 = 20$, $h_2 = 25$, $h_3 = 30$, $h_4 = 25$ (0,75 pt). Leur somme fait bien 100 ✓

C.4 — Indice de Gini (1,5 pt)

Tranche	b	B	h	Aire = (b+B)h/2
0 → 20	0,0	11,9	20	11,9 × 10 = 119,00
20 → 45	11,9	31,0	25	42,9 × 12,5 = 536,25
45 → 75	31,0	61,6	30	92,6 × 15 = 1 389,00
75 → 100	61,6	100,0	25	161,6 × 12,5 = 2 020,00
Somme			100	4 064,25

Conversion d'unité (0,5 pt — c'est le point le plus souvent perdu) : les cumuls étant exprimés en pourcentages, le carré de référence vaut $100 \times 100 = 10\,000$:

$$\text{mathcal{A}} = 0,5 - \frac{4\,064,25}{10\,000} = 0,5 - 0,406425 = 0,093575$$

$$G = 2 \times 0,093575 = \mathbf{0,187} \quad (0,5 \text{ pt})$$

Contrôles (0,5 pt) : $0 \leq 0,187 \leq 1$ ✓ ; la somme des hauteurs fait 100 ✓. (Avec les parts non arrondies, on obtiendrait 0,186 : l'écart d'arrondi annoncé en C.2 affecte bien la troisième décimale, sans conséquence sur l'interprétation.)

C.5 — Interprétation (0,5 pt)

① « Les **20 %** de salariés les moins payés perçoivent **11,9 %** de la masse salariale, tandis que les **25 %** les mieux payés en perçoivent **38,3 %** — soit un rapport de **3,2 pour 1**. » ② « L'indice de Gini vaut **0,187**, valeur **faible** : la masse salariale de cette PME est peu concentrée. C'est cohérent avec un coefficient de variation modéré (34 %) et avec l'absence de très hauts salaires — la distribution est bornée à 4 400 €. **Cette concentration est bien inférieure à celle observée sur l'ensemble des salaires français** ($G = 0,356$ en 2021), ce qui s'explique par l'homogénéité d'une population d'entreprise unique. »

CORRIGÉ — PARTIE D (3 POINTS)

D.1 — Moyenne et écart-type mensuels (1 pt)

$$\sum x_i = 3,2 - 1,8 + 2,4 + 0,6 - 2,2 + 1,8 = 4,0$$

$$m = \frac{4,0}{6} = 0,667 \text{ \% par mois} \quad (0,25 \text{ pt})$$

$$\sum x_i^2 = 10,24 + 3,24 + 5,76 + 0,36 + 4,84 + 3,24 = 27,68$$

$$V = \frac{27,68}{6} - (0,667)^2 = 4,6133 - 0,4444 = 4,1689 \quad (0,5 \text{ pt})$$

$$\sigma = \sqrt{4,1689} = 2,042 \text{ \% par mois} \quad (0,25 \text{ pt})$$

D.2 — Annualisation (1 pt)

Rendement (0,25 pt) : $12 \times 0,667 = 8,0 \text{ \% par an}$ (approximation additive, usuelle pour de petits rendements).

Volatilité (0,25 pt) : $\sigma_{\text{an}} = 2,042 \times \sqrt{12} = 2,042 \times 3,464 = 7,07 \text{ \%}$.

Justification (0,5 pt) : la propriété $V(aX) = a^2 V(X)$ montre que **les variances, et non les écarts-types, se cumulent**. Le rendement annuel étant la somme de douze rendements mensuels supposés indépendants, sa variance vaut $12 V_{\text{mens}}$, donc son écart-type vaut $\sqrt{12} \sigma_{\text{mens}}$. **Multiplier l'écart-type par 12 reviendrait à confondre la variance et l'écart-type — c'est l'erreur exacte que la propriété interdit.**

D.3 — Réfutation (1 pt)

L'affirmation est fausse pour trois raisons distinctes, à énoncer séparément.

① **L'écart-type n'est pas une borne, c'est une moyenne.** (0,4 pt) La volatilité mesure l'écart **typique** des rendements à leur moyenne, pas leur écart **maximal**. Rien dans sa définition n'interdit une réalisation à -3σ ou -5σ .

② **Le seul résultat du cours qui borne les écarts est l'inégalité de Bienaymé-Tchebychev — et c'est une borne de probabilité, pas de valeur.** (0,4 pt) Elle affirme $P(|\text{vert}X - m| \geq k\sigma) \leq 1/k^2$ pour $k > 1$: avec $k = 3$, au plus 11 % des observations s'écartent de plus de 3σ — soit ici plus de 21 points de rendement. **Elle autorise donc explicitement des pertes très supérieures à 7 %.**

③ **La perte maximale n'est pas bornée par la volatilité mais par la nature de l'actif.** (0,2 pt) Pour un fonds sans effet de levier, la perte maximale est de 100 % ; avec levier, elle peut la dépasser. La volatilité est **muette** sur ce point.

La formulation correcte serait : « La volatilité annuelle est de 7,07 %. Sous hypothèse de normalité — non vérifiée ici sur six observations —, environ deux tiers des années auraient un rendement dans un intervalle de ± 7 points autour de 8 %. Sans cette hypothèse, Bienaymé-Tchebychev garantit seulement qu'au plus 25 % des années s'écartent de plus de deux volatilités, soit plus de 14 points. »

POINT D'EXAMEN — GRILLE DE NOTATION ET SEUILS

Partie	Points	Ce qui est vérifié
A — Cours	5	Les démonstrations, et la capacité à refuser un calcul illégitime (A.3)
B — Position et dispersion	7	La densité, l'interpolation, la variance jusqu'à l'écart-type , le diagnostic d'asymétrie
C — Concentration	5	Les parts, les hauteurs de tranche inégales , la conversion d'unité du Gini
D — Application	3	L'annualisation en $\sqrt{12}$ et la distinction borne / moyenne
Total	20	

Les cinq points qui font basculer une copie : ① avoir calculé les **densités** en B.1 au lieu de lire l'effectif maximal ; ② avoir poussé jusqu'à l'**écart-type** en B.5 ; ③ avoir vu que les **hauteurs de tranche sont inégales** en C.3 ; ④ avoir **divisé par 10 000** en C.4 ; ⑤ avoir refusé le calcul du Gini sur des notes en A.3.

Barème d'auto-évaluation : moins de 10 → reprends la partie 2 en entier. Entre 10 et 13 → tu maîtrises les calculs mais pas les justifications : reprends les encadrés **Démonstration**. Entre 14 et 17 → niveau solide ; travaille les **Points de vigilance** (§ 3). Au-dessus de 17 → **c'est le niveau attendu pour viser les 3 % de tête**. Maintiens-le par le protocole de révision du § 6.3.

6. Auto-évaluation finale

6.1 — Liste de contrôle

*Si l'une de ces questions reste sans réponse **sans regarder le document**, le chapitre n'est pas maîtrisé.*

- ☐ J'explique la différence de nature entre « présenter » et « résumer », et je nomme les trois familles d'indicateurs avec leur question propre.
- ☐ Je définis le mode et j'explique pourquoi il faut parler de **classe modale** pour une variable continue.
- ☐ Je calcule une densité, je détermine une classe modale à amplitudes inégales, et j'explique en une phrase pourquoi l'effectif maximal ne suffit pas.
- ☐ Je démontre que **l'aire d'un rectangle d'histogramme est l'effectif** de sa classe.
- ☐ J'écris les **trois** formules de la moyenne et je dis dans quel cas chacune s'emploie.
- ☐ Je démontre que la somme des écarts à la moyenne est nulle et j'en tire la justification de l'EAM et de la variance.
- ☐ J'énonce la linéarité de la moyenne et j'explique pourquoi elle autorise l'agrégation.
- ☐ Je calcule une médiane sur données brutes (cas pair **et** impair) et sur une distribution par interpolation linéaire.
- ☐ Je démontre par un contre-exemple que **la médiane ne s'agrège pas**.
- ☐ Je déduis l'asymétrie d'une distribution de la comparaison entre médiane et moyenne, **et je sais que la réciproque est fausse**.
- ☐ Je définis un quantile comme **l'inverse de la fonction de répartition** et j'interpole un quantile dans une classe.
- ☐ Je cite les trois écarts inter-quantiles et je construis un *boxplot*.
- ☐ J'écris l'EAM, la variance et l'écart-type, et j'explique pourquoi on **ne s'arrête jamais à la variance**.
- ☐ J'énonce Koenig, je la démontre utile pour l'agrégation, et je l'applique sans erreur de signe.
- ☐ Je donne les **trois propriétés de la variance** et leur traduction sur l'écart-type.
- ☐ J'énonce Bienaymé-Tchebychev, **avec la condition $k > 1$** , et j'explique pourquoi la borne est lâche.
- ☐ Je définis le coefficient de variation et je dis dans quels cas l'écart-type ne suffit pas.
- ☐ J'écris la décomposition intra/inter et j'interprète le rapport $V_{\text{inter}}/\sigma^2$.
- ☐ Je vérifie qu'une variable est **additive** avant tout calcul de concentration, et je donne deux exemples de chaque côté.
- ☐ Je démontre que $\sum x_i = N_k m_k$ et que **l'effectif total se simplifie** dans le calcul des parts.
- ☐ Je construis une courbe de Lorenz, j'en énonce les **quatre propriétés** et je démontre que sa pente vaut m_{x_k}/m_x .
- ☐ Je calcule un indice de Gini **sans oublier la division par 10 000** et je contrôle qu'il est dans $[0 ; 1]$.
- ☐ J'explique ce qu'est la **dominance de Lorenz** et ce qui se passe quand deux courbes se croisent.
- ☐ Je récite l'arbre de décision : quel indicateur, dans quelle situation, et pourquoi.

- ☐ Je cite les **quatre anomalies du support** (diapositives 35, 43, 48, 55) et je dis ce que donne le recalcul.
- ☐ Je traduis chaque indicateur en vocabulaire de finance de marché : volatilité, VaR, Sharpe, risque spécifique et systématique, concentration de portefeuille.

6.2 — Grille de vérification chiffrée

Épreuve	Conditions	Seuil	Résultat obtenu	Décision si sous le seuil
Niveau 1 — restitution	Sans document	100 %	 / 22	Reprendre la section du §2 correspondante, refaire les cartes le jour même
Niveau 2 — application	Chronométré, sans document	80 %	 %	Refaire les exercices ratés à J+1, sans regarder le corrigé avant d'avoir cherché
Niveau 3 — maîtrise	Sans document	4 sur 6	 / 6	Approfondissement ciblé sur la notion en cause
Niveau 4 — simulation	2 h, sans document	14/20	 / 20	Nouvelle simulation à J+7 avec d'autres données chiffrées
Exposé blanc	À voix haute, 10 min, sans notes	Aucun blocage	<i>oui / non</i>	Le point de blocage est la notion mal comprise

Lecture des échecs. Échec au niveau 1 → défaut de **mémorisation**. Échec au niveau 2 alors que le 1 est acquis → défaut de **méthode de calcul**. Échec au niveau 3 alors que le 2 est acquis → défaut de **compréhension**. Échec au niveau 4 alors que 1, 2 et 3 sont acquis → défaut de **gestion du temps ou de rédaction**, pas de connaissance. **Quatre causes, quatre traitements différents — ne les confonds pas.**

MÉTHODE — L'EXPOSÉ BLANC POUR CE CHAPITRE — LE PLAN À TENIR EN 10 MINUTES

- (1 min)** Le projet : présenter conserve, résumer perd — et pourquoi cette perte est nécessaire. Les trois familles et leur question.
- (2 min)** La position : mode et classe modale (avec la densité), les trois écritures de la moyenne et ses trois propriétés, la médiane et l'interpolation. **Le diagnostic d'asymétrie en une phrase.**
- (4 min)** La dispersion : pourquoi la position ne suffit pas ; quantiles et écarts inter-quantiles ; **la somme des écarts est nulle donc valeur absolue ou carré** ; EAM, variance, écart-type ; Koenig et les trois propriétés, démontrées à voix haute ; Bienaymé-Tchebychev avec sa condition ; le coefficient de variation ; la décomposition intra/inter.
- (2 min)** La concentration : la condition d'additivité, la part de l'agrégat et la simplification de N , la courbe de Lorenz avec ses quatre propriétés, le Gini avec le piège d'unité.
- (1 min)** La clôture : l'arbre de décision, et la traduction en finance de marché.

Règle : si tu bloques plus de 5 secondes sur un point, note-le et continue. Le point noté est ta prochaine séance de travail.

6.3 — Protocole de révision daté

Document produit le **10 septembre 2026**. Les échéances sont donc :

Échéance	Date	Durée	Ce qui est révisé
J+1	11 septembre 2026	25 min	Fiche de synthèse (§4.1) + les 65 cartes (§4.2) + relecture du schéma (§4.4)
J+3	13 septembre 2026	35 min	Cartes échouées à J+1 + niveau 1 complet, chronométré + les huit ancrages (§4.3)
J+7	17 septembre 2026	60 min	Liste de contrôle à froid (§6.1) + exercices 2.2, 2.4 et 3.3 + relecture intégrale des points de vigilance (§3)
J+21	1 ^{er} octobre 2026	2 h 15	Simulation d'examen complète (niveau 4) en 2 h, puis auto-correction au barème

Règle de décision. Une carte échouée **deux fois de suite** relève de la compréhension, pas de la mémoire : reprends la section du §2 correspondante, et non la carte.

Règle d'entretien. Ce chapitre est **le socle calculatoire de toute la suite du cours** : le chapitre 3 (évolutions temporelles) et le chapitre 4 (croisement de variables) supposent la moyenne, la variance et la décomposition intra/inter acquises. **Une révision de 15 minutes avant chaque nouveau chapitre est un investissement, pas une perte de temps.**

Annexe — Tableau de couverture du support d'origine

Preuve de complétude, vérifiable en deux minutes. Le support d'origine — *CHAPITRE 2 : Résumer pour informer*, Hélène Couprie, **70 diapositives** — est inventorié ci-dessous **diapositive par diapositive**, sans trou de numérotation.

Légende. ✓ traité intégralement — △ traité, mais support d'origine incomplet, ambigu ou erroné : la reconstruction est signalée à l'endroit exact — ✕ impossible à traiter, donnée manquante.

#	Élément du support d'origine	Nature	Traité dans	État
1	Page de titre : « CHAPITRE 2 : Résumer pour informer », Hélène Couprie	titre	En-tête du document	✓
2	Contenu et plan du chapitre (3 sections)	plan	§2, encadré d'ouverture	✓
3	Section 1 : résumer la position — mode, moyenne, médiane	plan de section	§2.1.1	✓
4	Illustration pour le mode : logements en Outre-mer, recensement 2023 — 3 questions posées, aucune réponse	tableau + questions	§2.1.2 : les 3 questions corrigées ; écart d'arrondi de ± 1 sur trois colonnes signalé	△
5	Illustration pour le mode : diagramme en barres horizontales groupées	image non commentée	§2.1.2 : figure décrite et interprétée, lien avec le chapitre 1 rétabli	△
6	Deuxième illustration : personnes incarcérées par tranche d'âge (graphique)	image non commentée	§2.1.3 : figure décrite, piège de la lecture directe explicité	△
7	Deuxième illustration : le tableau des personnes incarcérées	tableau	§2.1.3 : amplitudes et densités recalculées ligne par ligne	✓
8	Définitions : amplitude, densité, classe modale	définitions	§2.1.3 : les trois définies simple puis académique, avec démonstration	✓

#	Élément du support d'origine	Nature	Traité dans	État
9	Deuxième illustration : le même graphique avec la densité en ordonnée	image non commentée	§2.1.3 : comparaison des deux figures, effet de la correction montré	⚠
10	Histogramme : définitions	définitions	§2.1.4	✓
11	Deuxième illustration : l'histogramme	image non commentée	§2.1.4 : démonstration « aire = effectif », contrôle de la somme des aires	⚠
12	La moyenne arithmétique (données brutes)	formule	§2.1.5 : énoncée, expliquée terme à terme, illustrée	✓
13	Calcul de la moyenne à partir d'une distribution	formule	§2.1.6 : les deux écritures (n_i et f_i) démontrées équivalentes	✓
14	Calcul de la moyenne par agrégation	formule	§2.1.7 : démonstration complète	✓
15	Calcul par agrégation (suite) : l'avertissement sur la variable de découpage	mise en garde	§2.1.7 : traduite et transformée en repère opératoire	✓
16	Propriété 1 : la somme des écarts à la moyenne est nulle	propriété	§2.1.8 : démontrée, et conséquence tirée pour toute la section 2	✓
17	Propriété 2 : la moyenne est un opérateur linéaire	propriété	§2.1.9 : démontrée	✓
18	Illustration : salaires des fonctionnaires 2022-2023 — 2 questions posées, aucune réponse	tableau + questions	§2.1.10 : les 2 questions corrigées ; écart de 1,6 € sur 2023 (3 114,4 recalculé contre 3 116 annoncé) expliqué par l'arrondi des fréquences	⚠
19	Propriété 3 : la moyenne est sensible aux valeurs extrêmes	propriété	§2.1.11 : illustrée numériquement	✓
20	La médiane : définition	définition	§2.1.12 : deux définitions équivalentes	✓
21	Calcul de la médiane sur données brutes	méthode	§2.1.13 : cas pair et impair traités séparément	✓

#	Élément du support d'origine	Nature	Traité dans	État
2 2	Illustration : densités de population UE15 / UE25 — 1 question posée, aucune réponse	tableau + question	§2.1.14 : médianes des trois ensembles calculées et interprétées	⚠
2 3	Illustration (suite) — 2 questions posées, aucune réponse	questions	§2.1.14 : les 3 moyennes calculées ; effet de la division par 2 de Malte démontré sur médianes et moyennes	⚠
2 4	Illustration : revenus salariaux médians par CSP (graphique) — 2 questions posées, aucune réponse	image + questions	§2.1.15 : questions corrigées ; démonstration par contre-exemple que la médiane ne s'agrège pas	⚠
2 5	Calcul de la médiane à partir d'une distribution	méthode	§2.1.16 : interpolation linéaire démontrée, pas seulement énoncée	✓
2 6	Illustration : familles selon le nombre d'enfants — 2 questions posées, aucune réponse	tableau + questions	§2.1.17 : questions corrigées ; l'interpolation donne 0,09 enfant pour 2008, résultat aberrant expliqué et remplacé par la règle du rang	⚠
2 7	Section 2 : indicateurs de dispersion — les quatre cas d'introduction	plan de section	§2.2.1 : les quatre cas décrits et comparés	✓
2 8	L'étendue	définition	§2.2.2 : définie, limite explicitée	✓
2 9	Écart inter-centiles $C_1 - C_{99}$	définition	§2.2.3 : remplacé dans la famille des écarts inter-quantiles	✓
3 0	Les quantiles	définition	§2.2.4 : définition par F^{-1} reconstruite	✓
3 1	Interprétation d'un quantile	méthode	§2.2.4 : phrases-types de lecture produites	✓
3 2	Application aux cas de l'introduction	application	§2.2.5 : les quatre cas recalculés	✓
3 3	Calcul d'un quantile d'ordre α % à partir d'une distribution	méthode	§2.2.6 : interpolation démontrée	✓
3 4	Interprétons quelques quantiles : niveau de vie 2024	tableau	§2.2.7 : $D_9/D_1 = 3,48$ recalculé, écarts entre déciles successifs analysés	✓

#	Élément du support d'origine	Nature	Traité dans	État
3 5	« Version alternative »	tableau	§2.2.7 : le titre annonce « retraités, année 2008 » alors que le tableau affiché est celui des niveaux de vie 2024 de la diapositive 34 — incohérence signalée	⚠
3 6	Représentation graphique : le <i>boxplot</i>	définition	§2.2.8 : construction détaillée, conventions des moustaches précisées	✓
3 7	Exemple d'un <i>boxplot</i>	image non commentée	§2.2.8 : figure décrite et reliée aux quantiles calculés	⚠
3 8	Interprétons des quantiles, encore : quantiles par CSP — 1 question posée, aucune réponse	tableau + question	§2.2.9 : question corrigée ; explication de l'écart inter-décile de l'ensemble supérieur à celui de 3 CSP sur 4 (composante inter)	⚠
3 9	Section 2 (suite) : indicateurs de dispersion	plan	§2.2.10	✓
4 0	Calcul des indicateurs : EAM, variance, écart-type	formules	§2.2.10 : les trois énoncées, expliquées et justifiées l'une par l'autre	✓
4 1	Tableau de calcul de la moyenne des écarts sur données brutes	méthode	§2.2.10 : structure du tableau expliquée colonne par colonne	✓
4 2	Illustration du tableau de calcul : série de 20 âges	tableau	§2.2.11 : tableau intégralement recalculé ($m = 47,9$; $EAM = 5,7$)	✓
4 3	Calcul des indicateurs sur données brutes : résultats	résultats	§2.2.11 : le support s'arrête à la variance (54,19) et ne calcule jamais l'écart-type — $\sigma = 7,36$ ans ajouté, seul chiffre interprétable	⚠
4 4	Interprétation de l'écart-type : inégalité de Bienaymé-Tchebychev	théorème	§2.2.12 : énoncée avec sa condition $k > 1$, appliquée et commentée	✓
4 5	Application en finance (introduction)	application	§2.2.13	✓
4 6	Application en finance 1/3 : la série des rendements	application	§2.2.13 : données reprises et recalculées	✓
4 7	Application en finance 2/3 : moyennes et écarts-types par période	application	§2.2.13 : tous les chiffres vérifiés	✓

#	Élément du support d'origine	Nature	Traité dans	État
48	Application en finance 3/3 : « 99 % de chances de faire des gains en périodes 1, 2, 3, 5 »	conclusions	§2.2.13 : conclusions non restructurables — Bienaymé-Tchebychev exige $k > 1$ or $m/\sigma < 1$ dans les cinq périodes, et la période 2 a une moyenne négative. Signalé, non masqué	⚠
49	Calculs d'agrégats : le problème posé	problématisation	§2.2.14 : les quatre points reformulés	✓
50	Propriétés de la variance : Koenig, translation, non-linéarité, corollaire	propriétés	§2.2.14 : les quatre démontrées, utilité de Koenig expliquée	✓
51	Illustration des propriétés : effet d'une translation (+ 6 points)	image non commentée	§2.2.14 : figure décrite, propriété vérifiée numériquement	⚠
52	Illustration des propriétés : effet d'une multiplication (× 2)	image non commentée	§2.2.14 : figure décrite, $\sigma_{aX} = \text{lverta rvert}\sigma_X$ vérifiée	⚠
53	Coefficient de variation	définition	§2.2.15 : défini, cas d'usage précisés, lien avec le ratio de Sharpe	✓
54	Calcul de la variance à partir d'une distribution	formule	§2.2.16 : pondération par les effectifs démontrée	✓
55	Illustration : cas n° 1 à 4	tableau	§2.2.16 : la variance du cas 4 annoncée à 10,4 vaut en réalité 20,8 ($\sigma = 4,56$ et non 3,2) — une division par 2 en trop, qui inverse le classement des cas 2 et 4. Vérification complète fournie	⚠
56	Choix de la formule de calcul	méthode	§2.2.16 : arbre de décision reconstruit	✓
57	Calcul de la variance par agrégation (via Koenig)	formule	§2.2.17 : démonstration complète	✓
58	Corollaire : décomposition de la variance intra / inter	corollaire	§2.2.18 : les deux formules démontrées, cas extrêmes décrits, lien avec le R^2 annoncé	✓
59	Section 3 : résumer la concentration — dispersion contre concentration	plan de section	§2.3.1 : distinction reconstruite, condition d'additivité transformée en règle opératoire avec tableau de cas	✓
60	Calcul de la part de l'agrégat ; relation $\sum x_i = N_k m_{X_k}$	méthode	§2.3.2 : relation démontrée ; démonstration que l'effectif total se simplifie , ce que le support pose sans le prouver	✓

#	Élément du support d'origine	Nature	Traité dans	État
6 1	Illustration : classes de salaires en France en 2005	tableau	§2.3.3 : colonne (5) intégralement recalculée. La colonne (4) « estimation du salaire moyen » n'est jamais expliquée : il s'agit du centre de classe — hypothèse identifiée, vérifiée sur les cinq classes, et sa fragilité sur la classe haute discutée	⚠
6 2	Illustration : les mêmes classes en 2021	tableau	§2.3.4 : recalcul complet. La somme des cinq parts arrondies vaut 100,1 et non 100,0 — excédent d'arrondi identifié et suivi jusqu'au Gini	⚠
6 3	Illustration : comparaison 2005 / 2021 — 1 question posée, aucune réponse	tableau + question	§2.3.5 : réponse complète (variations en points, en relatif, rapport entre extrêmes de 3,4 à 10,4) et réserve méthodologique sur le changement probable de champ, que je ne peux pas lever avec les seules données du support	⚠
6 4	Courbe de Lorenz : définition	définition	§2.3.6 : définie ; la condition de classement croissant, absente du support, est ajoutée et justifiée	✓
6 5	Tableau de calcul de la courbe de Lorenz (cumuls 2005 et 2021)	tableau	§2.3.6 : cumuls refaits ligne par ligne. Le support cumule des valeurs arrondies (d'où 40,7 au lieu de 40,8 en 2005, et 100,1 ramené à 100,0 en 2021) — effet quantifié	⚠
6 6	Graphe de la courbe de Lorenz, 2005 et 2021	image non commentée	§2.3.6 : figure reconstruite en intégralité — la diagonale d'égalité, absente du support, est ajoutée , sans quoi la figure ne se lit pas. Les quatre propriétés de la courbe sont démontrées	⚠
6 7	Interprétation de la courbe de Lorenz ; dominance ; croisement	interprétation	§2.3.7 : les trois énoncés reformulés et démontrés ; contre-exemple chiffré du croisement construit ; absence de croisement vérifiée sur 2005/2021	✓
6 8	Calcul du GINI, année 2005 : graphe avec l'aire de concentration et un trapèze (1 025)	image	§2.3.8 : calcul complet des cinq trapèzes (le 1 025 du support retrouvé ✓). Le piège d'unité — diviser par 10 000 quand les cumuls sont en % — n'est pas signalé par le support : il l'est ici, avec son contrôle	⚠
6 9	Calcul de l'indice de GINI : définition géométrique, bornes, formule	formule	§2.3.8 : formule démontrée en quatre étapes (carré unité, triangle, soustraction, trapèzes) ; bornes 0 et 1 démontrées, raffinement $(N-1)/N$ ajouté	✓
7 0	Récapitulons	synthèse	§2.4 : tableau complet des treize indicateurs + arbre de décision en cinq questions	✓

Bilan de couverture : 70 diapositives inventoriées, 70 traitées — dont 46 ✓ et 24 ⚠, et aucune ✗. Les 24 ⚠ ne signalent aucune lacune de ce document : elles marquent les endroits où le support d'origine était elliptique (images non commentées, questions posées sans réponse, méthode implicite), incohérent ou erroné — et où la reconstruction est explicitement signalée à l'endroit exact.

Les quatre anomalies de fond — diapositives **35** (titre erroné), **43** (écart-type jamais calculé), **48** (conclusion non démontrable) et **55** (variance fausse d'un facteur

1. — sont récapitulées au § 3.4.