

La démarche de l'étude statistique et la présentation des données

Vocabulaire, types de variables, distributions et graphiques — sans perte d'information

Reconstruction intégrale des 33 diapositives du chapitre 1 de Techniques statistiques (Hélène Couprie, L1 Portail Division A, 2026-2027). Les cinq exercices posés par le support et laissés sans corrigé sont tous corrigés ; les termes employés sans définition sont définis, chaque formule est démontrée, chaque graphique est redessiné et commenté ; quatre anomalies du support sont vérifiées et signalées. Format de l'épreuve non communiqué — hypothèse explicite.

Date · 28 septembre 2026

Travail estimé · Apprentissage — 4 sections × 4 pomodoros · révisions J+1, J+3, J+7, J+21

Version · 3.0

Document de travail autonome — il remplace le support de cours original, qu'il n'est pas nécessaire de relire. Toute notion évoquée dans le cours y est définie, démontrée et illustrée.

SOMMAIRE

2.1 — Réaliser une étude statistique (diapositives 1 à 10)

- 2.1.1 — Le cadre : le cours, son plan, sa place dans la maquette (diapositives 1, 2 et 9)
- 2.1.2 — Pourquoi une étude statistique : la chaîne de décision (diapositive 3)
- 2.1.3 — Les six étapes d'une étude statistique (diapositives 4 à 9)
- 2.1.4 — Délimiter la population, et le rapport qui conclut l'étude (diapositives 6 et 10)

2.2 — Le vocabulaire de la statisticienne (diapositives 11 à 14)

- 2.2.1 — Les cinq définitions fondatrices (diapositive 11)
- 2.2.2 — Première application : les infractions déclarées en 2024 (diapositive 12)
- 2.2.3 — Les deux types et quatre sous-types de variables (diapositives 13 et 14)

2.3 — Présenter une variable sans perte d'information (diapositives 15 à 23)

- 2.3.1 — Série brute et distribution : les deux présentations sans perte (diapositive 15)
- 2.3.2 — Du tri au comptage : l'exemple des 87 étudiants (diapositives 16 à 20)
- 2.3.3 — Effectif, fréquence, fréquence cumulée : le tableau des familles (diapositives 21 et 22)
- 2.3.4 — Les notations formelles (diapositive 23)

2.4 — Comparer des distributions, choisir un graphique, communiquer (diapositives 24 à 33)

- 2.4.1 — Une distribution par sous-population : les personnes écrouées (diapositives 24 et 25)
- 2.4.2 — Colonnes groupées : un même tableau, deux graphiques (diapositives 26 et 27)
- 2.4.3 — Empilé et empilé à 100 % : les enfants par famille (diapositives 28 à 31)
- 2.4.4 — Les quatre règles de présentation (diapositive 32)
- 2.4.5 — Conclusion : du descriptif à l'inférentiel (diapositive 33)

3.1 — Les quatre anomalies du support, et la conduite à tenir

3.2 — Le faux problème : l'écart de 0,1 de la diapositive 28

3.3 — Les huit paires à ne jamais confondre

3.4 — Les erreurs que fait la majorité de la promotion

3.5 — Ce qu'une copie à 18 écrit et qu'une copie à 14 n'écrit pas

3.6 — La check-list de la veille (20 minutes : fiche du § 4.1 et section 3)

4.1 — Fiche de synthèse

4.2 — Cartes de révision

- Section 2.1 — Réaliser une étude statistique
- Section 2.2 — Le vocabulaire de la statisticienne
- Section 2.3 — Présenter une variable sans perte d'information
- Section 2.4 — Comparer, choisir un graphique, communiquer

4.3 — Moyens mnémotechniques

4.4 — Le schéma qui relie tout

Méthode de l'épreuve — format, minutage, gabarits

Le format de l'épreuve

Le minutage

Gabarit 1 : « Identifiez la population, les unités statistiques, le caractère... »

Gabarit 2 : construire une distribution à partir d'une série brute

Gabarit 3 : écrire une phrase de lecture

Gabarit 4 : « Comment a été calculé ce chiffre ? »

Gabarit 5 : choisir et intituler un graphique

Niveau 1 — Questions de cours

Section 2.1 — Réaliser une étude statistique

Section 2.2 — Le vocabulaire de la statisticienne

Section 2.3 — Présenter une variable sans perte d'information

Section 2.4 — Comparer, choisir un graphique, communiquer

Niveau 2 — Les cinq exercices que le support pose et ne corrige jamais (1 h 30 au total — /36)

B1 — Diapositive 12 : les infractions déclarées en France en 2024 (15 min — /6)

B2 — Diapositive 22 : les familles selon le nombre d'enfants (20 min — /8)

B3 — Diapositive 25 : les personnes écrouées, 2020-2023 (20 min — /8)

B4 — Diapositive 28 : le nombre d'enfants par famille, 1990-2023 (20 min — /8)

B5 — Diapositive 30 : l'empilé à 100 % (15 min — /6)

Niveau 3 — Les exercices de construction (20 à 30 minutes chacun)

C1 — De la série brute à la distribution complète (/8)

C2 — Classer dix variables (/10, un point par ligne)

C3 — « Comment a été calculé ce chiffre ? » × 4 (/8)

C4 — Choisir et intituler le graphique × 6 (/6)

C5 — Corriger cinq phrases de lecture fausses (/10)

C6 — La preuve du « sans perte d'information » (/6)

Niveau 4 — Sujet au format supposé de l'examen (1 h 00, noté sur 20)

Le sujet

Le corrigé, au barème

1 — Carte du chapitre

SYNTHÈSE — LE CHAPITRE EN DIX LIGNES

1. Une étude statistique ne part jamais des données : elle part d'une **décision à prendre**, qui crée un **besoin d'information** — *besoin de décider* → *besoin d'information* → *étude statistique*.
2. Elle suit **six étapes** — problématique, données à observer, méthode de recueil, campagne de mesures, traitement, décision — et **tous les choix sont guidés par le type de problématique**.
3. Quatre méthodes de recueil : **expérimentation, enquête qualitative, données de seconde main, enquête quantitative** (la plus coûteuse).
4. Le rapport statistique **éclaire** la décision, il ne la prend pas : **toute décision est politique**.
5. Le vocabulaire : **population, unités statistiques, effectif total, variable** (une *application*), **modalités** — variable en majuscule X , modalités en minuscule x_i .
6. **Deux types, quatre sous-types** : qualitative **nominale** ou **ordinaire**, quantitative **discrete** (comptage) ou **continue** (mesure).
7. Deux présentations **sans perte d'information** : la **série brute** et la **distribution des effectifs** — on passe de l'une à l'autre par un **tri** puis un **comptage**.
8. **Effectif** n_i , **fréquence** $f_i = n_i/n$, **fréquence cumulée** $F_k = \sum_{i \leq k} f_i$ — le cumul exige un **ordre** entre modalités.
9. Plusieurs distributions juxtaposées servent à **comparer** des sous-populations : colonnes **groupées par catégorie** ou **par année, empilé, empilé à 100 %** — le graphique dépend de la question.
10. Un tableau **produit** de l'information : titre précis, lisible, note de lecture si besoin, **unités, population, choix méthodologiques**. Tout le chapitre est de la statistique **descriptive** ; l'**inférentielle** viendra plus tard.

Les idées maîtresses à retenir absolument

1. **La problématique commande tout** — les données, la méthode, la présentation.
2. **Le caractère est ce qui varie d'une unité à l'autre** ; l'unité est l'élément qu'on observe.
3. **Un nombre n'est une quantité que si sa moyenne a un sens** ; mesuré → continu, compté → discret.
4. **Pas d'ordre, pas de cumul** : la fréquence cumulée n'existe pas pour une qualitative nominale.
5. **Chaque sous-population a son propre dénominateur** — l'empilé à 100 % en est la traduction.
6. **Une phrase de lecture a cinq éléments** : quand, combien, de quoi, dans quelle population, quelle modalité.

Prérequis — aucun. Les notions mathématiques nécessaires — **application**, ensemble **dénombrable**, symbole Σ — sont **enseignées ici** au moment où elles servent.

ANALOGIE — MARCHÉS FINANCIERS — LE LIEN AVEC LA FINANCE, LÀ OÙ IL EST RÉEL

- **Le rendement d'un portefeuille** se calcule avec les poids de chaque ligne : ce sont des **fréquences** — la part de chaque actif dans le total, qui somment à 100 %.
- **Un empilé à 100 % est une allocation d'actifs** : il montre la composition d'un portefeuille à chaque date, indépendamment de sa taille — exactement comme la structure des familles indépendamment de leur nombre.
- **La fréquence cumulée est une fonction de répartition** : « 90,4 % des familles ont deux enfants ou moins » a la même forme que « 95 % des pertes journalières sont inférieures à X » — c'est la logique de la **VaR** (*Value at Risk* : le seuil de perte qui n'est dépassé qu'avec une probabilité donnée, par exemple 5 % des jours).
- **Données de seconde main contre expérimentation** : un backtest travaille sur des données collectées pour autre chose — il ne prouve aucune causalité.

Pour plus tard — fréquences, pourcentages, **points de pourcentage** et taux de variation, lecture de tableaux et de graphiques : le cœur des épreuves de calcul et de raisonnement du **TAGE MAGE**. Fréquence cumulée et fonction de répartition : le socle des probabilités et de la mesure du risque en **finance**.

2 — Le cours reconstruit

Quatre sections d'apprentissage. Chacune se travaille en un cycle APPRENDRE de quatre pomodoros : P1 lecture active · P2 restitution de mémoire, cours fermé · P3 cartes de la section (§ 4.2) · P4 questions de niveau 1 de la section (§ 5).

2.1 — Réaliser une étude statistique (diapositives 1 à 10)

À quoi sert cette section. Elle répond à la question que tout le reste suppose : **pourquoi fait-on une étude statistique, et comment la mène-t-on ?** Réponse du cours : on part d'une **décision**, et chaque choix technique — qui observer, comment, combien — se justifie par elle. C'est la partie « démarche » : peu de calcul, beaucoup de définitions à restituer au mot près.

2.1.1 — Le cadre : le cours, son plan, sa place dans la maquette (diapositives 1, 2 et 9)

Le cadre	Ce qu'il faut savoir
Enseignante	Hélène Couprie — Portail L1, Division A, année 2026-2027
Crédits	5 ECTS — BCC 2, « Compréhension de l'environnement des acteurs, firmes et organisations »
Place du chapitre	Chapitre 1 sur au moins 4 : présenter (CHAP 1) · résumer (CHAP 2) · évolutions temporelles (CHAP 3) · croiser les variables (CHAP 4)

PIÈGE FRÉQUENT — CE QUE L'ON SAIT — ET NE SAIT PAS — DE L'ÉPREUVE

Les 33 diapositives ne donnent **ni la nature, ni la durée, ni le barème** de l'examen. Hypothèse retenue et justifiée au § 5 (méthode de l'épreuve) : **écrit, exercices d'application et questions de cours, sans document**. Le support pose **cinq fois** les mêmes trois gestes — **identifier, calculer, lire** — : ce sont eux qui seront notés. La demande des modalités de contrôle figure dans SOURCES.md.

DÉFINITION — LE CONTENU ANNONCÉ PAR LA DIAPOSITIVE 2

« Découvrir la démarche de la statisticienne · définitions essentielles (variables et type, population et unités statistiques) · présenter de façon pertinente les informations contenues dans les données. »

Plan en trois sections : ① Réaliser une étude statistique · ② Communiquer : le vocabulaire de la statisticienne · ③ Communiquer : la présentation des données.

La place du chapitre dans le cours (diapositive 9) :

Chapitre	Ce qu'il fait
1	Présenter les données sans perte d'information
2	Résumer l'information contenue dans les données, variable par variable
3	S'intéresser aux évolutions temporelles
4	Croiser les informations de plusieurs variables

2.1.2 — Pourquoi une étude statistique : la chaîne de décision (diapositive 3)

DÉFINITION — DIAPOSITIVE 3, À RESTITUER TELLE QUELLE

Besoin de décider → Besoin d'information → Étude statistique.

Les quatre exemples du support, à pouvoir citer :

1. Identifier les populations à risque afin d'optimiser une **campagne de prévention**.
2. Connaître l'évolution démographique pour planifier le **financement du système de retraite**.
3. Prévoir la répartition d'une population selon des zones géographiques pour planifier d'éventuels **quotas de médecins**.
4. Localiser des prospects dans le but d'optimiser la **ventilation des forces de vente**.

SYNTHÈSE — CE QUE CET ORDRE IMPOSE, ET QUI COMMANDE TOUT LE CHAPITRE

Une étude statistique ne commence **jamais** par « voici des données, que peut-on en tirer ? ». Elle commence par **une décision à prendre**, qui crée un **besoin d'information**, auquel l'étude répond.

Conséquence immédiate, écrite dans le schéma de la diapositive 4 : « tous les choix sont guidés par le type de problématique » — et des flèches remontent de **chacune** des cinq étapes suivantes vers la première.

Deuxième conséquence, diapositive 10 : « toute information inutile, non informative au regard de la problématique, doit être bannie ». Un tableau juste mais hors sujet est un défaut, pas un supplément.

Troisième conséquence, la plus contre-intuitive : « ce n'est pas le rapport statistique qui décide : toute décision est politique ». Le statisticien éclaire, il ne tranche pas — d'autres considérations entrent en jeu, « **comme le coût par exemple** ».

EXEMPLE CHIFFRÉ — LES QUATRE EXEMPLES DE LA DIAPOSITIVE 3, DÉCOMPOSÉS — CE QUE LE SUPPORT LAISSE FAIRE AU LECTEUR

Le support aligne quatre exemples sans les commenter. Chacun se lit avec la même chaîne : **une décision** précise, **l'information** sans laquelle on la prendrait à l'aveugle, et **l'étude** qui fournit cette information.

Exemple du support	La décision à prendre	L'information nécessaire	Une étude possible
Campagne de prévention	À qui l'adresser, où concentrer un budget limité	Quels groupes (âge, lieu, comportement) sont les plus exposés, et combien de personnes chacun compte	Données de santé existantes (seconde main) ou enquête quantitative
Financement des retraites	Niveau des cotisations, âge de départ	Nombre futur de retraités rapporté au nombre futur d'actifs qui cotisent	Projections à partir des recensements
Quotas de médecins	Combien de médecins autoriser dans chaque zone	Population actuelle et future de chaque zone, et ses besoins de soins	Recensements, statistiques de santé par territoire
Forces de vente	Où affecter les commerciaux	Où se trouvent les clients potentiels (<i>prospects</i>), et combien il y en a par secteur	Fichiers clients, données de seconde main, enquête

Ce que l'exercice montre : la même donnée — une population par zone — sert trois décisions différentes. **Ce n'est pas la donnée qui définit l'étude, c'est la décision.**

2.1.3 — Les six étapes d'une étude statistique (diapositives 4 à 9)


DÉFINITION — LE SCHÉMA DE LA DIAPOSITIVE 4 — ET LA PHRASE QUI S'Y TROUVE

Nº	Étape
1	Quel type de problématique ?
2	Choix des données à observer
3	Choix de la méthode de recueil des données
4	Campagne de mesures
5	Traitement (présentation, résumé, etc.) des données
6	Prise de décision

Et la phrase inscrite au bas du schéma, avec des flèches qui remontent de chaque étape vers la première :

« *Tous les choix sont guidés par le type de problématique.* »

C'est la thèse de toute la section 1, et elle ne figure que dans l'image.



chaque étape se justifie par la problématique

« Tous les choix sont guidés par le type de problématique. »

Le schéma de la diapositive 4, redessiné : les six étapes s'enchaînent, et chacune renvoie à la première

Le détail des six étapes (diapositives 5 à 10) :

Étape	Ce qu'elle décide	Le point exigible
1 — Problématique	Ce qui intéresse le donneur d'ordre	L'exemple du support : une demande d'« enquête de satisfaction » est « beaucoup trop vague ». Il faut savoir si c'est pour modifier la mise en place des produits en rayon, améliorer l'affichage, mieux répondre aux attentes en matière de choix des produits, ou mieux définir les attentes en matière d'horaires d'ouverture et de conseil
2 — Données à observer	Qui ?	Définir sur quels individus ou unités statistiques les observations seront réalisées. La population devra être définie, délimitée ; « parfois on connaît sa taille, mais pas toujours »
3 — Méthode de recueil	Comment obtenir les informations ?	Quatre méthodes — tableau ci-dessous
4 — Campagne de mesures	Combien, quand, comment enquêter	En cas d'enquête quantitative, « c'est l'option la plus coûteuse »
5 — Traitement	Faire parler les données	« C'est l'objet du cours de Techniques statistiques » — et les quatre chapitres du plan (§ 2.1.1)
6 — Prise de décision	Le rapport statistique	Contenu et limites du rapport : § 2.1.4

Les quatre méthodes de recueil des données (diapositive 7) :

Méthode	Définition du support
L'expérimentation	« On dispose d'un protocole permettant l'observation directe de l'impact d'une variable de contrôle sur une variable d'observation. »
L'observation, ou enquête qualitative	« On observe de façon extensive un petit nombre d'individus. »
Les données de seconde main	« On réutilise des informations disponibles par ailleurs. »
L'enquête quantitative	« Il s'agit d'un travail sur-mesure, on collecte l'information utile par enquête, questionnaire, etc. »

Trois étapes demandent une explication que le support ne donne pas : la méthode de recueil (étape 3), la problématique (étape 1) et la campagne de mesures (étape 4).

DÉFINITION — ÉTAPE 3 — LES MOTS DE L'EXPÉRIMENTATION, EMPLOYÉS SANS ÊTRE DÉFINIS

Le support écrit que l'expérimentation repose sur « un protocole permettant l'observation directe de l'impact d'une **variable de contrôle** sur une **variable d'observation** ».

Variable de contrôle : celle que l'expérimentateur **fait varier lui-même** — le traitement administré, le prix affiché, le message publicitaire testé. On la contrôle, d'où son nom.

Variable d'observation : celle dont on **mesure la réaction** — la guérison, la quantité achetée, le taux de clic.

Ce qui fait la force de l'expérimentation : comme c'est l'expérimentateur qui fixe la variable de contrôle, **rien d'autre ne la détermine**. Toute différence observée sur la variable d'observation lui est donc imputable. C'est la seule des quatre méthodes qui établit directement un lien de **cause à effet**.

PIÈGE FRÉQUENT — LES QUATRE MÉTHODES DE RECUEIL, COMPARÉES — CE QUE LE SUPPORT JUXTAPOSE SANS OPPOSER

Méthode	Nombre d'individus	Coût	Ce qu'elle permet	Sa limite
Expérimentation	Variable	Élevé	Établir une causalité	Souvent impossible ou non éthique en sciences sociales
Observation / enquête qualitative	« Un petit nombre », observé « de façon extensive »	Modéré	Comprendre en profondeur, faire émerger des hypothèses	Non généralisable : trop peu d'individus
Données de seconde main	Celui de la source	Le plus faible	Disposer immédiatement de données massives	Les données n'ont pas été collectées pour ta question
Enquête quantitative	Défini par la campagne de mesures	« L'option la plus coûteuse »	Un travail sur-mesure, adapté à la problématique	Le coût, et la dépendance à la qualité du questionnaire

Le mot clé de l'opposition qualitatif / quantitatif ici : ce n'est pas le type de variable, c'est le **nombre d'individus** et la **profondeur** de l'observation. « Enquête qualitative » = peu d'individus observés en détail. « Enquête quantitative » = beaucoup d'individus sur un questionnaire standardisé. **Ne pas confondre avec variable qualitative / quantitative du § 2.2.3** — ce sont deux emplois différents des mêmes mots.

EXEMPLE CHIFFRÉ — L'ÉTAPE 1 APPLIQUÉE : POURQUOI « UNE ENQUÊTE DE SATISFACTION » NE VEUT RIEN DIRE

Le support prend l'exemple d'un **directeur d'hypermarché** qui demande une enquête de satisfaction auprès de sa clientèle, et tranche : « **cette demande est beaucoup trop vague** ».

Pourquoi. Selon ce que le directeur veut décider, l'étude n'interroge ni les mêmes personnes, ni sur les mêmes choses :

S'il veut...	Il faut mesurer...
Modifier la mise en place des produits en rayon	Les parcours en magasin, les produits non trouvés
Améliorer l'affichage des produits	La lisibilité perçue, les erreurs de prix relevées
Mieux répondre aux attentes en matière de choix des produits	Les références manquantes, les substitutions subies
Mieux définir les attentes en matière d'horaires d'ouverture et de conseil	Les heures de fréquentation souhaitées, le recours au personnel

Les quatre études sont incompatibles. Voilà pourquoi la problématique se définit d'abord, et pourquoi toutes les flèches du schéma y reviennent.

DÉFINITION — L'ÉTAPE 4 — CE QUE « COMBIEN, QUAND, COMMENT » ENGAGENT VRAIMENT

Le support pose les trois questions de la campagne de mesures sans y répondre. Chacune est un **arbitrage**, et chacune se tranche par la problématique.

Question	Ce qu'elle décide	L'arbitrage
Combien ?	Interroger toute la population (recensement , dit aussi <i>exhaustif</i>) ou seulement une partie (échantillon)	Plus on interroge de personnes, plus le résultat est précis — et plus l'enquête coûte. C'est pourquoi l'enquête quantitative est « l'option la plus coûteuse »
Quand ?	La date ou la période d'observation	La date fait partie de la population étudiée (le « quand » du champ). Mal choisie, elle déforme le résultat : interroger les clients d'un hypermarché le samedi après-midi ne décrit pas la clientèle de la semaine
Comment ?	Le mode de collecte (face à face, téléphone, en ligne) et la formulation des questions	Le mode choisit, sans le dire, qui répond ; une question mal posée produit une réponse inexploitable

À retenir : un résultat qui ne dit pas **qui, quand et comment** a été interrogé ne peut pas être jugé. C'est pour cela que le rapport doit contenir **les éléments méthodologiques** (§ 2.1.4).

2.1.4 — Délimiter la population, et le rapport qui conclut l'étude (diapositives 6 et 10)

DÉFINITION — « LA POPULATION DEVRA ÊTRE DÉFINIE, DÉLIMITÉE » — CE QUE DÉLIMITER VEUT DIRE

Le support emploie le mot à l'étape 2 et ne le définit pas. **C'est pourtant l'opération qui rapporte le plus de points dans tout le chapitre**, parce que c'est elle qu'on retrouve sous le nom de **champ** au bas de chaque tableau.

Délimiter une population, c'est répondre à trois questions :

La question		Sur l'exemple de la diapositive 28 (§ 2.4.3)
Qui ?	Quel type d'unité, et avec quelle restriction ?	Les familles vivant en ménage ordinaire et ayant au moins un enfant mineur
Où ?	Sur quel territoire ?	France hors Mayotte
Quand ?	À quelle date d'observation ?	1990, 1999, 2007, 2012, 2017, 2023 — les années de recensement

Pourquoi c'est décisif : deux tableaux sur le même sujet mais de champs différents **ne sont pas comparables**. La diapositive 22 compte les familles **sans enfant** ; la 28 les exclut. Confondre les deux, c'est comparer 48 % de familles sans enfant à un tableau où elles n'existent pas.

Et c'est aussi ce que veut dire « parfois on connaît sa taille, mais pas toujours » : un recensement donne l'effectif exact de la population ; une enquête sur « les clients d'un hypermarché » ne le donne pas — **on ne sait pas combien il y en a en tout**.

Ce que doit contenir un rapport statistique (diapositive 10) :

DÉFINITION — DIAPOSITIVE 10

« Un rapport statistique doit contenir le résultat des traitements statistiques bien sûr, mais aussi les éléments méthodologiques — choix réalisés quant aux méthodes statistiques utilisées —, le tout orienté selon la problématique, vers la prise de décision. »

Les deux règles qui l'accompagnent :

1. « Toute information inutile — non informative au regard de la problématique — doit être bannie. »
2. « Ce n'est pas le rapport statistique qui décide : toute décision est politique et repose sur les informations collectées et présentées dans le rapport, ainsi que d'autres considérations ou contraintes comme le coût par exemple. »

SYNTHÈSE — « CE N'EST PAS LE RAPPORT STATISTIQUE QUI DÉCIDE » — LA FRONTIÈRE, ET POURQUOI ELLE EXISTE

Le support conclut la section 1 sur une phrase qu'il ne développe pas : « **toute décision est politique et repose sur les informations collectées et présentées dans le rapport, ainsi que d'autres considérations ou contraintes comme le coût** ».

Ce qu'elle veut dire, précisément :

Le statisticien fournit	Le décideur ajoute
Des faits : combien, dans quelle proportion, en hausse ou en baisse	Des objectifs : ce qu'il veut obtenir
Des incertitudes : marge d'erreur, limites du champ	Des contraintes : budget, délai, acceptabilité
Des méthodes : les choix faits et leurs conséquences	Un arbitrage entre des objectifs contradictoires

Les données ne contiennent pas la décision. Savoir que 12,1 % des familles ont trois enfants ne dit pas s'il faut augmenter les allocations familiales : cela dépend de ce qu'on cherche à obtenir, et de ce qu'on peut financer.

La conséquence opératoire, et elle est notée : c'est **exactement** pour cela que le rapport doit contenir **les éléments méthodologiques**. Le décideur doit pouvoir juger de la solidité des chiffres avant de s'appuyer dessus. Et c'est la même exigence que la règle « indiquer les choix méthodologiques réalisés » de la diapositive 32 — **la section 1 et la section 3 disent la même chose, à deux endroits différents du cours.**

2.2 — Le vocabulaire de la statisticienne (diapositives 11 à 14)

À quoi sert cette section. Elle fixe les **mots** avec lesquels on décrit n'importe quel tableau : population, unité, variable, modalité, type. C'est la question posée cinq fois par le support — « indiquez la population, les unités statistiques, le caractère, son type » — donc la plus rentable du chapitre. Une définition approximative produit un exercice entièrement faux.

2.2.1 — Les cinq définitions fondatrices (diapositive 11)

DÉFINITION — DIAPOSITIVE 11 — À SAVOIR MOT POUR MOT

La population : « Ensemble (mathématique) étudié. »

Les individus, ou unités statistiques : « Les éléments de cette population. »

La taille de la population, ou effectif total : « Le nombre d'individus ou d'unités statistiques. »

Une variable statistique, ou caractère statistique : « Une application associant à chaque individu une valeur. »

Les modalités : « Les valeurs prises par une variable statistique. »

PIÈGE FRÉQUENT — LA CONVENTION DE NOTATION, QUI VAUT UN POINT À ELLE SEULE

« Les variables seront notées en majuscule et leurs valeurs prises en minuscule. »

Donc : X est le caractère, x_i est une modalité. Écrire X_i pour une modalité est une faute de notation visible immédiatement.

Une seule de ces cinq définitions contient un terme technique que le support ne définit pas.

DÉFINITION — « UNE APPLICATION ASSOCIANT À CHAQUE INDIVIDU UNE VALEUR »

Application est ici un mot de mathématiques, et il est précis. Une **application** d'un ensemble A vers un ensemble B associe à **chaque** élément de A **une et une seule** valeur de B .

Les deux exigences comptent :

— Chaque individu a une valeur — aucun n'est laissé sans réponse.

— Une seule valeur — un individu ne peut pas avoir deux modalités à la fois pour la même variable.

Ce que cela interdit concrètement : un tableau où un individu figurerait deux fois, ou une variable « moyen de transport » dont un individu cocherait à la fois « voiture » et « train ». Si les deux réponses sont possibles, **ce sont deux variables**, pas une.


Et c'est aussi ce qui garantit que la somme des effectifs fait exactement n : chaque individu est compté une fois et une seule.

2.2.2 — Première application : les infractions déclarées en 2024 (diapositive 12)

Le support applique aussitôt ces définitions à un tableau réel, et pose l'exercice sans le corriger.

Atteinte déclarée	Nombre d'infractions
Actes de vandalisme contre la voiture	2 893 000
Vols ou tentatives de vol d'objet dans ou sur la voiture	1 544 000
Vols ou tentatives de vol avec effraction de la résidence principale	1 516 000
Actes de vandalisme contre le logement	1 141 000
Vols ou tentatives de vol de vélo	853 000
Vols sans effraction de la résidence principale	616 000
Vols ou tentatives de vol de voiture	549 000
Vols ou tentatives de vol de deux-roues motorisés	264 000
Ensemble	9 376 000

Source : enquête « Vécu et ressenti en matière de sécurité », diffusion Insee. Champ : France métropolitaine, Martinique, Guadeloupe et La Réunion. Année 2024.



Infractions déclarées en 2024, par type d'atteinte, en millions — graphique reconstruit à partir du tableau de la diapositive 12 ; « cambriolage » = vol ou tentative de vol avec effraction de la résidence principale, « vol s. effr. » = vol sans effraction de la résidence principale

POINT D'EXAMEN — L'EXERCICE POSÉ PAR LA DIAPOSITIVE 12

► Indiquez la population, les unités statistiques, l'effectif total, la ou les variables ainsi que les modalités.

Fais-le maintenant, sur une feuille, avec les définitions du § 2.2.1 sous les yeux — puis compare au corrigé intégral du § 5, niveau 2, **exercice B1**. Les deux pièges : l'unité statistique n'est pas une victime, et « nombre d'infractions » n'est pas une variable.

2.2.3 — Les deux types et quatre sous-types de variables (diapositives 13 et 14)

DÉFINITION — LA CLASSIFICATION, À RESTITUER INTÉGRALEMENT

On distingue 2 types et 4 sous-types.

- ① **Variable QUALITATIVE** — « les modalités ne sont pas des nombres ».
 - **Nominale** : « lorsqu'il n'est pas possible de classer les modalités selon un ordre qui a du sens ».
 - **Ordinale** : « lorsqu'il est possible de classer les modalités selon un ordre qui a du sens ».
- ② **Variable QUANTITATIVE** — « les modalités sont des nombres ».
 - **Discrète** : « si les modalités relèvent du comptage (ensemble dénombrable) ».
 - **Continue** : « si les modalités relèvent de la mesure (ensemble non dénombrable) ».

PIÈGE FRÉQUENT — L'AVERTISSEMENT DU SUPPORT, MOT POUR MOT

« Attention aux confusions : une variable qualitative peut être codée dans une base de données sous forme de nombre, un mot valant un chiffre. »

Coder « homme = 1, femme = 2 » ne rend pas la variable quantitative. **Le test : la moyenne a-t-elle un sens ?** Une moyenne de 1,4 sur le sexe ne veut rien dire ; une moyenne de 1,4 enfant en veut un.

Les quatre exemples du support (diapositive 14), un par sous-type :

Variable	Modalités	Type
Sexe	« homme », « femme », « autre »	Qualitative nominale
Qualité du service	« mauvaise », « plutôt mauvaise », « plutôt bonne », « très bonne »	Qualitative ordinale
Nombre d'enfants	0, 1, 2, 3, 4, 5	Quantitative discrète
Taille en cm	179, 182, 183, 165, 148, 205...	Quantitative continue

Le support définit le discret et le continu par « **ensemble dénombrable** » et « **ensemble non dénombrable** », sans expliquer ces termes.

DÉFINITION — DÉNOMBRABLE ET NON DÉNOMBRABLE

Un ensemble est **dénombrable** quand on peut **énumérer ses éléments un par un**, en les numérotant, même si la liste ne s'arrête jamais. Les entiers 0, 1, 2, 3... sont dénombrables.

Il est **non dénombrable** quand **entre deux valeurs quelconques il en existe toujours une troisième**, si bien qu'aucune énumération n'est possible. Les nombres réels d'un intervalle sont non dénombrables.

La traduction statistique, plus simple à manier :

- **Discret** — les modalités relèvent du **comptage**. Entre 2 et 3 enfants, il n'y a rien.
- **Continu** — les modalités relèvent de la **mesure**. Entre 179 cm et 180 cm, il y a 179,4 cm, et entre les deux 179,42 cm, indéfiniment.

Le test pratique en examen : « *existe-t-il une valeur possible entre deux valeurs voisines ?* » Non → discret. Oui → continu.

PIÈGE FRÉQUENT — LES DEUX PIÈGES DE CLASSIFICATION, ET COMMENT LES TRANCHER

① **La variable qualitative codée en chiffres.** Le support le dit : « *une variable qualitative peut être codée dans une base de données sous forme de nombre, un mot valant un chiffre* ». Le code postal, le numéro de département, « homme = 1 » sont des **nombre**s qui ne comptent ni ne mesurent rien. **Le test : la moyenne a-t-elle un sens ?** Une moyenne de code postal ne veut rien dire.

② **La variable continue présentée en classes.** La taille arrondie au centimètre ressemble à du comptage. Mais la taille **se mesure**, et l'arrondi est une commodité d'affichage, non la nature de la variable. **Le test : la grandeur sous-jacente est-elle mesurée ou comptée ?**

Et le troisième cas, le plus subtil : l'ordinale. « Mauvaise, plutôt mauvaise, plutôt bonne, très bonne » se classe dans un ordre qui a du sens — mais les modalités **ne sont pas des nombres**. C'est donc une **qualitative ordinale**, pas une quantitative. On peut les ranger, on ne peut pas les additionner.

2.3 — Présenter une variable sans perte d'information (diapositives 15 à 23)

À quoi sert cette section. Elle apprend à transformer une liste de réponses en **tableau** — effectifs, fréquences, fréquences cumulées — et à l'écrire en **notations**. C'est le cœur calculatoire du chapitre, et **la base de tous les chapitres suivants** : on ne résume (chapitre 2) que ce qu'on a d'abord présenté.

2.3.1 — Série brute et distribution : les deux présentations sans perte (diapositive 15)

DÉFINITION — DIAPOSITIVE 15

« Il y a 2 grandes façons de présenter une variable (sans perte d'information) :

- sous forme de série ou données brutes (en anglais *raw data*) ;
- sous forme de distribution observée des effectifs (en anglais *frequencies*). »

DÉFINITION — LE PASSAGE DE L'UNE À L'AUTRE — DEUX OPÉRATIONS, DANS CET ORDRE

« Il y a un traitement de données nécessaire pour passer de la série brute à la distribution observée, qui nécessite (dans le cas quantitatif ou qualitatif ordinal) : un TRI des modalités, puis un COMPTAGE des effectifs. »

SYNTHÈSE — LA THÈSE QUE LE SUPPORT POSE SANS LA FORMULER

Le chapitre 1 s'intitule « Présenter pour informer », et la diapositive 15 précise : **deux façons de présenter une variable — sans perte d'information.**

Ce qualificatif oppose implicitement le chapitre 1 au chapitre 2. Une série brute contient toute l'information. Une distribution des effectifs aussi : **à partir du tableau, on peut reconstituer la série** — il suffit de réécrire chaque modalité autant de fois que son effectif. Rien n'est perdu, seul l'ordre de présentation a changé.

Le chapitre 2, lui, s'intitule « Résumer pour informer » — **et un résumé perd de l'information.** Une moyenne de 2,16 frères et sœurs — 188/87, calcul au chapitre 2 — ne permet pas de retrouver les 87 réponses.

C'est la raison pour laquelle la distribution est « souvent l'étape n° 1 d'une analyse statistique » : on commence par la présentation intégrale, on ne résume qu'ensuite, en sachant ce qu'on perd.

2.3.2 — Du tri au comptage : l'exemple des 87 étudiants (diapositives 16 à 20)

DÉFINITION — DIAPOSITIVE 16

« Une distribution observée des effectifs associe à chaque modalité d'une variable statistique l'effectif observé correspondant. »

« L'effectif d'une modalité est le nombre d'individus présentant une modalité donnée du caractère statistique. »

Trois précisions du support :

1. La représentation peut être un tableau ou un diagramme colonne.
2. « Il n'y a pas de perte d'information. »
3. « Il s'agit souvent de l'étape n° 1 d'une analyse statistique. »

DÉMONSTRATION — DEUX OPÉRATIONS, DANS CET ORDRE — ET POURQUOI CET ORDRE

Le support écrit : « **un tri des modalités, puis un comptage des effectifs** ».

1. **Trier** met côte à côte les valeurs identiques.
2. **Compter** devient alors une simple lecture de longueurs de blocs.

Sans le tri, le comptage exige de parcourir toute la série une fois par modalité — onze passages sur 87 valeurs dans l'exemple du cours. Avec le tri, un seul passage suffit.

C'est exactement ce que montrent les diapositives 17, 18 et 19 : la série brute, puis la série **ordonnée**, puis le tableau. Trois états du même contenu, et deux opérations pour passer de l'un à l'autre.

La précision entre parenthèses du support compte : le tri n'a de sens « **dans le cas quantitatif ou qualitatif ordinal** ». Pour une qualitative **nominale** — le sexe, la couleur, la région —, **il n'existe pas d'ordre naturel** : on regroupe, on ne trie pas, et l'ordre d'affichage est un choix de présentation.

Mini-enquête : 87 étudiants d'une promotion répondent à « *combien avez-vous de frères et sœurs ?* ». **Population** : l'ensemble des **87 étudiants**. **Taille** : $n = 87$ unités statistiques. **Caractère** : **quantitatif discret**.

La distribution donnée par le support (diapositive 19) :


x_i	0	1	2	3	4	5	6	7	9	13	14	Ensemble
n_i	11	33	23	7	3	4	1	2	1	1	1	87

Donc $n = 87$ et $p = 11$.

PIÈGE FRÉQUENT — UNE ANOMALIE VÉRIFIÉE DU SUPPORT — LA SÉRIE BRUTE NE DONNE PAS CETTE DISTRIBUTION

J'ai recompté la **série brute** de la diapositive 17, chiffre par chiffre, après vérification à l'image : elle contient **10 zéros et 24 « 2 »**. La **série ordonnée** (diapositive 18) et le **tableau** (diapositive 19) en contiennent **11 et 23**.

Un « 2 » de la **série brute** est devenu un « 0 » au **tri**. Les deux totaux font bien 87, et toutes les autres modalités concordent. → § 3.1, **A1**, pour la conduite à tenir.



Distribution du nombre de frères et sœurs des 87 étudiants — graphique reconstruit à partir du tableau de la diapositive 19 (le support le présente à la diapositive 20)

MÉTHODE — LIRE CE DIAGRAMME — CE QUE LE SUPPORT MONTRE SANS LE COMMENTER

- Une colonne par modalité observée, de hauteur égale à l'effectif : c'est la distribution du tableau, sous une autre forme — aucune information n'est perdue.
- La modalité la plus fréquente saute aux yeux : **1 frère ou sœur**, 33 étudiants sur 87, soit $33/87 = 37,9\%$.
- La distribution est concentrée à gauche : 67 étudiants sur 87 ($11 + 33 + 23$), soit $77,0\%$, ont deux frères et sœurs ou moins ; quelques valeurs extrêmes (9, 13, 14) s'étirent à droite.
- Attention à l'axe horizontal : les modalités absentes (8, 10, 11, 12) n'ont pas de colonne, donc 9 et 13 se retrouvent côte à côte. L'axe range des modalités, il ne mesure pas des distances — on ne lit pas un écart numérique sur un diagramme en colonnes.
- Pourquoi pas un camembert : onze modalités, dont sept d'effectif inférieur ou égal à 4 — des parts minuscules que l'œil ne distingue plus.

2.3.3 — Effectif, fréquence, fréquence cumulée : le tableau des familles (diapositives 21 et 22)

DÉFINITION — DIAPOSITIVE 21

La fréquence d'une modalité : « la proportion d'individus présentant une modalité donnée du caractère statistique dans la population totale (en pour cent de la population) ».

La fréquence cumulée d'une modalité — pour un caractère quantitatif : « la proportion d'individus présentant une modalité donnée OU INFÉRIEURE dans la population ».

Les représentations possibles : « un camembert ou un diagramme en barres peuvent être choisis » pour une répartition des fréquences.

PIÈGE FRÉQUENT — LES TROIS MOTS À NE PAS PERDRE

« ou inférieure » — c'est ce qui fait la différence entre fréquence et fréquence cumulée. Et « pour un caractère quantitatif » : la fréquence cumulée suppose un ordre sur les modalités — démonstration ci-dessous.

DÉFINITION — LES DEUX GRANDEURS, ET POURQUOI ON A BESOIN DES DEUX

L'effectif n_i est un nombre d'individus : 33 étudiants ont un frère ou une sœur. La fréquence f_i est une proportion : $33/87 = 37,9\%$.

$$f_i = \frac{n_i}{n}$$

Pourquoi la fréquence est indispensable : elle seule permet de comparer. Deux promotions de tailles différentes ne se comparent pas en effectifs — 33 sur 87 et 50 sur 200 ne se lisent pas côte à côte. En fréquences, $37,9\%$ et $25,0\%$ se comparent immédiatement.

C'est précisément le passage que fait la diapositive 30 : l'empilé à 100% « revient à prendre les fréquences et non les effectifs », pour comparer des structures entre années dont les totaux diffèrent.

DÉMONSTRATION — POURQUOI LA FRÉQUENCE CUMULÉE N'A DE SENS QUE POUR UN CARACTÈRE ORDONNÉ


La définition du support : « la proportion d'individus présentant une modalité donnée ou inférieure dans la population ».

1. Le mot « inférieure » suppose qu'on puisse comparer deux modalités.
2. Pour une variable quantitative, c'est immédiat : 2 enfants est inférieur à 3.
3. Pour une qualitative ordinale, c'est encore possible : « plutôt mauvaise » est inférieure à « plutôt bonne ».
4. Pour une qualitative nominale, c'est impossible : « le bleu est-il inférieur au vert ? » n'a pas de sens.

Donc : pas d'ordre, pas de cumul. Le support restreint d'ailleurs explicitement sa définition au cas « pour un caractère quantitatif ».

Corollaire à savoir : une fréquence cumulée est toujours croissante, et la dernière vaut toujours 100% . Si ce n'est pas le cas dans ta copie, tu t'es trompé.

Modalités x_i	Effectifs n_i (en milliers)	Fréquences f_i (%)	Fréquences cumulées $F(x_i)$ (%)
0 enfant	8 225	48,0	48,0
1 enfant	3 821	22,3	70,3
2 enfants	3 449	20,1	90,4
3 enfants	1 241	7,2	97,7
4 enfants et plus	396	2,3	100,0
Ensemble	17 132	100,0	



Les familles selon le nombre d'enfants, « année donnée » (2008), en % — graphique reconstruit à partir du tableau de la diapositive 22

Tous les chiffres ont été recalculés et sont exacts : $8\,225/17\,132 = 48,01\%$; la somme des effectifs fait bien **17 132** ; les cumuls s'enchaînent correctement.

PIÈGE FRÉQUENT — DEUX IMPRÉCISIONS DU SUPPORT SUR CETTE DIAPOSITIVE

① Le texte annonce une « **enquête menée auprès de 17 132 familles** », alors que la colonne est intitulée « **effectifs en milliers** » : il s'agit de **17 132 milliers de familles**, soit **17,1 millions**. ② L'« **année donnée** » n'est pas précisée ici — mais le graphique de la **diapositive 31** la révèle : c'est **2008**, puisque sa colonne 2008 reproduit exactement ces cinq fréquences. → § 3.1, **A2** et **A3**.

EXEMPLE CHIFFRÉ — VÉRIFIER UNE COLONNE DE FRÉQUENCES CUMULÉES — LE RÉFLEXE QUI SAUVE UN EXERCICE

Reprends le tableau des familles ci-dessus : $48,0 \cdot 48,0 + 22,3 = 70,3 \cdot 70,3 + 20,1 = 90,4 \cdot 90,4 + 7,2 = 97,6 \cdot 97,6 + 2,3 = 99,9$.
Le support annonce **97,7** puis **100,0**. L'écart vient des **arrondis** : les fréquences exactes sont $48,01 \cdot 22,30 \cdot 20,13 \cdot 7,24 \cdot 2,31$, dont les cumuls exacts donnent $48,01 \cdot 70,31 \cdot 90,44 \cdot 97,69 \cdot 100,00$.

La règle : on cumule les valeurs exactes, on arrondit à la fin. Cumuler des valeurs déjà arrondies fait dériver le total — et c'est exactement le genre de détail qu'un correcteur attend qu'on signale.

2.3.4 — Les notations formelles (diapositive 23)

FORMULE CLÉ — DIAPOSITIVE 23 — À SAVOIR ÉCRIRE

- Le caractère statistique est noté X , les modalités x_i sont **ordonnées** de $i = 1, \dots, p$.
- À chaque modalité x_i correspond un **effectif** n_i , et l'**effectif total** vaut

$$n = \sum_{i=1}^p n_i = n_1 + n_2 + \dots + n_p$$

- Les **fréquences** f_i , pour $i = 1, \dots, p$, se calculent ainsi :

$$f_i = \frac{n_i}{n}$$

- Les **fréquences cumulées** F_k , pour $k = 1, \dots, p$, sont telles que :

$$F_k = \sum_{i=1}^k f_i$$

PIÈGE FRÉQUENT — DEUX INDICES, DEUX RÔLES

p est le **nombre de modalités distinctes**. n est le **nombre d'individus**. Ce ne sont pas les mêmes : dans l'exemple des 87 étudiants, $n = 87$ et $p = 11$.

FORMULE CLÉ — LE SYMBOLE Σ , SI TU NE L'AS JAMAIS MANIPULÉ

$\sum_{i=1}^p n_i$ se lit « **somme des n_i pour i allant de 1 à p** », et signifie exactement $n_1 + n_2 + \dots + n_p$.

- i est un **compteur** : il prend successivement les valeurs 1, 2, ..., p .
- **Le nombre du bas** dit où il commence, **celui du haut** où il s'arrête.
- **Le nom du compteur est sans importance** : $\sum_{i=1}^p n_i$ et $\sum_{k=1}^p n_k$ désignent le même nombre.

Les deux formules du chapitre se lisent alors sans effort : $n = \sum_{i=1}^p n_i$ — l'**effectif total** est la somme de tous les effectifs.

$F_k = \sum_{i=1}^k f_i$ — la **fréquence cumulée au rang k** est la somme des fréquences **jusqu'à k** . La borne haute est k , pas p : c'est tout ce qui distingue un cumul partiel d'un total.

FORMULE CLÉ — LES PROPRIÉTÉS DES FRÉQUENCES — À CONNAÎTRE ET À SAVOIR DÉMONTRER

$$\sum_{i=1}^p f_i = 1 = 100 \% \quad F_p = 100 \% \quad F_{k+1} \geq F_k \quad f_k = F_k - F_{k-1} \text{ avec } F_0 = 0$$

Démonstrations : Statistiques Ch01, § 2.3.4. Elles servent de contrôle à chaque tableau construit.

DÉMONSTRATION — LES TROIS PROPRIÉTÉS DES FRÉQUENCES, DÉMONTRÉES — CE QUE LE SUPPORT POSE SANS PREUVE

① La somme des fréquences vaut 1, soit 100 %.

$$\sum_{i=1}^p f_i = \sum_{i=1}^p \frac{n_i}{n} = \frac{1}{n} \sum_{i=1}^p n_i = \frac{n}{n} = 1$$

Pas à pas : chaque fréquence a le même dénominateur n , qu'on met en facteur ; la somme des effectifs est l'effectif total, parce que chaque individu est compté **une fois et une seule** (c'est le sens du mot « application », § 2.2.1). **Conséquence** : la dernière fréquence cumulée vaut toujours $F_p = 1 = 100\%$.

② Les fréquences cumulées sont croissantes.

$$F_{k+1} = F_k + f_{k+1} \quad \text{et} \quad f_{k+1} \geq 0 \quad \implies \quad F_{k+1} \geq F_k$$

③ On retrouve chaque fréquence à partir des fréquences cumulées.

$$f_k = F_k - F_{k-1} \quad \text{avec la convention} \quad F_0 = 0$$

Exemple chiffré, tableau des familles : $f(2 \text{ enfants}) = F(2) - F(1) = 90,4 - 70,3 = 20,1\%$ — c'est bien la fréquence du tableau. Et $48,0 + 22,3 + 20,1 + 7,2 + 2,3 = 99,9$: l'écart de 0,1 à 100 vient des arrondis ; avec les valeurs exactes, la somme vaut 100,00 %.

Une notation à ne pas confondre : le support écrit $F(x_i)$ en tête de colonne (diapositive 22) et F_k dans les formules (diapositive 23). **C'est la même grandeur** : la fréquence cumulée **au rang** k , c'est-à-dire **à la modalité** x_k .

Une coquille du support : la diapositive 23 invite à « mettre les notations en adéquation avec l'illustration de la diapo 21 » — l'illustration est en réalité le **tableau des familles de la diapositive 22**. → § 3.1, **A4**.

2.4 — Comparer des distributions, choisir un graphique, communiquer (diapositives 24 à 33)

À quoi sert cette section. Elle passe d'une distribution à **plusieurs**, pour **comparer** — des années, des territoires, des catégories. Elle apprend à choisir le graphique qui répond à la question posée, à l'intituler, puis elle conclut le chapitre : un tableau est un **outil de communication**, et tout ce qu'on a fait est de la statistique **descriptive**.

2.4.1 — Une distribution par sous-population : les personnes écrouées (diapositives 24 et 25)

DÉFINITION — DIAPOSITIVE 24 — LES QUATRE PROPOSITIONS

1. « Il arrive fréquemment que plusieurs distributions statistiques d'un même caractère soient présentées simultanément dans une optique comparative. »

2. « Plusieurs populations (ou sous-populations) sont définies selon une AUTRE variable — par année, zone géographique, etc. »

3. « Il y a en fait une distribution par sous-population. Ces distributions sont présentées juxtaposées. »

4. « Le but d'une telle présentation est la COMPARAISON de la répartition de la variable entre sous-populations. »

SYNTHÈSE — LE MÉCANISME, EN TROIS TEMPS

1. Une seconde variable découpe la population en sous-populations : l'année, la zone géographique, le sexe. Le support le dit : « plusieurs populations (ou sous-populations) sont définies selon une AUTRE variable ».

2. On calcule la distribution du caractère étudié dans chaque sous-population séparément. Il y a donc autant de distributions que de sous-populations.

3. On les présente juxtaposées, et « le but d'une telle présentation est la comparaison ».

Le point qui piège : dans le tableau des personnes écrouées, la variable étudiée est la catégorie pénale, et la variable de découpage est l'année. Ce sont deux rôles différents, et l'examen demandera lequel est lequel. → § 5, niveau 2, B3.

Et c'est ce mécanisme qui annonce le chapitre 4 : dès qu'on croise deux variables, on quitte la présentation d'une variable seule.

Diapositive 25. Source : **ministère de la Justice**.

Catégorie	2020	2021	2022	2023
Prévenus détenus	17 692	18 486	18 779	19 755
Condamnés-prévenus détenus	2 405	2 613	2 908	3 117
Condamnés détenus	41 553	47 246	49 338	51 746
Condamnés non détenus	12 184	13 644	14 286	15 453
Total des personnes écrouées	73 834	81 989	85 311	90 071

Les quatre totaux ont été vérifiés : ils sont tous exacts.

DÉFINITION — LE VOCABULAIRE PÉNAL QUE LE SUPPORT EMPLOIE SANS JAMAIS LE DÉFINIR

Quatre termes techniques, indispensables pour justifier le type du caractère. **Aucun n'est expliqué dans les diapositives.**

- **Écroué** — inscrit au **registre d'écrou** d'un établissement pénitentiaire. **C'est la population totale du tableau**, et elle est plus large que « détenu » : on peut être écroué **sans être enfermé** (bracelet électronique, placement extérieur).
- **Prévenu** — personne **poursuivie et pas encore jugée définitivement**. Elle est **présumée innocente**.
- **Condamné** — personne dont la **condamnation est définitive**.
- **Condamné-prévenu** — personne **condamnée définitivement dans une affaire et encore prévenue dans une autre**. C'est la raison d'être de cette catégorie intermédiaire.

La clé de lecture : les quatre modalités croisent **deux critères** — le **statut judiciaire** (prévenu / condamné) et la **détention effective** (détenu / non détenu).

FORMULE CLÉ — TAUX DE VARIATION ET POINTS DE POURCENTAGE — LES DEUX OUTILS POUR COMMENTER UN TABLEAU PAR ANNÉE

Le support compare des années **sans donner l'outil de la comparaison**. Il est indispensable dès qu'on commente un tableau comme celui-ci — et c'est l'objet annoncé du chapitre 3, « évolutions temporelles ».

$$t = \frac{V_{\text{arrivée}} - V_{\text{départ}}}{V_{\text{départ}}} \times 100$$

- $V_{\text{départ}}$: la valeur à la date de départ — **c'est le dénominateur**.
- $V_{\text{arrivée}}$: la valeur à la date d'arrivée.
- t : la variation **rapportée au point de départ**, en pour cent.


Pourquoi cette formule : une hausse de 16 237 personnes ne dit rien seule ; rapportée aux 73 834 de départ, elle devient comparable à n'importe quelle autre évolution.

Application : $t = \frac{90\,071 - 73\,834}{73\,834} \times 100 = \frac{16\,237}{73\,834} \times 100 = +21,99\%$, soit **+22,0 %** de personnes écrouées entre 2020 et 2023.


L'écart entre deux pourcentages se dit en points de pourcentage. Les condamnés détenus représentent 56,3 % des écroués en 2020 et 57,5 % en 2023 : leur part augmente de **1,2 point** — pas de 1,2 %. Le taux de variation de cette part serait, sur les valeurs arrondies, $1,2 / 56,3 = +2,1\%$. **Les deux chiffres sont vrais et ne disent pas la même chose.**

2.4.2 — Colonnes groupées : un même tableau, deux graphiques (diapositives 26 et 27)

Le support pose le critère en une phrase : « **le choix du diagramme colonne groupé dépend de [ce qui] est au centre de l'analyse** ». Voici ce que cela donne sur le même tableau.



Diapositive 26 — groupement par catégorie : « Évolution, pour chaque catégorie, du nombre de personnes écrouées » ; on suit chaque catégorie de 2020 à 2023



Diapositive 27 — groupement par année : « Évolution, pour chaque année, des catégories de personnes écrouées » ; on compare la composition d'une année à l'autre

PIÈGE FRÉQUENT — DEUX GRAPHIQUES, MÊME TABLEAU, DEUX QUESTIONS

	Groupement par catégorie (d. 26)	Groupement par année (d. 27)
Ce que dit le support	« Si l'on s'intéresse à l'évolution des effectifs de chaque catégorie... »	« Si l'on s'intéresse à l'évolution de la structure des effectifs... »
Titre donné	Évolution, pour chaque catégorie, du nombre de personnes écrouées	Évolution, pour chaque année, des catégories de personnes écrouées
Ce qu'on lit d'un coup d'œil	Chaque catégorie monte-t-elle ou descend-elle dans le temps ?	La composition d'une année se déforme-t-elle par rapport à l'autre ?
Sur l'axe horizontal	Les catégories	Les années


Le titre change avec le graphique, et il n'est pas décoratif : « évolution, pour chaque catégorie » contre « évolution, pour chaque année ». C'est une application directe de la règle « intitulés précis » de la diapositive 32.

La lecture chiffrée des deux graphiques. Sur le premier, chaque groupe de quatre colonnes monte : les quatre catégories augmentent, de +11,7 % (prévenus détenus) à +29,6 % (condamnés-prévenus détenus). Sur le second, les quatre groupes ont presque le même profil : les condamnés détenus pèsent 56,3 % des écroués en 2020 et 57,5 % en 2023. **Même tableau : une hausse générale d'un côté, une structure presque stable de l'autre** — détail des calculs au § 5, niveau 2, B3.

2.4.3 — Empilé et empilé à 100 % : les enfants par famille (diapositives 28 à 31)

Diapositive 28. **Champ :** France hors Mayotte, familles vivant en ménage ordinaire ayant au moins un enfant mineur. **Unité :** milliers de familles. **Source :** Insee, recensements de la population.


Nombre d'enfants mineurs	1990	1999	2007	2012	2017	2023
1 enfant	3 353,7	3 418,3	3 565,0	3 614,8	3 590,7	3 578,3
2 enfants	2 800,5	2 841,1	2 996,3	3 074,1	3 101,1	3 039,0
3 enfants	1 087,1	1 033,5	1 015,2	1 022,3	1 012,2	956,2
4 enfants ou plus	410,9	334,5	296,9	296,1	310,7	308,4
Ensemble	7 652,2	7 627,5	7 873,5	8 007,3	8 014,7	7 881,9



Diapositive 29 — empilé : la hauteur de chaque colonne est l'ensemble des familles de l'année, en milliers

Et la même chose en fréquences — c'est l'empilé à 100 % de la diapositive 30 :

En %	1990	1999	2007	2012	2017	2023
1 enfant	43,8	44,8	45,3	45,1	44,8	45,4
2 enfants	36,6	37,2	38,1	38,4	38,7	38,6
3 enfants	14,2	13,5	12,9	12,8	12,6	12,1
4 enfants ou plus	5,4	4,4	3,8	3,7	3,9	3,9



Diapositive 30 — empilé à 100 % : « Répartition du nombre d'enfants par famille, par année » ; toutes les colonnes valent 100 %

J'ai recalculé les vingt-quatre pourcentages : ils sont tous exacts.

PIÈGE FRÉQUENT — LE CONTRÔLE « $\sum N_i = N$ » VA TE DONNER UN ÉCART DE 0,1 SUR DEUX COLONNES

1999 : les quatre lignes font 7 627,4 ; l'« Ensemble » annonce 7 627,5. 2007 : les quatre lignes font 7 873,4 ; l'« Ensemble » annonce 7 873,5. Les quatre autres colonnes tombent juste.

Ce n'est pas une erreur : les données sont publiées en milliers **arrondis au dixième**, lignes et total arrondis séparément. → § 3.2, pour la ligne exacte à écrire en examen.

DÉFINITION — LES DEUX TERMES DU CHAMP QUE LE SUPPORT N'EXPLIQUE PAS

- **Ménage ordinaire** — au sens de l'Insee, l'ensemble des personnes **partageant le même logement ordinaire**. Cela **exclut les ménages collectifs** : foyers de travailleurs, internats, maisons de retraite, casernes, établissements pénitentiaires. *Une famille vivant en foyer d'hébergement n'est donc pas dans ce tableau.*
- **Enfant mineur** — enfant de **moins de 18 ans** vivant dans la famille. *Un enfant majeur encore au domicile ne compte pas ici : c'est pourquoi une famille avec deux enfants de 19 et 16 ans figure dans la ligne « 1 enfant ».*


Ces deux restrictions expliquent pourquoi ce tableau n'a pas de ligne « 0 enfant » : le champ ne retient que les familles **ayant au moins un enfant mineur**.

PIÈGE FRÉQUENT — EMPILÉ OU EMPILÉ À 100 % — LE CRITÈRE

Empilé (d. 29) : les **effectifs** sont empilés, et « **la hauteur de l'empilement correspond à l'ensemble** ». On voit donc **à la fois** la composition **et** le total.

Empilé à 100 % (d. 30-31) : on empile les **fréquences**, toutes les colonnes ont la **même hauteur**. On ne voit plus le total — **on voit uniquement la structure**.

Le choix se déduit de la question : si le total varie et que cette variation compte, il faut l'empilé simple. Si l'on veut comparer des structures entre populations de tailles différentes, il faut le 100 %. Dans l'exemple des familles, l'ensemble ne varie que de 3 % (de 7 652,2 à 7 881,9 milliers) : **le total n'est pas l'enjeu, la structure l'est**. Le 100 % s'impose, parce qu'il met toutes les colonnes à la même hauteur et rend les parts directement comparables d'une année à l'autre.



Diapositive 31 — répartition des familles selon le nombre d'enfants, 1975-2008, en % : valeurs relevées sur le graphique du support ; la colonne 2008 reproduit exactement le tableau de la diapositive 22

Ce que montre la diapositive 31, et ce qu'elle révèle. Sur trente-trois ans, la part des familles **sans enfant** passe de 37,0 % à 48,0 %, et celle des familles de **quatre enfants et plus** de 7,7 % à 2,3 %. Le support dit que ce diagramme illustre « le tableau précédent » : c'est **faux** — il illustre le tableau de la **diapositive 22**, dont il révèle l'année non précisée : **2008**. → § 3.1, A3.

PIÈGE FRÉQUENT — LE CAMEMBERT, QUE LE SUPPORT AUTORISE SANS LE COMMENTER

La diapositive 21 indique qu'« **un camembert ou un diagramme en barres peuvent être choisis** » pour représenter une répartition de fréquences.

Quand le camembert convient : une **seule** distribution, **peu de modalités**, dont les parts **somment à 100 %** — donc des modalités **exclusives et exhaustives**.

Quand il ne convient pas : dès qu'il faut **comparer** deux distributions. L'œil compare mal deux angles ; il compare très bien deux hauteurs. C'est précisément pourquoi toutes les comparaisons du chapitre — diapositives 26, 27, 29, 30, 31 — utilisent des **colonnes**, et jamais des camemberts.

Récapitulatif — les graphiques du chapitre et la question à laquelle chacun répond :

Graphique	Quand le choisir	Ce qu'il montre	Diapositive
Diagramme colonne simple	Une seule distribution	Les effectifs ou les fréquences, modalité par modalité	20
Colonnes groupées, groupement par catégorie	On s'intéresse à l'évolution des effectifs de chaque catégorie	Pour chaque catégorie, une colonne par année, côte à côte	26

Graphique	Quand le choisir	Ce qu'il montre	Diapositive
Colonnes groupées, groupement par année	On s'intéresse à l'évolution de la structure des effectifs	Pour chaque année, une colonne par catégorie, côte à côte	27
Empilé	La hauteur totale a un sens	Les effectifs empilés — « la hauteur de l'empilement correspond à l'ensemble des enfants chaque année »	29
Empilé à 100 %	On compare des structures dans le temps	« Ce qui revient à prendre les fréquences et non les effectifs, par année »	30-31

PIÈGE FRÉQUENT — LE CRITÈRE DE CHOIX, QUE LE SUPPORT ÉNONCE EN UNE LIGNE

« Le choix du diagramme colonne groupé dépend de [ce qui] est au centre de l'analyse. »

Groupement par catégorie → on suit chaque catégorie dans le temps. Groupement par année → on compare la composition d'une année à l'autre. Même tableau, deux graphiques, deux questions différentes.

2.4.4 — Les quatre règles de présentation (diapositive 32)

DÉFINITION — DIAPOSITIVE 32

« La présentation des données sous forme de tableau ou de graphique sert à **INFORMER**, c'est-à-dire donner une forme, une signification à des données (le plus souvent numériques brutes). Les tableaux ou graphiques produisent de l'information, ils sont des outils de communication. Il est primordial de les choisir et les intituler à bon escient pour que l'information utile passe. »

Les quatre règles :

1. **Intitulés précis** — « pas de noms de variables ou de modalités obscurs ».
2. **Lisibles par un non-spécialiste.**
3. **Compréhension immédiate ou simplifiée au maximum** — « si complexité : note de lecture en bas de tableau ».
4. **Indiquer les unités de mesure, la population, les choix méthodologiques réalisés.**

Le mot décisif est dans la première phrase : **informer**, « c'est-à-dire donner une **FORME**, une **SIGNIFICATION** à des données ».

SYNTHÈSE — POURQUOI UN TABLEAU EST UN ACTE DE COMMUNICATION, PAS UN ACTE DE CALCUL

Le support écrit : « **les tableaux ou graphiques PRODUISENT de l'information, ils sont des outils de communication** ». Produire — pas transmettre.

Les mêmes données donnent des messages différents selon la présentation. Les personnes écrouées, groupées par catégorie, racontent une hausse générale ; groupées par année, elles racontent une structure à peu près stable. **Les deux graphiques sont exacts, et ils ne disent pas la même chose.**

D'où les quatre règles, qui sont toutes des règles de **lecteur**, pas de statisticien : intitulés précis, lisibilité par un non-spécialiste, compréhension immédiate ou note de lecture, et mention des unités, de la population et des choix méthodologiques.

Le tableau de la diapositive 28 les applique toutes : il porte un champ (« France hors Mayotte, familles vivant en ménage ordinaire ayant au moins un enfant mineur »), une unité (« milliers de familles ») et une source (« Insee, recensements de la population »). **Recopie cette discipline dans tes propres tableaux : c'est un point à chaque fois.**

2.4.5 — Conclusion : du descriptif à l'inférentiel (diapositive 33)

DÉFINITION — DIAPOSITIVE 33

« Nous venons de voir les principales étapes d'une étude statistique. Nous avons appris à présenter la distribution d'un caractère statistique d'une population en effectifs, en fréquence ou en fréquences cumulées. Il s'agit souvent de la première étape de différents traitements de statistique descriptive que nous allons étudier dans les chapitres suivants. »

Et l'ouverture : « Nous ne disposons pas toujours de l'information exhaustive sur une population d'intérêt. Il faut parfois tirer aléatoirement un échantillon. Les techniques statistiques permettant de déduire des éléments d'une population à partir d'un échantillon aléatoire relèvent de la STATISTIQUE INFÉRENTIELLE. »

PIÈGE FRÉQUENT — STATISTIQUE DESCRIPTIVE / STATISTIQUE INFÉRENTIELLE

Descriptive : on décrit la population dont on dispose. C'est tout ce chapitre. **Inférentielle** : on déduit des éléments d'une population à partir d'un échantillon tiré aléatoirement. Le support l'annonce sans la traiter.

DÉFINITION — ÉCHANTILLON ET INFÉRENCE

Le support conclut : « nous ne disposons pas toujours de l'information exhaustive sur une population d'intérêt. Il faut parfois tirer aléatoirement un échantillon. »

Un **échantillon** est un sous-ensemble de la population, tiré au hasard, sur lequel on observe effectivement les données.

La **statistique inférentielle** regroupe « les techniques permettant de déduire des éléments d'une population à partir d'un échantillon aléatoire ».

Pourquoi le tirage doit être aléatoire : parce que c'est la seule façon de garantir que l'échantillon ne soit pas systématiquement différent de la population. Interroger les clients d'un hypermarché le samedi après-midi donnerait un échantillon biaisé — pas un échantillon aléatoire.

Ce qui distingue les deux branches en une ligne : la statistique **descriptive** décrit ce qu'on a observé ; la statistique **inférentielle** énonce ce qu'on peut en conclure sur ce qu'on n'a pas observé. Tout ce chapitre est de la statistique descriptive.

3 — Points de vigilance

Relu avant chaque examen blanc et la veille de l'épreuve. Les anomalies du support et ce qu'il faut écrire, les confusions qui coûtent une question entière, et ce qui fait passer de 14 à 18.

3.1 — Les quatre anomalies du support, et la conduite à tenir

Chacune a été vérifiée, chiffre par chiffre, en relisant les diapositives à l'image. Tu n'as pas à les chercher : tu dois seulement savoir **quoi écrire** si la question tombe dessus.

PIÈGE FRÉQUENT — A1 — LA SÉRIE BRUTE NE DONNE PAS LA DISTRIBUTION DU TABLEAU (DIAPOSITIVES 17 À 19)

Le fait. La série brute de la diapositive 17 contient **10 zéros et 24 « 2 »**. La série ordonnée (d. 18) et le tableau (d. 19) en contiennent **11 et 23**. Un « 2 » est devenu un « 0 » au tri. Les deux totaux font bien 87, et **toutes les autres modalités concordent**.

Conduite à tenir — et elle dépend de l'énoncé :

- « Construisez la distribution **à partir de la série** » → **compte ce qui est écrit : 10 et 24**. Puis **ajoute une ligne** : « *Nota : le tableau du cours indique 11 et 23 ; l'écart provient d'une valeur modifiée au tri. L'effectif total, 87, est identique.* »
- « **Rappelez la distribution du cours** » → **11 et 23**, les chiffres du tableau.

Ne jamais corriger silencieusement l'enseignante, ne jamais la contredire sans montrer le comptage. Une ligne de nota suffit : **elle prouve que tu as recompté**, et c'est exactement ce qui distingue une copie à 18.

PIÈGE FRÉQUENT — A2 — « 17 132 FAMILLES » ALORS QUE LA COLONNE EST « EN MILLIERS » (DIAPOSITIVE 22)

Le fait. L'énoncé écrit « *enquête menée auprès de 17 132 familles* », mais la colonne est intitulée « *effectifs n_i en milliers* ».

La bonne lecture : 17 132 milliers, soit environ 17,1 millions de familles.

Conduite à tenir. Écris « **17 132 milliers de familles, soit 17,1 millions** ». **Tout raisonnement reste valide** — les fréquences sont des rapports, l'unité se simplifie. C'est donc **une faute d'unité, pas une faute de calcul**.

Et c'est le piège d'unité n° 1 du chapitre : le même problème se pose à la diapositive 28, dont l'unité est également le **millier de familles**. « 1 012,2 familles » au lieu de « **1 012,2 milliers** » est une **erreur d'un facteur mille**.

PIÈGE FRÉQUENT — A3 — LA DIAPOSITIVE 31 N'ILLUSTRE PAS « LE TABLEAU PRÉCÉDENT » (DIAPOSITIVES 28 ET 31)

Le fait. La diapositive 31 affirme : « *ce diagramme colonne a le même contenu informationnel que le tableau précédent* ». Le tableau qui précède est celui de la **diapositive 28** — enfants **mineurs**, six années de 1990 à 2023, **champ restreint aux familles ayant au moins un enfant mineur**.

Or le graphique de la diapositive 31 porte sur **cinq années** — **1975, 1982, 1990, 1999, 2008** — et sur **cinq modalités** dont « **0 enfant** ». Ses colonnes valent :

Année	0 enfant	1	2	3	4 et plus
1975	37,0	25,3	20,2	9,8	7,7
1982	38,4	25,1	22,1	9,4	5,0
1990	42,1	23,8	21,7	8,8	3,5
1999	45,8	22,8	20,5	8,0	2,9
2008	48,0	22,3	20,1	7,2	2,3

La colonne 2008 reproduit exactement les cinq fréquences de la diapositive 22.

Deux conséquences, et la seconde est un point gratuit :

1. Le renvoi « *le tableau précédent* » est **faux** : la 31 illustre la **diapositive 22**.
2. L'« **année donnée** » de la diapositive 22, jamais précisée, est donc **2008**.

Conduite à tenir. Si on te demande l'année du tableau de la diapositive 22, réponds **2008** et **justifie par la concordance des cinq fréquences**. C'est une réponse démontrable, pas une hypothèse.

PIÈGE FRÉQUENT — A4 — LE RENVOI À LA « DIAPO 21 » (DIAPOSITIVE 23)

Le fait. La diapositive 23, qui pose les notations formelles, conclut : « *à présent amusons-nous à mettre les notations mathématiques en adéquation avec l'illustration de la diapo 21* ».

Mais la diapositive 21 ne contient aucune illustration : elle contient les **définitions** de la fréquence et de la fréquence cumulée. L'illustration est à la diapositive 22 — le tableau des familles.

Conduite à tenir. Sans conséquence sur le contenu : c'est une coquille de numérotation. **Sache seulement que « l'illustration des notations » est le tableau des familles**, pour ne pas chercher une diapositive qui n'existe pas si l'énoncé y renvoie.

3.2 — Le faux problème : l'écart de 0,1 de la diapositive 28

PIÈGE FRÉQUENT — TU VAS LE TROUVER EN FAISANT LE CONTRÔLE « $\sum N_i = N$ » — CE N'EST PAS UNE ERREUR

Le fait, vérifié. Sur le tableau de la diapositive 28, **quatre colonnes sur six** somment exactement au total annoncé. **Deux ne le font pas** :

Année	Somme des quatre lignes	« Ensemble » annoncé	Écart
1999	7 627,4	7 627,5	0,1
2007	7 873,4	7 873,5	0,1

L'explication. Les données sont publiées **en milliers, arrondies au dixième**. L'Insee arrondit **chaque ligne et le total séparément**, à partir des valeurs exactes. **La somme des arrondis n'est donc pas l'arrondi de la somme**. Un écart de 0,1 millier — **cent familles sur près de huit millions** — est le résidu normal de ce procédé.

Conduite à tenir. Ne corrige rien. Si tu fais le contrôle et que tu tombes dessus, écris une ligne : « *Écart de 0,1 millier sur deux colonnes, imputable aux arrondis au dixième des données publiées.* » **C'est une remarque de statisticien, et elle rapporte.**

Le même phénomène, en sens inverse, sur les fréquences : les huit fréquences des infractions (§ 5, niveau 2, B1) somment à **100,2 %** parce que sept d'entre elles s'arrondissent vers le haut. **On signale, on ne truque pas.**

3.3 — Les huit paires à ne jamais confondre

N°	Ne pas confondre	Le critère qui tranche
1	Effectif n_i / fréquence f_i	Un nombre d'individus / une proportion , $f_i = n_i/n$
2	Fréquence / fréquence cumulée	« présentant cette modalité » / « cette modalité ou inférieure »
3	Population / unité statistique	L' ensemble étudié / un élément de cet ensemble
4	Variable / modalité	L' application X / les valeurs x_i qu'elle prend
5	Qualitative nominale / ordinale	Aucun ordre qui ait du sens / un ordre qui a du sens
6	Quantitative discrète / continue	Relève du comptage , ensemble dénombrable / de la mesure , ensemble non dénombrable
7	n / p	Le nombre d' individus / le nombre de modalités distinctes
8	Statistique descriptive / inférentielle	Décrire la population dont on dispose / déduire à partir d'un échantillon aléatoire

3.4 — Les erreurs que fait la majorité de la promotion

PIÈGE FRÉQUENT — LES DIX FAUTES, ET LE RÉFLEXE QUI LES ÉVITE

N°	La faute	Le réflexe
1	Lire une fréquence cumulée comme une fréquence : « 90,4 % ont deux enfants »	Le « ou moins » est obligatoire . Sans lui, la phrase est fausse.
2	Oublier l' unité : « 3 578,3 familles »	L'unité est le millier : facteur 1 000. Vérifie l'en-tête de colonne avant d'écrire.
3	Oublier le champ : « toutes les familles françaises »	Le champ définit la population . Il est dans le bas du tableau, et il est noté .
4	Confondre unité statistique et caractère	Le caractère est ce qui varie d'une unité à l'autre .
5	Classer en quantitatif une variable codée en chiffres	La moyenne a-t-elle un sens ? Code postal, sexe codé 1/2 : non → qualitatif .
6	Confondre discret et continu	Compté → discret. Mesuré → continu. <i>L'arrondi d'affichage ne change pas la nature.</i>
7	Oublier la qualitative ordinale et répondre « nominale »	Des libellés + un ordre qui a du sens = ordinale .
8	Inverser caractère étudié et variable de découpage	Le total est du côté de la sous-population.
9	Inventer une modalité d'effectif nul , ou oublier une valeur extrême	Le tableau contient exactement les modalités observées : ni plus, ni moins.
10	Calculer une fréquence sur le total général au lieu du total de la colonne	Dans un empilé à 100 %, chaque colonne a son propre dénominateur .

PIÈGE FRÉQUENT — LES DEUX FAUTES DE VOCABULAIRE QUI COÛTENT LE PLUS CHER

① « **Écroué** » ≠ « **détenu** ». En 2023 : **90 071 écroués**, dont **15 453 non détenus**. Écrire « 90 071 détenus » est **faux** : **17,2 %** des écroués (15 453 sur 90 071) ne sont pas détenus — il y a **74 618 détenus**.

② « **+ 10 %** » ≠ « **+ 10 points** ». Un écart entre deux pourcentages se dit **en points de pourcentage**. De 20,0 % à 30,0 % : **+ 10 points**, et **+ 50 % d'effectif**. **Les deux chiffres sont vrais, ils ne disent pas la même chose.**

3.5 — Ce qu'une copie à 18 écrit et qu'une copie à 14 n'écrit pas

SYNTHÈSE — LES HUIT RÉFLEXES QUI VALENT LES QUATRE DERNIERS POINTS

N°	Ce que la copie à 18 ajoute	Pourquoi ça rapporte
1	Elle justifie le type au lieu de l'affirmer : « qualitatif, car les modalités sont des libellés ; nominal, car aucun ordre n'a de sens »	Le barème sépare presque toujours la réponse et la justification
2	Elle écrit les trois contrôles : $\sum n_i = n$, $\sum f_i = 100$, dernière cumulée = 100	Trente secondes, et cela prouve la méthode même si un calcul est faux
3	Elle donne la formule en lettres avant l'application numérique	La formule est notée séparément du résultat
4	Elle écrit une phrase de lecture complète : quand · combien · de quoi · champ · modalité	C'est la question type de l'Insee, et le support la pose deux fois
5	Elle signale les arrondis au lieu de les masquer : « somme à 100,2 % par cumul d'arrondis »	Une copie qui force un total à 100 est une copie qui triche
6	Elle intitule ses tableaux et graphiques : titre, unité, population, champ, source	Ce sont les quatre règles de la diapositive 32 — donc du barème explicite
7	Elle ajoute la grandeur qu'on ne demandait pas — les fréquences quand on demande les effectifs, la structure quand on demande l'évolution	Un point d'initiative, à condition que le demandé soit complet
8	Elle nomme le mécanisme : « l'année découpe, la catégorie est distribuée » ; « chaque colonne a son propre dénominateur »	Le correcteur cherche la compréhension, pas la récitation

SYNTHÈSE — LES CINQ PHRASES À RECOPIER TELLES QUELLES LE JOUR DE L'ÉPREUVE

- « La population est l'ensemble des [unités], sur le champ [champ]. L'unité statistique est [une unité]. L'effectif total est $n =$ [valeur]. »
- « Le caractère est [X]. Il est [type], car [justification en une ligne]. »
- « En [année], [valeur] [unité] de [population, champ] avaient [modalité]. »
- « [F] % de [population] présentaient [modalité] ou moins. »
- « Contrôles : la somme des effectifs vaut l'effectif total ; la somme des fréquences vaut 100 % ; la dernière fréquence cumulée vaut 100 %. »

3.6 — La check-list de la veille (20 minutes : fiche du § 4.1 et section 3)

MÉTHODE — SEPT QUESTIONS. SI TU RÉPONDS AUX SEPT, TU ES PRÊT.

- Les six étapes, dans l'ordre, et la phrase qui les commande ?
- Les cinq définitions : population, unité, caractère, modalité, effectif ?
- Les quatre sous-types de variables, avec le critère de chacun et un exemple ?
- $f_i = ? \cdot F_k = ? \cdot n = ?$ — en notations, et ce que vaut p ?
- Quand une fréquence cumulée a-t-elle un sens, et quand n'en a-t-elle pas ?
- Les quatre graphiques du chapitre et la question à laquelle chacun répond ?
- Les quatre règles de présentation de la diapositive 32 ?

Puis : les cartes du § 4.2 dues ou ratées, à froid, en dix minutes. Toute carte ratée deux fois de suite renvoie au § 2 sur cette notion — c'est un défaut de compréhension, pas de mémoire.

4 — Ancrage mémoriel

4.1 — Fiche de synthèse

Bloc	À savoir par cœur
Examen	Format non communiqué — hypothèse : écrit, exercices + questions de cours, sans document · 5 ECTS, BCC 2 · Héléne Couprie · 4 chapitres : présenter · résumer · évolutions temporelles · croiser
Démarche	Besoin de décider → besoin d'information → étude statistique · 6 étapes : ① problématique ② données à observer (qui ? population définie, délimitée) ③ méthode de recueil ④ campagne de mesures (combien, quand, comment) ⑤ traitement ⑥ décision · « Tous les choix sont guidés par le type de problématique »
Recueil	Expérimentation (variable de contrôle → variable d' observation : seule à établir une causalité) · enquête qualitative (petit nombre, de façon extensive) · seconde main (informations disponibles par ailleurs) · enquête quantitative (sur-mesure, la plus coûteuse)
Rapport	Résultats + éléments méthodologiques , orientés vers la décision · toute information inutile bannie · « ce n'est pas le rapport qui décide : toute décision est politique » (coût...) · délimiter = qui, où, quand = le champ
Vocabulaire	Population : « ensemble (mathématique) étudié » · unités : « les éléments de cette population » · effectif total : leur nombre · variable : « une application associant à chaque individu une valeur » (chaque individu, une seule valeur) · modalités : « les valeurs prises » · X majuscule, x_i minuscule
Types	Qualitative (modalités ≠ nombres) : nominale (aucun ordre qui ait du sens) / ordinaire (un ordre qui a du sens) · Quantitative : discrète (comptage, dénombrable) / continue (mesure, non dénombrable) · test : la moyenne a-t-elle un sens ? · sexe / qualité du service / nombre d'enfants / taille en cm
Présenter	Sans perte d'information : série brute (<i>raw data</i>) ou distribution des effectifs (<i>frequencies</i>) · passage : TRI puis COMPTAGE (quantitatif ou ordinal) · distribution = « étape n° 1 » · 87 étudiants : $n = 87$, $p = 11$, modalité la plus fréquente : 1 (33 étudiants)
Formules	$n = \sum_{i=1}^p n_i$ · $f_i = n_i / n$ · $F_k = \sum_{i=1}^k f_i$ · $\sum f_i = 1$ · $F_p = 100\%$ · F croissante · $f_k = F_k - F_{k-1}$ · cumuler exact, arrondir à la fin · fréquence cumulée = « ou inférieure », pas d'ordre, pas de cumul
Familles d. 22	17 132 milliers (2008) · 48,0 · 22,3 · 20,1 · 7,2 · 2,3 % · cumulées 48,0 · 70,3 · 90,4 · 97,7 · 100,0
Comparer	Une distribution par sous-population , définie par une autre variable (année...) · groupées par catégorie = évolution de chaque catégorie · par année = évolution de la structure · empilé = structure + total · empilé à 100 % = structure seule (fréquences par année) · camembert : une distribution, peu de modalités
Chiffres	Infractions 2024 : 9 376 000 , 30,9 % vandalisme voiture, somme des arrondis 100,2 % · écroués 73 834 → 90 071 , +22,0 % · 2023 : 74 618 détenus, 15 453 non détenus · enfants mineurs : 12,6 % à 3 enfants en 2017 (1 012,2 / 8 014,7) · écart 0,1 en 1999 et 2007 = arrondis
Présentation	Informer = « donner une forme , une signification » · 4 règles : intitulés précis · lisibles par un non-spécialiste · compréhension immédiate , sinon note de lecture · unités, population, choix méthodologiques · descriptive (ce qu'on a) / inférentielle (échantillon aléatoire)
Sources	Enquête « Vécu et ressenti en matière de sécurité » (Insee) · ministère de la Justice · Insee , recensements de la population

4.2 — Cartes de révision

74 cartes, exportées dans `Statistiques/Anki/Statistiques_Ch01_Presenter_pour_informer.csv` · P3 de chaque cycle APPRENDRE : les cartes de la section étudiée ; RÉVISER : les cartes dues. **Protocole**. Cache la réponse. Formule la tienne **à voix haute ou par écrit** — la reformuler dans sa tête ne compte pas. Puis compare. Note ✓ ou ✗. À la révision suivante, tu ne reprends que les ✗ — Anki le fait pour toi.

Section 2.1 — Réaliser une étude statistique

Donne la chaîne qui justifie toute étude statistique.

Besoin de décider → Besoin d'information → Étude statistique.

Cite les six étapes d'une étude statistique.

① Quel type de problématique ? · ② choix des données à observer · ③ choix de la méthode de recueil des données · ④ campagne de mesures · ⑤ traitement des données · ⑥ prise de décision.

Quelle phrase figure au bas du schéma des six étapes, et que signifient les flèches ?

« Tous les choix sont guidés par le type de problématique. » Les flèches remontent de **chacune** des cinq étapes suivantes vers la première.

Pourquoi la demande « faites-moi une enquête de satisfaction » est-elle insuffisante ?

Elle est « **beaucoup trop vague** » : selon qu'il s'agit de **modifier la mise en place des produits en rayon**, d'**améliorer l'affichage**, de **mieux répondre aux attentes en matière de choix des produits** ou de **mieux définir les attentes en matière d'horaires et de conseil**, l'étude n'interroge ni les mêmes personnes ni sur les mêmes choses.

Que décide l'étape 2, et que sait-on de la population ?

Qui ? — « sur quels individus ou unités statistiques les observations vont être réalisées ». La population doit être **définie, délimitée** ; « **parfois on connaît sa taille, mais pas toujours** ».

Cite les quatre méthodes de recueil des données.

① L'expérimentation · ② l'observation, ou enquête qualitative · ③ les données de seconde main · ④ l'enquête quantitative.

Définis l'expérimentation, avec ses deux variables.

« On dispose d'un protocole permettant l'observation directe de l'impact d'une **variable de contrôle** sur une **variable d'observation**. » La **variable de contrôle** est celle que l'expérimentateur fait varier ; la **variable d'observation** est celle dont on mesure la réaction.

Définis l'enquête qualitative et les données de seconde main.

Qualitative : « on observe de façon extensive un **petit nombre** d'individus ». **Seconde main** : « on réutilise des informations disponibles par ailleurs ».

Définis l'enquête quantitative et cite sa caractéristique économique.

« Un travail sur-mesure : on collecte l'information utile par enquête, questionnaire, etc. » C'est « l'**option la plus coûteuse** ».

Que doit définir la campagne de mesures ?

Combien de personnes enquêter · **quand** les enquêter · **comment** les enquêter.

Que doit contenir un rapport statistique ?

Le résultat des traitements statistiques, mais aussi **les éléments méthodologiques** — les choix réalisés quant aux méthodes utilisées — **le tout orienté selon la problématique, vers la prise de décision**.

Cite les deux règles qui accompagnent le rapport statistique.

« Toute information inutile, non informative au regard de la problématique, doit être bannie. » Et : « ce n'est pas le rapport statistique qui décide, toute décision est politique » et repose aussi sur d'autres considérations ou contraintes, « comme le coût par exemple ».

Cite les quatre chapitres du cours et ce que chacun fait.

CHAP 1 présenter sans perte d'information · CHAP 2 résumer variable par variable · CHAP 3 les évolutions temporelles · CHAP 4 croiser plusieurs variables.

Décompose un exemple de la diapositive 3 — le financement des retraites — en décision, information et étude.

Décision : fixer le niveau des cotisations et l'âge de départ. **Information** : le nombre futur de retraités rapporté au nombre futur d'actifs qui cotisent. **Étude** : des projections démographiques à partir des recensements.

Campagne de mesures : quel est l'enjeu de chacune des trois questions « combien, quand, comment » ?

Combien : recensement ou échantillon — précision contre coût. **Quand** : la date fait partie du champ, et une date mal choisie déforme le résultat (clients du samedi). **Comment** : le mode de collecte et la formulation des questions conditionnent les réponses.

Délimiter une population, c'est répondre à quelles trois questions ?

Qui ? (quel type d'unité, avec quelle restriction) · **Où ?** (quel territoire) · **Quand ?** (quelle date d'observation). C'est exactement ce qu'on appelle le champ, au bas de chaque tableau.

« Ce n'est pas le rapport statistique qui décide » : qui apporte quoi ?

Le statisticien apporte des faits, des incertitudes et des méthodes. Le décideur ajoute des objectifs, des contraintes et un arbitrage. Les données ne contiennent pas la décision — d'où l'obligation de joindre les éléments méthodologiques.

Section 2.2 — Le vocabulaire de la statisticienne

Définis la population et les unités statistiques.

Population : « ensemble (mathématique) étudié ». **Individus ou unités statistiques** : « les éléments de cette population ».

Définis la taille de la population.

« Le nombre d'individus ou d'unités statistiques » — on l'appelle aussi **effectif total**.

Définis une variable statistique et ses modalités.

Variable (ou caractère) statistique : « une application associant à chaque individu une valeur ». **Modalités** : « les valeurs prises par une variable statistique ».

Que signifie « application » dans cette définition, et qu'est-ce que cela interdit ?

Une application associe à **chaque** individu **une et une seule** valeur. Cela interdit qu'un individu soit **sans réponse** ou qu'il présente **deux modalités à la fois** pour la même variable. C'est aussi ce qui garantit que $\sum n_i = n$.

Quelle est la convention de notation du cours ?

« Les variables seront notées en majuscule et leurs valeurs prises en minuscule » : le caractère est X , les modalités sont x_i .

Combien de types et de sous-types de variables, et lesquels ?

2 types et 4 sous-types. Qualitative : nominale et ordinale. Quantitative : discrète et continue.

Distingue qualitative nominale et ordinale.

Nominale : « il n'est pas possible de classer les modalités selon un ordre qui a du sens ». **Ordinale** : « il est possible de classer les modalités selon un ordre qui a du sens ».

Distingue quantitative discrète et continue.

Discrète : « les modalités relèvent du **comptage** (ensemble **dénombrable**) ». **Continue** : « les modalités relèvent de la **mesure** (ensemble **non dénombrable**) ».

Que signifient dénombrable et non dénombrable ?

Dénombrable : on peut énumérer les éléments un par un, même si la liste est infinie. **Non dénombrable** : entre deux valeurs quelconques il en existe toujours une troisième. Test pratique : existe-t-il une valeur possible entre deux valeurs voisines ?

Quel avertissement le support donne-t-il sur les variables qualitatives ?

« Une variable qualitative peut être codée dans une base de données sous forme de nombre, un mot valant un chiffre. » Test : la moyenne a-t-elle un sens ?

Donne les quatre exemples du support, un par sous-type.

Sexe (homme, femme, autre) → **qualitative nominale**. **Qualité du service** (mauvaise, plutôt mauvaise, plutôt bonne, très bonne) → **qualitative ordinale**. **Nombre d'enfants** (0 à 5) → **quantitative discrète**. **Taille en cm** (179, 182, 183...) → **quantitative continue**.

Tableau des infractions (d. 12) : population, unité statistique, effectif total, caractère, type, nombre de modalités ?

Population : les infractions déclarées en 2024 sur le champ — France métropolitaine, Martinique, Guadeloupe, La Réunion.
Unité : une infraction déclarée (pas une victime). $n = 9\,376\,000$. **Caractère** : le type d'atteinte, **qualitatif nominal**. $p = 8$.

Combien font, additionnées, les huit fréquences du tableau des infractions — et pourquoi ?

100,2 %. Sept des huit s'arrondissent vers le haut. Les valeurs exactes, elles, somment à 100,000 %. **En examen** : on signale le cumul d'arrondis, on ne trèque aucun chiffre.

Section 2.3 — Présenter une variable sans perte d'information

Quelles sont les deux façons de présenter une variable sans perte d'information ?

La **série**, ou **données brutes** (*raw data*) · et la **distribution observée des effectifs** (*frequencies*).

Quelles sont les deux opérations pour passer de la série brute à la distribution, et dans quel ordre ?

Un **TRI** des modalités, puis un **COMPTAGE** des effectifs — et cela « dans le cas quantitatif ou qualitatif ordinal ».

Pourquoi trier avant de compter ?

Parce que le tri met **côte à côte les valeurs identiques** : le comptage devient une lecture de longueurs de blocs, en **un seul passage** au lieu d'un passage par modalité.

Définis la distribution observée des effectifs, et l'effectif d'une modalité.

Distribution : « associe à chaque modalité d'une variable statistique l'effectif observé correspondant ». **Effectif d'une modalité** : « le nombre d'individus présentant une modalité donnée du caractère statistique ».

Quelles représentations pour une distribution des effectifs, et quelle remarque le support ajoute-t-il ?

Un tableau ou un diagramme colonne. « Il n'y a pas de perte d'information », et « il s'agit souvent de l'étape n° 1 d'une analyse statistique ».

Pourquoi dit-on que la distribution est « sans perte d'information » ?

Parce qu'à partir du tableau on peut reconstituer la série : il suffit de réécrire chaque modalité autant de fois que son effectif. Seul l'ordre de présentation a changé. **Le chapitre 2, qui résume, perd de l'information.**

Définis la fréquence d'une modalité.

« La proportion d'individus présentant une modalité donnée du caractère statistique dans la population totale (en pour cent de la population). »

Définis la fréquence cumulée, et donne la restriction du support.

« Pour un caractère quantitatif, la proportion d'individus présentant une modalité donnée OU INFÉRIEURE dans la population. »

Pourquoi la fréquence cumulée n'a-t-elle pas de sens pour une qualitative nominale ?

Parce que le mot « inférieure » suppose qu'on puisse **comparer deux modalités**. Sur une nominale, il n'y a **pas d'ordre** : « le bleu est-il inférieur au vert ? » n'a pas de sens.

Quelles sont les deux propriétés d'une colonne de fréquences cumulées ?

Elle est **toujours croissante**, et la **dernière valeur vaut toujours 100 %**.

Quelles représentations pour une répartition des fréquences ?

« Un camembert ou un diagramme en barres peuvent être choisis. »

Quand le camembert convient-il, et quand ne convient-il pas ?

Il convient pour **une seule** distribution, **peu de modalités**, exclusives et exhaustives. **Il ne convient pas** dès qu'il faut **comparer** : l'œil compare mal deux angles, bien deux hauteurs.

Écris les quatre formules du cours.

$n = \sum_{i=1}^p n_i$, $f_i = \frac{n_i}{n}$, $F_k = \sum_{i=1}^k f_i$ et les modalités x_i **ordonnées** de $i = 1$ à p .

Que désignent n et p ? Ne pas confondre.

n = le nombre d'**individus** (effectif total). p = le nombre de **modalités distinctes**. Dans l'exemple des frères et sœurs, $n = 87$ et $p = 11$.

Comment se lit $\sum_{i=1}^k f_i$, et qu'est-ce qui le distingue de $\sum_{i=1}^p f_i$?

« Somme des f_i pour i allant de 1 à k ». La **borne haute est k , pas p** : c'est un **cumul partiel**, pas le total.

Pourquoi cumuler les valeurs exactes plutôt que les valeurs arrondies ?

Parce que cumuler des arrondis **fait dériver le total**. Dans le tableau des familles, les arrondis donnent 97,6 alors que le cumul exact donne **97,7**. **On cumule exact, on arrondit à la fin**.

Démontre que la somme des fréquences vaut 100 %.

$\sum f_i = \sum \frac{n_i}{n} = \frac{1}{n} \sum n_i = \frac{n}{n} = 1$, soit **100 %** — on met n en facteur, et la somme des effectifs est l'effectif total. D'où $F_p = 100 \%$.

Comment retrouve-t-on une fréquence à partir des fréquences cumulées ?

$f_k = F_k - F_{k-1}$, avec $F_0 = 0$. Exemple : $90,4 - 70,3 = 20,1 \%$ de familles à deux enfants.

Dans l'exemple des 87 étudiants : population, taille, caractère, type ?

Population : l'ensemble des **87 étudiants** d'une promotion. **Taille** : **$n = 87$ unités statistiques**. **Caractère** : « nombre de frères et sœurs ». **Type** : **quantitatif discret**.

Donne la distribution des 87 étudiants, telle que le support la présente.

$0 \rightarrow 11 \cdot 1 \rightarrow 33 \cdot 2 \rightarrow 23 \cdot 3 \rightarrow 7 \cdot 4 \rightarrow 3 \cdot 5 \rightarrow 4 \cdot 6 \rightarrow 1 \cdot 7 \rightarrow 2 \cdot 9 \rightarrow 1 \cdot 13 \rightarrow 1 \cdot 14 \rightarrow 1$. **Ensemble : 87**. Donc $p = 11$.

Quelle anomalie contient l'exemple des 87 étudiants ?

La **série brute** (d. 17) contient **10 zéros et 24 « 2 »** ; la **série ordonnée** (d. 18) et le **tableau** (d. 19) en contiennent **11 et 23**. Un « 2 » est devenu un « 0 » au tri. Les deux totaux font bien 87.

Dans le tableau des familles (d. 22) : les cinq fréquences et les cinq fréquences cumulées ?

Fréquences : 48,0 · 22,3 · 20,1 · 7,2 · 2,3 %. **Cumulées** : 48,0 · 70,3 · 90,4 · 97,7 · 100,0 %. **Effectif total** : **17 132 milliers de familles**.

Quelle imprécision le tableau de la diapositive 22 contient-il, et quelle est l'année ?

Le texte dit « **17 132 familles** » alors que la colonne est « **en milliers** » : ce sont **17,1 millions**. Et l'« **année donnée** » non précisée est **2008**, révélée par le graphique de la diapositive 31.

Section 2.4 — Comparer, choisir un graphique, communiquer

Dans quelle optique présente-t-on plusieurs distributions d'un même caractère ?

Dans une optique comparative. « Plusieurs populations ou sous-populations sont définies selon une **autre** variable — par année, zone géographique, etc. » Il y a une **distribution par sous-population**, et elles sont **juxtaposées**.

Quel est le but d'une présentation juxtaposée ?

« La comparaison de la répartition de la variable entre sous-populations. »

Quand choisir un diagramme colonnes groupées par catégorie ?

« Si l'on s'intéresse à l'évolution des effectifs de chaque catégorie. » Titre type : « Évolution, **pour chaque catégorie**, du nombre de... ».

Quand choisir un diagramme colonnes groupées par année ?

« Si l'on s'intéresse à l'évolution de la structure des effectifs. » Titre type : « Évolution, **pour chaque année**, des... ».

Que représente la hauteur d'un diagramme empilé ?

« La hauteur de l'empilement correspond à l'ensemble » — on voit à la fois la composition et le total.

Qu'est-ce qu'un empilé à 100 %, et à quoi sert-il ?

On empile les **fréquences** et non les effectifs : toutes les colonnes ont la même hauteur. On ne voit plus le total, on voit **uniquement la structure** — ce qui permet de comparer des populations de **tailles différentes**.

Cite les quatre règles de présentation d'un tableau ou d'un graphique.

① **Intitulés précis** — pas de noms obscurs · ② **lisibles par un non-spécialiste** · ③ **compréhension immédiate**, sinon **note de lecture** en bas de tableau · ④ **indiquer les unités de mesure, la population, les choix méthodologiques**.

Que signifie « informer », selon le support ?

« Donner une forme, une signification à des données, le plus souvent numériques brutes. » Les tableaux et graphiques « produisent de l'information, ils sont des outils de communication ».

Personnes écrouées : total 2020 et total 2023, et l'évolution en % ?

73 834 en 2020, 90 071 en 2023, soit + 22,0 %.

Dans le tableau des personnes écrouées, quel est le caractère et quelle est la variable de découpage ?

Le caractère étudié est la catégorie pénale (qualitative nominale). La variable de découpage en sous-populations est l'année.

Définis les quatre catégories pénales du tableau de la diapositive 25.

Écroué : inscrit au registre d'écrou — plus large que « détenu ». **Prévenu** : poursuivi, pas encore jugé définitivement.

Condamné : condamnation définitive. **Condamné-prévenu** : condamné dans une affaire et encore prévenu dans une autre.

Écris la formule du taux de variation et applique-la aux personnes écrouées 2020-2023.

$$t = \frac{V_{\text{arrivée}} - V_{\text{départ}}}{V_{\text{départ}}} \times 100 = \frac{90\,071 - 73\,834}{73\,834} \times 100 = +21,99 \%, \text{ soit } +22,0 \%. \text{ Le dénominateur est la valeur de départ.}$$

Un écart entre deux pourcentages se dit comment ?

En points de pourcentage, jamais en pourcent. De 20,0 % à 30,0 % : + **10 points** de part, et + **50 %** d'effectif. Les deux chiffres sont vrais et différents.

« Ménage ordinaire » et « enfant mineur » : les deux définitions Insee du champ de la diapositive 28 ?

Ménage ordinaire : personnes partageant un même **logement ordinaire** — cela **exclut** foyers, internats, maisons de retraite, casernes, établissements pénitentiaires. **Enfant mineur** : enfant de **moins de 18 ans** vivant dans la famille.

Quel champ porte le tableau des enfants par famille ?

« France hors Mayotte, familles vivant en ménage ordinaire ayant au moins un enfant mineur. » Unité : milliers de familles.
Source : Insee, recensements de la population.

Quel écart le contrôle « $\sum n_i = n$ » donne-t-il sur le tableau de la diapositive 28, et que faut-il en faire ?

0,1 millier sur 1999 et 2007 (7 627,4 contre 7 627,5 · 7 873,4 contre 7 873,5). On ne corrige rien : lignes et total sont arrondis séparément au dixième. On écrit une ligne de nota.

À quoi correspond le chiffre 12,6 de la diapositive 30 ?

À la fréquence des familles à 3 enfants mineurs en 2017 : $1\,012,2 / 8\,014,7 = 12,6\%$. Le dénominateur est le total de l'année 2017, pas le total général.

Cite les trois sources de données utilisées dans le chapitre.

L'enquête « Vécu et ressenti en matière de sécurité », diffusion Insee · le ministère de la Justice · l'Insee, recensements de la population.

Qu'est-ce que la statistique inférentielle ?

« Les techniques statistiques permettant de déduire des éléments d'une population à partir d'un échantillon aléatoire. » On y recourt quand « on ne dispose pas de l'information exhaustive » et qu'il faut « tirer aléatoirement un échantillon ».

Distingue statistique descriptive et inférentielle.

La descriptive décrit ce qu'on a observé — tout ce chapitre. L'inférentielle énonce ce qu'on peut conclure sur ce qu'on n'a pas observé, à partir d'un échantillon aléatoire.

Pourquoi le tirage d'un échantillon doit-il être aléatoire ?



C'est la seule façon de garantir que l'échantillon ne soit pas systématiquement différent de la population. Interroger les clients un samedi après-midi donne un échantillon biaisé, pas aléatoire.

4.3 — Moyens mnémotechniques

Ce qu'il faut retenir	Le moyen
La chaîne de la diapositive 3	« Décider d'abord » — la chaîne se lit de gauche à droite : décision → information → étude , jamais en partant des données
Les six étapes	« Pour Donner Mes Chiffres, Traite-les, Décide » — Problématique, Données, Méthode, Campagne, Traitement, Décision
Les quatre méthodes de recueil	« Labo, loupe, archives, sondage » — expérimentation (le labo), enquête qualitative (la loupe sur peu d'individus), seconde main (les archives), enquête quantitative (le sondage, le plus cher)
Délimiter une population	« Qui, où, quand » — les trois questions du champ
Nominale / ordinale	« Nom » = on peut seulement nommer ; « Ordre » = on peut ordonner
Discrète / continue	« Je compte des billes, je mesure de l'eau » — les billes se comptent (discret), l'eau se mesure (continu)
Qualitative codée en chiffres	« Le code postal ne se moyenne pas » — si la moyenne n'a pas de sens, c'est qualitatif
Série → distribution	« Trier puis compter » — comme on range ses cartes avant de les compter

Ce qu'il faut retenir	Le moyen
Fréquence cumulée	« Ou moins » — trois mots obligatoires dans chaque phrase de lecture d'une cumulée
Groupé par catégorie / par année	« Ce qui est en bas, on le suit » — sur l'axe horizontal : les catégories (on suit chaque catégorie) ou les années (on compare les structures)
Empilé / 100 %	« Empilé = taille + forme ; 100 % = forme seule »
Les 4 règles de présentation	« TLCU » — T itre précis, L isible, C ompréhension immédiate (ou note de lecture), U nités-population-méthode
Phrase de lecture	« QCQPM » — Q uand, C ombien, de Q ui, P opulation, M odalité
Les trois contrôles	« n, 100, 100 » — $\sum n_i = n \cdot \sum f_i = 100 \cdot$ dernière cumulée = 100

4.4 — Le schéma qui relie tout



« Tous les choix sont guidés par le type de problématique. »

La démarche entière tient dans la diapositive 4 : chaque étape se justifie par la problématique

5 — Entraînement

Niveau 1 : à la fin de chaque cycle APPRENDRE (P4), les questions de la section étudiée. **Niveaux 2 à 4** : pomodoros S'ENTRAÎNER, document fermé, chronomètre, correction au barème, chaque erreur classée — **connaissance, méthode ou inattention**.

Méthode de l'épreuve — format, minutage, gabarits

À consulter avant les niveaux 2 à 4, puis la veille. Le support pose **cinq fois** les mêmes trois gestes — **identifier, calculer, lire** — : voici leurs gabarits.

Le format de l'épreuve

PIÈGE FRÉQUENT — LE FORMAT N'EST PAS DONNÉ PAR LE SUPPORT — HYPOTHÈSE EXPLICITE

Les 33 diapositives ne précisent ni la nature, ni la durée, ni le barème de l'épreuve. **Je ne l'inventerai pas.**

Hypothèse retenue : épreuve écrite, exercices d'application + questions de cours, sans document.

Pourquoi. Le support est bâti sur **cinq exercices posés à l'étudiant** — diapositives 12, 22, 25, 28 et 30 — toujours de la même forme : « indiquez la population, les unités statistiques, le caractère, son type », « comment a été calculé ce chiffre ? », « écrivez une phrase de lecture ». **Un enseignant qui pose cinq fois la même question dans un cours l'interroge à l'examen.** Les niveaux 2 à 4 sont construits exactement sur ces trois gestes.

Ce que l'hypothèse ne change pas : le cours (§ 2) est le même quel que soit le format. Les définitions, les types de variables et les formules se savent dans tous les cas.

La demande figure dans SOURCES.md . Avec le format réel, les niveaux 2 et 4 sont recalibrés en une passe.

Le minutage

La durée n'est pas donnée par le support. La règle est indépendante de la durée : **5 % de lecture · 85 % de production · 10 % de vérification**, et à l'intérieur, **autant de minutes par point que le barème en accorde**.

MÉTHODE — LES TROIS VÉRIFICATIONS DE FIN D'ÉPREUVE, DANS CET ORDRE

1. **La somme des effectifs fait-elle l'effectif total annoncé** ? Si non, il manque une ligne ou tu as compté deux fois.
2. **La somme des fréquences fait-elle 100 %** ? À 0,1 près, écart d'arrondi accepté et **signalé**.
3. **La dernière fréquence cumulée fait-elle 100 %** ? Si non, l'erreur est dans le cumul.

Ces trois contrôles prennent trente secondes et rattrapent la quasi-totalité des erreurs de calcul de ce chapitre.

Gabarit 1 : « Identifiez la population, les unités statistiques, le caractère... »

C'est la question posée cinq fois dans le support. Six éléments, toujours dans cet ordre.

N°	Ce qu'on demande	Comment le trouver
1	La population	L'ensemble dont parle le tableau. Cherche le champ et le titre
2	Les unités statistiques	Un élément de cet ensemble : une famille, un étudiant, une personne écrouée
3	L'effectif total n	La ligne « Ensemble » ou « Total ». S'il n'y a pas de ligne totale, c'est la somme
4	Le caractère (ou variable) X	Ce que le tableau mesure sur chaque unité — pas l'unité elle-même
5	Les modalités x_i	Les valeurs prises : les intitulés de lignes, ou les valeurs de la série
6	Le type	Qualitative nominale ou ordinale · quantitative discrète ou continue — et justifie

PIÈGE FRÉQUENT — L'ERREUR QUI COÛTE LA MOITIÉ DE LA QUESTION

Confondre l'unité statistique et le caractère. Dans le tableau des infractions, l'unité n'est pas « l'infraction en général », c'est **une infraction déclarée** ; le caractère est **le type d'atteinte subie**. Dans le tableau des familles, l'unité est **une famille**, le caractère est **le nombre d'enfants**.

Le test : le caractère est ce qui VARIE d'une unité à l'autre. Si ça ne varie pas, ce n'est pas le caractère.

Gabarit 2 : construire une distribution à partir d'une série brute

Quatre étapes, à écrire toutes les quatre — même les évidentes, elles sont notées.

1. **Annoncer la population, son effectif n , et le type du caractère.**
2. **Trier** la série par ordre croissant des modalités.
3. **Compter** : dresser le tableau modalité / effectif, **et vérifier que $\sum n_i = n$.**
4. **Ajouter les colonnes demandées** — fréquences $f_i = n_i/n$, cumulées $F_k = \sum_{i=1}^k f_i$ — **avec leurs unités (%) et une ligne « Ensemble ».**

PIÈGE FRÉQUENT — TROIS RÉFLEXES QUI RAPPORTENT

- **N'oublie aucune modalité présente**, même d'effectif 1 : les valeurs extrêmes (13, 14 frères et sœurs) font partie de la distribution.
- **N'invente pas les modalités absentes.** Il n'y a pas de ligne « 8 » ni « 10 » dans le tableau du cours, parce qu'aucun étudiant n'a déclaré ces valeurs.
- **Cumule les valeurs exactes, arrondis à la fin** ($\rightarrow$ § 2.3.3).

Gabarit 3 : écrire une phrase de lecture

La phrase de lecture est la question type de l'Insee, et le support la demande deux fois. Cinq éléments, toujours les cinq.

Quand $_{\text{la date}}$ + Combien $_{\text{la valeur}}$ + de quoi $_{\text{l'unité}}$ + dans quelle population $_{\text{le champ}}$ + présentaient quelle modalité $_{\text{la valeur du caractère}}$

CORRIGÉ — TROIS PHRASES DE LECTURE MODÈLES, PRÊTES À L'EMPLOI

Sur un effectif : « En 2023, **3 578,3 milliers de familles** vivant en ménage ordinaire en France hors Mayotte et ayant au moins un enfant mineur **avaient exactement un enfant mineur.** »

Sur une fréquence : « En 2017, **12,6 %** des familles ayant au moins un enfant mineur **avaient trois enfants mineurs.** »

Sur une fréquence cumulée : « **90,4 %** des familles avaient **deux enfants ou moins.** » — le « ou moins » est obligatoire, c'est ce qui signale le cumul.

PIÈGE FRÉQUENT — LES TROIS FAUTES DE LECTURE LES PLUS FRÉQUENTES

1. **Oublier l'unité.** « 3 578,3 familles » au lieu de « **milliers de familles** » : erreur d'un facteur mille.
2. **Oublier le champ.** Ce ne sont pas toutes les familles, ce sont celles **ayant au moins un enfant mineur, vivant en ménage ordinaire, en France hors Mayotte.**
3. **Lire une fréquence cumulée comme une fréquence.** « 90,4 % avaient deux enfants » est **faux** — ils en avaient **deux ou moins.**

Gabarit 4 : « Comment a été calculé ce chiffre ? »

Le support pose cette question deux fois. Quatre lignes, toujours les mêmes.

1. **Nommer la grandeur** : effectif, fréquence, fréquence cumulée.
2. **Écrire la formule en lettres** : $f_i = n_i/n$.
3. **Écrire l'application numérique complète**, avec les deux nombres tirés du tableau.
4. **Donner le résultat avec son unité, et une phrase de lecture.**

CORRIGÉ — EXEMPLE APPLIQUÉ — LE CHIFFRE 12,6 DE LA DIAPOSITIVE 30

« Il s'agit d'une **fréquence**, exprimée en pourcentage, calculée **au sein de l'année 2017**.

$$f = \frac{n_{3 \text{ enfants, 2017}}}{n_{\text{ensemble, 2017}}} = \frac{1\,012,2}{8\,014,7} = 0,1263$$

soit **12,6 %**. **Lecture** : en 2017, 12,6 % des familles ayant au moins un enfant mineur avaient trois enfants mineurs. »

Le point qui distingue une copie à 18 : préciser que le dénominateur est **le total de l'année 2017**, et non le total général. Dans un empilé à 100 %, **chaque colonne a son propre dénominateur** — c'est exactement ce qui fait qu'elles atteignent toutes 100 %.

Gabarit 5 : choisir et intituler un graphique

Si la question est...	Choisis...	Intitule...
Une seule distribution, à présenter	Diagramme colonne (ou camembert si peu de modalités)	« Distribution de <i>[caractère]</i> dans <i>[population]</i> »
Suivre chaque catégorie dans le temps	Colonnes groupées par catégorie	« Évolution, pour chaque catégorie , de... »
Comparer la composition d'une période à l'autre	Colonnes groupées par année, ou empilé	« Évolution, pour chaque année , des... »
Comparer des structures entre populations de tailles différentes	Empilé à 100 %	« Répartition de... par <i>[variable de découpage]</i> »

MÉTHODE — LES QUATRE MENTIONS OBLIGATOIRES, QUELLE QUE SOIT LA FORME

Un titre précis · l'unité de mesure · la population et son champ · la source. Et, si la lecture n'est pas immédiate, **une note de lecture en bas**. Ce sont les quatre règles de la diapositive 32, et elles sont chacune notées.

Niveau 1 — Questions de cours

Section 2.1 — Réaliser une étude statistique

POINT D'EXAMEN — SIX QUESTIONS (10 MINUTES)

1. Énonce la chaîne de la diapositive 3, puis décompose l'exemple du financement des retraites en décision, information et étude.
2. Cite les six étapes d'une étude statistique dans l'ordre, et la phrase qui les commande.
3. Cite les quatre méthodes de recueil avec leur définition. Laquelle établit une causalité ? Laquelle est la plus coûteuse ?
4. Pourquoi la demande « faites-moi une enquête de satisfaction » est-elle insuffisante ?
5. Que signifie « délimiter » une population ? Applique au tableau de la diapositive 28.
6. Que doit contenir un rapport statistique, et que veut dire « ce n'est pas le rapport statistique qui décide » ?

CORRIGÉ — CORRIGÉ

1. **Besoin de décider** → **besoin d'information** → **étude statistique**. Retraites : décision = niveau des cotisations, âge de départ ; information = nombre futur de retraités rapporté au nombre futur d'actifs ; étude = projections démographiques à partir des recensements.
2. ① Quel type de problématique ? ② choix des données à observer ③ choix de la méthode de recueil des données ④ campagne de mesures ⑤ traitement des données ⑥ prise de décision. « **Tous les choix sont guidés par le type de problématique.** »
3. **Expérimentation** : un protocole permettant l'observation directe de l'impact d'une variable de contrôle sur une variable d'observation — **la seule qui établit une causalité**. **Enquête qualitative** : on observe de façon extensive un petit nombre d'individus. **Données de seconde main** : on réutilise des informations disponibles par ailleurs. **Enquête quantitative** : un travail sur-mesure par enquête, questionnaire — **la plus coûteuse**.
4. Elle est « beaucoup trop vague » : selon que le directeur veut modifier la mise en rayon, l'affichage, le choix des produits ou les horaires et le conseil, l'étude n'interroge ni les mêmes personnes ni sur les mêmes choses.
5. Répondre à **qui, où, quand** — c'est le **champ**. Diapositive 28 : les familles vivant en ménage ordinaire ayant au moins un enfant mineur (qui), France hors Mayotte (où), 1990 à 2023, années de recensement (quand).
6. Les résultats des traitements **et les éléments méthodologiques**, orientés vers la décision ; toute information inutile est bannie. Le statisticien apporte faits, incertitudes et méthodes ; le décideur ajoute objectifs, contraintes (le coût) et arbitrage : **toute décision est politique**.

Section 2.2 — Le vocabulaire de la statisticienne

POINT D'EXAMEN — CINQ QUESTIONS (8 MINUTES)

1. Donne au mot près les cinq définitions de la diapositive 11, et la convention de notation.
2. Que signifie « application » dans la définition d'une variable ? Que garantit cette exigence ?
3. Donne le type précis, avec justification : nombre de frères et sœurs · mention au baccalauréat · taille en centimètres · région de naissance.
4. Pourquoi une variable codée en chiffres peut-elle rester qualitative ? Donne le test.
5. Tableau des infractions (diapositive 12) : population, unité statistique, effectif total, caractère, type, nombre de modalités.

CORRIGÉ — CORRIGÉ

1. Population : « ensemble (mathématique) étudié » · unités statistiques : « les éléments de cette population » · taille ou effectif total : « le nombre d'individus ou d'unités statistiques » · variable ou caractère : « une application associant à chaque individu une valeur » · modalités : « les valeurs prises par une variable statistique ». Variable en **majuscule** X , valeurs en **minuscule** x_i .
2. À **chaque** individu, **une et une seule** valeur : aucun individu sans réponse, aucun avec deux modalités. Cela garantit $\sum n_i = n$.
3. Quantitative **discrète** (comptage) · qualitative **ordinaire** (ordre qui a du sens, pas des nombres) · quantitative **continue** (mesure) · qualitative **nominale** (aucun ordre qui ait du sens).
4. Parce qu'« un mot peut valoir un chiffre » dans une base de données (homme = 1). Test : **la moyenne a-t-elle un sens ?**
5. Population : les infractions déclarées en 2024 sur le champ (France métropolitaine, Martinique, Guadeloupe, La Réunion) · unité : **une infraction déclarée** · $n = 9\,376\,000$ · caractère : le type d'atteinte · **qualitatif nominal** · $p = 8$.

Section 2.3 — Présenter une variable sans perte d'information

POINT D'EXAMEN — SIX QUESTIONS (10 MINUTES)

1. Quelles sont les deux façons de présenter une variable sans perte d'information, et pourquoi « sans perte » ?
2. Quelles opérations font passer de l'une à l'autre, dans quel ordre, et pourquoi cet ordre ?
3. Définis la fréquence et la fréquence cumulée. Pourquoi la cumulée exige-t-elle un ordre ?
4. Écris les formules de n , f_i et F_k . Que valent n et p dans l'exemple des 87 étudiants ?
5. Démontre que la somme des fréquences vaut 100 %.
6. Tableau des familles : $F(1) = 70,3$ et $F(2) = 90,4$. Retrouve la fréquence des familles à deux enfants, et écris la phrase de lecture de 90,4.

CORRIGÉ — CORRIGÉ

1. La **série brute** (*raw data*) et la **distribution observée des effectifs** (*frequencies*). Sans perte : à partir du tableau on reconstitue la série en réécrivant chaque modalité autant de fois que son effectif.
2. Un **tri** des modalités, puis un **comptage** des effectifs (cas quantitatif ou qualitatif ordinal) : le tri met côte à côte les valeurs identiques, le comptage devient une lecture de blocs en un seul passage.
3. Fréquence : la proportion d'individus présentant une modalité donnée dans la population totale. Cumulée : la proportion présentant une modalité donnée **ou inférieure** — « inférieure » suppose de pouvoir comparer deux modalités : **pas d'ordre, pas de cumul**.
4. $n = \sum_{i=1}^p n_i \cdot f_i = n_i/n \cdot F_k = \sum_{i=1}^k f_i$. Ici $n = 87$ individus, $p = 11$ modalités distinctes.
5. $\sum f_i = \sum n_i/n = \frac{1}{n} \sum n_i = n/n = 1$, soit 100 %.
6. $f = F(2) - F(1) = 90,4 - 70,3 = 20,1$ %. Lecture : « **90,4 % des familles avaient deux enfants ou moins.** »

Section 2.4 — Comparer, choisir un graphique, communiquer

POINT D'EXAMEN — SIX QUESTIONS (10 MINUTES)

1. Que signifie présenter plusieurs distributions d'un même caractère ? Dans le tableau des personnes écrouées, quel est le caractère étudié, quelle est la variable de découpage ?
2. Définis : écroué · prévenu · condamné · condamné-prévenu.
3. Colonnes groupées par catégorie ou par année : quand choisir chacune, et quel titre donner ?
4. Qu'est-ce que l'empilé montre que l'empilé à 100 % ne montre pas, et inversement ?
5. Calcule le taux de variation du nombre de personnes écrouées entre 2020 et 2023. Pourquoi un écart entre deux parts se dit-il en points ?
6. Cite les quatre règles de présentation, puis distingue statistique descriptive et inférentielle.

CORRIGÉ — CORRIGÉ

1. Des sous-populations sont définies par une **autre** variable (année, zone) ; une distribution par sous-population, juxtaposées, pour **comparer**. Écroués : caractère = **la catégorie pénale** ; variable de découpage = **l'année**.
2. **Écroué** : inscrit au registre d'écrou, détenu ou non · **prévenu** : poursuivi, pas encore jugé définitivement · **condamné** : condamnation définitive · **condamné-prévenu** : condamné dans une affaire, encore prévenu dans une autre.
3. **Par catégorie** : pour suivre l'évolution des effectifs de chaque catégorie — « Évolution, pour chaque catégorie, du nombre de... ». **Par année** : pour suivre l'évolution de la structure — « Évolution, pour chaque année, des... ».
4. L'**empilé** montre la structure **et** le total (la hauteur est l'ensemble). Le **100 %** montre la structure **seule**, comparable entre années de totaux différents, mais **efface les effectifs**.
5. $t = (90\,071 - 73\,834)/73\,834 \times 100 = +22,0$ %. Une part passe de 56,3 % à 57,5 % : **+1,2 point** ; « +1,2 % » serait un taux de variation de la part, autre grandeur.
6. Intitulés précis · lisibles par un non-spécialiste · compréhension immédiate, sinon note de lecture · unités, population et choix méthodologiques. **Descriptive** : décrire la population dont on dispose ; **inférentielle** : déduire des éléments d'une population à partir d'un **échantillon aléatoire**.

Niveau 2 — Les cinq exercices que le support pose et ne corrige jamais (1 h 30 au total — /36)

Le cœur de l'entraînement. Ces cinq énoncés sont **dans les diapositives**, mot pour mot. Aucun n'a de corrigé dans le support. Ils sont corrigés ici, intégralement, au barème. **Fais-les document fermé, chronométrés, puis compare ligne à ligne.**

B1 — Diapositive 12 : les infractions déclarées en France en 2024 (15 min — /6)

POINT D'EXAMEN — DIAPOSITIVE 12 — L'ÉNONCÉ, MOT POUR MOT

« Selon l'enquête "Vécu et ressenti en matière de sécurité", la répartition des infractions a été la suivante en France en 2024. »

Atteinte déclarée	Nombre d'infractions
Actes de vandalisme contre la voiture	2 893 000
Vols ou tentatives de vol d'objet dans ou sur la voiture	1 544 000
Vols ou tentatives de vol avec effraction de la résidence principale	1 516 000
Actes de vandalisme contre le logement	1 141 000
Vols ou tentatives de vol de vélo	853 000
Vols sans effraction de la résidence principale	616 000
Vols ou tentatives de vol de voiture	549 000
Vols ou tentatives de vol de deux-roues motorisés	264 000
Ensemble	9 376 000

Champ : France métropolitaine, Martinique, Guadeloupe et La Réunion, diffusion Insee.

► Indiquez la population, les unités statistiques, l'effectif total, la ou les variables ainsi que les modalités.

CORRIGÉ — COPIE DE MAJOR — LES CINQ ÉLÉMENTS DEMANDÉS

① La population (1 pt) — l'ensemble des infractions déclarées en 2024 sur le champ de l'enquête, c'est-à-dire la France métropolitaine, la Martinique, la Guadeloupe et La Réunion. Ce n'est pas « la France », ni « les Français » : une population statistique est l'ensemble des objets sur lesquels on observe le caractère.

② Les unités statistiques (1 pt) — une infraction déclarée. Pas « une victime » : une même personne peut déclarer plusieurs atteintes, et le tableau compte des atteintes.

③ L'effectif total (1 pt) — $n = 9\,376\,000$ infractions déclarées. Vérification faite : la somme des huit effectifs vaut exactement 9 376 000.

④ La variable (1,5 pt) — une seule : le type d'atteinte déclarée, notée X . Le pluriel de l'énoncé est un piège : « nombre d'infractions » n'est pas une seconde variable, c'est la colonne des effectifs n_i . Type : qualitative nominale. Justification exigée : les modalités sont des libellés, et aucun ordre entre « vandalisme contre la voiture » et « vol de vélo » n'aurait de sens.

⑤ Les modalités (1,5 pt) — les huit libellés de lignes, donc $p = 8$: vandalisme voiture · vol d'objet dans la voiture · vol avec effraction de la résidence principale · vandalisme logement · vol de vélo · vol sans effraction de la résidence principale · vol de voiture · vol de deux-roues motorisés. « Ensemble » n'est pas une modalité : c'est la ligne de total.

PIÈGE FRÉQUENT — LES TROIS POINTS QUE 80 % DES COPIES PERDENT ICI

① Répondre « la population, c'est la France ». La population est l'ensemble des unités observées, et ici les unités sont des infractions, pas des territoires ni des personnes.

② Classer la variable en quantitative parce que la colonne contient de gros nombres. Les nombres sont les effectifs, pas les modalités. Le test : peut-on calculer la moyenne des modalités ? Moyenne de « vol de vélo » et « vandalisme » : aucun sens → qualitative.

③ Oublier le champ. « France métropolitaine, Martinique, Guadeloupe et La Réunion » — donc ni la Guyane ni Mayotte. Le champ fait partie de la définition de la population, et il est noté.

CORRIGÉ — LES POINTS VOLÉS — CE QU'AJOUTE UNE COPIE À 18

On ne demandait pas les fréquences. Les donner en deux lignes vaut un point d'initiative, et prouve la maîtrise de $f_i = n_i/n$.

Modalité	n_i	f_i (%)
Vandalisme contre la voiture	2 893 000	30,9
Vol d'objet dans ou sur la voiture	1 544 000	16,5
Vol avec effraction de la résidence principale	1 516 000	16,2
Vandalisme contre le logement	1 141 000	12,2
Vol de vélo	853 000	9,1
Vol sans effraction de la résidence principale	616 000	6,6
Vol de voiture	549 000	5,9
Vol de deux-roues motorisés	264 000	2,8
Ensemble	9 376 000	100,0

Et la remarque qui fait la différence : $30,9 + 16,5 + \dots + 2,8 = 100,2$. Sept des huit fréquences s'arrondissent vers le haut, la somme des valeurs arrondies dépasse donc 100. Les valeurs exactes, elles, somment bien à 100,000 %. En examen : on écrit « somme à 100,2 % par cumul d'arrondis » — on ne truque aucun chiffre pour retomber sur 100.

Deux observations de plus, gratuites :

- **Pas de fréquence cumulée possible ici.** Le support le dit à la diapositive 21 : la fréquence cumulée n'existe que « pour un caractère quantitatif ». Ce caractère est qualitatif nominal — cumuler des libellés non ordonnés n'a aucun sens.
- **Le tableau est trié par effectif décroissant.** C'est un **choix de présentation**, pas une propriété des données : il applique la règle « compréhension immédiate » de la diapositive 32. Pour un caractère nominal, le tri par effectif décroissant est la convention.

B2 — Diapositive 22 : les familles selon le nombre d'enfants (20 min — /8)

POINT D'EXAMEN — DIAPOSITIVE 22 — L'ÉNONCÉ, MOT POUR MOT

« Enquête menée auprès de 17 132 familles. On a demandé à chaque famille le nombre d'enfants pour une année donnée. »

Modalités x_i	Effectifs n_i en milliers	Fréquences f_i en %	Fréquences cumulées $F(x_i)$ en %
0 enfant	8 225	48,0	48,0
1 enfant	3 821	22,3	70,3
2 enfants	3 449	20,1	90,4
3 enfants	1 241	7,2	97,7
4 enfants et plus	396	2,3	100,0
Ensemble	17 132	100,0	

► Indiquez la population, le caractère statistique, les unités statistiques. Comment ont été calculés ces chiffres ?

CORRIGÉ — COPIE DE MAJOR, PREMIÈRE PARTIE : IDENTIFIER (4 PTS)

① **La population** — l'ensemble des familles interrogées pour l'année considérée, soit 17 132 milliers de familles, c'est-à-dire environ 17,1 millions. L'énoncé écrit « 17 132 familles », mais la colonne est intitulée « effectifs en milliers ». Signaler l'incohérence et retenir la bonne lecture vaut un point. → § 3.1, A2.

② **Les unités statistiques** — une famille. L'enquête interroge « chaque famille », pas chaque enfant ni chaque individu.

③ **Le caractère statistique** — le nombre d'enfants, noté X . **Type : quantitatif discret** — il relève du **comptage**, et entre 2 et 3 enfants il n'existe aucune valeur possible. **Nuance qui rapporte** : la dernière modalité, « 4 enfants et plus », est une **classe ouverte** : on a **regroupé** toutes les valeurs ≥ 4 . La variable reste discrète, mais sa présentation est **partiellement regroupée** — et ce regroupement **interdit tout calcul de moyenne** sans hypothèse supplémentaire sur cette classe.

④ **Les effectifs** — $n = 17\,132$ milliers ; $p = 5$ modalités.

CORRIGÉ — COPIE DE MAJOR, DEUXIÈME PARTIE : « COMMENT ONT ÉTÉ CALCULÉS CES CHIFFRES ? » (4 PTS)

Il y a trois colonnes, donc trois réponses. Les donner toutes les trois.

Colonne 1 — les effectifs n_i . Ils ne sont pas *calculés* : ils sont **comptés**. Pour chaque modalité, on dénombre les familles qui la déclarent. C'est l'étape « comptage » du passage série brute → distribution. **Contrôle :**

$$\sum n_i = 8\,225 + 3\,821 + 3\,449 + 1\,241 + 396 = 17\,132 \checkmark$$

Colonne 2 — les fréquences f_i . Formule :

$$f_i = \frac{n_i}{n} \times 100$$

	Application numérique	Résultat exact	Arrondi
0 enfant	8 225 / 17 132	48,0096 %	48,0
1 enfant	3 821 / 17 132	22,3033 %	22,3
2 enfants	3 449 / 17 132	20,1319 %	20,1
3 enfants	1 241 / 17 132	7,2438 %	7,2
4 enfants et plus	396 / 17 132	2,3115 %	2,3

Les cinq valeurs du support sont exactes. (Je les ai toutes recalculées.)

Colonne 3 — les fréquences cumulées $F(x_k)$. Formule :

$$F(x_k) = \sum_{i=1}^k f_i$$

$$F(0) = 48,0 \cdot F(1) = 48,0 + 22,3 = 70,3 \cdot F(2) = 70,3 + 20,1 = 90,4 \cdot F(3) = 90,4 + 7,2 = 97,7 \cdot F(4^+) = 97,7 + 2,3 = 100,0 \checkmark$$

Les trois contrôles de fin : $\sum n_i = n \checkmark \cdot \sum f_i = 100,0 \checkmark \cdot F(\text{dernière}) = 100,0 \checkmark$

CORRIGÉ — LES POINTS VOLÉS — CE QU'AJOUTE UNE COPIE À 18

① **Justifier que la colonne cumulée a le droit d'exister.** La diapositive 21 réserve la fréquence cumulée aux **caractères quantitatifs**. Ici le caractère est quantitatif discret, donc ordonné : « **2 enfants ou moins** » a un sens, et le cumul est légitime. Dans le tableau des infractions (B1), il serait absurde.

② **Donner une phrase de lecture par colonne, sans qu'on la demande :**

- **Effectif** : « 3 449 milliers de familles, soit près de 3,4 millions, avaient deux enfants. »
- **Fréquence** : « 20,1 % des familles avaient deux enfants. »
- **Cumulée** : « 90,4 % des familles avaient **deux enfants ou moins**. »

③ **Signaler les deux imprécisions du support**, en une ligne chacune : « 17 132 familles » au lieu de « 17 132 milliers » ; « une année donnée » jamais précisée — **c'est 2008**, la diapositive 31 reproduisant exactement ces cinq fréquences dans sa colonne 2008. → § 3.1, A2 et A3.

④ **Le contraste qui prouve qu'on a compris le champ.** Ce tableau **inclut les familles sans enfant** (48 % du total !). Celui de la diapositive 28 ne porte que sur les familles **ayant au moins un enfant mineur** — d'où l'absence de ligne « 0 enfant ». **Deux tableaux sur le même sujet, deux populations différentes : leurs chiffres ne sont pas comparables.**

B3 — Diapositive 25 : les personnes écrouées, 2020-2023 (20 min — /8)

POINT D'EXAMEN — DIAPOSITIVE 25 — L'ÉNONCÉ, MOT POUR MOT

« Distribution des personnes écrouées en France, par année. »

Catégorie	2020	2021	2022	2023
Prévenus détenus	17 692	18 486	18 779	19 755
Condamnés-prévenus détenus	2 405	2 613	2 908	3 117
Condamnés détenus	41 553	47 246	49 338	51 746
Condamnés non détenus	12 184	13 644	14 286	15 453
Total des personnes écrouées	73 834	81 989	85 311	90 071

Source : ministère de la Justice.

► Identifier la population, les sous-populations, le caractère statistique étudié, son type ? ► Le choix du diagramme colonne groupé dépend de la comparaison [qui] est au centre de l'analyse...

MÉTHODE — AVANT DE RÉDIGER — LE VOCABULAIRE PÉNAL

Les quatre catégories — **écroué, prévenu, condamné, condamné-prévenu** — sont définies au § 2.4.1. Elles sont indispensables pour **justifier** le type du caractère : si tu hésites sur l'une d'elles, relis-les **avant** de commencer, puis ferme le cours.

CORRIGÉ — COPIE DE MAJOR — POPULATION, SOUS-POPULATIONS, CARACTÈRE, TYPE

① La population (1 pt) — l'ensemble des personnes écrouées en France, telles que recensées par le **ministère de la Justice**.

Attention : écrouées, donc y compris non détenues — 12 184 personnes en 2020, soit 16,5 % du total, ne sont pas enfermées.

② Les sous-populations (2 pts) — quatre sous-populations, définies par l'année : les personnes écrouées en 2020, en 2021, en 2022, en 2023. La variable de découpage est donc l'année, et il y a une distribution par année. Leurs effectifs totaux : 73 834 · 81 989 · 85 311 · 90 071. (Les quatre totaux du support ont été vérifiés : ils sont exacts.)

③ Le caractère statistique étudié (2 pts) — la catégorie pénale de la personne écrouée. Quatre modalités, donc $p = 4$: prévenu détenu · condamné-prévenu détenu · condamné détenu · condamné non détenu.

④ Le type (2 pts) — **qualitatif nominal**. Justification : les modalités sont des **statuts**, pas des nombres, et **aucun ordre unique n'a de sens** — parce qu'elles croisent deux critères indépendants (statut judiciaire × détention). On ne peut pas dire qu'un « condamné non détenu » est « avant » ou « après » un « prévenu détenu ».

⑤ Le choix du graphique (1 pt) — il dépend de la question posée :

- Comment évolue chaque catégorie ? → **colonnes groupées par catégorie** (d. 26), intitulé « Évolution, pour chaque catégorie, du nombre de personnes écrouées en France ».
- Comment évolue la structure ? → **colonnes groupées par année** (d. 27), intitulé « Évolution, pour chaque année, des catégories de personnes écrouées en France ».

PIÈGE FRÉQUENT — LE PIÈGE CENTRAL DE CET EXERCICE — ET IL VAUT 2 POINTS

Inverser les deux rôles. Il est tentant de répondre « les sous-populations sont les quatre catégories pénales ». **C'est faux, et voici le critère qui tranche :**

Le caractère étudié est celui dont on calcule la distribution ; la variable de découpage est celle qui définit les colonnes qu'on compare.

Ici chaque **colonne-année** contient une distribution complète qui somme à son propre total. **L'année découpe, la catégorie est distribuée.** Si les catégories étaient les sous-populations, chacune devrait porter une distribution sommant à 100 % — ce n'est pas le cas.

Le test en deux secondes : où est la ligne "Total" ? Elle est **au bas de chaque année**. Le total est du côté de la sous-population.

CORRIGÉ — LES POINTS VOLÉS — CE QU'AJOUTE UNE COPIE À 18

① Chiffrer l'évolution, puisque le tableau est là pour comparer.

Catégorie	2020	2023	Évolution
Prévenus détenus	17 692	19 755	+ 11,7 %
Condamnés-prévenus détenus	2 405	3 117	+ 29,6 %
Condamnés détenus	41 553	51 746	+ 24,5 %
Condamnés non détenus	12 184	15 453	+ 26,8 %
Total	73 834	90 071	+ 22,0 %

② Chiffrer la structure, ce que le tableau ne montre pas (c'est exactement ce que ferait un empilé à 100 %) :

Catégorie	2020 (%)	2023 (%)
Prévenus détenus	24,0	21,9
Condamnés-prévenus détenus	3,3	3,5
Condamnés détenus	56,3	57,5
Condamnés non détenus	16,5	17,2

Chaque colonne somme à 100,1 % : cumul d'arrondis au dixième, pas une erreur.

③ La phrase de conclusion qui vaut le point d'analyse : « Les effectifs augmentent dans les quatre catégories — de + 11,7 % à + 29,6 % — mais la structure ne bouge presque pas : les condamnés détenus restent un peu plus de 56 % des écroués. Le phénomène est une hausse de volume, pas une déformation de composition. » **C'est la distinction d. 26 / d. 27 appliquée aux chiffres.**

B4 — Diapositive 28 : le nombre d'enfants par famille, 1990-2023 (20 min — /8)

POINT D'EXAMEN — DIAPOSITIVE 28 — L'ÉNONCÉ, MOT POUR MOT

« Distribution du nombre d'enfants par famille (en milliers), par année. »

Nombre d'enfants mineurs	1990	1999	2007	2012	2017	2023
1 enfant	3 353,7	3 418,3	3 565,0	3 614,8	3 590,7	3 578,3
2 enfants	2 800,5	2 841,1	2 996,3	3 074,1	3 101,1	3 039,0
3 enfants	1 087,1	1 033,5	1 015,2	1 022,3	1 012,2	956,2
4 enfants ou plus	410,9	334,5	296,9	296,1	310,7	308,4
Ensemble	7 652,2	7 627,5	7 873,5	8 007,3	8 014,7	7 881,9

Champ : France hors Mayotte, familles vivant en ménage ordinaire ayant au moins un enfant mineur. Unité : milliers de familles.
Source : Insee, recensements de la population.

► Identifier la population, les sous-populations, le caractère statistique étudié, son type ► Donner un exemple de lecture de ce tableau

MÉTHODE — AVANT DE RÉDIGER — LES DEUX TERMES DU CHAMP

« Ménage ordinaire » et « enfant mineur » sont définis au § 2.4.3. Ils expliquent pourquoi ce tableau n'a pas de ligne « 0 enfant ».

CORRIGÉ — COPIE DE MAJOR — LES CINQ QUESTIONS, AU BARÈME

① La population (2 pts) — l'ensemble des familles vivant en ménage ordinaire, en France hors Mayotte, et ayant au moins un enfant mineur. Les trois restrictions du champ doivent être citées : elles font partie de la définition, et c'est le point que la majorité des copies oublie.

② Les unités statistiques (1 pt) — une famille. Unité de compte du tableau : le millier de familles — les chiffres sont donc à multiplier par 1 000.

③ Les sous-populations (1,5 pt) — six, définies par l'année : 1990, 1999, 2007, 2012, 2017, 2023. Ce sont les années de recensement. La variable de découpage est l'année. Chaque colonne porte sa propre distribution, avec son propre total, et ces totaux varient : de 7 627,5 milliers en 1999 à 8 014,7 en 2017.

④ Le caractère étudié (1,5 pt) — le nombre d'enfants mineurs de la famille. Type : quantitatif discret — comptage, aucune valeur entre 2 et 3. Nuance : la dernière modalité « 4 enfants ou plus » est une classe ouverte, donc la présentation est partiellement regroupée. p = 4 modalités.

⑤ L'exemple de lecture (2 pts) — cinq éléments obligatoires : quand · combien · de quoi · dans quelle population · quelle modalité.

« En 2017, 1 012,2 milliers de familles — soit un peu plus d'un million — vivant en ménage ordinaire en France hors Mayotte et ayant au moins un enfant mineur, avaient exactement trois enfants mineurs. »

PIÈGE FRÉQUENT — LES QUATRE FAUTES DE LECTURE DE CE TABLEAU

- ① **Écrire « 1 012,2 familles ».** L'unité est le **millier** : c'est **1 012 200 familles**. **Erreur d'un facteur mille, et la faute la plus fréquente du chapitre.**
- ② **Oublier « au moins un enfant mineur ».** Sans cette mention, la phrase prétend décrire **toutes** les familles de France — c'est faux, et le correcteur le sanctionne parce que c'est la règle « indiquer la population » de la diapositive 32.
- ③ **Dire « trois enfants ou plus ».** La ligne est **exactement trois**. Seule la dernière ligne, « 4 enfants ou plus », est cumulative — et **c'est une classe ouverte, pas une fréquence cumulée**.
- ④ **Comparer une colonne à une autre en oubliant que les totaux diffèrent.** 1 087,1 en 1990 contre 1 012,2 en 2017 pour trois enfants : la baisse en **effectif** est de 6,9 %, mais la baisse en **part** est plus forte encore, puisque l'ensemble a **augmenté** sur la période. → **c'est exactement pourquoi la diapositive 30 passe en empilé à 100 %.**

CORRIGÉ — LES POINTS VOLÉS — CE QU'AJOUTE UNE COPIE À 18

- ① **Nommer la différence avec le tableau de la diapositive 22, en une phrase.** « *Les deux tableaux portent sur le nombre d'enfants par famille, mais pas sur la même population : la diapositive 22 inclut les familles sans enfant — 48 % de l'ensemble — alors que celui-ci ne retient que les familles ayant au moins un enfant mineur. Leurs chiffres ne sont pas comparables.* »
- ② **Donner une lecture par nature de chiffre, pas une seule :**
 - **Effectif de colonne :** « En 2023, 7 881,9 milliers de familles avaient au moins un enfant mineur. »
 - **Comparaison dans le temps :** « Entre 1990 et 2023, le nombre de familles à 4 enfants ou plus est passé de 410,9 à 308,4 milliers, soit une baisse d'un quart. »
- ③ **Annoncer le graphique adapté, sans qu'on le demande :** « *Pour suivre chaque catégorie, colonnes groupées par nombre d'enfants ; pour comparer les structures malgré des totaux différents, empilé à 100 % — c'est le choix de la diapositive 30.* »

B5 — Diapositive 30 : l'empilé à 100 % (15 min — /6)

POINT D'EXAMEN — DIAPOSITIVE 30 — L'ÉNONCÉ, MOT POUR MOT

« Dans une optique comparative des structures des familles dans le temps, on peut procéder à un empilement à 100 %, ce qui revient à prendre les fréquences et non les effectifs, par année. » — Graphique : « Répartition du nombre d'enfants par famille, par année ».

► Écrire une phrase de lecture ► Comment a été calculé le chiffre 12,6 ?

CORRIGÉ — COPIE DE MAJOR — LA PHRASE DE LECTURE ET LE CALCUL DU 12,6

① La phrase de lecture (2 pts) — cinq éléments :

« En 2017, 12,6 % des familles vivant en ménage ordinaire en France hors Mayotte et ayant au moins un enfant mineur avaient exactement trois enfants mineurs. »

② « Comment a été calculé le chiffre 12,6 ? » (4 pts) — les quatre lignes du gabarit 4 :

a. La nature — c'est une **fréquence**, exprimée en pourcentage, calculée à l'intérieur de la seule année 2017.

b. La formule en lettres —

$$f_i = \frac{n_i}{n} \times 100$$

c. L'application numérique — avec les deux chiffres tirés du tableau de la diapositive 28 :

$$f_{3 \text{ enfants}, 2017} = \frac{1\,012,2}{8\,014,7} \times 100 = 12,63 \%$$

d. Le résultat et sa lecture — **12,6 %** après arrondi au dixième : en 2017, 12,6 % des familles du champ avaient trois enfants mineurs.

Le point décisif, celui qui sépare 4/4 de 2/4 : le dénominateur est le **total de l'année 2017 seule** — 8 014,7 milliers — **et non le total général des six années**. C'est **précisément** la raison pour laquelle **toutes les colonnes de l'empilé atteignent 100 %** : chaque année a son propre dénominateur.

CORRIGÉ — LE TABLEAU COMPLET DES VINGT-QUATRE FRÉQUENCES — ET SA LECTURE

Je les ai toutes recalculées à partir de la diapositive 28 : elles sont exactes.

En %	1990	1999	2007	2012	2017	2023
1 enfant	43,8	44,8	45,3	45,1	44,8	45,4
2 enfants	36,6	37,2	38,1	38,4	38,7	38,6
3 enfants	14,2	13,5	12,9	12,8	12,6	12,1
4 enfants ou plus	5,4	4,4	3,8	3,7	3,9	3,9
Ensemble	100,0	99,9	100,1	100,0	100,0	100,0

Les « 99,9 » et « 100,1 » sont des cumuls d'arrondis au dixième, pas des erreurs.

La lecture d'ensemble, en trois phrases — c'est ce que l'empilé à 100 % sert à voir :

1. Les familles à un enfant restent la modalité majoritaire, autour de **45 %**, très stable sur trente-trois ans.
2. Les familles à deux enfants progressent de 36,6 % à 38,6 %.
3. Les familles nombreuses reculent : trois enfants, de **14,2 % à 12,1 %** ; quatre enfants ou plus, de **5,4 % à 3,9 %**. La déformation de structure se fait au détriment des grandes familles.

PIÈGE FRÉQUENT — CE QUE L'EMPLÉ À 100 % TE FAIT PERDRE — ET LA PHRASE QUI RÉCUPÈRE LE POINT

Un empilé à 100 % efface complètement les effectifs. Toutes les colonnes ont la même hauteur : **on ne voit plus que l'ensemble est passé de 7 652,2 à 7 881,9 milliers de familles.**

La phrase qui montre qu'on l'a compris : « *La part des familles à trois enfants passe de 14,2 % à 12,1 %, mais ce graphique ne dit pas si leur nombre a baissé : il faut revenir aux effectifs de la diapositive 28, qui montrent une baisse de 1 087,1 à 956,2 milliers.* »

Et la comparaison de graphiques, en une ligne : empilé simple (d. 29) = structure + total · empilé à 100 % (d. 30) = structure seule, mais comparable entre années.

Niveau 3 — Les exercices de construction (20 à 30 minutes chacun)

Niveau 2 = les questions du support. Niveau 3 = les gestes que le support ne fait jamais faire, mais qu'il faudra savoir exécuter. Toutes les données de cette série sont construites pour l'entraînement : elles ne proviennent pas du cours.

C1 — De la série brute à la distribution complète (/8)

POINT D'EXAMEN — C1 — ÉNONCÉ : 25 SALARIÉS, JOURS DE TÉLÉTRAVAIL

On relève, auprès des 25 salariés d'une PME, le nombre de jours de télétravail par semaine :

2 0 3 1 2 5 2 1 0 4 3 2 2 1 0 2 3 1 2 4 1 2 0 3 2

- Identifiez la population, l'unité statistique, l'effectif total, le caractère et son type.
- Ordonnez la série.
- Construisez le tableau de la distribution : effectifs, fréquences, fréquences cumulées.
- Donnez une phrase de lecture pour chacune des trois colonnes.
- Choisissez et intitulez le graphique adapté.

CORRIGÉ — C1 — CORRIGÉ : LES CINQ QUESTIONS, AU BARÈME

1. Identification (2 pts) — Population : l'ensemble des salariés de cette PME. **Unité statistique :** un salarié. **Effectif total :** $n = 25$. **Caractère :** le nombre de jours de télétravail hebdomadaire. **Type :** quantitatif discret — comptage, aucune valeur entre 2 et 3 jours.

2. La série ordonnée (1 pt) — on trie par ordre croissant :

0 0 0 0 1 1 1 1 1 2 2 2 2 2 2 2 2 2 3 3 3 3 4 4 5

Le tri rassemble les valeurs identiques : le comptage devient une lecture de longueurs de blocs.

3. Le tableau (3 pts) — $p = 6$ modalités.

x_i	n_i	f_i (%)	$F(x_i)$ (%)
0	4	16,0	16,0
1	5	20,0	36,0
2	9	36,0	72,0
3	4	16,0	88,0
4	2	8,0	96,0
5	1	4,0	100,0
Ensemble	25	100,0	

Détail des calculs : $f_1 = 4/25 = 0,16$ soit 16,0 % · $f_3 = 9/25 = 0,36$ soit 36,0 % · $F(x_3) = 16,0 + 20,0 + 36,0 = 72,0$ %. Les trois contrôles : $\sum n_i = 25$ ✓ · $\sum f_i = 100,0$ ✓ · $F(5) = 100,0$ ✓

4. Les trois phrases de lecture (1,5 pt)

- Effectif : « 9 des 25 salariés de cette PME télétravaillent 2 jours par semaine. »
- Fréquence : « 36,0 % des salariés télétravaillent 2 jours par semaine. »
- Cumulée : « 72,0 % des salariés télétravaillent 2 jours ou moins par semaine. »

5. Le graphique (0,5 pt) — un diagramme en colonnes, une colonne par modalité, hauteur = effectif (ou fréquence). Intitulé : « Distribution du nombre de jours de télétravail hebdomadaire parmi les 25 salariés de l'entreprise », avec l'unité (nombre de salariés) et la source (relevé interne). Le camembert est acceptable pour les fréquences — six modalités, c'est la limite haute.

C2 — Classer dix variables (/10, un point par ligne)

POINT D'EXAMEN — C2 — ÉNONCÉ : DIX VARIABLES À CLASSER

Donnez le type **précis** — qualitative nominale, qualitative ordinale, quantitative discrète, quantitative continue — et **justifiez en une ligne** :

a. le code postal · b. la mention au baccalauréat · c. la taille en centimètres · d. le nombre d'enfants · e. le chiffre d'affaires annuel en euros · f. le sexe codé « 1 = homme, 2 = femme » · g. le nombre d'abonnés d'un compte · h. la durée d'un appel en minutes · i. le numéro de département · j. la catégorie pénale d'une personne écrouée

CORRIGÉ — C2 — CORRIGÉ : LES DIX TYPES, AVEC LA JUSTIFICATION QUI VAUT LE POINT

	Variable	Type	La justification qui vaut le point
a	Code postal	Qualitative nominale	C'est un code , pas une quantité. Une moyenne de codes postaux n'a aucun sens.
b	Mention au bac	Qualitative ordinale	Passable < AB < B < TB : l'ordre a un sens , mais les modalités ne sont pas des nombres et les écarts ne se mesurent pas.
c	Taille en cm	Quantitative continue	Elle se mesure ; entre 179 et 180 cm il existe 179,4 cm. L'arrondi au centimètre est un affichage, pas la nature de la variable.
d	Nombre d'enfants	Quantitative discrète	Elle se compte ; rien entre 2 et 3.
e	Chiffre d'affaires en €	Quantitative continue	Grandeur monétaire mesurée sur un ensemble non dénombrable de valeurs. <i>(Le centime est une unité d'affichage.)</i>
f	Sexe codé 1/2	Qualitative nominale	Exactement le cas du support : « <i>un mot valant un chiffre</i> ». La moyenne « 1,5 » ne désigne personne.
g	Nombre d'abonnés	Quantitative discrète	Comptage d'individus, valeurs entières.
h	Durée d'un appel	Quantitative continue	Le temps se mesure : entre 2 et 3 minutes, il y a 2,4 minutes.
i	Numéro de département	Qualitative nominale	Un identifiant. <i>Et « 2A » et « 2B » ne sont même pas des nombres.</i>
j	Catégorie pénale	Qualitative nominale	Des statuts, et aucun ordre unique : les modalités croisent statut judiciaire et détention.

La règle qui règle les dix cas :

Un nombre n'est une quantité que si sa moyenne a un sens. Et si la grandeur se mesure, elle est continue ; si elle se compte, elle est discrète.

C3 — « Comment a été calculé ce chiffre ? » × 4 (/8)

POINT D'EXAMEN — C3 — ÉNONCÉ : QUATRE CHIFFRES À EXPLIQUER

Pour chacun des quatre chiffres, appliquez le gabarit 4 en **quatre lignes** : nature, formule en lettres, application numérique, résultat et lecture.

a. Le **90,4** de la diapositive 22. · b. Le **48,0** de la diapositive 22. · c. Le **+ 22,0 %** d'évolution des personnes écrouées entre 2020 et 2023. · d. Le **57,5 %** de condamnés détenus parmi les écroués de 2023.

CORRIGÉ — C3 — CORRIGÉ : LE GABARIT 4 APPLIQUÉ QUATRE FOIS

a. Le 90,4 — c'est une **fréquence cumulée**.

$$F(x_3) = \sum_{i=1}^3 f_i = 48,0 + 22,3 + 20,1 = 90,4 \%$$

Lecture : 90,4 % des familles avaient deux enfants ou moins. Le « ou moins » est obligatoire.

b. Le 48,0 — c'est une **fréquence**.

$$f_1 = \frac{n_1}{n} \times 100 = \frac{8\,225}{17\,132} \times 100 = 48,01 \%$$

Lecture : 48,0 % des familles n'avaient aucun enfant.

c. Le + 22,0 % — c'est un **taux de variation**, pas une fréquence. La formule n'est pas dans le support ; elle est au § 2.4.1, et indispensable dès qu'on commente un tableau par année :

$$t = \frac{V_{\text{arrivée}} - V_{\text{départ}}}{V_{\text{départ}}} \times 100 = \frac{90\,071 - 73\,834}{73\,834} \times 100 = + 21,99 \%$$

Lecture : le nombre de personnes écrouées a augmenté de 22,0 % entre 2020 et 2023. Le dénominateur est l'année de départ — c'est l'erreur classique.

d. Le 57,5 % — c'est une **fréquence à l'intérieur d'une sous-population**.

$$f = \frac{51\,746}{90\,071} \times 100 = 57,45 \%$$

Lecture : en 2023, 57,5 % des personnes écrouées étaient des condamnés détenus. Le dénominateur est le total de 2023, pas le total des quatre années.

C4 — Choisir et intituler le graphique × 6 (/6)

POINT D'EXAMEN — C4 — ÉNONCÉ : SIX SITUATIONS

Pour chaque situation : quel graphique, et quel intitulé exact ?

a. Présenter la répartition des 87 étudiants selon leur nombre de frères et sœurs. · b. Montrer si chaque catégorie de personnes écrouées augmente ou diminue de 2020 à 2023. · c. Montrer si la composition de la population écrouée se déforme d'une année à l'autre. · d. Comparer la structure des familles en 1990 et en 2023, alors que les totaux diffèrent. · e. Montrer à la fois la structure et le nombre total d'enfants chaque année. · f. Présenter la répartition des 9 376 000 infractions de 2024.

CORRIGÉ — C4 — CORRIGÉ : LE GRAPHIQUE ET SON INTITULÉ, POUR LES SIX

	Le graphique	L'intitulé
a	Diagramme en colonnes, une colonne par modalité (11 modalités : trop pour un camembert)	« Distribution du nombre de frères et sœurs parmi les 87 étudiants de la promotion »
b	Colonnes groupées par catégorie (d. 26)	« Évolution, pour chaque catégorie, du nombre de personnes écrouées en France, 2020-2023 »
c	Colonnes groupées par année (d. 27)	« Évolution, pour chaque année, des catégories de personnes écrouées en France »
d	Empilé à 100 % (d. 30) — c'est le seul qui neutralise la différence de totaux	« Répartition du nombre d'enfants par famille, par année »
e	Empilé simple (d. 29) — la hauteur de l'empilement porte le total	« Évolution du nombre d'enfants par type de famille, par année »
f	Colonnes triées par effectif décroissant ; camembert acceptable mais 8 parts, dont trois sous 7 % : la lecture devient difficile	« Répartition des infractions déclarées en France en 2024, par type d'atteinte » (+ champ et source)

Les quatre mentions obligatoires dans les six cas : titre précis · unité · population et champ · source. Et une note de lecture en bas si la compréhension n'est pas immédiate.

C5 — Corriger cinq phrases de lecture fausses (/10)

POINT D'EXAMEN — C5 — ÉNONCÉ : CINQ PHRASES À CORRIGER

Chacune de ces phrases contient **au moins une erreur**. Trouvez-la, et réécrivez la phrase.

a. « 90,4 % des familles ont deux enfants. » b. « En 2023, 3 578,3 familles avaient un enfant mineur. » c. « En 2017, 12,6 % de toutes les familles françaises avaient trois enfants. » d. « Il y a 9 376 000 infractions : la moyenne des infractions vaut donc 1 172 000. » e. « En 2023, il y avait 90 071 détenus en France. »

CORRIGÉ — C5 — CORRIGÉ : L'ERREUR, PUIS LA PHRASE JUSTE

a. Erreur : fréquence cumulée lue comme une fréquence. ✓ « 90,4 % des familles avaient deux enfants ou moins. » (La fréquence simple des familles à deux enfants est 20,1 %.)

b. Erreur : l'unité est le millier — facteur 1 000 — et la modalité est mal dite. ✓ « En 2023, 3 578,3 milliers de familles, soit près de 3,6 millions, avaient exactement un enfant mineur. »

c. Erreur : le champ. Le dénominateur n'est pas « toutes les familles françaises », mais les familles vivant en ménage ordinaire, en France hors Mayotte, ayant au moins un enfant mineur — et il s'agit d'enfants mineurs. ✓ « En 2017, 12,6 % des familles vivant en ménage ordinaire en France hors Mayotte et ayant au moins un enfant mineur avaient trois enfants mineurs. »

d. Erreur : on calcule une moyenne sur une variable qualitative nominale. 9 376 000 est un effectif total, et « type d'atteinte » ne se moyenne pas. Le chiffre 1 172 000 est seulement $9\,376\,000/8$: l'effectif moyen par modalité, une grandeur sans intérêt ici. ✓ « La modalité la plus fréquente est le vandalisme contre la voiture, avec 2 893 000 infractions, soit 30,9 % de l'ensemble. »

e. Erreur : « écroué » confondu avec « détenu ». En 2023, sur 90 071 écroués, 15 453 n'étaient pas détenus. ✓ « En 2023, 90 071 personnes étaient écrouées en France, dont 74 618 détenues. » ($19\,755 + 3\,117 + 51\,746 = 74\,618$.)

C6 — La preuve du « sans perte d'information » (/6)

POINT D'EXAMEN — C6 — ÉNONCÉ : RECONSTITUER LA SÉRIE À PARTIR DU TABLEAU

On ne vous donne que le tableau de C1 :

x_i	0	1	2	3	4	5
n_i	4	5	9	4	2	1

- Reconstituez la série ordonnée des 25 observations.
- Peut-on reconstituer la série brute, c'est-à-dire l'ordre initial de collecte ?
- Que prouve cet exercice sur le titre du chapitre ?

CORRIGÉ — C6 — CORRIGÉ : LA DÉMONSTRATION DU « SANS PERTE D'INFORMATION »

1. On réécrit chaque modalité autant de fois que son effectif :

0 0 0 0 1 1 1 1 1 2 2 2 2 2 2 2 2 2 3 3 3 3 4 4 5

25 valeurs ✓ — identiques à la série ordonnée de C1.

2. Non — et c'est la nuance qui rapporte. On retrouve l'ensemble des valeurs observées, pas l'ordre dans lequel elles ont été collectées. Or cet ordre n'est pas de l'information statistique : il dépend de l'ordre de passage des salariés, pas du caractère étudié. L'information sur le caractère, elle, est intégralement conservée.

3. C'est exactement ce que signifie « présenter sans perte d'information », le sous-titre de la diapositive 15 : la distribution des effectifs et la série brute portent la même information, seule la forme change. Et c'est ce qui oppose le chapitre 1 au chapitre 2 : une moyenne de 1,92 jour de télétravail ne permet pas de reconstituer les 25 réponses. Résumer, c'est perdre. (Vérification : $(4 \times 0 + 5 \times 1 + 9 \times 2 + 4 \times 3 + 2 \times 4 + 1 \times 5)/25 = 48/25 = 1,92$.)

Niveau 4 — Sujet au format supposé de l'examen (1 h 00, noté sur 20)

PIÈGE FRÉQUENT — LE FORMAT SIMULÉ EST UNE HYPOTHÈSE, PAS UNE INFORMATION DU SUPPORT

Les 33 diapositives ne donnent **ni la durée, ni la nature, ni le barème** de l'épreuve. **Durée et barème retenus ici : 1 h 00, sur 20 points, sans document** — calibrés sur les quatre gestes que le support fait répéter : **restituer, identifier, construire, lire**. Dès que tu me donnes le format réel, je recalibre cette simulation en une passe.

Le sujet

Techniques statistiques — Chapitre 1 — Durée : 1 h 00 — Aucun document autorisé.

POINT D'EXAMEN — EXERCICE 1 — QUESTIONS DE COURS (6 POINTS)

- 1. Énoncez la chaîne en trois maillons qui justifie toute étude statistique. (0,5 pt)
- 2. Citez les six étapes d'une étude statistique, dans l'ordre. (1,5 pt)
- 3. Définissez : population · unité statistique · caractère statistique · modalité. (2 pts)
- 4. Donnez les deux types de variables et leurs quatre sous-types, avec un exemple par sous-type. (1,5 pt)
- 5. Quelle différence faites-vous entre statistique descriptive et statistique inférentielle ? (0,5 pt)

POINT D'EXAMEN — EXERCICE 2 — IDENTIFICATION (5 POINTS)

Une enquête est menée auprès des **1 200 étudiants** d'un portail universitaire. On leur demande leur appréciation du dispositif de tutorat.

Appréciation	Effectifs
Très insatisfait	96
Plutôt insatisfait	204
Plutôt satisfait	588
Très satisfait	312
Ensemble	1 200

Champ : étudiants inscrits au portail au 1er octobre. Source : enquête interne.

- 1. Population, unités statistiques, effectif total, caractère, modalités, type — **avec justification du type**. (3 pts)
- 2. Complétez le tableau par les fréquences et les fréquences cumulées. (1,5 pt)
- 3. Une fréquence cumulée a-t-elle un sens ici ? Justifiez. (0,5 pt)

POINT D'EXAMEN — EXERCICE 3 — CONSTRUCTION (6 POINTS)

On relève, pour **20 clients**, le **nombre d'achats en ligne effectués dans le mois** :

1 3 0 2 1 4 1 2 3 1 0 2 1 6 2 3 1 2 0 2

- 1. Identifiez la population, l'unité, l'effectif total, le caractère, son type. (1,5 pt)
- 2. Ordonnez la série, puis construisez le tableau complet : x_i , n_i , f_i , $F(x_i)$. (3 pts)
- 3. Donnez une phrase de lecture d'une fréquence cumulée. (0,5 pt)
- 4. Choisissez et **intitulez** le graphique adapté. (1 pt)

POINT D'EXAMEN — EXERCICE 4 — LECTURE ET CALCUL (3 POINTS)

Nombre d'achats	2023	2024
Aucun	3	2
1 à 3 achats	13	12
4 achats ou plus	4	6
Ensemble	20	20

1. Identifiez le caractère étudié et la variable de découpage en sous-populations. (1 pt)
2. Écrivez une phrase de lecture du chiffre 6. (1 pt)
3. En 2024, quelle est la fréquence des clients à 4 achats ou plus ? Détaillez le calcul et commentez l'évolution depuis 2023. (1 pt)

Le corrigé, au barème

CORRIGÉ — EXERCICE 1 — QUESTIONS DE COURS (6 POINTS)

1. (0,5) **Besoin de décider** → **besoin d'information** → **étude statistique**. Une étude statistique n'existe jamais pour elle-même : elle sert une décision.

2. (1,5 — 0,25 par étape) ① Quel type de problématique ? · ② choix des données à observer · ③ choix de la méthode de recueil des données · ④ campagne de mesures · ⑤ traitement des données · ⑥ prise de décision. **Phrase qui rapporte le demi-point d'analyse** : « tous les choix sont guidés par le type de problématique » — c'est pourquoi les flèches du schéma remontent des cinq étapes suivantes vers la première.

3. (2 — 0,5 par définition)

— **Population** : « **ensemble (mathématique) étudié** » — l'ensemble des individus ou objets sur lesquels porte l'étude.

— **Unité statistique** : « **les éléments de cette population** » — un élément de cet ensemble.

— **Caractère (ou variable) X** : une **application** qui associe à **chaque** individu **une et une seule** valeur.

— **Modalités x_i** : « **les valeurs prises par une variable statistique** ».

4. (1,5) Deux types : **qualitatif** et **quantitatif**.

Sous-type	Critère	Exemple
Qualitative nominale	aucun ordre qui ait du sens	sexe, code postal
Qualitative ordinaire	un ordre qui a du sens	qualité du service : mauvaise → très bonne
Quantitative discrète	comptage, ensemble dénombrable	nombre d'enfants
Quantitative continue	mesure, ensemble non dénombrable	taille en cm

5. (0,5) La **descriptive** décrit **la population dont on dispose** ; l'**inférentielle déduit** des éléments d'une population **à partir d'un échantillon tiré aléatoirement**. Tout le chapitre 1 est de la statistique descriptive.

CORRIGÉ — EXERCICE 2 — IDENTIFICATION (5 POINTS)

1. (3 points)

- **Population** (0,5) — l'ensemble des **1 200 étudiants inscrits au portail au 1er octobre**. *Le champ fait partie de la réponse.*
- **Unités statistiques** (0,5) — **un étudiant**.
- **Effectif total** (0,5) — $n = 1\,200$. **Vérification** : $96 + 204 + 588 + 312 = 1\,200$ ✓
- **Caractère** (0,5) — l'**appréciation du dispositif de tutorat**.
- **Modalités** (0,5) — **quatre**, donc $p = 4$: très insatisfait, plutôt insatisfait, plutôt satisfait, très satisfait.
- **Type** (0,5) — **qualitatif ORDINAL**. **Justification exigée** : les modalités sont des **libellés**, pas des nombres — donc **qualitatif** — mais elles se rangent dans un **ordre qui a du sens**, du moins satisfait au plus satisfait — donc **ordinal**. *C'est exactement l'exemple « qualité du service » de la diapositive 14.*

2. (1,5 point)

Appréciation	n_i	f_i (%)	$F(x_i)$ (%)
Très insatisfait	96	8,0	8,0
Plutôt insatisfait	204	17,0	25,0
Plutôt satisfait	588	49,0	74,0
Très satisfait	312	26,0	100,0
Ensemble	1 200	100,0	

Détail : $96/1\,200 = 0,08$ soit 8,0 % · $204/1\,200 = 17,0$ % · $588/1\,200 = 49,0$ % · $312/1\,200 = 26,0$ % . **Contrôles** : $\sum n_i = 1\,200$ ✓ · $\sum f_i = 100,0$ ✓ · $F(\text{dernier}) = 100,0$ ✓

3. (0,5 point) Réponse en deux temps — et c'est la réponse complète qui prend le point :

« Le cours réserve la fréquence cumulée aux caractères quantitatifs. Ici le caractère est qualitatif — mais il est ordinal, donc ses modalités sont ordonnées, et l'énoncé "25,0 % des étudiants sont insatisfaits, au moins plutôt" a un sens parfaitement défini. La fréquence cumulée est donc interprétable ici, alors qu'elle ne le serait pas pour un caractère nominal comme le type d'infraction. »

CORRIGÉ — EXERCICE 3 — CONSTRUCTION (6 POINTS)

1. (1,5) **Population** : l'ensemble des **20 clients** observés. **Unité** : un client. **Effectif total** : $n = 20$. **Caractère** : le **nombre d'achats en ligne dans le mois**. **Type** : **quantitatif discret** — comptage, aucune valeur entre 1 et 2 achats.

2. (3) **Série ordonnée** :

0 0 0 1 1 1 1 1 1 2 2 2 2 2 2 3 3 3 4 6

x_i	n_i	f_i (%)	$F(x_i)$ (%)
0	3	15,0	15,0
1	6	30,0	45,0
2	6	30,0	75,0
3	3	15,0	90,0
4	1	5,0	95,0
6	1	5,0	100,0
Ensemble	20	100,0	

$p = 6$ modalités. Le piège est là : il n'y a pas de ligne « 5 » — aucun client n'a effectué exactement 5 achats. On n'invente pas une modalité d'effectif nul, et on ne saute pas non plus la valeur extrême 6. **Contrôles** : $\sum n_i = 3+6+6+3+1+1 = 20$ ✓ · $\sum f_i = 100,0$ ✓ · $F(6) = 100,0$ ✓

3. (0,5) « 75,0 % des 20 clients observés ont effectué deux achats ou moins dans le mois. » (Le « ou moins » est obligatoire.)

4. (1) **Diagramme en colonnes**, une colonne par modalité, hauteur = effectif. Intitulé : « **Distribution du nombre d'achats en ligne effectués dans le mois par les 20 clients observés** », avec l'**unité** (nombre de clients) et la **source**. Un camembert serait acceptable sur les fréquences, mais six modalités dont deux à 5 % le rendent peu lisible : les colonnes sont préférables.

CORRIGÉ — EXERCICE 4 — LECTURE ET CALCUL (3 POINTS)

1. (1) Le caractère étudié est le **nombre d'achats**, présenté **regroupé en trois classes** — aucun · 1 à 3 · 4 ou plus — dont la dernière est **ouverte**. Il est **quantitatif discret regroupé**. La **variable de découpage en sous-populations** est l'**année** : deux sous-populations, les clients de **2023** et ceux de **2024**, chacune de 20 clients.

2. (1) « **En 2024, 6 des 20 clients observés ont effectué 4 achats ou plus dans le mois.** » (Quand · combien · de quoi · dans quelle population · quelle modalité.)

3. (1) **Nature** : une fréquence, calculée à l'intérieur de 2024.

$$f = \frac{6}{20} \times 100 = 30,0 \%$$

En 2023 : $4/20 = 20,0 \%$. La part des gros acheteurs passe donc de 20,0 % à 30,0 %, soit + 10 points de pourcentage — ou une hausse de 50 % de leur effectif $(6-4)/4$. Le point volé : écrire « + 10 points de pourcentage » et non « + 10 % ». Un écart entre deux pourcentages se dit en points, jamais en pourcent. Ici les deux chiffres coexistent : + 10 points de part, + 50 % d'effectif.

MÉTHODE — GRILLE D'AUTO-ÉVALUATION — À REMPLIR JUSTE APRÈS LA SIMULATION

Bloc de points	Obtenu	Seuil de sécurité	Si tu es en dessous
Ex. 1 — cours (6)	—	6/6	Les définitions ne sont pas sues : cartes du § 4.2 et fiche du § 4.1 avant tout le reste.
Ex. 2 — identifier (5)	—	4,5/5	Reprends le gabarit 1 (méthode de l'épreuve) et refais B1 et B3.
Ex. 3 — construire (6)	—	5/6	Reprends le gabarit 2 (méthode de l'épreuve) et refais C1.
Ex. 4 — lire (3)	—	2,5/3	Reprends les gabarits 3 et 4 (méthode de l'épreuve) et refais B5.
Total	—	18/20	

Décision. $\geq 18/20$: le chapitre est acquis ; garde seulement la révision de la veille. **14 à 17,5** : reprends les cartes du § 4.2 et les corrigés des questions ratées, puis refais la simulation à J+5 en changeant l'ordre des questions. **< 14** : les définitions ne sont pas sues — défaut de **mémorisation**, pas de compréhension ; reprends les cartes et la fiche du § 4 en entier avant toute autre chose.

Les trois contrôles de fin d'épreuve, encore : $\sum n_i = n \cdot \sum f_i = 100 \cdot$ dernière cumulée = 100. **Trente secondes, et ils rattrapent presque toutes les erreurs de calcul de ce chapitre.**

6 — Auto-évaluation

Si tu ne sais pas répondre à ces questions sans regarder, tu ne maîtrises pas encore le chapitre. À faire à la fin de la révision J+7, sur feuille blanche.

N°	Question	Seuil
1	Je restitue au mot près : les cinq définitions de la diapositive 11, les quatre sous-types, la distribution observée, l'effectif, la fréquence, la fréquence cumulée, le rapport statistique	100 %
2	Je cite dans l'ordre les six étapes et la phrase qui les commande, puis les quatre méthodes de recueil avec leur définition	100 %
3	Je classe dix variables quelconques dans le bon sous-type, avec la justification en une ligne	10 / 10
4	À partir d'une série brute de 25 valeurs, je construis en moins de 10 minutes le tableau complet (n_i, f_i, F) avec les trois contrôles	sans erreur
5	Je démontre $\sum f_i = 1$, la croissance des fréquences cumulées et $f_k = F_k - F_{k-1}$	3 / 3
6	J'écris une phrase de lecture à cinq éléments pour un effectif, une fréquence et une fréquence cumulée	3 / 3
7	Je réponds à « comment a été calculé ce chiffre ? » en quatre lignes : nature, formule, application numérique, lecture	4 lignes
8	Dans un tableau par année, je distingue immédiatement le caractère étudié et la variable de découpage	sans hésiter
9	Je choisis et j'intitule le bon graphique pour six situations différentes	6 / 6
10	Je cite les quatre anomalies du support, le faux problème de la diapositive 28, et la conduite à tenir pour chacun	5 / 5
11	Niveau 2 : au moins 90 % des points, soit 32,5 sur 36	≥ 90 %
12	Niveau 4 : au moins 18/20 au barème	≥ 18

Protocole si un seuil n'est pas atteint : une carte ratée deux fois de suite est un défaut de **compréhension**, pas de mémoire → relire la sous-section du § 2 concernée, puis restitution Feynman ; une confusion → § 3.3 et § 3.4 ; une erreur de calcul ou de rédaction → méthode de l'épreuve, § 5.

7 — Révision en marchant

Hors pomodoros. Question à voix haute, réponse en une phrase, puis vérification. Une réponse hésitante revient le lendemain.

1. **La chaîne de la diapositive 3 ?** → Besoin de décider, besoin d'information, étude statistique.
2. **Les six étapes ?** → Problématique, données à observer, méthode de recueil, campagne de mesures, traitement, décision.
3. **La phrase du schéma ?** → Tous les choix sont guidés par le type de problématique.
4. **Les quatre méthodes de recueil ?** → Expérimentation, enquête qualitative, données de seconde main, enquête quantitative.
5. **Laquelle établit une causalité ?** → L'expérimentation, parce que l'expérimentateur fixe lui-même la variable de contrôle.
6. **Laquelle coûte le plus ?** → L'enquête quantitative, travail sur-mesure.
7. **Les trois questions de la campagne de mesures ?** → Combien, quand, comment.
8. **Délimiter une population ?** → Dire qui, où et quand : c'est le champ.
9. **Qui décide, le rapport ou le décideur ?** → Le décideur : toute décision est politique.
10. **Population ?** → Ensemble mathématique étudié.
11. **Unité statistique ?** → Un élément de cette population.
12. **Variable ?** → Une application associant à chaque individu une valeur.
13. **Pourquoi « application » ?** → Chaque individu a une valeur, et une seule.
14. **Modalités ?** → Les valeurs prises par la variable.
15. **Nominale ou ordinale ?** → Aucun ordre qui ait du sens, ou un ordre qui a du sens.
16. **Discrète ou continue ?** → Comptage, ou mesure.

17. **Le test contre les faux quantitatifs ?** → La moyenne a-t-elle un sens ?
18. **Les deux présentations sans perte ?** → Série brute et distribution des effectifs.
19. **Les deux opérations, dans l'ordre ?** → Trier, puis compter.
20. **Fréquence ?** → n_i sur n : la part des individus qui présentent la modalité.
21. **Fréquence cumulée ?** → La part des individus qui présentent la modalité ou une inférieure.
22. **Quand n'a-t-elle pas de sens ?** → Pour une qualitative nominale : pas d'ordre, pas de cumul.
23. **n et p ?** → Le nombre d'individus, le nombre de modalités distinctes.
24. **Pourquoi la somme des fréquences fait 100 % ?** → On met n en facteur : la somme des effectifs sur n vaut un.
25. **Le 90,4 des familles ?** → 90,4 % des familles avaient deux enfants ou moins.
26. **L'année du tableau de la diapositive 22 ?** → 2008, révélée par la diapositive 31.
27. **Écroué ou détenu ?** → Écroué est plus large : en 2023, 15 453 écroués n'étaient pas détenus.
28. **Caractère ou variable de découpage, chez les écroués ?** → La catégorie pénale est étudiée, l'année découpe.
29. **Grouper par catégorie ou par année ?** → Suivre chaque catégorie, ou comparer les structures.
30. **Empilé ou empilé à 100 % ?** → Structure et total, ou structure seule.
31. **Le 12,6 ?** → 1 012,2 sur 8 014,7 : la part des familles à trois enfants mineurs en 2017.
32. **Taux de variation des écroués ?** → Plus 22 % entre 2020 et 2023.
33. **Points ou pour cent ?** → Un écart entre deux parts se dit en points.
34. **Les quatre règles de présentation ?** → Titre précis, lisible, compréhension immédiate ou note de lecture, unités-population-méthode.
35. **Descriptive ou inférentielle ?** → Décrire ce qu'on a, ou déduire à partir d'un échantillon aléatoire.

Annexe A — Glossaire du chapitre

Terme	En une phrase	Définition académique
Étude statistique	Collecter et traiter des données pour éclairer une décision	Démarche en six étapes, de la problématique à la décision, répondant à un besoin d'information né d'un besoin de décider
Problématique	La question que l'étude doit trancher	Ce qui intéresse le donneur d'ordre, formulé assez précisément pour guider tous les choix de l'étude
Donneur d'ordre	Celui qui commande l'étude	Personne ou organisation qui a une décision à prendre et demande l'étude statistique
Expérimentation	On fait varier une chose et on regarde l'effet	Méthode de recueil fondée sur un protocole permettant l'observation directe de l'impact d'une variable de contrôle sur une variable d'observation
Variable de contrôle	Ce que l'expérimentateur fait varier	Variable fixée par l'expérimentateur, dont on mesure l'effet
Variable d'observation	Ce dont on mesure la réaction	Variable dont les variations sont attribuées à la variable de contrôle
Enquête qualitative	Peu de personnes, observées en profondeur	Méthode de recueil observant de façon extensive un petit nombre d'individus
Données de seconde main	Des données déjà collectées par d'autres	Informations disponibles par ailleurs, réutilisées pour l'étude
Enquête quantitative	Un questionnaire posé à beaucoup de monde	Collecte sur-mesure de l'information utile par enquête ou questionnaire ; la méthode la plus coûteuse
Campagne de mesures	L'organisation concrète de la collecte	Étape fixant combien, quand et comment enquêter
Recensement	Tout le monde est compté	Observation exhaustive de l'ensemble d'une population
Échantillon	Une partie de la population, tirée au hasard	Sous-ensemble de la population tiré aléatoirement, sur lequel on observe les données
Biais	Une déformation systématique	Écart systématique entre ce que mesure l'échantillon et ce qu'est la population, dû à la façon dont il a été constitué
Rapport statistique	Le document qui conclut l'étude	Document contenant les résultats des traitements et les éléments méthodologiques, orienté par la problématique vers la prise de décision
Champ	Qui, où et quand : les limites de la population	Délimitation d'une population par le type d'unité et ses restrictions, le territoire et la date d'observation
Population	Ce qu'on étudie, pris comme un tout	« Ensemble (mathématique) étudié »
Unité statistique	Un élément de ce qu'on étudie	« Les éléments de cette population » ; synonyme : individu
Effectif total	Combien il y a d'unités en tout	« Le nombre d'individus ou d'unités statistiques » ; noté n ; synonyme : taille de la population
Variable statistique	Ce qu'on observe sur chaque unité	« Une application associant à chaque individu une valeur » ; synonyme : caractère statistique ; notée X
Application	Chaque élément reçoit une valeur, et une seule	Relation associant à chaque élément d'un ensemble de départ une et une seule valeur d'un ensemble d'arrivée
Modalité	Une réponse possible	« Les valeurs prises par une variable statistique » ; notée x_i
Variable qualitative	Les réponses sont des mots	Variable dont les modalités ne sont pas des nombres
Qualitative nominale	Des mots sans ordre	Variable qualitative dont les modalités ne peuvent être classées selon un ordre qui a du sens

Terme	En une phrase	Définition académique
Qualitative ordinale	Des mots qu'on peut ranger	Variable qualitative dont les modalités peuvent être classées selon un ordre qui a du sens
Variable quantitative	Les réponses sont des nombres	Variable dont les modalités sont des nombres
Quantitative discrète	Des nombres qu'on compte	Variable quantitative dont les modalités relèvent du comptage (ensemble dénombrable)
Quantitative continue	Des nombres qu'on mesure	Variable quantitative dont les modalités relèvent de la mesure (ensemble non dénombrable)
Dénombrable	On peut numéroter les éléments un par un	Se dit d'un ensemble dont les éléments peuvent être énumérés un par un, même indéfiniment
Série brute	La liste des réponses, telle quelle	Présentation d'une variable par la liste de ses valeurs observées, dans l'ordre de collecte (<i>raw data</i>)
Série ordonnée	La même liste, triée	Série brute dont les valeurs sont rangées par ordre croissant
Distribution observée des effectifs	Le tableau réponse → nombre de fois	Présentation associant à chaque modalité d'une variable l'effectif observé correspondant (<i>frequencies</i>)
Effectif d'une modalité	Combien d'individus ont donné cette réponse	Nombre d'individus présentant une modalité donnée du caractère ; noté n_i
Fréquence	La part des individus qui ont cette réponse	Proportion d'individus présentant une modalité donnée dans la population totale : $f_i = n_i/n$
Fréquence cumulée	La part des individus qui ont cette réponse ou moins	Proportion d'individus présentant une modalité donnée ou inférieure : $F_k = \sum_{i=1}^k f_i$; suppose un ordre
Classe ouverte	Une dernière ligne « et plus »	Modalité regroupant toutes les valeurs au-delà d'un seuil, sans borne supérieure (« 4 enfants et plus »)
Sous-population	Un morceau de la population	Partie de la population définie par une autre variable (année, zone), dans laquelle on calcule une distribution
Variable de découpage	Ce qui sépare les colonnes qu'on compare	Variable définissant les sous-populations entre lesquelles on compare la distribution du caractère étudié
Diagramme en colonnes	Une colonne par réponse, haute comme son effectif	Représentation d'une distribution où chaque modalité reçoit une colonne de hauteur proportionnelle à son effectif ou à sa fréquence
Colonnes groupées	Des colonnes côte à côte pour comparer	Diagramme juxtaposant, pour chaque catégorie (ou chaque année), une colonne par année (ou par catégorie)
Diagramme empilé	Les parts posées les unes sur les autres	Diagramme où les effectifs des modalités sont superposés, la hauteur totale représentant l'ensemble
Empilé à 100 %	Toutes les colonnes à la même hauteur	Diagramme empilé construit sur les fréquences de chaque sous-population, pour comparer des structures
Camembert	Un disque découpé en parts	Diagramme circulaire dont les secteurs sont proportionnels aux fréquences d'une distribution
Note de lecture	La phrase sous le tableau qui dit comment le lire	Mention accompagnant un tableau ou un graphique complexe, donnant l'exemple de lecture d'une valeur
Phrase de lecture	Traduire un chiffre en phrase complète	Énoncé donnant la date, la valeur, l'unité, la population et la modalité auxquelles un chiffre se rapporte
Taux de variation	De combien une valeur a changé, en %	$(V_{\text{arrivée}} - V_{\text{départ}}) / V_{\text{départ}} \times 100$
Point de pourcentage	L'unité d'écart entre deux pourcentages	Différence arithmétique entre deux taux exprimés en pourcentage
Écroué	Inscrit en prison, enfermé ou non	Personne inscrite au registre d'écrou d'un établissement pénitentiaire, détenue ou non (bracelet électronique, placement extérieur)

Terme	En une phrase	Définition académique
Prévenu	Poursuivi, pas encore jugé définitivement	Personne poursuivie pénalement qui n'a pas fait l'objet d'une condamnation définitive ; présumée innocente
Condamné	Jugé définitivement	Personne dont la condamnation pénale est définitive
Condamné-prévenu	Condamné pour une affaire, poursuivi pour une autre	Personne condamnée définitivement dans une affaire et encore prévenue dans une autre
Ménage ordinaire	Des personnes qui vivent dans un logement normal	Au sens de l'Insee, ensemble des personnes partageant un même logement ordinaire, à l'exclusion des ménages collectifs (foyers, internats, maisons de retraite, casernes, prisons)
Enfant mineur	Un enfant de moins de 18 ans	Enfant âgé de moins de 18 ans vivant dans la famille
Statistique descriptive	Décrire ce qu'on a observé	Ensemble des techniques présentant et résumant les données d'une population observée
Statistique inférentielle	Conclure sur tous à partir de quelques-uns	Techniques permettant de déduire des éléments d'une population à partir d'un échantillon aléatoire
Symbole Σ (somme)	« Additionne tout ça »	$\sum_{i=1}^p a_i = a_1 + a_2 + \dots + a_p$; l'indice i va de la borne basse à la borne haute

Annexe B — Tableau de couverture du support

Une ligne par diapositive du support « CHAPITRE 1 — Présenter pour informer », 33 diapositives, aucun numéro manquant. ✓ traité intégralement · Δ support muet, elliptique ou fautif : reconstruit à l'endroit indiqué · ✗ donnée manquante, demande formulée dans SOURCES.md .

Nº	Élément du support	État	Où c'est traité
1	Page de titre — Hélène Couprie, Portail L1 Division A, 2026-27	✓	§ 2.1.1
2	Contenu et plan du chapitre en trois sections	✓	§ 2.1.1
3	Section 1 · chaîne « décider → information → étude » + quatre exemples	Δ	§ 2.1.2 — les quatre exemples sont posés sans commentaire : chacun est décomposé en décision visée / information nécessaire
4	Schéma muet des six étapes	Δ	§ 2.1.3 (schéma redessiné) — diapositive sans une ligne de texte : les six étapes, le sens des flèches et la phrase qui les commande sont reconstruits
5	Étape 1 · « quel type de problématique ? » + exemple de l'hypermarché	Δ	§ 2.1.3 — les quatre sous-questions sont énumérées sans être exploitées : ce qu'elles changent pour l'étude est explicité
6	Étape 2 · « Qui ? » — choix des données à observer	Δ	§ 2.1.3, § 2.1.4 — « la population devra être définie, délimitée » : ce que <i>délimiter</i> veut dire est reconstruit
7	Étape 3 · les quatre méthodes de recueil	Δ	§ 2.1.3 — les quatre méthodes sont nommées sans critère de choix : tableau comparatif coût / précision / usage ajouté
8	Étape 4 · campagne de mesures, trois questions	Δ	§ 2.1.3 — « combien, quand, comment » sans réponse : les enjeux de chacune sont développés
9	Étape 5 · traitement + annonce des quatre chapitres du cours	✓	§ 2.1.1, § 2.1.3
10	Étape 6 · prise de décision et contenu du rapport	Δ	§ 2.1.4 — « toute décision est politique » n'est pas expliqué : le partage entre statisticien et décideur est reconstruit
11	Section 2 · les cinq définitions + convention de notation majuscule/minuscule	Δ	§ 2.2.1 — « application » est un terme mathématique employé sans définition : défini, avec ses deux exigences et leurs conséquences
12	Illustration · infractions déclarées, France 2024 + exercice sans corrigé	Δ	§ 2.2.2 (graphique ajouté), niveau 2 (B1) — l'exercice posé par la diapositive est corrigé intégralement , fréquences comprises
13	Les deux types et quatre sous-types + avertissement sur le codage numérique	Δ	§ 2.2.3 — « dénombrable » et « non dénombrable » sont employés sans définition : définis, avec le test pratique d'examen
14	Illustration · quatre couples caractère / modalités	✓	§ 2.2.3 — les quatre exemples sont repris et classés
15	Section 3 · les deux façons de présenter, et le traitement qui fait passer de l'une à l'autre	✓	§ 2.3.1
16	Distribution observée des effectifs · définition + trois précisions	✓	§ 2.3.2
17	Illustration · série brute des 87 étudiants	Δ	§ 2.3.2, § 3.1 (A1) — série recomptée chiffre par chiffre à l'image : 10 zéros et 24 « 2 » → anomalie A1
18	Illustration · série ordonnée	✓	§ 2.3.2 — recomptée : 11 zéros, 23 « 2 » , conforme au tableau
19	Illustration · tableau de la distribution, total 87	✓	§ 2.3.2
20	Illustration · diagramme colonne de la distribution (<i>image seule</i>)	Δ	§ 2.3.2 (graphique redessiné) — graphique sans aucun commentaire : ce qu'il montre, ce qu'il permet de lire et pourquoi 11 modalités excluent le camembert
21	Répartition · définitions de la fréquence et de la fréquence cumulée + camembert ou barres	Δ	§ 2.3.3, § 2.4.3 (camembert) — la restriction « <i>pour un caractère quantitatif</i> » et le choix camembert/barres sont posés sans justification : les deux sont démontrés

N°	Élément du support	État	Où c'est traité
22	Illustration · tableau des familles + exercice sans corrigé	△	§ 2.3.3, niveau 2 (B2), § 3.1 (A2, A3) — exercice corrigé intégralement ; deux imprécisions relevées → A2, A3
23	Formellement · X, x_i, n_i, n, f_i, F_k + renvoi « diapo 21 »	△	§ 2.3.4, § 3.1 (A4) — les notations sont posées sans démonstration : $\sum n_i = n$ est démontré ; renvoi fautif → A4
24	Plusieurs distributions · le mécanisme en quatre puces	△	§ 2.4.1 — « définies selon une AUTRE variable » n'est pas explicité : le mécanisme en trois temps est reconstruit
25	Tableau des personnes écrouées + exercice sans corrigé	△	§ 2.4.1, niveau 2 (B3) — exercice corrigé ; quatre termes pénaux employés sans définition (écroué, prévenu, condamné, condamné-prévenu) : tous définis
26	Diagramme colonnes groupées 1 — groupement par catégorie (<i>image seule</i>)	△	§ 2.4.2 (graphique redessiné) — la règle « le choix dépend de ce qui est au centre de l'analyse » est énoncée sans être appliquée : tableau comparatif d. 26 / d. 27
27	Diagramme colonnes groupées 2 — groupement par année (<i>image seule</i>)	△	§ 2.4.2 (graphique redessiné) — <i>idem</i> , avec la lecture chiffrée des deux graphiques
28	Tableau enfants par famille, 1990-2023 + exercice sans corrigé	△	§ 2.4.3, niveau 2 (B4), § 3.2 — exercice corrigé ; « ménage ordinaire » et « enfant mineur » définis ; écart d'arrondi de 0,1 expliqué → § 3.2
29	Diagramme empilé (<i>image seule</i>)	△	§ 2.4.3 (graphique redessiné) — « la hauteur correspond à l'ensemble » sans en tirer la conséquence : le critère de choix empilé / empilé 100 % est établi
30	Diagramme empilé à 100 % + exercice sans corrigé	△	§ 2.4.3 (graphique redessiné), niveau 2 (B5) — exercice corrigé ; les 24 fréquences recalculées et vérifiées
31	Diagramme colonne 1975-2008 + renvoi « le tableau précédent »	△	§ 2.4.3 (graphique redessiné), § 3.1 (A3) — les 25 valeurs relevées à l'image ; le renvoi est faux, et sa correction révèle l'année du tableau de la diapositive 22 : 2008
32	Section 3 · les quatre règles de présentation	✓	§ 2.4.4
33	Remarques conclusives + ouverture sur la statistique inférentielle	△	§ 2.4.5 — « échantillon » et « inférentielle » employés sans définition opératoire : définis, avec la raison du tirage aléatoire

SYNTHÈSE — BILAN DE COUVERTURE

33 diapositives, 0 trou — 9 ✓, 24 △, 0 ✖. Les 24 △ recouvrent huit termes employés sans définition (application, dénombrable, écroué, prévenu, condamné-prévenu, ménage ordinaire, enfant mineur, échantillon), six graphiques ou schémas sans commentaire — tous redessinés —, cinq exercices posés sans corrigé — tous corrigés au niveau 2 —, trois règles énoncées sans justification et deux listes sans mécanisme. Quatre anomalies du support sont vérifiées et traitées au § 3.1, et un faux problème d'arrondi au § 3.2. Les demandes qui amélioreraient encore ce cours — format exact de l'épreuve, sujets de TD, annales, chapitres suivants, questions posées en amphithéâtre — sont inscrites dans **SOURCES.md**.