

Fiche — Résumer pour informer

La page à savoir par cœur, puis les questions à se poser en marchant

Extraite automatiquement du cours Statistiques_Ch02_Resumer_pour_informer.md. Ne pas modifier ici : corriger le cours, puis republier.

Date · 28 septembre 2026

Document de travail autonome — il remplace le support de cours original, qu'il n'est pas nécessaire de relire. Toute notion évoquée dans le cours y est définie, démontrée et illustrée.

La fiche de synthèse

SYNTHÈSE — CHAPITRE 2 « RÉSUMER POUR INFORMER » — L'ESSENTIEL SUR DEUX PAGES

LE PROJET DU CHAPITRE. Présenter (chapitre 1) conserve **toute** l'information. Résumer en **perd volontairement** pour produire quelques chiffres décisionnels. Trois familles : **position** (où ?), **dispersion** (à quel point c'est étalé ?), **concentration** (comment le total se partage-t-il ?).

① **POSITION — LE MODE.** La modalité de **fréquence maximale**. Variable continue → **classe modale**. Δ Si les amplitudes sont **inéga**les, la classe modale est celle de **densité maximale** : $d_i = f_i / a_i$ avec $a_i = b_{\text{sup}} - b_{\text{inf}}$. **Histogramme** : hauteur = densité, et c'est l'aire qui représente la fréquence ($d_i \times a_i = f_i$).

① **POSITION — LA MOYENNE.** Trois écritures du même objet : $m_X = \frac{1}{N} \sum_{i=1}^N x_i$ (données brutes) · $m_X = \sum_{i=1}^p f_i x_i$

(distribution) · $m_X = \sum_{k=1}^K \frac{N_k}{N} m_{X_k}$ (agrégation). **Trois propriétés** : ① $\sum (x_i - m_X) = 0$ — la somme des écarts est nulle ; ② **linéarité** $m_{aX+b} = a m_X + b$; ③ **sensibilité aux valeurs extrêmes**.

① **POSITION — LA MÉDIANE.** La valeur qui **partage l'effectif en deux** : $F(\text{Me}) = 0,5$. N impair → valeur de rang $(N+1)/2$; N pair → **moyenne** des rangs $N/2$ et $N/2+1$. Sur une distribution : classe médiane puis **interpolation linéaire**. Δ **La médiane ne s'agrége JAMAIS**.

DIAGNOSTIC D'ASYMÉTRIE. $\text{Me} < m_X \rightarrow$ distribution **étalée à droite** (salaires, patrimoines). $\text{Me} > m_X \rightarrow$ étalée à gauche. $\text{Me} \approx m_X \rightarrow$ symétrique.

② **DISPERSION — LES INDICATEURS D'ÉCART ENTRE POSITIONS.** **Étendue** = $x_{\text{max}} - x_{\text{min}}$ (totalement sensible aux extrêmes). **Quantile** Q_p : la valeur telle que $F(Q_p) = p$ — c'est l'**inverse de la fonction de répartition**. Quartiles (4 parts), déciles (10), centiles (100). **Écart inter-quartile** = $Q_3 - Q_1$ (50 % centraux) · **inter-décile** = $D_9 - D_1$ (80 % centraux) · **rapport inter-décile** = D_9/D_1 (sans unité). **Boxplot** : boîte de Q_1 à Q_3 , trait à la médiane, moustaches selon une convention à préciser ($1,5 \times \text{IQR}$, $D1$ et $D9 \dots$).

② **DISPERSION — LES INDICATEURS D'ÉCART À LA MOYENNE.**

$$EAM = \frac{1}{N} \sum |x_i - m_X| \quad \sigma^2 = V(X) = \frac{1}{N} \sum (x_i - m_X)^2 \quad \sigma = \sqrt{V(X)}$$

Koenig : $V(X) = \frac{1}{N} \sum x_i^2 - m_X^2$ (« moyenne des carrés moins carré de la moyenne ») — **un seul passage sur les données**,

donc agrégation possible. Propriétés : $V(X+a) = V(X)$ · $V(aX) = a^2 V(X)$ · $\sigma_{aX} = |a| \sigma_X$ · $V(-X) = V(X)$. **Coefficient de variation** $CV = \sigma / m_X$ — **sans unité**, seul comparable entre séries d'échelles différentes. **Bienaymé-Tchebychev** :

$P(|x - m| \geq k\sigma) \leq 1/k^2$, **valable quelle que soit la loi**, donc **très lâche**. Δ **Ne dit rien pour $k \leq 1$** . **Décomposition** :

$\sigma^2 = V_{\text{intra}} + V_{\text{inter}}$ avec $V_{\text{intra}} = \sum \frac{N_k}{N} \sigma_k^2$ et $V_{\text{inter}} = \sum \frac{N_k}{N} (m_{X_k} - m_X)^2$. Le rapport $V_{\text{inter}}/\sigma^2$ mesure le **pouvoir explicatif du découpage**.

③ **CONCENTRATION — LA CONDITION D'EXISTENCE.** Elle n'existe que si **la somme de X a un sens** (salaires → masse salariale ✓ ; tailles, notes, âges ✗).

③ **CONCENTRATION — LA PART DE L'AGRÉGAT.** $\sum_{i=1}^{N_k} x_i = N_k m_{X_k}$ (« la somme = la moyenne × l'effectif »), d'où

$$p_k = \frac{N_k m_{X_k}}{\sum_j N_j m_{X_j}} = \frac{f_k m_{X_k}}{m_X} = f_k \times \frac{m_{X_k}}{m_X}$$

L'effectif total se simplifie : le calcul est possible à N inconnu.

③ **CONCENTRATION — LORENZ ET GINI.** La **courbe de Lorenz** met la **part cumulée de X** (ordonnée) en face de la **fréquence cumulée de la population** (abscisse), individus **rangés par X croissant**. Elle part de (0;0), arrive à (100;100), est **croissante et convexe**, et sa **pente sur la classe k vaut m_{X_k}/m_X** . La **diagonale** est la courbe de l'**égalité parfaite**. **Dominance de Lorenz** : une courbe partout plus éloignée de la diagonale → **tous** les indicateurs concluent à plus d'inégalité. **Croisement** → conclusions possiblement contradictoires.

$$G = 2 \times \text{mathcal{A}} = 2 \left[\frac{1}{2} - \sum \frac{(b+B)h}{2} \right], \quad 0 \leq G \leq 1$$

⚠ **Si les cumuls sont en %, diviser la somme des trapèzes par 10 000.** $G = 0 \rightarrow$ égalité parfaite · $G \rightarrow 1 \rightarrow$ concentration totale (max exact = $(N-1)/N$).

LES CHIFFRES DU CHAPITRE À CONNAÎTRE. Âges (diapo 42-43) : $m = 47,9$; $EAM = 5,7$; $\sigma^2 = 54,19$; $\sigma = 7,36$.

Niveau de vie 2024 : $D_9/D_1 = 3,48$. Salaires : $G_{2005} = 0,2472 \rightarrow G_{2021} = 0,3564$ (+ 44 %). Part du 1^{er} quintile : 11,2 % $\rightarrow$ 3,9 % (divisée par 2,9).

LE CHOIX DE L'INDICATEUR. Type de données **puis** objectif. Asymétrie $\rightarrow$ médiane. Agrégation $\rightarrow$ moyenne. Unités différentes $\rightarrow$ CV. Partage d'un total $\rightarrow$ Lorenz et Gini.

Révision en marchant

Hors pomodoros. Question à voix haute, réponse en une phrase, puis vérification. Une réponse hésitante revient le lendemain.

1. **Présenter ou résumer ?** → Présenter garde tout ; résumer perd volontairement pour décider.
2. **Les trois familles ?** → Position, dispersion, concentration : où, comment étalé, à qui le total.
3. **Le mode ?** → La modalité la plus fréquente — le seul indicateur de position d'une nominale.
4. **La classe modale, classes inégales ?** → Celle de plus forte densité, pas de plus gros effectif.
5. **La densité ?** → La fréquence divisée par l'amplitude.
6. **L'aire d'un rectangle d'histogramme ?** → La fréquence de la classe ; la somme des aires vaut un.
7. **Classe modale des incarcérés en 2020 ?** → 25 à 30 ans, densité 0,0375.
8. **Les trois écritures de la moyenne ?** → Données brutes, distribution, agrégation.
9. **La somme des écarts à la moyenne ?** → Zéro — d'où la valeur absolue ou le carré.
10. **La moyenne est-elle linéaire ?** → Oui : moyenne de aX plus b égale a fois m plus b .
11. **Moyenne de moyennes ?** → Seulement pondérée par les effectifs des groupes.
12. **Somme, moyenne, effectif ?** → La somme égale l'effectif fois la moyenne.
13. **Moyenne ou médiane face aux extrêmes ?** → La moyenne bouge, la médiane résiste.
14. **La médiane s'agrège-t-elle ?** → Jamais : 1-2-3 et 100-200-300 donnent 51,5, pas 101.
15. **L'hypothèse de l'interpolation ?** → Une répartition uniforme dans l'intervalle.
16. **Médiane des familles en 2008 ?** → 0,09 par la formule, 1 enfant au sens du rang : le dire.
17. **Médiane moins que moyenne ?** → Distribution étalée à droite.
18. **Un quantile ?** → L'inverse de la fonction de répartition.
19. **Q3 moins Q1 ?** → L'étalement des 50 % centraux.
20. **D9 sur D1, niveau de vie 2024 ?** → 3,48.
21. **UC ?** → Unité de consommation : 1, puis 0,5, puis 0,3.
22. **Les moustaches d'un boxplot ?** → Une convention à préciser : 1,5 fois l'écart interquartile, ou D1 et D9.
23. **CSP la plus dispersée ?** → Les cadres, D9 sur D1 égal à 3,2.
24. **Variance ou écart-type ?** → La variance est au carré ; l'écart-type est dans l'unité.
25. **Écart-type des 20 âges ?** → 7,36 ans, que le support ne calcule pas.
26. **EAM ou écart-type, lequel est le plus grand ?** → L'écart-type, toujours.
27. **Bienaymé-Tchebychev à deux écarts-types ?** → Au moins 75 %, quelle que soit la loi.
28. **L'écart-type en finance ?** → La volatilité.
29. **Koenig ?** → La moyenne des carrés moins le carré de la moyenne.
30. **Ajouter une constante ?** → La variance ne bouge pas.
31. **Multiplier par a ?** → Variance fois a au carré, écart-type fois valeur absolue de a .
32. **Le coefficient de variation ?** → Écart-type sur moyenne, sans unité.
33. **Variance du cas 4 ?** → 20,8, et non 10,4 comme le support.
34. **Intra et inter ?** → Dans les groupes, entre les groupes ; leur somme fait la variance.
35. **Concentration, condition ?** → Que la somme de la variable ait un sens.
36. **La part de l'agrégat ?** → Fréquence fois moyenne de classe sur moyenne générale.
37. **Pourquoi N disparaît ?** → Il est au numérateur et au dénominateur.
38. **Part du premier quintile, 2005 puis 2021 ?** → 11,2 %, puis 3,9 %.
39. **La courbe de Lorenz ?** → La part cumulée du total contre la part cumulée de la population, rangée par ordre croissant.
40. **La pente de Lorenz ?** → La moyenne de la classe sur la moyenne générale.
41. **Deux courbes qui se croisent ?** → Les indicateurs peuvent se contredire.
42. **Le Gini ?** → Deux fois l'aire entre la diagonale et la courbe.
43. **Cumuls en pour cent ?** → Diviser la somme des trapèzes par 10 000.
44. **Gini des salaires 2005, 2021 ?** → 0,247 puis 0,356.
45. **La dernière phrase du chapitre ?** → Le choix dépend du type de données et de ce qu'on veut en faire.

