

Formulaire cumulatif — Techniques statistiques

Toutes les formules de tous les chapitres, dans l'ordre du cours

Généré automatiquement à partir des encadrés « formule » des cours. 22 formule(s).

Date · 28 septembre 2026

Document de travail autonome — il remplace le support de cours original, qu'il n'est pas nécessaire de relire. Toute notion évoquée dans le cours y est définie, démontrée et illustrée.

SOMMAIRE

Chapitre 1 — Présenter pour informer

Chapitre 2 — Résumer pour informer

Chapitre 1 — Présenter pour informer

FORMULE CLÉ — DIAPOSITIVE 23 — À SAVOIR ÉCRIRE

- Le caractère statistique est noté X , les modalités x_i sont **ordonnées** de $i = 1, \dots, p$.
- À chaque modalité x_i correspond un **effectif** n_i , et l'**effectif total** vaut

$$n = \sum_{i=1}^p n_i = n_1 + n_2 + \dots + n_p$$

- Les **fréquences** f_i , pour $i = 1, \dots, p$, se calculent ainsi :

$$f_i = \frac{n_i}{n}$$

- Les **fréquences cumulées** F_k , pour $k = 1, \dots, p$, sont telles que :

$$F_k = \sum_{i=1}^k f_i$$

FORMULE CLÉ — LE SYMBOLE Σ , SI TU NE L'AS JAMAIS MANIPULÉ

$\sum_{i=1}^p n_i$ se lit « **somme des n_i pour i allant de 1 à p** », et signifie exactement $n_1 + n_2 + \dots + n_p$.

- i est un **compteur** : il prend successivement les valeurs $1, 2, \dots, p$.
- **Le nombre du bas** dit où il commence, **celui du haut** où il s'arrête.
- **Le nom du compteur est sans importance** : $\sum_{i=1}^p n_i$ et $\sum_{k=1}^p n_k$ désignent le même nombre.

Les deux formules du chapitre se lisent alors sans effort : $n = \sum_{i=1}^p n_i$ — l'*effectif total* est la somme de tous les effectifs.

$F_k = \sum_{i=1}^k f_i$ — la *fréquence cumulée au rang k* est la somme des fréquences **jusqu'à k** . La borne haute est k , pas p : c'est tout ce qui distingue un cumul partiel d'un total.

FORMULE CLÉ — LES PROPRIÉTÉS DES FRÉQUENCES — À CONNAÎTRE ET À SAVOIR DÉMONSTRER

$$\sum_{i=1}^p f_i = 1 = 100 \% \quad F_p = 100 \% \quad F_{k+1} \geq F_k \quad f_k = F_k - F_{k-1} \text{ avec } F_0 = 0$$

Démonstrations : Statistiques Ch01, § 2.3.4. Elles servent de contrôle à chaque tableau construit.

FORMULE CLÉ — TAUX DE VARIATION ET POINTS DE POURCENTAGE — LES DEUX OUTILS POUR COMMENTER UN TABLEAU PAR ANNÉE

Le support compare des années **sans donner l'outil de la comparaison**. Il est indispensable dès qu'on commente un tableau comme celui-ci — et c'est l'objet annoncé du chapitre 3, « évolutions temporelles ».

$$t = \frac{V_{\text{arrivée}} - V_{\text{départ}}}{V_{\text{départ}}} \times 100$$

- $V_{\text{départ}}$: la valeur à la date de départ — **c'est le dénominateur**.
- $V_{\text{arrivée}}$: la valeur à la date d'arrivée.
- t : la variation **rapportée au point de départ**, en pour cent.

Pourquoi cette formule : une hausse de 16 237 personnes ne dit rien seule ; rapportée aux 73 834 de départ, elle devient comparable à n'importe quelle autre évolution.

Application : $t = \frac{90\,071 - 73\,834}{73\,834} \times 100 = \frac{16\,237}{73\,834} \times 100 = +21,99 \%$, soit **+22,0 %** de personnes écrouées entre 2020 et 2023.

L'écart entre deux pourcentages se dit en points de pourcentage. Les condamnés détenus représentent 56,3 % des écroués en 2020 et 57,5 % en 2023 : leur part augmente de **1,2 point** — pas de 1,2 %. Le taux de variation de cette part serait, sur les valeurs arrondies, $1,2 / 56,3 = +2,1 \%$. **Les deux chiffres sont vrais et ne disent pas la même chose.**

Chapitre 2 — Résumer pour informer

FORMULE CLÉ — LES DEUX FORMULES DE LA DIAPOSITIVE

$$\text{amplitude} = x_{\max} - x_{\min} \quad \text{densité} = \frac{\text{fréquence de la classe}}{\text{amplitude de la classe}}$$

FORMULE CLÉ — LA MOYENNE SUR DONNÉES BRUTES

$$m = \frac{1}{N} \sum_{i=1}^N x_i = \frac{1}{N} (x_1 + x_2 + \dots + x_N) \quad (3)$$

- N : le **nombre d'observations** (l'effectif total).
- x_i : la valeur observée pour la **i-ème unité statistique** de la base.
- **L'indice i renvoie ici au numéro d'observation**, pas au numéro de modalité.

Ce calcul correspond à celui obtenu à partir de **données brutes** (*raw data*).

FORMULE CLÉ — LES DEUX ÉCRITURES ÉQUIVALENTES

Pour un caractère X à p modalités, d'effectifs n_i et de fréquences f_i — **ici l'indice i renvoie au numéro de modalité** :

$$m = \frac{1}{N} \sum_{i=1}^p n_i x_i \quad (4)$$

ou, en plaçant le N dans la somme, de façon équivalente à partir des fréquences :

$$m = \sum_{i=1}^p \frac{n_i}{N} x_i = \sum_{i=1}^p f_i x_i \quad (5)$$

FORMULE CLÉ — LA MOYENNE D'UNE POPULATION À PARTIR DES MOYENNES DE SES SOUS-POPULATIONS

Soient K sous-populations **disjointes** d'effectifs n_k , avec $N = \sum_{k=1}^K n_k$, et de moyennes respectives m_k . Alors :

$$m = \sum_{k=1}^K \frac{n_k}{N} m_k \quad (6)$$

Il s'agit d'une **moyenne pondérée par la part de la sous-population dans la population entière**, n_k / N .

FORMULE CLÉ — LINÉARITÉ

$$\text{si } Y = aX + b \text{ alors } m_Y = a m_X + b \quad (8)$$

- Multiplier toutes les valeurs par a multiplie la moyenne par a .
- Ajouter b à toutes les valeurs augmente la moyenne de b .
- **A fortiori**, la moyenne de la somme de deux variables est la somme des moyennes.

FORMULE CLÉ — INTERPOLATION LINÉAIRE

Lorsque les données sont présentées sous forme de distribution intégrant les **fréquences cumulées** :

- **si on dispose d'une valeur de X telle que $F(x_j) = 50\%$, alors la médiane vaut x_j ;**
- **dans le cas contraire, on procède par interpolation linéaire.** Si $F(x_a) < 50\%$ et $F(x_b) > 50\%$:

$$\text{med} \approx x_a + \frac{(x_b - x_a)(0,5 - F(x_a))}{F(x_b) - F(x_a)} \quad (9)$$

FORMULE CLÉ — LE QUANTILE D'ORDRE α %

Lorsque les données sont présentées sous forme de distribution intégrant les fréquences cumulées :

- **si** on dispose d'une valeur de X telle que $F(x_j) = \alpha$ %, **alors le quantile vaut x_j** ;
- **sinon**, par interpolation linéaire, si $F(x_a) < \alpha$ % et $F(x_b) > \alpha$ % :

$$Q_{\alpha\%} \approx x_a + \frac{(x_b - x_a)(\alpha\% - F(x_a))}{F(x_b) - F(x_a)} \quad (10)$$

FORMULE CLÉ — LES TROIS COLONNES DU TABLEAU DE CALCUL (DIAPOSITIVE 41)

Soit m_X la moyenne de X , et $i = 1, \dots, N$ observations x_i :

Colonne	Contenu	Notation
(1)	La série ordonnée	x_i
(2)	L' écart à la moyenne	$y_i = x_i - m_X$
(3)	L' écart absolu à la moyenne	$z_i = x_i - m_X $
(4)	Le carré de l'écart à la moyenne	$w_i = (x_i - m_X)^2$

« C'est ainsi que l'on obtient un tableau de calcul contenant N lignes. »

FORMULE CLÉ — LES TROIS INDICATEURS, LUS AU BAS DES COLONNES (DIAPOSITIVE 43)

Colonne 3 — l'écart absolu moyen :

$$EAM = \frac{1}{N} \sum_{i=1}^N |x_i - m_X| = 5,7$$

Lecture du support : « **les âges s'écartent en moyenne de l'âge moyen (47,9 ans) de 5,7 années** ».

Colonne 4 — la variance :

$$\sigma^2 = V(X) = \frac{1}{N} \sum_{i=1}^N (x_i - m_X)^2 = 54,2$$

« La variance vaut 54,2, elle **n'est pas d'une interprétation aisée** puisque les écarts d'âge sont mesurés **au carré**. »

L'écart-type :

$$\sigma = \sqrt{V(X)} = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - m_X)^2}$$

« **est ici interprétable** puisque mesuré en années ».

FORMULE CLÉ — L'INÉGALITÉ

C'est l'inégalité d'Irénée-Jules Bienaymé et Pafnouti Tchebychev qui va permettre d'interpréter l'écart-type en lien avec la moyenne.

Pour $k > 1$, l'intervalle $[m - k\sigma ; m + k\sigma]$ contient au moins $1 - 1/k^2$ des observations.

k	$1 - 1/k^2$	Énoncé
2	0,75	Au moins 75 % des observations sont dans $m \pm 2\sigma$
3	$\approx 0,89$	Au moins 89 % des observations sont dans $m \pm 3\sigma$

« C'est **très pratique** quand on ne nous donne qu'une moyenne et un écart-type pour résumer des données. »

FORMULE CLÉ — LA RENTABILITÉ JOURNALIÈRE

$$r_t = \frac{P_t - P_{t-1}}{P_{t-1}} \times 100$$

où P_t est le prix de clôture du jour et P_{t-1} celui de la veille.

FORMULE CLÉ — LES PROPRIÉTÉS DE LA VARIANCE (DIAPOSITIVE 50)

1. **Formule de Koenig.** La variance se calcule aussi comme :

$$V(X) = \frac{1}{N} \sum_{i=1}^N x_i^2 - m_X^2$$

(« la moyenne des carrés moins le carré de la moyenne »)

2. **Invariance par translation.** Si j'ajoute le même nombre a à toutes les valeurs de X , la variance est inchangée :

$$V(a + X) = V(X).$$

3. **Non-linéarité.** Si je multiplie tous les éléments par a , la variance est multipliée par a^2 : $V(aX) = a^2 V(X)$.

4. **Corollaire** : $V(-X) = V(X)$.

FORMULE CLÉ — LE COEFFICIENT DE VARIATION

- Les mesures de la variance et de l'écart-type sont **sensibles à la conversion d'unités de mesure** (changement de monnaie, de métrique, etc.).
- Le coefficient de variation est **exprimé sans unité**, en pourcentage.
- Il permet des **comparaisons d'indicateurs de dispersion entre caractères mesurés différemment**.

$$CV = \frac{\sigma_X}{m_X}$$

FORMULE CLÉ — LES QUATRE ÉCRITURES ÉQUIVALENTES

Lorsqu'on n'a pas les données brutes mais un **tableau de distribution** — p modalités, effectifs n_i , fréquences f_i , l'indice i renvoyant au **numéro de modalité** :

À partir des effectifs :

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^p n_i (x_i - m)^2 = \frac{1}{N} \sum_{i=1}^p n_i x_i^2 - m^2 \quad (11)$$

À partir des fréquences :

$$\sigma^2 = \sum_{i=1}^p f_i (x_i - m)^2 = \sum_{i=1}^p f_i x_i^2 - m^2 \quad (12)$$

FORMULE CLÉ — LA VARIANCE AGRÉGÉE PAR LA FORMULE DE KOENIG

Soient K sous-groupes d'effectifs N_k , de moyennes m_{X_k} et de variances σ_k^2 , avec $\sum_{k=1}^K N_k = N$:

- **Moyenne agrégée** : $m_X = \frac{1}{N} \sum_{k=1}^K N_k m_{X_k}$
- **Pour chaque groupe**, la formule de Koenig donne : $\sum_{i=1}^{N_k} x_i^2 = [\sigma_k^2 + m_{X_k}^2] N_k$
- **Au niveau agrégé** : $\sum_{i=1}^N x_i^2 = \sum_{k=1}^K \sum_{i=1}^{N_k} x_i^2$
- **D'où la variance agrégée** :

$$\sigma^2 = \frac{1}{N} \sum_{k=1}^K [\sigma_k^2 + m_{X_k}^2] N_k - m_X^2$$

FORMULE CLÉ — VARIANCE INTRA, VARIANCE INTER, VARIANCE TOTALE

La connaissance des variances par groupe et de la variance globale permet de mesurer l'importance des variations dites **intra** et **inter** groupes dans la variation totale.

Variance intra-groupe — la dispersion à l'intérieur des groupes :

$$V_{\text{intra}} = \sum_{k=1}^K \frac{N_k}{N} \sigma_k^2$$

Variance inter-groupe — la dispersion des moyennes entre groupes :

$$V_{\text{inter}} = \sum_{k=1}^K \frac{N_k}{N} (m_{X_k} - m_X)^2 = \sum_{k=1}^K \frac{N_k}{N} m_{X_k}^2 - m_X^2$$

Et la relation fondamentale :

$$\boxed{\sigma^2 = V_{\text{intra}} + V_{\text{inter}}}$$

FORMULE CLÉ — LA SOMME = LA MOYENNE × L'EFFECTIF

$$\sum_{i=1}^{N_k} x_i = N_k m_{X_k}$$

où N_k est l'effectif de la classe k et m_{X_k} la moyenne de X dans cette classe.

En mots : la somme d'une variable sur un groupe est égale à la moyenne du groupe multipliée par la taille du groupe. Dans le cas des salaires :

$$\text{masse salariale de la classe} = \text{salaire moyen de la classe} \times \text{effectif de la classe}$$

FORMULE CLÉ — LA FORMULE DE CALCUL (DIAPOSITIVE 69)

$$G = 2 \left[\frac{1}{2} - \sum \frac{(b + B) \cdot h}{2} \right]$$

où, pour chaque tranche : b est la **petite base** (la valeur cumulée à gauche), B la **grande base** (la valeur cumulée à droite) et h la **hauteur** — c'est-à-dire la largeur de la tranche en abscisse.