

Présenter pour informer — l'étude statistique et la distribution d'une variable

Mener une étude statistique, nommer ses éléments, présenter une distribution en effectifs, fréquences et fréquences cumulées, choisir le bon diagramme

Reconstruit à partir des 33 diapositives du cours magistral, des notes du tableau de la séance 1 et de la planche de TD du chapitre 1, dont les quatre exercices sont corrigés en entier. Les erreurs relevées dans les supports — une série brute qui ne correspond pas à son tableau, « 17 132 familles » qui sont des milliers, un empilement qui compte des familles et non des enfants, un graphique présenté à tort comme équivalent au tableau — sont corrigées. Tu n'as besoin d'aucun autre document.

Date · 30 septembre 2026

Travail estimé · Apprendre — 3 sections × 4 pomodoros · réviser — J+1, J+3, J+7, J+21 · s'entraîner — 5 pomodoros

Version · 1.0

Document de travail autonome — il remplace le support de cours original, qu'il n'est pas nécessaire de relire. Toute notion évoquée dans le cours y est définie, démontrée et illustrée.

SOMMAIRE

2.1 — L'étude statistique et son vocabulaire

Pourquoi une étude statistique ?

Les six étapes d'une étude statistique

Le vocabulaire : population, unités, caractère, modalités

Les types de variables

Population ou échantillon

2.2 — La distribution d'une variable : effectifs, fréquences, fréquences cumulées

Deux façons de présenter une variable sans perte d'information

La fréquence

La fréquence cumulée

Les notations du cours

2.3 — Représenter pour informer : diagrammes et tableaux

Un diagramme pour une distribution

Plusieurs distributions d'un même caractère

Tableaux et graphiques : des outils de communication

Les confusions qui coûtent des points

Si tu lis autre chose ailleurs : les erreurs des sources, corrigées

Ce que les correcteurs récompensent

4.1 — Fiche de synthèse

4.2 — Moyens mnémotechniques

4.3 — Le schéma qui relie tout

Niveau 1 — QCM

Niveau 2 — Exercices types d'examen

Exercice 1 — Identifier les types de variables (planche, exercice 1 ; § 2.1)

Exercice 2 — Les éléments d'une étude statistique (planche, exercice 2 ; § 2.1)

Exercice 3 — Manier les représentations d'une variable (planche, exercice 3 ; § 2.2 et 2.3)

Exercice 4 — Interpréter une étude statistique (planche, exercice 4 ; § 2.2)

Niveau 3 — Questions pièges et cas transversaux

Niveau 4 — Sujet au format de l'examen

Corrigé du niveau 1 — QCM

Corrigé du niveau 2 — Exercices types d'examen

Exercice 1 — Identifier les types de variables

Exercice 2 — Les éléments d'une étude statistique

Exercice 3 — Manier les représentations d'une variable

Exercice 4 — Interpréter une étude statistique

Corrigé du niveau 3 — Questions pièges et cas transversaux

Corrigé du niveau 4 — Sujet au format de l'examen

1 — Carte du chapitre

SYNTHÈSE — LE CHAPITRE EN QUELQUES LIGNES

Le cours de Techniques statistiques compte **quatre chapitres** : présenter les données (**chapitre 1 — ce cours**), les résumer (chapitre 2), étudier leurs évolutions dans le temps (chapitre 3), croiser plusieurs variables (chapitre 4). Ce premier chapitre répond à trois questions :

1. **Comment mène-t-on une étude statistique ?** En **six étapes**, toutes guidées par la **problématique** : la question de départ, les données à observer, la méthode de recueil, la campagne de mesures, le traitement, la décision.
2. **Comment nomme-t-on ce qu'on étudie ?** La **population** est l'ensemble étudié ; ses éléments sont les **unités statistiques** ; on observe sur elles un **caractère** (ou variable) X , qui prend des **modalités**. Le caractère est **qualitatif** (nominal ou ordinal) ou **quantitatif** (discret ou continu).
3. **Comment présente-t-on les données sans rien perdre ?** Sous forme de **série brute** — une ligne par individu — ou de **distribution** — une ligne par modalité, avec son **effectif**, sa **fréquence** et sa **fréquence cumulée** —, dans un **tableau** ou un **diagramme** bien choisi et bien titré.

Ce qui tombe à l'examen — le format de l'épreuve n'est pas encore connu (à demander en TD). La planche de TD montre ce qui est attendu, et c'est ce qui tombera : **identifier** la population, l'unité statistique, la taille de la population, le caractère, son type et son sous-type, ses modalités ; **passer** d'une série brute à une distribution ; **calculer** des fréquences et des fréquences cumulées, en écrivant la formule ; **écrire une phrase de lecture** pour une valeur du tableau ; **tracer** un diagramme correctement annoté, avec son échelle ; **choisir** entre données brutes et distribution, entre colonnes groupées, empilées ou empilées à 100 %, et **justifier** ce choix.

Ce qu'il faut savoir par cœur

Quoi	Le contenu exact
Les six étapes	Problématique → choix des données à observer → méthode de recueil → campagne de mesures → traitement → prise de décision ; tous les choix sont guidés par la problématique
Les quatre méthodes de recueil	Expérimentation · observation (enquête qualitative) · données de seconde main · enquête quantitative
Le vocabulaire	Population (l'ensemble étudié) · individus ou unités statistiques (ses éléments) · taille ou effectif total N · caractère ou variable X (associe une valeur à chaque individu) · modalités (ses valeurs)
Les types de variables	Qualitative (modalités = mots) : nominale (pas d'ordre qui ait un sens) ou ordinaire (un ordre qui a un sens) · quantitative (modalités = nombres) : discrète (comptage) ou continue (mesure)
Les formules	$f_k = n_k / N$ · $\sum n_k = N$ · $\sum f_k = 1$ · $F_k = f_1 + f_2 + \dots + f_k = F_{k-1} + f_k$
Les lectures	f_k : « f % des individus ont la modalité x_k » · F_k : « F % des individus ont la modalité x_k ou moins »
Les diagrammes	Colonnes ou barres : une distribution · colonnes groupées : comparer des sous-populations · empilées : comparer des totaux · empilées à 100 % : comparer des structures

2 — Le cours reconstruit

2.1 — L'étude statistique et son vocabulaire

OBJECTIFS — À LA FIN DE CETTE SECTION, SANS SUPPORT, TU SAIS

- dire à quoi sert une étude statistique et réciter ses six étapes dans l'ordre, avec ce que chacune décide ;
- définir population, unité statistique, taille de la population, caractère et modalité, et les repérer dans n'importe quel tableau ;
- donner le type et le sous-type de n'importe quelle variable, en justifiant.


Pourquoi une étude statistique ?

Tout part d'une **décision à prendre**. Pour bien décider, il faut de l'**information** ; pour obtenir cette information, on mène une **étude statistique** :

besoin de décider → **besoin d'information** → **étude statistique**

Les exemples du cours : identifier les **populations à risque** pour cibler une campagne de prévention ; connaître l'**évolution démographique** pour financer les retraites ; prévoir la **répartition géographique** d'une population pour fixer des quotas de médecins ; **localiser des prospects** pour répartir les forces de vente.

Les six étapes d'une étude statistique



Les six étapes d'une étude statistique — à savoir redessiner

- 1. Quel type de problématique ?** On précise la question du **donneur d'ordre** — celui qui commande l'étude. L'exemple du cours : un directeur d'hypermarché demande « une enquête de satisfaction ». C'est **beaucoup trop vague** : veut-il modifier la mise en rayon, améliorer l'affichage des produits, mieux répondre aux attentes des clients sur le choix des produits, les horaires d'ouverture, le conseil ? Chaque réponse conduit à une autre étude.
- 2. Choix des données à observer** — « **qui ?** ». On définit et on **délimite la population** sur laquelle portent les observations, et ses **unités statistiques**. On connaît parfois sa taille, pas toujours.
- 3. Choix de la méthode de recueil** — « **comment obtenir l'information ?** ». Quatre façons de faire :
 - l'**expérimentation** : un protocole permet d'observer directement l'effet d'une **variable de contrôle** (celle qu'on fait varier) sur une **variable d'observation** (celle qu'on mesure) ;
 - l'**observation**, ou **enquête qualitative** : on observe **de façon approfondie un petit nombre** d'individus ;
 - les **données de seconde main** : on **réutilise** des informations disponibles ailleurs (Insee, ministères, entreprises) ;
 - l'**enquête quantitative** : un travail **sur mesure** — on collecte soi-même l'information utile, par questionnaire, auprès d'un grand nombre d'individus.
- 4. Campagne de mesures**. Si l'on choisit l'enquête quantitative — **l'option la plus coûteuse** —, il faut décider **combien** de personnes interroger, **quand** et **comment**.
- 5. Traitement des données : les faire parler**. C'est l'objet de tout le cours, chaque traitement étant orienté vers la problématique : **présenter** les données sans perte d'information (**chapitre 1**), les **résumer** variable par variable (**chapitre 2**), étudier leurs **évolutions dans le temps** (**chapitre 3**), **croiser** plusieurs variables (**chapitre 4**).

6. **Prise de décision.** Le **rapport statistique** donne les résultats des traitements **et** les **éléments méthodologiques** — les choix faits et les méthodes utilisées —, le tout orienté vers la décision. **Toute information inutile**, c'est-à-dire non informative pour la problématique, **est bannie**. Et **ce n'est pas le rapport qui décide** : la décision est **politique** ; elle s'appuie sur le rapport, mais aussi sur d'autres contraintes, comme le coût.

POINT D'EXAMEN — CE QU'IL FAUT RETENIR DU SCHÉMA

Les flèches de retour vers la première étape disent l'essentiel : **tous les choix — données, méthode, mesures, traitement — sont guidés par le type de problématique**. Une question du type « Pourquoi la demande du directeur est-elle trop vague ? » attend cette idée : sans problématique précise, on ne sait ni qui interroger, ni quoi mesurer, ni comment traiter les réponses.

Le vocabulaire : population, unités, caractère, modalités

DÉFINITION — POPULATION, UNITÉ STATISTIQUE, TAILLE

En une phrase : la population est l'ensemble de ce qu'on étudie ; chacun de ses éléments est une unité statistique ; leur nombre est la taille de la population.

Définitions à connaître :

- la **population** est l'**ensemble** (au sens mathématique) étudié ;
- ses éléments s'appellent les **individus** ou **unités statistiques** ;
- le **nombre d'individus** s'appelle la **taille de la population** ou **effectif total**, noté N .

Une unité statistique n'est pas forcément une personne : ce peut être une **famille**, un **logement**, une **infraction**, un **match**, un **pays**, une **entreprise**. Pour la trouver, demande-toi : « **sur quoi a-t-on relevé chaque valeur ?** »

DÉFINITION — CARACTÈRE (VARIABLE) ET MODALITÉS

En une phrase : le caractère est ce qu'on observe sur chaque individu ; les modalités sont les valeurs qu'il peut prendre.

Définitions à connaître :

- une **variable statistique** ou **caractère statistique** est une **application** qui associe à **chaque individu une valeur** ;
- les valeurs prises par une variable statistique sont ses **modalités**.

Notation : la variable s'écrit en **majuscule** (X), ses valeurs en **minuscule** ($x_1, x_2, \dots$).

EXEMPLE CHIFFRÉ — TOUT REPÉRER DANS UN TABLEAU — LES INFRACTIONS DE 2024 (COURS, SÉANCE 1)

Selon l'enquête « Vécu et ressenti en matière de sécurité », la répartition des atteintes déclarées en France en 2024 est la suivante.


Atteinte déclarée	Nombre d'infractions
Actes de vandalisme contre la voiture	2 893 000
Vols ou tentatives de vol d'objet dans ou sur la voiture	1 544 000
Vols ou tentatives de vol avec effraction de la résidence principale	1 516 000
Actes de vandalisme contre le logement	1 141 000
Vols ou tentatives de vol de vélo	853 000
Vols sans effraction de la résidence principale	616 000
Vols ou tentatives de vol de voiture	549 000
Vols ou tentatives de vol de deux-roues motorisés	264 000
Ensemble	9 376 000

Champ : France métropolitaine, Martinique, Guadeloupe et La Réunion. Diffusion Insee.

- **Population** : l'ensemble des **infractions** déclarées commises en France (dans le champ de l'enquête) en 2024.
- **Unité statistique** : une **infraction** — pas une personne.
- **Taille de la population** : $N = 9\,376\,000$ infractions (la ligne « Ensemble » ; vérifié : la somme des huit lignes fait bien 9 376 000).
- **Caractère** : X = le **type d'atteinte** — qualitatif nominal.
- **Modalités** : les **8 types** d'atteinte, numérotés $k = 1, \dots, 8$; l'**effectif** de chacune est noté n_k : $n_1 = 2\,893\,000$, $n_2 = 1\,544\,000$, et ainsi de suite.

Ce tableau est un **tableau de distribution des effectifs du caractère X** : à chaque modalité, il associe son effectif.

Les types de variables



Les deux types et les quatre sous-types de variables — à savoir redessiner avec un exemple par case

DÉFINITION — VARIABLE QUALITATIVE, NOMINALE OU ORDINALE

En une phrase : une variable qualitative a des modalités qui ne sont pas des nombres ; elle est ordinale si l'on peut ranger ses modalités dans un ordre qui a du sens, nominale sinon.

Définitions à connaître :

- les modalités d'une variable **qualitative ne sont pas des nombres** ;
- elle est **nominale** lorsqu'il **n'est pas possible** de classer les modalités selon un **ordre qui a du sens** — le sexe (« homme », « femme », « autre »), la nationalité, la couleur des yeux ;
- elle est **ordinale** lorsqu'il **est possible** de classer les modalités selon un **ordre qui a du sens** — la qualité d'un service (« mauvaise », « plutôt mauvaise », « plutôt bonne », « très bonne »), une mention, une satisfaction.

DÉFINITION — VARIABLE QUANTITATIVE, DISCRÈTE OU CONTINUE

En une phrase : une variable quantitative a des modalités qui sont des nombres ; elle est discrète si ces nombres viennent d'un comptage, continue s'ils viennent d'une mesure.

Définitions à connaître :

- les modalités d'une variable **quantitative sont des nombres** ;
- elle est **discrète** si les modalités relèvent du **comptage** : elles forment un ensemble **dénombrable** (0, 1, 2, ...) — le nombre d'enfants, de frères et sœurs, de langues parlées ;
- elle est **continue** si les modalités relèvent de la **mesure** : elles forment un ensemble **non dénombrable** (toutes les valeurs d'un intervalle) — la taille en cm (179, 182, 165, 148, 205...), le poids, une durée, un revenu.

Deux types, quatre sous-types : c'est la formule du cours. Pour classer une variable, pose deux questions, dans l'ordre :

1. **Les modalités sont-elles des nombres qui mesurent une quantité ?** Non → qualitative ; oui → quantitative.
2. Qualitative : **peut-on ranger les modalités dans un ordre qui a du sens ?** Non → nominale ; oui → ordinale. Quantitative : **les valeurs se comptent-elles ou se mesurent-elles ?** Compter → discrète ; mesurer → continue.

PIÈGE FRÉQUENT — UN CHIFFRE NE FAIT PAS UNE VARIABLE QUANTITATIVE

Une variable qualitative peut être **codée par des nombres** dans une base de données — « un mot valant un chiffre » (cours). Une satisfaction notée de **1 (très mauvaise) à 5 (très bonne)**, un code postal, un numéro de département restent **qualitatifs** : le 4 n'est pas « deux fois » le 2, et additionner deux codes postaux n'a aucun sens. **Le test** : la moyenne des valeurs aurait-elle un sens concret ? Si non, la variable est qualitative (ordinale si l'ordre a un sens, comme pour la satisfaction ; nominale sinon, comme pour le code postal).

PIÈGE FRÉQUENT — LES CAS LIMITES : DIS COMMENT LA VARIABLE EST MESURÉE

- **L'âge** est par nature **continu** (une durée) ; relevé en **années entières** (18, 19, 20...), il se présente comme une variable **discrète**, avec une colonne par âge ; regroupé en **classes** (de 25 à moins de 30 ans), il se traite comme une variable **continue** (histogramme, chapitre 2).
- **Un revenu, un prix** se mesurent en euros : on les traite comme des variables **continues**, même s'ils s'arrêtent au centime.
- **Une fréquence de consommation** est **ordinale** si on la relève par « jamais, rarement, souvent, toujours », **quantitative discrète** si l'on compte le nombre de fois par semaine.

À l'examen, **justifie en une demi-phrase** (« discrète, car elle résulte d'un comptage ») : c'est ce qui fait la différence quand deux réponses sont défendables.

Population ou échantillon

On ne dispose pas toujours d'une information **exhaustive** sur toute la population qui nous intéresse : il faut parfois **tirer aléatoirement un échantillon**, c'est-à-dire une partie de la population. Deux branches des statistiques :

- la **statistique descriptive** — tout ce cours — décrit les données observées : les présenter, les résumer ;
- la **statistique inférentielle** — hors programme de ce semestre — **déduit** des propriétés de la population **à partir d'un échantillon aléatoire**.

POINT D'EXAMEN — LE RÉFLEXE À AVOIR DEVANT TOUT TABLEAU

Avant tout calcul, écris quatre lignes : **population** (qui, où, quand), **unité statistique**, **taille de la population N** , **caractère** avec son **type** et **sous-type** et le **nombre de modalités**. Ces éléments ouvrent presque chaque exercice des planches de TD et rapportent des points faciles.

2.2 — La distribution d'une variable : effectifs, fréquences, fréquences cumulées

OBJECTIFS — À LA FIN DE CETTE SECTION, SANS SUPPORT, TU SAIS

- distinguer série brute et distribution, et passer de l'une à l'autre ;
- définir effectif, fréquence et fréquence cumulée, écrire leurs formules et leurs propriétés ;
- compléter un tableau de distribution et écrire une phrase de lecture pour chaque colonne.

Deux façons de présenter une variable sans perte d'information

DÉFINITION — SÉRIE BRUTE ET DISTRIBUTION OBSERVÉE

En une phrase : la série brute donne la valeur de chaque individu ; la distribution donne, pour chaque modalité, le nombre d'individus qui la présentent.


Définitions à connaître :

- la **série brute**, ou **données brutes** (*raw data*), liste la valeur du caractère **pour chaque individu** : **une ligne = un individu** ;
- la **distribution observée des effectifs** (*frequencies*) **associe à chaque modalité d'une variable statistique l'effectif observé correspondant** : **une ligne = une modalité**. On la présente dans un **tableau** ou un **diagramme en colonnes**. Elle ne perd **aucune information** sur la répartition de la variable ; c'est souvent **l'étape n° 1** d'une analyse statistique.

DÉFINITION — EFFECTIF D'UNE MODALITÉ

En une phrase : le nombre d'individus qui ont cette modalité.

Définition à connaître : l'**effectif** d'une modalité est le **nombre d'individus présentant cette modalité** du caractère statistique. On le note n_k pour la modalité x_k .



Aucune information n'est perdue : on peut toujours revenir en arrière (sauf l'ordre du recueil).

De la série brute à la distribution : trier, puis compter

Pour passer de la série brute à la distribution, il faut un **traitement** : pour une variable **quantitative** ou **qualitative ordinale**, **trier** les modalités (on obtient la **série ordonnée**), puis **compter** les effectifs. Pour une variable nominale, on se contente de compter.

EXEMPLE CHIFFRÉ — LES FRÈRES ET SŒURS DE 87 ÉTUDIANTS (COURS)

Une mini-enquête : 87 étudiants d'une promotion répondent à la question « Combien avez-vous de frères et sœurs ? ».

Population : les 87 étudiants — $N = 87$ unités statistiques. Caractère : le **nombre de frères et sœurs**, quantitatif **discret**.

La série brute — dans l'ordre des réponses :

```
2 2 5 2 3 1 1 1 1 2 1 1 0 2 2
5 1 4 2 2 1 0 2 2 1 2 1 1 2 1
3 1 2 1 0 0 1 3 13 2 1 1 2 1 1
1 6 1 3 1 0 1 5 7 2 1 2 2 3 0
3 2 2 7 14 9 5 4 1 0 1 2 1 3 2
1 2 2 0 4 1 0 1 0 1 1 1
```


La série ordonnée range ces 87 valeurs de la plus petite à la plus grande : onze fois 0, trente-trois fois 1, vingt-trois fois 2, sept fois 3, puis 4, 4, 4, 5, 5, 5, 5, 6, 7, 7, 9, 13, 14.

La distribution compte chaque modalité :

Nombre de frères et sœurs x_k	0	1	2	3	4	5	6	7	9	13	14	Ensemble
Effectif n_k	11	33	23	7	3	4	1	2	1	1	1	87

Vérification : $11 + 33 + 23 + 7 + 3 + 4 + 1 + 2 + 1 + 1 + 1 = 87$.

Attention, erreur du support : la série brute de la diapositive 17 contient en réalité **10** fois « 0 » et **24** fois « 2 », alors que la série ordonnée et le tableau (diapositives 18 et 19) en comptent **11** et **23** : une valeur a été mal recopiée. Le tableau, cohérent avec la série ordonnée, est celui qu'on retient ; retiens surtout la méthode — **toujours vérifier que la somme des effectifs redonne N** .



Une colonne par modalité ; les modalités 8, 10, 11 et 12 ont un effectif nul.

La distribution du nombre de frères et sœurs, en diagramme en colonnes — une colonne par modalité

La fréquence

FORMULE CLÉ — FRÉQUENCE D'UNE MODALITÉ

$$f_k = \frac{n_k}{N}$$

- f_k : la **fréquence** de la modalité x_k ;
- n_k : son **effectif** ;
- N : l'**effectif total** (la taille de la population).

La fréquence d'une modalité est la **proportion d'individus** qui présentent cette modalité dans la population totale. C'est un nombre entre 0 et 1, qu'on exprime souvent **en pourcentage** (on multiplie par 100).

Propriétés : les effectifs s'additionnent pour donner l'effectif total, et les fréquences pour donner 1 :

$$\sum_{k=1}^K n_k = n_1 + n_2 + \dots + n_K = N \quad \sum_{k=1}^K f_k = f_1 + f_2 + \dots + f_K = 1 = 100 \%$$

Pourquoi la somme des fréquences vaut 1 : $\sum f_k = \sum \frac{n_k}{N} = \frac{1}{N} \sum n_k = \frac{N}{N} = 1$.

On représente une répartition en fréquences par un **camembert** ou un **diagramme en barres** (cours). Dans un camembert, chaque part a un **angle proportionnel à sa fréquence** : $\text{angle} = f_k \times 360^\circ$ — une fréquence de 25 % donne un quart de disque, 90° .

La fréquence cumulée

FORMULE CLÉ — FRÉQUENCE CUMULÉE

$$F_k = f_1 + f_2 + \dots + f_k = \sum_{i=1}^k f_i \quad \text{d'où} \quad F_k = F_{k-1} + f_k$$

- F_k , qu'on note aussi $F(x_k)$: la **fréquence cumulée** de la modalité x_k ;
- on l'obtient en ajoutant les fréquences **de la première modalité jusqu'à** x_k ;
- en pratique, **de proche en proche** : chaque fréquence cumulée est la précédente plus la fréquence de la ligne.


La fréquence cumulée d'une modalité est la **proportion d'individus présentant cette modalité ou une modalité inférieure**. Elle n'a de sens que si les modalités **peuvent être rangées** : variable **quantitative** ou **qualitative ordinale** — jamais nominale. La dernière vaut toujours **1 = 100 %**.

EXEMPLE CHIFFRÉ — LES FAMILLES SELON LE NOMBRE D'ENFANTS, EN 2008 (COURS, DIAPOSITIVE 22 ET SÉANCE 1)

Modalités x_k	Effectifs n_k (en milliers)	Fréquences f_k (en %)	Fréquences cumulées $F(x_k)$ (en %)
0 enfant	8 225	48,0	48,0
1 enfant	3 821	22,3	70,3
2 enfants	3 449	20,1	90,4
3 enfants	1 241	7,2	97,7
4 enfants et plus	396	2,3	100,0
Ensemble	17 132	100,0	

- **Population** : l'ensemble des familles en France en 2008 ; **taille** : $N = 17\,132$ **milliers** de familles, soit environ 17,1 millions.
- **Caractère** : le nombre d'enfants, quantitatif **discret**, 5 modalités ($k = 1, \dots, 5$).
- **Une fréquence** : $f_2 = n_2 / N = 3\,821 / 17\,132 = 0,223$, soit **22,3 %** — « **22,3 % des familles ont 1 enfant** ».
- **Des fréquences cumulées** : $F_1 = f_1 = 48,0 \%$; $F_2 = f_1 + f_2 = 48,0 + 22,3 = 70,3 \%$ — « **70,3 % des familles ont 1 enfant ou moins** » ; $F_3 = F_2 + f_3 = 70,3 + 20,1 = 90,4 \%$, que l'on retrouve aussi par $f_1 + f_2 + f_3 = 48 + 22,3 + 20,1$.
- **Vérifications** : $8\,225 + 3\,821 + 3\,449 + 1\,241 + 396 = 17\,132$; $48,0 + 22,3 + 20,1 + 7,2 + 2,3 = 99,9$ — l'écart de 0,1 vient des arrondis ; la dernière fréquence cumulée vaut 100,0.

Attention, erreur du support : la diapositive annonce une « enquête menée auprès de 17132 familles », mais les effectifs sont **en milliers** : il s'agit de **17 132 milliers** de familles, soit toutes les familles de France. L'« année donnée » est **2008** (les mêmes chiffres reviennent au chapitre 2 avec cette date).



Nombre d'enfants — familles en France, 2008

Lecture : $F(1) = 70,3 \%$ — 70,3 % des familles ont 1 enfant ou moins.

Le diagramme des fréquences cumulées : un escalier qui monte jusqu'à 100 %

Comment lire ce diagramme : pour une variable discrète, la fréquence cumulée reste constante entre deux modalités, puis **saute** à chaque modalité d'une hauteur égale à sa fréquence : c'est un **diagramme en escalier**. Le premier palier qui dépasse la ligne des 50 % montre où se trouve le « milieu » de la population — la **médiane**, au chapitre 2.

Les notations du cours

Au tableau, les modalités sont numérotées par l'indice **k** ($k = 1, \dots, K$) ; dans les diapositives, par l'indice **i** ($i = 1, \dots, p$, pour p modalités) : n_i , $f_i = n_i / n$, $F_k = \sum_{i=1}^k f_i$. **C'est la même chose** : utilise l'une ou l'autre, mais une seule dans une copie. Au chapitre 2, on distinguera l'indice d'une **observation** (données brutes, $i = 1, \dots, N$) et celui d'une **modalité** (distribution, $i = 1, \dots, p$).

MÉTHODE — COMPLÉTER UN TABLEAU DE DISTRIBUTION, SANS RIEN OUBLIER

1. **Identifier** : population, unité, N , caractère, type, nombre de modalités.
2. **Écrire la formule** avant le premier calcul : $f_k = n_k / N$ — la planche de TD le demande (« après avoir écrit la formule correspondante »).
3. **Calculer chaque fréquence**, en gardant assez de décimales (au moins quatre, ou un dixième de pour cent).
4. **Cumuler de proche en proche** : $F_1 = f_1$, puis $F_k = F_{k-1} + f_k$.
5. **Vérifier** : $\sum n_k = N$, $\sum f_k = 1$ (à l'arrondi près), dernière $F = 100\%$.
6. **Écrire une phrase de lecture** pour une fréquence et une fréquence cumulée, avec la population, le lieu, la date et l'unité :
« En 2008, 70,3 % des familles vivant en France ont 1 enfant ou moins. »

2.3 — Représenter pour informer : diagrammes et tableaux

OBJECTIFS — À LA FIN DE CETTE SECTION, SANS SUPPORT, TU SAIS

- choisir le diagramme adapté à une distribution et le tracer correctement ;
- comparer les distributions de plusieurs sous-populations avec des colonnes groupées, empilées ou empilées à 100 %, en disant ce que chacune montre ;
- écrire une phrase de lecture et donner un titre complet à un tableau ou un graphique.

Un diagramme pour une distribution

Type de variable	Le diagramme	Ce qu'on met en ordonnée
Qualitative nominale	Colonnes (ou barres, horizontales) ; camembert	Effectifs ou fréquences ; l'ordre des colonnes est libre
Qualitative ordinale	Colonnes dans l'ordre des modalités ; fréquences cumulées en escalier	Effectifs ou fréquences
Quantitative discrète	Colonnes — une par modalité, y compris les modalités d'effectif nul — ; fréquences cumulées en escalier	Effectifs ou fréquences
Quantitative continue	Regroupée en classes : histogramme (chapitre 2)	La densité

Tracer un diagramme en colonnes, pas à pas : une colonne par modalité, **de même largeur** ; une hauteur proportionnelle à l'effectif ou à la fréquence ; une **échelle** indiquée (par exemple 1 cm pour 10 %) ; les deux axes **nommés**, avec leur unité ; un **titre** complet et la **source**. Le diagramme des frères et sœurs, plus haut, en est un modèle : les modalités 8, 10, 11 et 12 y figurent avec une hauteur nulle, pour ne pas écraser l'échelle des nombres.

Plusieurs distributions d'un même caractère

Il arrive souvent que **plusieurs distributions d'un même caractère** soient présentées ensemble, **pour les comparer**. La population est alors découpée en **sous-populations** selon une autre variable — l'année, la zone géographique... — ; il y a une **distribution par sous-population**, et on les **juxtapose**. Le but est de **comparer la répartition** de la variable entre sous-populations.


EXEMPLE CHIFFRÉ — LES PERSONNES ÉCROUÉES EN FRANCE, DE 2020 À 2023 (COURS)

Catégorie	2020	2021	2022	2023
Prévenus détenus	17 692	18 486	18 779	19 755
Condamnés-prévenus détenus	2 405	2 613	2 908	3 117
Condamnés détenus	41 553	47 246	49 338	51 746
Condamnés non détenus	12 184	13 644	14 286	15 453
Total des personnes écrouées	73 834	81 989	85 311	90 071

Source : ministère de la Justice. Les totaux ont été vérifiés.

- **Population** : les personnes écrouées en France de 2020 à 2023 ; **sous-populations** : les **quatre années** (une distribution par année) ; **caractère** : la **catégorie** de personne écrouée — qualitatif **nominal**, 4 modalités.
- Une **personne écrouée** est placée sous la garde de l'administration pénitentiaire : **prévenue** (pas encore jugée définitivement), **condamnée**, ou **condamnée-prévenue** (condamnée dans une affaire, en attente de jugement dans une autre) ; **détenue** en prison, ou **non détenue** — par exemple sous bracelet électronique.


Pour comparer ces distributions, on trace un **diagramme en colonnes groupées**. Le **groupement** dépend de la comparaison au **centre de l'analyse** :



Groupement par catégorie : on lit l'évolution de chaque catégorie d'une année à l'autre.

Groupement par catégorie : l'évolution de chaque catégorie

- Si l'on s'intéresse à l'évolution des effectifs de chaque catégorie, on **groupe par catégorie** : les quatre années côte à côte pour chaque catégorie. On voit d'un coup d'œil que **chaque catégorie augmente chaque année** — les condamnés détenus passent de 41 553 à 51 746.



Groupement par année : on lit la structure de chaque année, puis son évolution.

Groupement par année : la structure de chaque année

- Si l'on s'intéresse à l'évolution de la structure des effectifs, on **groupe par année** : les quatre catégories côte à côte pour chaque année. On voit la **structure** de chaque année — les condamnés détenus dominent toujours, loin devant les prévenus détenus —, puis on compare les années.


EXEMPLE CHIFFRÉ — LES FAMILLES SELON LE NOMBRE D'ENFANTS MINEURS, DE 1990 À 2023 (COURS)

Nombre d'enfants mineurs	1990	1999	2007	2012	2017	2023
1 enfant	3 353,7	3 418,3	3 565,0	3 614,8	3 590,7	3 578,3
2 enfants	2 800,5	2 841,1	2 996,3	3 074,1	3 101,1	3 039,0
3 enfants	1 087,1	1 033,5	1 015,2	1 022,3	1 012,2	956,2
4 enfants ou plus	410,9	334,5	296,9	296,1	310,7	308,4
Ensemble	7 652,2	7 627,5	7 873,5	8 007,3	8 014,7	7 881,9

Champ : France hors Mayotte, familles vivant en ménage ordinaire ayant au moins un enfant mineur. Unité : milliers de familles.

Source : Insee, recensements de la population.

- **Population** : les familles vivant en France (hors Mayotte), en ménage ordinaire, ayant **au moins un enfant mineur** ; **sous-populations** : les **six années** ; **unité statistique** : une **famille** ; **caractère** : le **nombre d'enfants mineurs**, quantitatif **discret**, 4 modalités (la dernière est une classe ouverte : « 4 ou plus »). Les effectifs sont **en milliers**.
- **Une phrase de lecture** : « En 2023, en France hors Mayotte, 3 578,3 milliers de familles — près de 3,6 millions — ont un seul enfant mineur. »
- Les totaux de 1999 et 2007 dépassent de 0,1 la somme des lignes (7 627,4 et 7 873,4) : ce sont des **arrondis**, sans conséquence.




La hauteur d'une colonne = le nombre total de familles de l'année (en gras).

Colonnes empilées : la hauteur d'une colonne est le nombre total de familles de l'année

Le diagramme empilé superpose les modalités dans une même colonne : la **hauteur de l'empilement est l'effectif total de la sous-population** — ici, le **nombre total de familles** de l'année. Il sert à comparer les **totaux** et, grossièrement, leur composition.

Attention, erreur du support : la diapositive dit que la hauteur de l'empilement « correspond à l'ensemble des **enfants** » et titre « nombre d'enfants par type de famille ». Chaque colonne compte des **familles** (en milliers) : c'est le **nombre de familles selon leur nombre d'enfants**, et la hauteur est le **nombre total de familles** ayant au moins un enfant mineur.



Chaque colonne vaut 100 % : on compare des structures.

Colonnes empilées à 100 % : chaque année vaut 100 %, on compare des structures

Le diagramme empilé à 100 % ramène chaque colonne à 100 % : cela **revient à prendre les fréquences et non les effectifs**, année par année. Il sert à comparer des **structures** dans le temps — la part des familles de 3 enfants baisse de 14,2 % à 12,1 % —, mais **il ne montre plus les effectifs** : il ne dit pas combien il y a de familles.

EXEMPLE CHIFFRÉ — COMMENT A ÉTÉ CALCULÉ LE CHIFFRE 12,6 ? (QUESTION DE LA DIAPOSITIVE 30)

C'est la **fréquence** des familles de **3 enfants** en **2017** : $f = 1\,012,2 / 8\,014,7 = 0,1263$, soit **12,6 %**. **Phrase de lecture** : « En 2017, en France hors Mayotte, 12,6 % des familles ayant au moins un enfant mineur ont trois enfants mineurs. »

PIÈGE FRÉQUENT — UN GRAPHIQUE N'EST PAS TOUJOURS LA TRADUCTION DU TABLEAU VOISIN

La diapositive 31 présente un diagramme empilé à 100 % comme ayant « **le même contenu informationnel** » que le tableau de 1990-2023. **C'est faux** : ses années sont 1975, 1982, 1990, 1999 et 2008, et il compte **toutes les familles**, avec la modalité « **0 enfant** » — ce sont d'autres données (sa colonne 2008 reprend le tableau de la diapositive 22 : 48,0 ; 22,3 ; 20,1 ; 7,2 ; 2,3). **Le réflexe** : avant de commenter un graphique, vérifie ses années, son champ et ses modalités.

Tableaux et graphiques : des outils de communication

Présenter des données sous forme de tableau ou de graphique sert à **informer** : **donner une forme et une signification** à des données, le plus souvent numériques et brutes. Les tableaux et les graphiques **produisent de l'information** : ce sont des **outils de communication**, qu'il faut **choisir et intituler à bon escient** pour que l'information utile passe.

MÉTHODE — LES RÈGLES D'UN TABLEAU OU D'UN GRAPHIQUE QUI INFORME (COURS)

1. **Des intitulés précis** — pas de noms de variables ou de modalités obscurs (« NBENF_M » → « Nombre d'enfants mineurs »).
2. **Lisible par un non-spécialiste**.
3. **Compréhension immédiate**, ou simplifiée au maximum ; si c'est complexe, une **note de lecture** en bas du tableau.
4. **Indiquer les unités de mesure, la population, les choix méthodologiques** — et la **source**.

Le titre complet dit **quoi** (le caractère), **qui** (la population), **où et quand** : « Répartition des familles selon le nombre d'enfants mineurs, France hors Mayotte, de 1990 à 2023 (en milliers) ». **La note de lecture** traduit une case en phrase : « Lecture : en 2017, 12,6 % des familles ayant au moins un enfant mineur ont trois enfants mineurs. »

POINT D'EXAMEN — CONCLUSION DU CHAPITRE

Présenter la distribution d'un caractère en **effectifs**, en **fréquences** ou en **fréquences cumulées** est souvent la **première étape** des traitements de statistique descriptive. Le chapitre 2 part de là pour **résumer** cette distribution en quelques nombres.

3 — Pièges et points bonus

Les confusions qui coûtent des points

Ne confonds pas...	Ce qui est juste
Population et unité statistique	L'ensemble étudié (toutes les infractions de 2024) contre un de ses éléments (une infraction)
Unité statistique et personne interrogée	L'unité est ce sur quoi porte chaque valeur : une famille, un logement, un match, une infraction — pas toujours une personne
Caractère et modalité	La variable observée (le type d'atteinte) contre une de ses valeurs (vol de vélo)
Nominale et ordinale	Aucun ordre qui ait un sens (nationalité) contre un ordre qui a un sens (satisfaction)
Discrète et continue	Un comptage, des valeurs isolées (nombre d'enfants) contre une mesure, toutes les valeurs d'un intervalle (taille)
Qualitative codée en chiffres et quantitative	Une échelle de 1 à 5 ou un code postal restent qualitatifs : leur moyenne n'a pas de sens concret
Série brute et distribution	Une ligne par individu contre une ligne par modalité
Effectif et fréquence	Un nombre d'individus (n_k) contre une proportion ($f_k = n_k / N$)
Fréquence et fréquence cumulée	« 20,1 % ont 2 enfants » contre « 90,4 % ont 2 enfants ou moins »

Ne confonds pas...	Ce qui est juste
Somme des fréquences et dernière fréquence cumulée	Les deux valent 1, mais la somme des fréquences cumulées ne vaut rien de particulier
Groupement par catégorie et par année	L'évolution de chaque catégorie contre la structure de chaque année
Empilé et empilé à 100 %	Des effectifs, qui montrent les totaux contre des fréquences, qui montrent les structures
Statistique descriptive et inférentielle	Décrire les données observées contre déduire des propriétés d'une population à partir d'un échantillon

Si tu lis autre chose ailleurs : les erreurs des sources, corrigées

On lit dans les supports...	Ce qui est exact
La série brute des 87 étudiants (diapositive 17)	Elle compte 10 fois « 0 » et 24 fois « 2 » ; le tableau et la série ordonnée, 11 et 23 : c'est le tableau qu'on retient
« Enquête menée auprès de 17132 familles » (diapositive 22) ; « taille pop = 17132 »	Des milliers : 17 132 milliers de familles, soit 17,1 millions, en 2008
« L'illustration de la diapo 21 » (diapositive 23)	C'est la diapositive 22
La hauteur de l'empilement « correspond à l'ensemble des enfants » (diapositive 29)	Au nombre total de familles ayant au moins un enfant mineur
Le diagramme de la diapositive 31 a « le même contenu informationnel que le tableau précédent »	Non : autres années (1975-2008), familles avec ou sans enfant, fréquences
La répartition par âge d'obtention du bac totalise 100 % (planche de TD, exercice 3)	Elle totalise 100,6 % : incohérence de la source, à signaler

Ce que les correcteurs récompensent

- **Les éléments statistiques identifiés d'abord**, dans l'ordre : population (qui, où, quand), unité, taille N , caractère, type **et** sous-type, nombre de modalités.
- **Une justification du type** en une demi-phrase : « discrète, car elle résulte d'un comptage » ; « ordinale, car les modalités se rangent de la plus mauvaise à la meilleure ».
- **La formule écrite avant le calcul** ($f_k = n_k / N$, $F_k = F_{k-1} + f_k$), puis le calcul posé, puis le résultat avec son unité.
- **Une phrase de lecture complète** : qui, où, quand, combien — et « ou moins » pour une fréquence cumulée.
- **Un diagramme propre** : titre complet, axes nommés avec unités, échelle indiquée, source ; les modalités d'effectif nul d'une variable discrète figurent sur l'axe.
- **L'esprit critique** : repérer qu'un tableau est en milliers, qu'un total ne tombe pas juste, qu'un effectif calculé à partir d'un échantillon ne vaut pas pour toute la population.

4 — Ancrage mémoriel

4.1 — Fiche de synthèse


L'essentiel à savoir par cœur	
L'étude	Décider → s'informer → étudier · 6 étapes : problématique · choix des données (qui ?) · méthode de recueil (expérimentation, observation qualitative, seconde main, enquête quantitative) · campagne de mesures (combien, quand, comment ; la plus coûteuse) · traitement (présenter ch. 1, résumer ch. 2, évolutions ch. 3, croiser ch. 4) · décision (rapport = résultats + méthode ; l'information inutile est bannie ; le rapport ne décide pas) · tout est guidé par la problématique

L'essentiel à savoir par cœur	
Vocabulaire	Population : l'ensemble étudié · individus ou unités statistiques : ses éléments · taille ou effectif total N · caractère ou variable X : associe une valeur à chaque individu · modalités x_k : ses valeurs · X majuscule, x minuscule
Types	Qualitative (mots) : nominale (pas d'ordre) · ordinaire (ordre qui a un sens) · quantitative (nombres) : discrète (comptage) · continue (mesure) · piège : un code en chiffres reste qualitatif
Présenter	Série brute : 1 ligne = 1 individu · distribution : 1 ligne = 1 modalité et son effectif · trier puis compter · sans perte d'information sur la répartition
Formules	$f_k = n_k / N$ · $\sum n_k = N$ · $\sum f_k = 1$ · $F_k = f_1 + \dots + f_k = F_{k-1} + f_k$; fréquence cumulée = « ou moins », quantitatif ou ordinal seulement ; dernière $F = 100\%$
Diagrammes	Colonnes, barres, camembert (angle = $f \times 360^\circ$) · escalier des fréquences cumulées · continue en classes → histogramme (ch. 2)
Comparer	Sous-populations juxtaposées · colonnes groupées par catégorie (évolution de chaque catégorie) ou par année (structure) · empilées : totaux · empilées à 100 % : structures (= fréquences)
Communiquer	Intitulés précis · lisible par un non-spécialiste · note de lecture · unités, population, champ, méthode, source · titre = quoi, qui, où, quand
Échantillon	Statistique descriptive (décrire) ≠ inférentielle (de l'échantillon aléatoire à la population)

4.2 — Moyens mnémotechniques

Pour retenir...	Le moyen
Les six étapes	« Pour Décider, Mieux Compter, Traiter, Trancher » : Problématique, Données, Méthode de recueil, Campagne de mesures, Traitement, Trancher (la décision)
Les quatre méthodes de recueil	E-O-S-Q : Expérimenter, Observer, réutiliser la Seconde main, Questionner (enquête quantitative)
Les quatre chapitres	Présenter, Résumer, Dater, Croiser
Qualitatif ou quantitatif	« Peut-on en faire la moyenne ? » Non → qualitatif ; oui → quantitatif
Nominal ou ordinal	Nominal = Nom (une étiquette, sans rang) · Ordinal = Ordre
Discret ou continu	Discret = je Compte (des personnes, des langues) · Continu = je Mesure (avec une règle, une balance, un chronomètre)
La fréquence cumulée	F majuscule = « ou moins » : F grimpe comme un escalier jusqu'à 100 %
Groupé, empilé, 100 %	Groupé = comparer les colonnes · Empilé = comparer les totaux · 100 % = comparer les structures

4.3 — Le schéma qui relie tout



Le chapitre en un schéma : l'étude, le vocabulaire, la distribution, les diagrammes — à refaire de mémoire

Comment t'en servir : à chaque révision, redessine ce schéma sur une feuille blanche, **de mémoire** : « présenter » au centre, puis les cinq blocs, puis, dans chaque bloc, tout ce que tu peux accrocher — les six étapes, les définitions, les formules, les types de diagrammes et ce qu'ils montrent. Compare ensuite avec le modèle et complète en couleur ce qui manquait.

5 — Teste-toi

Fais tout ce test sur une feuille, **sans regarder le cours**. Le corrigé est **à la fin du document**, dans la partie « Corrigés », sur une page à part : ne la lis qu'après. En statistiques, l'examen est fait d'exercices : le QCM vérifie que tu sais le cours ; les exercices des niveaux 2 à 4 te mettent en condition d'examen. Chaque question renvoie à sa section (§).

Niveau 1 — QCM

Une seule bonne réponse par question.

1. Dans quel ordre se déroule une étude statistique ? (§ 2.1)

- a) problématique → méthode de recueil → choix des données → campagne de mesures → traitement → décision
- b) problématique → choix des données → méthode de recueil → campagne de mesures → traitement → décision
- c) choix des données → problématique → traitement → méthode de recueil → campagne de mesures → décision
- d) méthode de recueil → traitement → problématique → décision → campagne de mesures → choix des données

2. Qu'est-ce qui guide tous les choix d'une étude statistique ? (§ 2.1)

- a) le coût de l'enquête
- b) la taille de la population
- c) le type de problématique
- d) la méthode de recueil

3. Observer en profondeur un petit nombre d'individus, c'est : (§ 2.1)

- a) une enquête qualitative (observation)
- b) une enquête quantitative
- c) une expérimentation

— **d)** utiliser des données de seconde main

4. La méthode de recueil la plus coûteuse est : (§ 2.1)

- **a)** l'observation
- **b)** les données de seconde main
- **c)** le rapport statistique
- **d)** l'enquête quantitative

5. Dans le tableau des infractions de 2024, l'unité statistique est : (§ 2.1)

- **a)** une personne victime
- **b)** un type d'atteinte
- **c)** une infraction
- **d)** la France

6. Une variable statistique est : (§ 2.1)

- **a)** l'ensemble étudié
- **b)** le nombre d'individus
- **c)** une valeur prise par un individu
- **d)** une application qui associe une valeur à chaque individu

7. La nationalité est une variable : (§ 2.1)

- **a)** qualitative nominale
- **b)** qualitative ordinale
- **c)** quantitative discrète
- **d)** quantitative continue

8. La qualité d'un service (« mauvaise », « plutôt mauvaise », « plutôt bonne », « très bonne ») est une variable : (§ 2.1)

- **a)** qualitative nominale
- **b)** qualitative ordinale
- **c)** quantitative discrète
- **d)** quantitative continue

9. Le nombre de langues parlées est une variable : (§ 2.1)

- **a)** qualitative ordinale
- **b)** quantitative continue
- **c)** qualitative nominale
- **d)** quantitative discrète

10. Une satisfaction notée de 1 à 5 est une variable : (§ 2.1)

- **a)** quantitative discrète, puisque ses modalités sont des nombres
- **b)** quantitative continue
- **c)** qualitative ordinale codée en chiffres
- **d)** qualitative nominale

11. Le poids d'un nouveau-né est une variable : (§ 2.1)

- **a)** quantitative continue
- **b)** quantitative discrète
- **c)** qualitative ordinale
- **d)** qualitative nominale

12. Déduire des propriétés d'une population à partir d'un échantillon aléatoire relève : (§ 2.1)

- **a)** de la statistique descriptive
- **b)** de la campagne de mesures
- **c)** de la problématique

— **d)** de la statistique inférentielle

13. Dans une série brute, une ligne correspond à : (§ 2.2)

- **a)** un individu
- **b)** une modalité
- **c)** une fréquence
- **d)** une sous-population

14. Pour passer d'une série brute d'une variable quantitative à sa distribution, on : (§ 2.2)

- **a)** compte, puis trie
- **b)** trie, puis compte
- **c)** calcule les fréquences cumulées
- **d)** calcule la moyenne

15. La fréquence d'une modalité se calcule par : (§ 2.2)

- **a)** $f_k = N / n_k$
- **b)** $f_k = n_k \times N$
- **c)** $f_k = n_k / N$
- **d)** $f_k = n_k - N$

16. La somme de toutes les fréquences d'une distribution vaut : (§ 2.2)

- **a)** 1
- **b)** N
- **c)** 0
- **d)** le nombre de modalités

17. En 2008, la fréquence cumulée de la modalité « 1 enfant » vaut 70,3 %. Cela signifie que : (§ 2.2)

- **a)** 70,3 % des familles ont exactement 1 enfant
- **b)** 70,3 % des familles ont 1 enfant ou moins
- **c)** 70,3 % des familles ont 1 enfant ou plus
- **d)** 70,3 % des familles ont au moins 2 enfants

18. On peut calculer des fréquences cumulées pour : (§ 2.2)

- **a)** la couleur des yeux
- **b)** la nationalité
- **c)** le nombre d'enfants
- **d)** le lieu de résidence

19. Si $f_1 = 48,0$ %, $f_2 = 22,3$ % et $f_3 = 20,1$ %, alors F_3 vaut : (§ 2.2)

- **a)** 20,1 %
- **b)** 42,4 %
- **c)** 70,3 %
- **d)** 90,4 %

20. Dans le tableau des familles de 2008, le nombre « 17 132 » de la ligne Ensemble représente : (§ 2.2)

- **a)** 17 132 milliers de familles
- **b)** 17 132 familles interrogées
- **c)** 17 132 enfants
- **d)** 17 132 %

21. Pour suivre l'évolution de chaque catégorie de personnes écrouées d'une année à l'autre, on groupe les colonnes : (§ 2.3)

- **a)** par année
- **b)** en camembert
- **c)** en empilement à 100 %

— **d)** par catégorie

22. Un diagramme empilé à 100 % permet de comparer : (§ 2.3)

— **a)** des totaux

— **b)** des structures

— **c)** des effectifs

— **d)** des moyennes

23. Dans un camembert, une fréquence de 20 % correspond à un angle de : (§ 2.3)

— **a)** 20°

— **b)** 36°

— **c)** 72°

— **d)** 90°

24. Dans le diagramme empilé des familles de 1990 à 2023, la hauteur d'une colonne mesure : (§ 2.3)

— **a)** le nombre total de familles ayant au moins un enfant mineur

— **b)** le nombre total d'enfants

— **c)** 100 %

— **d)** le nombre de familles de 4 enfants ou plus

25. Le titre complet d'un tableau dit : (§ 2.3)

— **a)** seulement le caractère étudié

— **b)** le nom de l'auteur

— **c)** la formule utilisée

— **d)** quoi, qui, où et quand

Niveau 2 — Exercices types d'examen

Ce sont les quatre exercices de la planche de TD du chapitre 1 : fais-les seul avant la séance, chronomètre en main, puis corrige avec la partie « Corrigés », à la fin du document.

Exercice 1 — Identifier les types de variables (planche, exercice 1 ; § 2.1)

Précisez le type et le sous-type de chaque caractère : revenu annuel ; sexe ; situation matrimoniale ; lieu de résidence ; poids ; taille ; nationalité ; couleur des yeux ; nombre de langues parlées ; fréquence de consommation d'un bien.

Exercice 2 — Les éléments d'une étude statistique (planche, exercice 2 ; § 2.1)

Pour chaque sujet d'étude, précisez l'unité statistique, le caractère étudié et son type : **a)** le temps de jeu effectif (en minutes) dans les matchs de la Coupe du monde de rugby 2023 ; **b)** l'absentéisme (en jours) des salariés de Google en 2023 ; **c)** la préférence pour les fraises Tagada dans une école maternelle.

Exercice 3 — Manier les représentations d'une variable (planche, exercice 3 ; § 2.2 et 2.3)

L'enquête « Conditions de vie des étudiants 2020 » de l'Observatoire de la vie étudiante (OVE) donne la répartition des étudiants en cours d'études au printemps 2020 en France selon l'âge d'obtention du bac. Champ : ensemble des répondants ($n = 60\,014$).

Âge d'obtention du bac	Moins de 18 ans	18 ans	19 ans	20 ans	21 ans	22 ans	23 ans	24 ans	25 ans	26 ans et plus
%	8,7	68,3	15,8	3,8	1,3	0,7	0,4	0,2	0,2	1,2

1. Quelle est la population étudiée ? L'unité statistique ?
2. Quel est le caractère étudié ? Son type ? Combien y a-t-il de modalités ?
3. Proposez une question de questionnaire permettant d'observer cette variable.
4. Quel est ce tableau ? Sous quelle forme sont présentées les données ?
5. Écrivez une note de lecture à partir d'un exemple.

- Après avoir écrit la formule correspondante, calculez l'effectif de la 4^e modalité et faites une phrase. Ce chiffre correspond-il au nombre d'étudiants ayant obtenu le bac à 20 ans en 2020 en France ?
- Tracez un diagramme en colonnes des fréquences, correctement annoté, avec son échelle.

Exercice 4 — Interpréter une étude statistique (planche, exercice 4 ; § 2.2)

Votre entreprise, qui peine à recruter, vous charge d'une étude sur la qualité de l'emploi, pour identifier les postes ou les salariés pour lesquels une intervention est urgente. Quatre dimensions : la sécurité de l'emploi (le type de contrat), la souplesse dans l'organisation de son temps (Likert à 4 modalités), la qualité du soutien social (Likert de 1 : très mauvaise, 2 : plutôt mauvaise, 3 : moyenne, 4 : plutôt bonne, à 5 : très bonne) et l'autonomie décisionnelle (forte ou faible). Données recueillies et anonymisées :

Salarié	Contrat	Souplesse de l'organisation du temps	Lien social	Autonomie
1	CDI	Pas du tout souple	5	Forte
2	CDD	Plutôt souple	5	Forte
3	CDD	Plutôt souple	3	Forte
4	Intérim	Très souple	4	Faible
5	CDI	Très souple	4	Faible
6	CDI	Plutôt pas souple	5	Faible
7	CDI	Pas du tout souple	1	Faible
8	CDI	Plutôt souple	1	Faible
9	CDD	Plutôt pas souple	2	Forte
10	CDD	Très souple	2	Forte
11	CDI	Plutôt souple	3	Forte
12	CDI	Plutôt pas souple	4	Faible
13	Intérim	Plutôt pas souple	5	Faible
14	CDI	Plutôt pas souple	5	Forte
15	CDI	Très souple	4	Faible
16	CDD	Plutôt souple	4	Faible

- Identifiez la population, l'unité statistique, la taille de la population.
- De quel type de données disposez-vous : brutes ou de distribution ?
- Quelle question poseriez-vous pour chaque dimension ? Quel est le type de chaque variable ?
- Créez un tableau de répartition de la qualité du lien social.
- Calculez les fréquences cumulées et tracez le diagramme correspondant.
- Ordonnez les quatre variables en 3, 4, 5 et 2 niveaux.
- Après avoir calculé les fréquences cumulées dans chaque cas et repéré la position de la médiane, coloriez en rouge les cases situées sous la médiane.
- Au vu de l'objectif, vaut-il mieux présenter les données sous forme brute ou sous forme de distribution ? Pourquoi ?
- Si l'objectif était un suivi annuel de la qualité de l'emploi pour vos investisseurs, comment résumeriez-vous l'information ?

Niveau 3 — Questions pièges et cas transversaux

Vrai ou faux ? Justifie chaque réponse en une phrase.

- Le code postal est une variable quantitative discrète.
- Une satisfaction notée de 1 à 5 est quantitative, puisque ses modalités sont des nombres.
- On peut calculer les fréquences cumulées de la nationalité.
- F(2 enfants) = 90,4 % signifie que 90,4 % des familles ont 2 enfants.

5. La somme des fréquences cumulées vaut 1.
6. Un diagramme empilé à 100 % montre que le nombre de familles a augmenté de 1990 à 2012.
7. L'unité statistique d'une étude sur le temps de jeu des matchs de rugby est le joueur.
8. La distribution observée des effectifs perd de l'information sur la répartition de la variable.
9. Dans un diagramme en colonnes d'une variable discrète, on peut omettre les modalités d'effectif nul.
10. Un camembert convient bien pour montrer le nombre de frères et sœurs de 87 étudiants.
11. Si 20 % des étudiants du site A et 30 % de ceux du site B viennent en voiture, plus d'étudiants viennent en voiture sur le site B.
12. Une enquête qualitative porte sur un grand nombre d'individus, interrogés par questionnaire.

Niveau 4 — Sujet au format de l'examen

OBJECTIFS — LE CADRE

Le format réel de l'épreuve n'est pas encore connu : aucune annale ni modalité n'a été reçue. Ce sujet suit le format des planches de TD — exercices sur données, calculs posés, phrases d'interprétation —, avec calculatrice, sans document. Les données sont **fictives**. Il sera recalé sur les annales dès que tu les auras envoyées.

En trois pomodoros : **P1** l'exercice 1 ; **P2** les exercices 2 et 3 ; **P3** la correction au barème. Les examens blancs, eux, se feront d'une traite, à la durée réelle.

Exercice 1 — Les TD manqués (9 points). On a relevé, pour les 40 étudiants d'un groupe de TD, le nombre de séances de TD manquées au premier semestre :

```
0 1 0 2 0 1 3 0 1 0
2 0 1 4 0 0 1 2 5 1
0 3 1 0 2 1 0 4 0 2
1 0 3 2 1 0 4 1 2 3
```

1. Identifiez la population, l'unité statistique, la taille de la population, le caractère, son type et son sous-type. Sous quelle forme les données sont-elles présentées ? (2 points)
2. Construisez le tableau de distribution : effectifs, fréquences, fréquences cumulées. Écrivez les formules utilisées. (4 points)
3. Écrivez une phrase de lecture pour la fréquence de la modalité 0 et pour la fréquence cumulée de la modalité 1. (1 point)
4. Tracez le diagramme en colonnes des effectifs, correctement annoté. (2 points)

Exercice 2 — Venir à la faculté (8 points). Une université interroge ses étudiants de deux sites sur leur mode de transport principal (données fictives).

Mode de transport principal	Site A	Site B
Bus	180	50
Tramway	60	100
Voiture	80	75
Vélo ou marche	80	25
Ensemble	400	250

1. Identifiez la population, les sous-populations, le caractère, son type et ses modalités. (2 points)
2. Calculez la répartition en fréquences de chaque site. (2 points)
3. Quel diagramme choisir pour comparer les habitudes des deux sites ? Justifiez. (2 points)
4. « Les étudiants du site B viennent plus souvent en voiture : il y a donc plus de voitures d'étudiants sur le site B. » Discutez. (2 points)

Exercice 3 — Questions de cours (3 points). 1. Citez dans l'ordre les six étapes d'une étude statistique. (1,5 point) 2. Donnez le type et le sous-type de : l'ancienneté d'un salarié en années, la catégorie socio-professionnelle, la mention au bac. (1,5 point)

6 — Auto-évaluation

Si tu ne sais pas répondre à ces questions sans regarder, tu ne maîtrises pas encore le chapitre.

1. Récite les six étapes d'une étude statistique, dans l'ordre, et dis ce que décide chacune.
2. Cite les quatre méthodes de recueil et celle qui coûte le plus cher.
3. Dis pourquoi « une enquête de satisfaction » est une demande trop vague.
4. Définis population, unité statistique, taille, caractère et modalité, puis repère-les dans le tableau des infractions de 2024.
5. Classe dix variables de ton choix dans les quatre sous-types, en justifiant chacune.
6. Explique pourquoi une note de satisfaction de 1 à 5 est qualitative.
7. Transforme une série brute de 20 valeurs en distribution complète, avec formules et vérifications.
8. Écris les formules de la fréquence et de la fréquence cumulée, et démontre que la somme des fréquences vaut 1.
9. Traduis en phrases une fréquence et une fréquence cumulée du tableau des familles de 2008.
10. Dis quelles variables admettent des fréquences cumulées, et pourquoi.
11. Trace de mémoire le diagramme en escalier des fréquences cumulées des familles de 2008.
12. Dis ce que montrent des colonnes groupées par catégorie, par année, un empilement, un empilement à 100 %.
13. Retrouve le calcul du 12,6 % et écris sa phrase de lecture.
14. Donne les quatre règles d'un tableau qui informe et le contenu d'un titre complet.

7 — Révision en marchant

1. **Pourquoi une étude statistique ?** → Pour décider : décider, s'informer, étudier.
2. **La première étape ?** → Préciser le type de problématique.
3. **Qu'est-ce qui guide tous les choix ?** → La problématique.
4. **La deuxième étape ?** → Choisir les données à observer : qui ?
5. **Les quatre méthodes de recueil ?** → Expérimentation, observation qualitative, seconde main, enquête quantitative.
6. **La méthode la plus coûteuse ?** → L'enquête quantitative.
7. **La campagne de mesures fixe quoi ?** → Combien, quand et comment enquêter.
8. **Les quatre traitements ?** → Présenter, résumer, étudier les évolutions, croiser.
9. **Qui décide, le rapport ?** → Non : la décision est politique.
10. **La population ?** → L'ensemble étudié.
11. **Une unité statistique ?** → Un élément de la population.
12. **N ?** → La taille de la population, l'effectif total.
13. **Une variable statistique ?** → Une application qui associe une valeur à chaque individu.
14. **Les modalités ?** → Les valeurs prises par la variable.
15. **Les deux types de variables ?** → Qualitative et quantitative.
16. **Nominale ?** → Aucun ordre qui ait un sens.
17. **Ordinale ?** → Un ordre qui a un sens.
18. **Discrète ?** → Un comptage.
19. **Continue ?** → Une mesure.
20. **Une note de 1 à 5 ?** → Qualitative ordinale codée en chiffres.
21. **Série brute ?** → Une ligne par individu.
22. **Distribution ?** → Une ligne par modalité, avec son effectif.
23. **De la série brute à la distribution ?** → Trier, puis compter.
24. **La fréquence ?** → L'effectif divisé par l'effectif total.
25. **La somme des fréquences ?** → 1, soit 100 %.
26. **La fréquence cumulée ?** → La part des individus qui ont cette modalité ou moins.
27. **F de proche en proche ?** → La précédente plus la fréquence de la ligne.
28. **Fréquences cumulées de la nationalité ?** → Impossible : variable nominale.

29. **70,3 % en 2008 ?** → Les familles ayant 1 enfant ou moins.
30. **17 132 dans le tableau des familles ?** → Des milliers de familles.
31. **Le graphique des fréquences cumulées ?** → Un escalier jusqu'à 100 %.
32. **L'angle d'une part de camembert ?** → La fréquence fois 360 degrés.
33. **Colonnes groupées par catégorie ?** → L'évolution de chaque catégorie.
34. **Colonnes groupées par année ?** → La structure de chaque année.
35. **Empilé à 100 % ?** → Des structures, plus d'effectifs.
36. **La hauteur d'un empilement ?** → L'effectif total de la sous-population.
37. **Un titre complet ?** → Quoi, qui, où, quand, et l'unité.
38. **Statistique inférentielle ?** → De l'échantillon aléatoire à la population.

Annexe A — Glossaire du chapitre

Terme	En une phrase	Définition académique
Étude statistique	Recueillir et traiter des données pour décider	Démarche en six étapes — problématique, choix des données, méthode de recueil, campagne de mesures, traitement, décision — guidée par la problématique
Problématique	La question à laquelle l'étude doit répondre	Question précise du donneur d'ordre, liée à une décision, qui guide tous les choix de l'étude
Expérimentation	Provoquer une variation pour en mesurer l'effet	Méthode de recueil fondée sur un protocole permettant l'observation directe de l'impact d'une variable de contrôle sur une variable d'observation
Enquête qualitative	Observer en profondeur quelques individus	Méthode de recueil par observation extensive d'un petit nombre d'individus
Données de seconde main	Des données déjà produites par d'autres	Informations disponibles par ailleurs (Insee, administrations, entreprises), réutilisées pour l'étude
Enquête quantitative	Interroger beaucoup d'individus par questionnaire	Collecte sur mesure de l'information utile, par questionnaire, auprès d'un grand nombre d'individus ; l'option la plus coûteuse
Campagne de mesures	Organiser la collecte	Étape qui fixe combien d'individus enquêter, quand et comment
Population	Ce qu'on étudie, dans son ensemble	Ensemble (au sens mathématique) sur lequel porte l'étude statistique
Individu (unité statistique)	Un élément de la population	Élément de la population sur lequel on observe le caractère : une personne, une famille, un logement, une infraction...
Taille de la population	Le nombre d'individus	Nombre d'unités statistiques de la population, ou effectif total, noté N
Variable statistique (caractère)	Ce qu'on observe sur chaque individu	Application qui associe à chaque individu de la population une valeur (une modalité)
Modalité	Une valeur possible de la variable	Valeur prise par une variable statistique ; notée en minuscule, x indicé
Variable qualitative	Des modalités qui sont des mots	Variable dont les modalités ne sont pas des nombres (elles peuvent être codées par des nombres)
Variable nominale	Des mots sans ordre	Variable qualitative dont les modalités ne peuvent pas être classées selon un ordre qui a du sens
Variable ordinale	Des mots qui se rangent	Variable qualitative dont les modalités peuvent être classées selon un ordre qui a du sens
Variable quantitative	Des modalités qui sont des nombres	Variable dont les modalités sont des nombres mesurant une quantité
Variable discrète	On compte	Variable quantitative dont les modalités relèvent du comptage (ensemble dénombrable)

Terme	En une phrase	Définition académique
Variable continue	On mesure	Variable quantitative dont les modalités relèvent de la mesure (ensemble non dénombrable)
Série brute	Une valeur par individu	Liste des valeurs du caractère pour chaque individu, dans l'ordre du recueil (raw data)
Série ordonnée	La série brute triée	Série brute dont les valeurs sont rangées de la plus petite à la plus grande
Distribution observée des effectifs	Chaque modalité avec son nombre d'individus	Association à chaque modalité d'une variable statistique de l'effectif observé correspondant
Effectif	Combien d'individus ont cette modalité	Nombre d'individus présentant une modalité donnée du caractère statistique, noté n
Fréquence	La part des individus qui ont cette modalité	Proportion d'individus présentant une modalité donnée dans la population totale : $f = n / N$
Fréquence cumulée	La part des individus qui ont cette modalité ou moins	Proportion d'individus présentant une modalité donnée ou inférieure : $F(k) = f(1) + \dots + f(k)$; variables quantitatives ou ordinales
Sous-population	Une partie de la population, définie par une autre variable	Sous-ensemble de la population défini selon une autre variable (année, zone géographique...), pour lequel on observe une distribution distincte
Diagramme en colonnes groupées	Des colonnes côte à côte, par groupe	Représentation juxtaposant les distributions de plusieurs sous-populations, groupées par modalité ou par sous-population selon la comparaison recherchée
Diagramme empilé	Des colonnes superposées	Représentation où les effectifs des modalités sont superposés : la hauteur de chaque colonne est l'effectif total de la sous-population
Diagramme empilé à 100 %	Des colonnes ramenées à 100 %	Diagramme empilé des fréquences de chaque sous-population, qui permet de comparer des structures
Note de lecture	Une case du tableau traduite en phrase	Phrase placée sous un tableau ou un graphique, qui explique comment lire une de ses valeurs
Échantillon	Une partie tirée de la population	Sous-ensemble de la population, tiré aléatoirement, sur lequel porte l'observation quand l'information exhaustive manque
Statistique descriptive	Décrire les données observées	Ensemble des méthodes qui présentent et résument les données observées
Statistique inférentielle	De l'échantillon à la population	Ensemble des techniques qui déduisent des éléments d'une population à partir d'un échantillon aléatoire

Annexe B — Tableau de couverture des sources

Chaque élément des sources : ✓ traité · △ traité et corrigé · ✕ absent des sources.

N°	Élément des sources	État	Où c'est traité
1	Diapo 1 — titre du chapitre 1	✓	§ 1
2	Diapo 2 — contenu et plan du chapitre (3 parties)	✓	§ 1, § 2.1 à 2.3
3	Diapo 3 — besoin de décider, d'information, étude ; quatre exemples	✓	§ 2.1
4	Diapo 4 — schéma des six étapes	✓	§ 2.1 — schéma redessiné
5	Diapo 5 — étape 1, la problématique ; l'hypermarché	✓	§ 2.1
6	Diapo 6 — étape 2, le choix des données : qui ?	✓	§ 2.1
7	Diapo 7 — étape 3, les quatre méthodes de recueil	✓	§ 2.1 — variables de contrôle et d'observation expliquées
8	Diapo 8 — étape 4, la campagne de mesures	✓	§ 2.1

N°	Élément des sources	État	Où c'est traité
9	Diapo 9 — étape 5, le traitement ; les quatre chapitres	✓	§ 1, § 2.1
10	Diapo 10 — étape 6, la décision et le rapport	✓	§ 2.1
11	Diapo 11 — le vocabulaire : population, individus, taille, variable, modalités ; notations	✓	§ 2.1
12	Diapo 12 — les infractions de 2024 : identifier les éléments	✓	§ 2.1 — exercice résolu, total vérifié
13	Diapo 13 — deux types, quatre sous-types ; le piège du codage	✓	§ 2.1
14	Diapo 14 — illustrations : sexe, qualité du service, nombre d'enfants, taille	✓	§ 2.1
15	Diapo 15 — série brute et distribution ; trier puis compter	✓	§ 2.2
16	Diapo 16 — distribution observée des effectifs ; effectif ; sans perte d'information	✓	§ 2.2
17	Diapo 17 — la série brute des 87 étudiants	⚠	§ 2.2 — 10 « 0 » et 24 « 2 » au lieu de 11 et 23
18	Diapo 18 — la série ordonnée	✓	§ 2.2
19	Diapo 19 — le tableau de distribution	✓	§ 2.2 — somme vérifiée
20	Diapo 20 — le diagramme en colonnes	✓	§ 2.2 — redessiné, modalités nulles comprises
21	Diapo 21 — fréquence, camembert, barres, fréquence cumulée	✓	§ 2.2 — angle du camembert reconstruit ; ordinales ajoutées
22	Diapo 22 — les familles selon le nombre d'enfants	⚠	§ 2.2 — des milliers de familles, en 2008
23	Diapo 23 — les notations formelles	⚠	§ 2.2 — renvoi à la diapo 22 et non 21 ; indices k et i
24	Diapo 24 — plusieurs distributions d'un même caractère	✓	§ 2.3
25	Diapo 25 — les personnes écrouées, 2020-2023	✓	§ 2.3 — totaux vérifiés ; catégories expliquées
26	Diapo 26 — colonnes groupées par catégorie	✓	§ 2.3 — redessiné
27	Diapo 27 — colonnes groupées par année	✓	§ 2.3 — redessiné
28	Diapo 28 — les familles de 1990 à 2023	✓	§ 2.3 — écarts d'arrondi de 1999 et 2007 signalés
29	Diapo 29 — le diagramme empilé	⚠	§ 2.3 — il compte des familles, pas des enfants
30	Diapo 30 — l'empilé à 100 % ; le chiffre 12,6	✓	§ 2.3 — calcul et phrase de lecture
31	Diapo 31 — un empilé à 100 % présenté comme équivalent au tableau	⚠	§ 2.3 — autres données : 1975-2008, familles avec ou sans enfant
32	Diapo 32 — tableaux et graphiques, outils de communication ; les règles	✓	§ 2.3
33	Diapo 33 — conclusion ; échantillon ; statistique inférentielle	✓	§ 2.1, § 2.3
34	Notes du tableau, séance 1 — les infractions annotées : k, n _k , N, population, X, 8 modalités	✓	§ 2.1
35	Notes du tableau, séance 1 — les familles : F ₁ , F ₂ , F ₃ , f ₂ = 22,3 %, propriétés	✓	§ 2.2
36	Planche de TD, exercice 1 — les types de variables	✓	§ 5, niveau 2 — corrigé à la fin
37	Planche de TD, exercice 2 — les éléments d'une étude	✓	§ 5, niveau 2 — corrigé à la fin
38	Planche de TD, exercice 3 — l'âge d'obtention du bac	⚠	§ 5, niveau 2 — corrigé à la fin ; la somme des pourcentages vaut 100,6 %
39	Planche de TD, exercice 4 — la qualité de l'emploi	✓	§ 5, niveau 2 — corrigé à la fin

Corrigés

Ne lis cette partie qu'après avoir fait le test en entier, sur une feuille. Pour chaque erreur, relis la section indiquée, puis refais la question le lendemain.

Corrigé du niveau 1 — QCM

Question	Réponse	Pourquoi
1	b	L'ordre du schéma : problématique, puis données (qui ?), méthode de recueil (comment ?), campagne de mesures, traitement, décision.
2	c	Tous les choix — données, méthode, mesures, traitement — dépendent de la problématique : les flèches de retour du schéma.
3	a	L'observation, ou enquête qualitative, étudie de façon extensive un petit nombre d'individus.
4	d	C'est un travail sur mesure : combien, quand, comment enquêter — l'option la plus coûteuse.
5	c	Chaque valeur est relevée sur une infraction : l'unité statistique n'est pas toujours une personne.
6	d	Définition du cours : une application qui associe à chaque individu une valeur (une modalité).
7	a	Des mots, sans ordre qui ait un sens.
8	b	Des mots qui se rangent de la plus mauvaise à la meilleure.
9	d	Un comptage : 1, 2, 3 langues.
10	c	Un mot valant un chiffre : la moyenne de 1 à 5 n'a pas de sens concret.
11	a	Une mesure (en kilogrammes), qui peut prendre toutes les valeurs d'un intervalle.
12	d	L'inférence va de l'échantillon aléatoire à la population ; la statistique descriptive décrit les données observées.
13	a	Une ligne par individu ; la distribution, elle, a une ligne par modalité.
14	b	On trie les valeurs (série ordonnée), puis on compte les effectifs.
15	c	La fréquence est une proportion : l'effectif de la modalité divisé par l'effectif total.
16	a	$\Sigma f = \Sigma n / N = N / N = 1$, soit 100 %.
17	b	Une fréquence cumulée se lit « ou moins » ; exactement 1 enfant, c'est la fréquence : 22,3 %.
18	c	Il faut des modalités qui se rangent : quantitatives ou ordinales ; les trois autres sont nominales.
19	d	$48,0 + 22,3 + 20,1 = 90,4 \%$, ou $F_2 + f_3 = 70,3 + 20,1$.
20	a	Les effectifs sont en milliers : 17,1 millions de familles, en 2008.
21	d	Grouper par catégorie met côte à côte les années de chaque catégorie ; grouper par année montre la structure de chaque année.
22	b	Chaque colonne vaut 100 % : on compare des parts, plus des effectifs.
23	c	$\text{Angle} = f \times 360^\circ = 0,20 \times 360^\circ = 72^\circ$.
24	a	L'empilement compte des familles (en milliers), pas des enfants — l'erreur de la diapositive 29.
25	d	Quoi (le caractère), qui (la population), où et quand — et l'unité.

Ton score : 23 bonnes réponses ou plus sur 25, le cours est su ; de 18 à 22, relis les sections de tes erreurs ; moins de 18, reprends le cycle APPRENDRE des sections concernées.

Corrigé du niveau 2 — Exercices types d'examen

Exercice 1 — Identifier les types de variables

CORRIGÉ — TYPES ET SOUS-TYPES, JUSTIFIÉS

Caractère	Type et sous-type	Justification
Revenu annuel	Quantitatif continu	Une mesure en euros ; on le traite comme continu même s'il s'arrête au centime
Sexe	Qualitatif nominal	Des mots, sans ordre qui ait un sens
Situation matrimoniale	Qualitatif nominal	Célibataire, marié, pacsé, divorcé, veuf : aucun ordre
Lieu de résidence	Qualitatif nominal	Des noms de lieux
Poids	Quantitatif continu	Une mesure
Taille	Quantitatif continu	Une mesure
Nationalité	Qualitatif nominal	Aucun ordre
Couleur des yeux	Qualitatif nominal	Aucun ordre
Nombre de langues parlées	Quantitatif discret	Un comptage : 1, 2, 3...
Fréquence de consommation d'un bien	Qualitatif ordinal s'il est relevé par « jamais, rarement, souvent, toujours » ; quantitatif discret s'il est relevé en nombre de fois par semaine	Dis comment tu la mesures : c'est ce qui rapporte le point

Exercice 2 — Les éléments d'une étude statistique

CORRIGÉ — UNITÉ, CARACTÈRE, TYPE


Sujet	Unité statistique	Caractère	Type
a) Rugby	Un match de la Coupe du monde 2023	Le temps de jeu effectif, en minutes	Quantitatif continu (une durée mesurée)
b) Absentéisme	Un salarié de Google en 2023	Le nombre de jours d'absence en 2023	Quantitatif discret (un comptage de jours)
c) Fraises Tagada	Un enfant de l'école maternelle	La préférence pour les fraises Tagada	Qualitatif : nominal si la réponse est oui ou non ; ordinal si on la relève sur une échelle (« pas du tout » à « beaucoup »)

Le piège du **a)** : l'unité n'est pas un joueur, mais **un match** — c'est sur chaque match qu'on relève un temps de jeu.

Exercice 3 — Manier les représentations d'une variable

CORRIGÉ — LES SEPT RÉPONSES

1. **Population** : les étudiants en cours d'études en France au printemps 2020 — plus précisément, le **champ** est celui des **60 014 répondants** à l'enquête. **Unité statistique** : un **étudiant** (répondant).
2. **Caractère** : l'**âge d'obtention du bac**. **Type** : **quantitatif** ; par nature continu (un âge est une durée), il est relevé ici **en années entières** et se présente donc comme **discret**, avec deux classes ouvertes aux extrémités (« moins de 18 ans », « 26 ans et plus »). **10 modalités**.
3. « **À quel âge avez-vous obtenu votre baccalauréat ?** » — réponse en années.
4. C'est un **tableau de distribution des fréquences** (une répartition en pourcentage) : les données sont présentées **sous forme de distribution**, pas de série brute.
5. **Note de lecture** : « Parmi les étudiants interrogés au printemps 2020, **68,3 %** ont obtenu leur bac à **18 ans**. »
6. **Formule** : $f_k = n_k / N$, donc $n_k = f_k \times N$. **Calcul** : $n_4 = 0,038 \times 60\,014 = 2\,280,5$, soit **environ 2 281 étudiants**. **Phrase** : « Environ 2 281 des 60 014 étudiants interrogés en 2020 ont obtenu leur bac à 20 ans. » **Non**, ce n'est pas le nombre d'étudiants ayant obtenu le bac à 20 ans **en 2020** en France, pour deux raisons : **a)** il ne compte que les **répondants** à l'enquête, pas tous les étudiants de France ; **b)** il s'agit de l'**âge** auquel ils ont eu leur bac, **quelle que soit l'année** — beaucoup l'ont obtenu avant 2020. De plus, le résultat est **approché** : la fréquence est arrondie au dixième, et **la somme des pourcentages du tableau vaut 100,6 %**, ce que les arrondis seuls ne peuvent pas expliquer (au plus 0,5 point pour dix valeurs) — une incohérence de la source, à signaler en une phrase.
7. Le diagramme :



Étudiants en cours d'études au printemps 2020, répondants à l'enquête ($n = 60\,014$)
Échelle : 1 cm pour 10 % en ordonnée. Source : OVE, Conditions de vie des étudiants 2020.

Corrigé de la question 7 : diagramme en colonnes des fréquences, avec son titre, ses axes, son échelle et sa source

Titre : « Répartition des étudiants en cours d'études au printemps 2020 selon l'âge d'obtention du bac (en %) » · **axes** : l'âge en abscisse, la fréquence en ordonnée · **échelle** : par exemple 1 cm pour 10 % · **source** : OVE, Conditions de vie des étudiants 2020.


Exercice 4 — Interpréter une étude statistique

CORRIGÉ — LES NEUF RÉPONSES

1. **Population** : les **16 salariés** de l'entreprise couverts par l'étude · **unité statistique** : un salarié · **taille** : $N = 16$.
2. Des **données brutes** : une ligne par salarié.
3. Une question par dimension, et le type :
 - **sécurité** : « Quel est votre type de contrat ? CDI, CDD, intérim » — qualitative, **ordinaire** une fois rangée par sécurité croissante ;
 - **souplesse** : « Diriez-vous que l'organisation de votre temps de travail est pas du tout souple, plutôt pas souple, plutôt souple ou très souple ? » — qualitative **ordinaire** ;
 - **soutien social** : « Comment jugez-vous la qualité du soutien de vos collègues et de votre hiérarchie, de 1 (très mauvaise) à 5 (très bonne) ? » — qualitative **ordinaire codée en chiffres** (le piège : elle n'est pas quantitative) ;
 - **autonomie** : « Votre autonomie de décision est-elle forte ou faible ? » — qualitative **ordinaire** à deux niveaux.

4. et 5. Répartition de la qualité du lien social — formule $f_k = n_k / 16$, puis $F_k = F_{k-1} + f_k$:

Lien social x_k	Salariés	Effectif n_k	Fréquence f_k	Fréquence cumulée F_k
1	7, 8	2	12,5 %	12,5 %
2	9, 10	2	12,5 %	25 %
3	3, 11	2	12,5 %	37,5 %
4	4, 5, 12, 15, 16	5	31,25 %	68,75 %
5	1, 2, 6, 13, 14	5	31,25 %	100 %
Ensemble		16	100 %	



Qualité du lien social (échelle de 1 à 5) — 16 salariés

Lecture : $F(3) = 37,5\%$ — 37,5 % des salariés jugent la qualité de leur lien social à 3 ou moins.

Corrigé de la question 5 : le diagramme en escalier des fréquences cumulées

- 6. Les quatre variables ordonnées**, du moins bon au meilleur : contrat — **intérim** < **CDD** < **CDI** (3 niveaux) ; souplesse — **pas du tout souple** < **plutôt pas souple** < **plutôt souple** < **très souple** (4) ; lien social — **1** < **2** < **3** < **4** < **5** (5) ; autonomie — **faible** < **forte** (2).

- 7. Fréquences cumulées et position de la médiane** — la médiane est la modalité où la fréquence cumulée **atteint ou dépasse** 50 % :

Variable	Fréquences cumulées	Médiane	Sous la médiane (en rouge)
Contrat	intérim 12,5 % · CDD 43,75 % · CDI 100 %	CDI	Intérim et CDD : salariés 2, 3, 4, 9, 10, 13, 16
Souplesse	pas du tout 12,5 % · plutôt pas 43,75 % · plutôt souple 75 % · très souple 100 %	Plutôt souple	Salariés 1, 6, 7, 9, 12, 13, 14
Lien social	12,5 · 25 · 37,5 · 68,75 · 100 %	4	1, 2 et 3 : salariés 3, 7, 8, 9, 10, 11
Autonomie	faible 56,25 % · forte 100 %	Faible	Aucune case : la médiane est déjà le niveau le plus bas

Lecture pour l'objectif : le salarié **9** cumule **trois** dimensions sous la médiane (CDD, plutôt pas souple, lien social 2) : c'est la priorité ; viennent ensuite les salariés **3, 7, 10 et 13** (deux dimensions chacun).

8. Sous forme brute : l'objectif est d'**identifier des salariés** ; la distribution conserve la répartition de chaque variable mais **perd le lien entre chaque salarié et ses valeurs** — on ne saurait plus qui aider.

9. Sous forme résumée et agrégée, sans identifier personne : pour chaque dimension, la **répartition en fréquences** ou la **part de salariés sous un seuil** (part des CDI, part des organisations « souples », part d'un lien social de 4 ou 5, part d'autonomie forte), éventuellement la **médiane** du lien social, suivies **d'une année sur l'autre** (chapitre 3) — plusieurs réponses sont possibles, pourvu qu'elles soient justifiées.

Corrigé du niveau 3 — Questions pièges et cas transversaux

CORRIGÉ — VRAI OU FAUX, JUSTIFIÉ

- Faux** : c'est une **étiquette** (qualitative nominale) ; additionner deux codes postaux n'a aucun sens.
- Faux** : c'est une variable **qualitative ordinale codée en chiffres** ; « un mot valant un chiffre ».
- Faux** : la nationalité est **nominale** — ses modalités ne se rangent pas, « ou moins » n'a pas de sens.
- Faux** : 90,4 % des familles ont 2 enfants **ou moins** ; celles qui ont exactement 2 enfants sont 20,1 %.
- Faux** : c'est la somme des **fréquences** qui vaut 1 ; la **dernière** fréquence cumulée vaut 100 %.
- Faux** : il montre des **structures** (des fréquences) ; les totaux se lisent sur le diagramme **empilé** en effectifs.
- Faux** : c'est **le match** — la valeur relevée (un temps de jeu) porte sur chaque match.
- Faux** : elle conserve **toute la répartition** ; elle ne perd que le lien entre chaque individu et sa valeur (et l'ordre du recueil).
- Faux** : elles figurent sur l'axe, avec une hauteur nulle — sinon l'axe des nombres est faussé (diagramme des frères et sœurs).
- Faux** : onze modalités **ordonnées**, des parts minuscules : les **colonnes** conviennent ; le camembert sert aux variables nominales à peu de modalités.
- Pas forcément** : une fréquence n'est pas un effectif. Avec 400 étudiants sur le site A et 250 sur le site B, 20 % de 400 = **80** et 30 % de 250 = **75** : **moins** d'étudiants en voiture sur le site B.
- Faux** : c'est **l'enquête quantitative** ; l'enquête qualitative observe **un petit nombre** d'individus en profondeur.

Corrigé du niveau 4 — Sujet au format de l'examen

CORRIGÉ — CORRIGÉ ET BARÈME — EXERCICE 1

1. **Population** : les 40 étudiants du groupe de TD · **unité** : un étudiant · $N = 40$ · **caractère** : le nombre de séances de TD manquées au premier semestre · **quantitatif discret** (un comptage) · **série brute** (une valeur par étudiant). (2 points : 0,5 pour population et unité, 0,5 pour N , 1 pour le caractère et son type justifié.)
2. Formules : $f_k = n_k / N$; $F_k = F_{k-1} + f_k$. (1 point pour les formules, 3 pour le tableau juste.)

Séances manquées x_k	Effectif n_k	Fréquence f_k	Fréquence cumulée F_k
0	14	35 %	35 %
1	11	27,5 %	62,5 %
2	7	17,5 %	80 %
3	4	10 %	90 %
4	3	7,5 %	97,5 %
5	1	2,5 %	100 %
Ensemble	40	100 %	

Vérification : $14 + 11 + 7 + 4 + 3 + 1 = 40$.

3. « 35 % des étudiants du groupe n'ont manqué **aucune** séance de TD au premier semestre » ; « 62,5 % en ont manqué **une ou moins** ». (0,5 + 0,5.)
4. Six colonnes (0 à 5) de hauteurs 14, 11, 7, 4, 3, 1 ; axes nommés (« Nombre de séances manquées », « Nombre d'étudiants ») ; échelle ; titre complet : « Répartition des 40 étudiants du groupe selon le nombre de séances de TD manquées au premier semestre ». (1 point pour le tracé, 1 point pour les annotations.)

CORRIGÉ — CORRIGÉ ET BARÈME — EXERCICES 2 ET 3

Exercice 2.

1. **Population** : les 650 étudiants interrogés des deux sites · **sous-populations** : le **site A** (400) et le **site B** (250) · **caractère** : le mode de transport principal, **qualitatif nominal** · **4 modalités**. (2 points.)
2. $f_k = n_k / N_{\text{site}}$ — site A : bus **45 %**, tramway **15 %**, voiture **20 %**, vélo ou marche **20 %** · site B : bus **20 %**, tramway **40 %**, voiture **30 %**, vélo ou marche **10 %**. (1 point par site.)
3. Les deux sites n'ont pas la même taille : pour comparer des **habitudes** (des structures), il faut des **fréquences** — un diagramme **empilé à 100 %** (une colonne par site) ou des **colonnes groupées des fréquences**. Un diagramme des effectifs ferait paraître le site A plus « gros » partout. (1 point pour le choix, 1 pour la justification.)
4. **Faux raisonnement** : 30 % contre 20 %, ce sont des **fréquences** ; en **effectifs**, 75 étudiants viennent en voiture sur le site B contre **80** sur le site A. La part est plus forte sur le site B, mais le **nombre** est plus faible, car le site B est plus petit. (1 point pour l'idée, 1 pour les chiffres.)

Exercice 3.

1. Problématique → choix des données → méthode de recueil → campagne de mesures → traitement → prise de décision. (1,5 point ; 0,25 par étape bien placée.)
2. L'ancienneté en années : **quantitative** — continue par nature (une durée), discrète si on la relève en années entières (justifier) ; la CSP : **qualitative nominale** ; la mention au bac : **qualitative ordinale** (passable < assez bien < bien < très bien). (0,5 point chacune.)