

Formulaire cumulatif — Techniques statistiques

Toutes les formules de tous les chapitres, dans l'ordre du cours

Généré automatiquement à partir des encadrés « formule » des cours. 19 formule(s).

Date · 30 septembre 2026

Document de travail autonome — il remplace le support de cours original, qu'il n'est pas nécessaire de relire. Toute notion évoquée dans le cours y est définie, démontrée et illustrée.

SOMMAIRE

Chapitre 1 — Présenter pour informer

Chapitre 2 — Résumer pour informer

Chapitre 1 — Présenter pour informer

FORMULE CLÉ — FRÉQUENCE D'UNE MODALITÉ

$$f_k = \frac{n_k}{N}$$

- f_k : la **fréquence** de la modalité x_k ;
- n_k : son **effectif** ;
- N : l'**effectif total** (la taille de la population).

La fréquence d'une modalité est la **proportion d'individus** qui présentent cette modalité dans la population totale. C'est un nombre entre 0 et 1, qu'on exprime souvent **en pourcentage** (on multiplie par 100).

Propriétés : les effectifs s'additionnent pour donner l'effectif total, et les fréquences pour donner 1 :

$$\sum_{k=1}^K n_k = n_1 + n_2 + \dots + n_K = N \quad \sum_{k=1}^K f_k = f_1 + f_2 + \dots + f_K = 1 = 100 \%$$

Pourquoi la somme des fréquences vaut 1 : $\sum f_k = \sum \frac{n_k}{N} = \frac{1}{N} \sum n_k = \frac{N}{N} = 1$.

FORMULE CLÉ — FRÉQUENCE CUMULÉE

$$F_k = f_1 + f_2 + \dots + f_k = \sum_{i=1}^k f_i \quad \text{d'où} \quad F_k = F_{k-1} + f_k$$

- F_k , qu'on note aussi $F(x_k)$: la **fréquence cumulée** de la modalité x_k ;
- on l'obtient en ajoutant les fréquences **de la première modalité jusqu'à** x_k ;
- en pratique, **de proche en proche** : chaque fréquence cumulée est la précédente plus la fréquence de la ligne.

La fréquence cumulée d'une modalité est la **proportion d'individus présentant cette modalité ou une modalité inférieure**. Elle n'a de sens que si les modalités **peuvent être rangées** : variable **quantitative** ou **qualitative ordinale** — jamais nominale. La dernière vaut toujours **1 = 100 %**.

Chapitre 2 — Résumer pour informer

FORMULE CLÉ — L'AIRE D'UN RECTANGLE EST LA FRÉQUENCE DE LA CLASSE

$$\text{Aire} = \text{Base} \times \text{Hauteur} = a \times d = a \times \frac{f}{a} = f$$

- a : l'amplitude de la classe (la base du rectangle) ;
- d : la densité de la classe (sa hauteur) ;
- f : la fréquence de la classe.

Conséquence : la **somme des aires vaut 1** (100 %), puisque la somme des fréquences vaut 1 : $\sum_{k=1}^8 f_k = 1$ (séance 2). **Exemple** : pour la 4^e classe d'âge, aire = $5 \times 0,0375 = \mathbf{0,187}$ = sa fréquence ; pour la 6^e (40-50 ans), aire = $10 \times 1,68 \% = \mathbf{0,168}$.

FORMULE CLÉ — MOYENNE ARITHMÉTIQUE SUR DONNÉES BRUTES

$$m = \frac{1}{N} \sum_{i=1}^N x_i = \frac{1}{N} (x_1 + x_2 + \dots + x_N)$$

- N : le nombre d'observations ;
- x_i : la valeur de la i -ième observation — **l'indice i renvoie au numéro d'observation**, c'est-à-dire à la i -ième unité statistique de la base de données.

C'est l'indicateur de tendance centrale le plus connu : on **divise la somme des observations par leur nombre**.

FORMULE CLÉ — MOYENNE D'UNE DISTRIBUTION

$$m = \frac{1}{N} \sum_{i=1}^p n_i x_i \quad \text{ou, de façon équivalente,} \quad m = \sum_{i=1}^p \frac{n_i}{N} x_i = \sum_{i=1}^p f_i x_i$$

- p : le nombre de **modalités** — ici, l'**indice i renvoie au numéro de modalité** ;
- n_i : l'effectif de la modalité x_i ; $f_i = n_i / N$: sa fréquence.

La première forme part des **effectifs** (formule 4 du cours), la seconde des **fréquences** (formule 5) : on a simplement fait entrer le $\frac{1}{N}$ dans la somme.

FORMULE CLÉ — MOYENNE PAR AGRÉGATION

$$m = \sum_{k=1}^K \frac{N_k}{N} m_k = \frac{1}{N} \sum_{k=1}^K N_k m_k \quad \text{avec} \quad N = \sum_{k=1}^K N_k$$

- K : le nombre de sous-populations **disjointes** ;
- N_k : l'effectif du groupe k ; m_k : la moyenne de X dans ce groupe.

C'est une **moyenne pondérée** des moyennes de groupe, chacune pesant **la part de son groupe dans la population**, N_k / N . Cette part est parfois donnée sous forme de **fréquence** f_k .

FORMULE CLÉ — PROPRIÉTÉ 1 — LA SOMME DES ÉCARTS À LA MOYENNE EST NULLE

$$\sum_{i=1}^N (x_i - m) = \sum_{i=1}^N x_i - N m = \sum_{i=1}^N x_i - N \times \frac{\sum x_i}{N} = 0$$

N fois la moyenne, c'est la somme des observations. Les **écarts positifs et négatifs se compensent exactement** : la moyenne est le **point d'équilibre** de la distribution. C'est pourquoi on ne peut pas mesurer la dispersion par la moyenne des écarts (elle vaut toujours 0) : il faudra des valeurs absolues ou des carrés (section 2.5). Si la distribution est **symétrique**, l'axe de symétrie passe par la moyenne, et **la moyenne égale la médiane**.

FORMULE CLÉ — PROPRIÉTÉ 2 — LA MOYENNE EST LINÉAIRE

$$\text{si } Y = aX + b \text{ alors } m_Y = a m_X + b$$

- **multiplier** toutes les valeurs par a multiplie la moyenne par a (convertir des euros en dollars) ;
- **ajouter** b à toutes les valeurs augmente la moyenne de b (6 points de bonus pour tous : la moyenne monte de 6) ;
- à plus forte raison, **la moyenne d'une somme de deux variables est la somme de leurs moyennes**.

Démonstration : $m_Y = \frac{1}{N} \sum (a x_i + b) = a \times \frac{1}{N} \sum x_i + \frac{1}{N} \times N b = a m_X + b$.

FORMULE CLÉ — MÉDIANE D'UNE DISTRIBUTION

Cas 1 — s'il existe une modalité x_j telle que $F(x_j) = 50\%$, alors **la médiane vaut x_j** .

Cas 2 — sinon, on procède par **interpolation linéaire** entre les deux modalités qui encadrent 50 % : si $F(x_a) < 50\%$ et $F(x_b) > 50\%$,

$$\text{med} \approx x_a + \frac{(x_b - x_a)(0,5 - F(x_a))}{F(x_b) - F(x_a)}$$

- x_a, x_b : les modalités (ou, pour des classes, les **bornes supérieures** des classes) juste avant et juste après le passage de 50 % ;
- $F(x_a), F(x_b)$: leurs fréquences cumulées ;
- la fraction $\frac{0,5 - F(x_a)}{F(x_b) - F(x_a)}$ dit **quelle proportion du chemin** de $F(x_a)$ à $F(x_b)$ il faut parcourir pour atteindre 50 % ; on parcourt la **même proportion** du chemin de x_a à x_b .

FORMULE CLÉ — QUANTILE D'ORDRE A PAR INTERPOLATION LINÉAIRE

Si une modalité x_j vérifie $F(x_j) = \alpha$, le quantile vaut x_j ; sinon, si $F(x_a) < \alpha < F(x_b)$:

$$Q_\alpha \approx x_a + \frac{(x_b - x_a)(\alpha - F(x_a))}{F(x_b) - F(x_a)}$$

C'est la formule de la médiane, avec α à la place de 0,5. **Attention à l'écriture** : au tableau de la séance 3, le facteur $(x_b - x_a)$ est écrit au dénominateur ; il **multiplie** — le résultat était juste parce que $x_b - x_a = 1$.

FORMULE CLÉ — VARIANCE À PARTIR D'UNE DISTRIBUTION

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^p n_i (x_i - m)^2 = \frac{1}{N} \sum_{i=1}^p n_i x_i^2 - m^2$$

$$\sigma^2 = \sum_{i=1}^p f_i (x_i - m)^2 = \sum_{i=1}^p f_i x_i^2 - m^2$$

- p modalités, d'effectifs n_i et de fréquences f_i ; l'indice i renvoie au numéro de modalité ;
- chaque carré d'écart est **pondéré** par l'effectif (ou la fréquence) de sa modalité ;
- la seconde égalité de chaque ligne est la **formule de Koenig** (ci-dessous).

FORMULE CLÉ — FORMULE DE KOENIG

$$V(X) = \frac{1}{N} \sum_{i=1}^N x_i^2 - m^2$$

La variance est la moyenne des carrés moins le carré de la moyenne. C'est souvent plus rapide à calculer, et c'est l'outil pour **agréger** des variances (section 2.6).

FORMULE CLÉ — CHANGER D'ORIGINE OU D'UNITÉ

$$V(a + X) = V(X) \quad V(aX) = a^2 V(X) \quad V(-X) = V(X)$$

- **ajouter le même nombre a** à toutes les valeurs **ne change pas la variance** : tous les écarts à la moyenne restent les mêmes ;
- **multiplier** toutes les valeurs par a **multiplie la variance par a^2** — la variance **n'est pas linéaire** ; l'écart-type, lui, est multiplié par $|a|$;
- en corollaire, $V(-X) = (-1)^2 V(X) = V(X)$.

FORMULE CLÉ — COEFFICIENT DE VARIATION

$$CV = \frac{\sigma(X)}{m_X}$$

Il est **sans unité** et s'exprime **en pourcentage**. Il permet de comparer la dispersion de variables d'unités ou de niveaux différents : des revenus en dollars et en yens, des poids de naissance et des tailles. Exemple : l'écart-type des âges (7,36 ans) rapporté à leur moyenne (47,9 ans) donne $CV \approx 15,4 \%$.

FORMULE CLÉ — INÉGALITÉ DE BIENAYMÉ-TCHEBYCHEV

Pour tout $k > 1$, l'intervalle $[m - k\sigma; m + k\sigma]$ contient **au moins une proportion** $1 - \frac{1}{k^2}$ des observations — donc **au plus** $\frac{1}{k^2}$ des observations sont en dehors.

k	Au moins dans $m \pm k\sigma$	Au plus en dehors
2	$1 - 1/4 = 75 \%$	25 %
3	$1 - 1/9 \approx 89 \%$	11 %
10	$1 - 1/100 = 99 \%$	1 %

Elle est vraie **pour toute distribution**, quelle que soit sa forme : c'est une **garantie minimale** — en pratique, la proportion réelle est souvent bien plus forte. Irénée-Jules **Bienaymé** et Pafnouti **Tchebychev** l'ont établie au XIX^e siècle.

FORMULE CLÉ — VARIANCE PAR AGRÉGATION

K groupes d'effectifs N_k , de moyennes m_k et de variances σ_k^2 ; $N = \sum N_k$ et $m = \frac{1}{N} \sum N_k m_k$:

$$\sigma^2 = \frac{1}{N} \sum_{k=1}^K N_k (\sigma_k^2 + m_k^2) - m^2$$

FORMULE CLÉ — VARIANCE TOTALE = VARIANCE INTRA-GROUPE + VARIANCE INTER-GROUPE

$$\sigma^2 = V_{\text{intra}} + V_{\text{inter}}$$

$$V_{\text{intra}} = \sum_{k=1}^K \frac{N_k}{N} \sigma_k^2 \quad V_{\text{inter}} = \sum_{k=1}^K \frac{N_k}{N} (m_k - m)^2 = \sum_{k=1}^K \frac{N_k}{N} m_k^2 - m^2$$

- la **variance intra-groupe** est la **moyenne pondérée des variances des groupes** : la dispersion **à l'intérieur** des groupes ;
- la **variance inter-groupe** est la **variance des moyennes des groupes** autour de la moyenne générale : la dispersion **entre** les groupes.

Attention, erreur du support : la diapositive 58 écrit $V_{\text{intra}} = \sum \frac{N_k}{N} \sigma_k$ — **sans le carré**. C'est bien la moyenne des **variances** σ_k^2 , comme au tableau de la séance 4.

FORMULE CLÉ — PART DE L'AGRÉGAT D'UNE CLASSE

$$\text{somme de } X \text{ dans la classe } k = \sum_{i \in k} x_i = N_k m_k \quad \text{part de la classe } k = \frac{N_k m_k}{\sum_j N_j m_j}$$

Pour des salaires, la somme s'appelle la **masse salariale** : **salaire moyen de la classe** $\times$ **effectif de la classe**. Si l'on ne connaît que les **proportions** de la population, on peut poser l'effectif total égal à 1 : dans le calcul des parts, N disparaît.

FORMULE CLÉ — CALCUL DE L'INDICE DE GINI PAR LES TRAPÈZES

$$G = 2 \left[\frac{1}{2} - \sum \frac{(b + B) h}{2} \right] = 1 - \sum (b + B) h$$

- $\frac{1}{2}$: l'aire sous la diagonale ;
- sous la courbe de Lorenz, l'aire se découpe en **trapèzes**, un par classe : b et B sont les parts cumulées **au début et à la fin** de la classe (la petite et la grande base), h est la **part de la population de la classe** (la hauteur, en proportion) ;
- aire de concentration = $\frac{1}{2} - \sum$ aires des trapèzes ; Gini = $2 \times$ aire de concentration.